

EMR Skills: 从 Lakehouse 到 Agentic Lakehouse

数据智能化的新一站

畅含 | EMR 产品经理 | 计算平台事业部

目录

content

—

01

EMR AI Native 全景图

02

EMR Skills 能力

03

EMR StarRocks Skills能力介绍

开发·诊断·管控，五大场景全覆盖

04

EMR AI Native 展望


01 / EMR AI NATIVE 全景图

—

什么是EMR? 什么是Lakehouse?

阿里云EMR：基于开源框架的一站式大数据处理服务，是运行大数据任务的“操作系统”或“基础设施平台”，帮你搞定底层复杂性，让你专注于数据本身。

Lakehouse：一份数据、多引擎协同。通过引入元数据层和事务机制，实现数仓级别的管理能力。EMR Serverless Spark + StarRocks + DLF（统一元数据）。



如何构建一个面向 Agent 协作的数据平台

过去十年，大数据平台的核心目标是：把数据“存下来、算出来、用起来”。

但今天，我们面对的不再只是 BI 与报表、数据工程师，分析师，而是越来越多的**智能体（Agent）**——它们自动读取数据、调用算力、生成结果，甚至驱动业务决策。

所以，如何构建一个面向“智能体协作”的大数据平台？

Agent 时代，对大数据平台提出了新的要求

从"支持人分析"，走向"支持 Agent 自主调用"

新要求

更低门槛的调用方式

从作业/SQL配置，走向 API / 能力调用

更统一的能力抽象

数据处理、查询分析、系统运维，需要统一对外抽象成能力调用

更实时的响应能力

支持 Agent 的即时决策与交互

能力 Skill 化

数据处理 Skill

查询分析 Skill

系统运维 Skill

EMR：面向 Agent 的数据与计算能力平台

EMR 不再只是一个"集群产品"，它对外提供的是三类核心能力：



EMR AI Native 大图将回答以下问题：

- 1. Agent 时代大数据平台需要具备哪些**关键能力**
- 2. EMR 如何把这些能力**"Skill 化"**，对外提供统一接口
- 3. 这种模式在真实业务场景中能带来什么**变化**

EMR AI Native 产品功能大图

SQL 层原生大模型调用 · 百炼 MaaS 深度集成 · 全栈 Serverless 免运维



02 / EMR SKILLS 能力介绍

—

EMR Skill 能力全景图

三大子产品通过 Skills 接入 Agent，覆盖集群管理、计算作业、分析数据的全场景

EMR Serverless Spark alibabacloud-emr-spark-manage	EMR Serverless StarRocks alibabacloud-emr-starrocks-manage + assistant	EMR on ECS 集群管理 alibabacloud-emr-cluster-manage
管理 Spark 工作空间全生命周期：创建工作空间、提交作业、Kyuubi 交互式查询、资源扩缩容	管理 StarRocks 实例全生命周期 + 开发运维助手：建表设计、SQL 调优、数据导入、集群诊断	管理 EMR 集群全生命周期：创建、扩缩容、续费、状态查询
1 工作空间管理 创建、查询、删除工作空间，查询可用引擎版本 2 作业提交与监控 提交 Spark 作业（JAR/PySpark/SQL）、查询状态与日志、取消作业 3 Kyuubi 交互式查询 创建/启停 SQL 网关、JDBC 连接、Token 管理、取消查询 4 资源队列扩缩容 资源队列 CU 扩缩容、查询队列状态，按需弹性调整计算资源	1 实例生命周期管理 创建（存算一体/分离）、查询状态、释放、恢复暂停 2 弹性扩缩容 节点/磁盘扩缩容、计算组节点增减，均支持预检 3 SQL 开发与调优 [assistant] 慢 SQL 诊断、Profile 分析、Join 策略优化、改写验证 4 建表设计与数据导入 [assistant] 分区分桶策略、Stream/Routine Load、Schema 设计	1 集群生命周期管理 5 种集群类型、HA/普通部署、存算分离/一体架构、状态查询、克隆、删除 2 节点组管理与扩缩容 5 种节点角色(MASTER/CORE/TASK 等)、新建节点组、手动扩缩容 3 弹性伸缩 定时策略与指标策略(CPU/内存/YARN 负载触发)、伸缩活动历史查询 4 运维与诊断 集群与节点巡检、续费管理、属性修改、创建失败诊断
用法 "帮我建个 Spark 工作空间" "跑个 PySpark 任务，数据在 OSS 上"	用法 "这条SQL跑了30秒，帮我优化" "帮我建个存算分离的StarRocks，再扩2个节点"	用法 "帮我建个高可用数据湖集群" "请帮我扩容节点G的到10台"
诊断优化（作业失败分析、性能瓶颈定位、参数优化建议）	诊断优化（慢查询分析、Profile 定位、表结构优化、Colocate Join、调参建议）	故障与诊断（智能定位、根因分析、优化建议、自动调参）

已支持接入：EMR Agent/Dataworks Agent/Qoder/Claude

已支持多种接入方式，生态产品已预装Skills

阿里云Skills门户/Qoder/Claude Code/OpenClaw · Dataworks Data Agent· EMR AI助手

让 Agent 用好阿里云

从 Skills 开始

官方出品 | 安装即用 | 安全合规

查看全部 Skills

安装 alibabacloud-emr-starrocks-assistant

CLI 命令安装 下载安装

在终端中执行命令安装，请确保已安装 Node.js (≥18)

1 选择安装工具

Skills CLI
通用安装工具，支持 45+ Agent

ClawHub CLI
OpenClaw 生态专属工具

2 选择 Agent 客户端

Qoder

Qwen Code

Claude Code

OpenClaw

Codex

Cursor

Gemini CLI

GitHub Copilot

3 安装范围

当前项目
仅当前项目可用，团队可共享

全局安装
所有项目均可使用

\$ npx skills add aliyun/alibabacloud-aiops-skills --skill alibabacloud-emr-starrocks-assistant --agent qoder

运行后，重启 Agent 客户端即可使用此 Skill

New session - 5/26, 09:54 AM

DATA AGENT

> DataWorks DataAgent (Powered by Qwen Code)
(v0.15.11-datavvorks.1)
Built-in DataWorks Official Skills
API Key | qwen3.6-plus (/model to change)
/mnt/workspace

示例：任务分析："帮我分析下 datavvorks_analyze 这个工作空间最近一周新建的节点有哪些，并分析下具体在做什么？"

这是 Beta 版本，个人开发环境实例删除后聊天记录会丢失。

> /skills

Available skills:

alibabacloud-elasticsearch-instance-manage

alibabacloud-elasticsearch-network-manage

alibabacloud-emr-spark-manage

alibabacloud-emr-starrocks-assistant

alibabacloud-emr-starrocks-manage

alibabacloud-flink-console-ops

alibabacloud-flink-instance-manage

alibabacloud-hologres-instance-manage

alibabacloud-odps-project-manage

alibabacloud-odps-quota-manage

batch

dataworks

dataworks-datastudio

dataworks-design-html

dataworks-di-batch-sync-job

dataworks-di-doctor

dataworks-di-filespec

dataworks-governance-core

dataworks-governance-scenario

dataworks-infra-manage

dataworks-scheduler-task

loop

maxframe-job-coding

qc-helper

review

边界

仅管理 实例生命周期（创建/查询/配置变更），不涉及 StarRocks 内部的表操作/SQL 执行

SQL 开发/调优/表设计 → 使用 alibabacloud-emr-starrocks-assistant

3. alibabacloud-emr-starrocks-assistant — StarRocks 开发与运维助手（已介绍过）

专注于 StarRocks 实例内部使用：Schema 设计、数据导入、SQL 开发与调优、集群健康诊断。

三个 Skill 的关系

TEXT

EMR Serverless Spark (spark-manage)
└─ Spark 作业提交、Kyuubi SQL Gateway、资源队列管理

EMR Serverless StarRocks
└─ 实例生命周期 (starrocks-manage) ← 创建/查询/配置/升级实例
└─ 内部开发运维 (starrocks-assistant) ← 表设计/SQL/导入/诊断

需要我帮你操作哪个产品吗？

Hello, I'm EMR AI 助手

帮您解决大数据集群的日常运维、稳定性问题

「慢查询分析」针对以下实例：prod-starrocks-01，请开始执行。

专家技能

EMR AI助手能为我做什么

EMR Serverless StarRocks最近的新功能有哪些

我的StarRocks实例是否存在风险

查看StarRocks实例今日Top10慢SQL

场景模版

集群健康诊断
全面检查集群状态

慢查询分析
定位 SQL 性能瓶颈

资源优化建议
降本增效推荐方案

作业失败排查
快速定位失败原因

存储容量预警
磁盘使用趋势分析

安全配置检查
识别安全风险项

03 / EMR STAROCKS SKILLS 能力 介绍

AI Native：能力全景

AI Function × 11
一条 SQL 调用大模型
商用 SQL 原生 AI

已上线

AI 助手
问题主动发现，根因自动定位
运维效率从天级降至分钟级

已上线

Agent Skills
开放标准化运维 Skill
客户 Agent 即插即用

已上线

多模态混合检索
全文 + 向量 + 标量
一个引擎统一三种检索模态

公测中

11

内置 AI 函数

<500ms

单次推理延迟

100%

MySQL 协议兼容

3

多模态混合检索

AI Native: StarRocks Skill 能力地图

阿里云Agent Skills官方输出，按用户意图拆分，满足多角色用户（DBA/SRE、数据工程师/分析师、应用开发者）所需能力

Skills分类

意图识别

渐进披露

SR领域知识 - Assistant/

「我想了解 StarRocks」

- knowledge-qa-skill — 文档查询、概念解释、功能了解
- config-guide-skill — 配置项含义和推荐值

SR开发管理 - Assistant/

「我要构建」

- sql-assistant-skill — 写 SQL、改 SQL、理解 SQL
- schema-design-skill — 建表、分区分桶、索引设计
- data-import-skill — 数据导入方式选择和实施

SR性能分析 - Assistant/

「我要优化系统」

- query-tune-skill — 单条 SQL 执行瓶颈分析
- workload-tune-skill — 系统级资源和负载调优
- workload-analysis-skill — 系统负载统计（Top SQL、pattern、趋势）

SR诊断 - Assistant/

「我遇到问题了」

- error-fix — 无法归类领域的通用报错兜底
- bug-search — 搜社区已知 bug 和修复
- health-diagnose — 深度根因分析与修复建议
- health-inspect — 主动巡检、发现潜在风险

SR运维 - Manage/

「我要执行运维操作」

- instance-manage — 查看/管理实例信息
- migration-execute — 执行数据或集群迁移
- cluster-upgrade — 执行版本升级
- backup-recovery — 执行备份和恢复
- access-control — 用户权限、认证、访问策略
- ha-setup — 高可用配置和管理

SR数据分析 - Assistant/

「我要理解数据」

- schema-explore — 库表结构与字段探索（实例数据）
- data-profile — 数据分布、质量、统计
- anomaly-detect — 数据层面异常发现

核心优势

Agent 原生集成

一键添加 Skill
开箱即用，无需额外开发

核心场景 覆盖

覆盖开发、诊断、运维、数据分析、领域知识、性能分析六大管理场景

安全合规

基于 RAM 权限体系
细粒度访问控制

Serverless 免运维

无需管理基础设施
弹性能力

生产级稳定性

企业级可靠性保障
完善的容错与重试机制

场景一：金融实时风控 — 毫秒级交易异常检测

痛点

- 反欺诈需实时聚合用户近 N 笔交易特征（金额突增、频次异常），T+1 跑批来不及
- 风控规则涉及多表 JOIN（交易流水 × 用户画像 × 黑名单），查询超时影响拦截
- 业务方天天改规则，每次都要 DBA 手动调 SQL + 建物化视图，响应慢

方案：StarRocks Skill 智能 SQL 调优 + 物化视图设计

- 自动分析执行计划：发现 Shuffle JOIN 瓶颈 → 建议 Colocate / Broadcast
- 物化视图一键设计：根据高频查询模式自动推荐 MV，滚动窗口预聚合
- 窗口函数即写即优化：LAG / LEAD / SUM OVER 实时计算交易特征



- StarRocks 集群几十个节点，逐个检查 FE/BE/CN 状态、Tablet、Compaction?
- 半夜告警响了，打开控制台翻日志翻到天亮
- 新同事不熟悉诊断命令，出问题只会重启大法

- "帮我巡检集群" — 自动执行 SHOW FRONTENDS / BACKENDS 全套诊断
- 30 秒输出结构化巡检报告：节点状态 + Tablet 健康 + Compaction 积压
- 异常项高亮 + 风险等级 + 修复建议，运维照着做就行



推送测试  机器人

集群ID: 

评级: 健康 · 综合评分 91/100

版本: 3.5/3.5.7-2.0.4-1.8.1

拓扑: shared_data

风险项

- 磁盘使用率 78.8%，超过 80%
- IO Util 100.0%，超过 80%
- 每分钟查询错误 0.6 次

👉 点击按钮查看完整巡检报告

 在钉钉

 在浏览

需要我帮你执行修复操作吗？

 群签到

肩捌入消

说出你想要的，Qoder会决定接下来怎么做

场景三：金融报表加速 — 告别 T+1，今天的数据今天看

痛点

- 监管报表、经营日报依赖 T+1 跑批，领导早会看到的是"昨天的昨天"
- MySQL 分库分表查不动聚合，BI 工具超时转圈
- 接一个新报表需求就要写 ETL + 建宽表，排期两周起步

方案：StarRocks Skill 智能 Schema 设计 + 数据入湖选型

- 一句话建表：描述业务场景 → 自动推荐表模型、分区分桶策略
- 入湖方式自动选型：MySQL CDC → Flink CDC + Connector；文件 → Broker Load
- 物化视图替代宽表：无需手动 ETL，MV 自动增量刷新，报表实时可查

`/starrocks-assistant` 我有一张 MySQL 交易流水表，5000 万行/天，想做实时报表。
帮我设计表结构和入湖方案

📄 Schema 设计建议：

表模型：Primary Key（支持 CDC 实时更新）
分区：PARTITION BY RANGE(txn_date) 按天
分桶：DISTRIBUTED BY HASH(user_id) BUCKETS 32
排序键：(user_id, txn_date, txn_time)

📁 入湖方案：

MySQL → Flink CDC → StarRocks Connector

- ✅ 全量 + 增量自动切换
- ✅ Exactly-Once 语义
- ✅ 延迟 < 5s

⚡ 报表加速：

```
CREATE MATERIALIZED VIEW mv_daily_summary
REFRESH ASYNC EVERY (INTERVAL 1 MINUTE) AS
SELECT txn_date, branch_id,
       COUNT(*), SUM(amount) ...
```

领导早会看实时数据，不再是"昨天的昨天"。

说出你想要的，Qoder 会决定接下来怎么做

场景四：MySQL → StarRocks 报表迁移

痛点

- 团队有 20 张业务报表跑在 MySQL (RDS) 上，覆盖订单、商品、客户、营销等核心域。随着数据量增长，复杂聚合查询越来越慢。业务方要求做分析加速，同时保留 MySQL 作为业务写入源
- 传统做法：逐表导出 MySQL DDL (10 分钟) → 手动改写为 StarRocks 语法并调优分区分桶策略 (30 分钟 × 20张表) → 编写数据迁移脚本 (20 分钟) → 全量导入并校验一致性 (15 分钟)。总计约 2-3 小时，且 DDL 改写过程中极易遗漏 StarRocks 的分区裁剪、排序键、Colocate Join 等优化点。

方案：StarRocks Skill 智能 生成StarRocks DDL+ 自动比对

- 读取 MySQL Schema 后自动生成最优 StarRocks DDL;
- 无需担心网络等配置问题，AI帮你搞定工程问题
- 根据业务特征，自动生成StarRocks 的分区裁剪、排序键、Colocate Join 等优化点

Step 1: 告诉 AI 你的需求

你：MySQL RDS 上有 20 张报表要迁到 StarRocks 做加速分析。
MySQL 实例 ID 是 rm-bp12x3j5kn08q105x，数据库 report_db，账号 sr_reader。
StarRocks 集群已经有了，帮我建 JDBC Catalog 连上 MySQL，然后把报表迁过来。

Create JDBC Catalog
sql = '''CREATE CATALOG jdbc_catalog WITH
PROPERTIES (\"type\\\": \"jdbc\\\",
\"user\\\": \"sr_reader\\\",
\"password\\\": \"\\\",
\"jdbc_url\\\": \"jdbc:mysql://rm-bp12x3j5kn08q105x.mysql.aliyuncs.com:3306/report_db\\\",
\"driver\\\": \"com.mysql.jdbc.Driver\\\",
\"driver_classpath\\\": \")''';

深度思考 · 1s

JDBC Catalog 创建成功

cd /Users/yan... 终端已运行

深度思考 · 1s

JDBC Catalog 连接成功

report_db 的全部表名

类别	表名
客户	customer_info
商品	product_info
订单	orders, invoices
报表	daily_sales, store_performance
营销	marketing_campaigns, user_behavior_log

MySQL 原始 DDL (AI 自动读取)

CREATE TABLE orders
order_id BIGINT,
customer_id INT,
order_date DATE,
total_amount DECIMAL(10,2),
discount_amount DECIMAL(10,2),
pay_amount DECIMAL(10,2),
order_status VARCHAR(10),
channel VARCHAR(20),
store_id INT,
shipping_address VARCHAR(255);

AI 优化后的 StarRocks DDL:

-- orders: Primary Key
CREATE TABLE sr_replicate_orders
(
order_id BIGINT,
customer_id INT,
order_date DATE,
total_amount DECIMAL(10,2),
discount_amount DECIMAL(10,2),
pay_amount DECIMAL(10,2),
order_status VARCHAR(10),
channel VARCHAR(20),
store_id INT,
shipping_address VARCHAR(255)
) PRIMARY KEY (order_id)
PARTITION BY date_trunc('month', order_date)
DISTRIBUTED BY HASH(order_id)
PROPERTIES (
\"replication_num\" = 3,
\"enable_persistent_index\" = true
);

EMR-... 26-05-25

AI 自动优化

优化建议

表类型

排序键

深度思考 · 1s

好的，开始全量数据迁移——通过 JDBC Catalog 将 MySQL 20 张表数据导入 StarRocks:

cd /Users/yan... 终端已运行

深度思考 · 2s

6 张表失败了——"strict mode filtered data"。这是因为 StarRocks 表的列顺序调整后与 MySQL 源表不一致，SELECT * 的列顺序不匹配。需要显式指定列映射。让我先查看错误详情:

cd /Users/yan... 终端已运行

深度思考 · 3s

问题清楚了——MySQL 原始列顺序与 StarRocks 调整后的列顺序不一致。需要显式指定列映射。修复 6 张表:

cd /Users/yan... 终端已运行

深度思考 · 1s

还剩 invoices 一张表。查看错误详情:

cd /Users/yan... 终端已运行

深度思考 · 2s

invoice_type 的 VARCHAR(20) 太短了——"增值税专用发票" 在 UTF-8 下超过 20 字节。扩大列宽修复:

cd /Users/yan... 终端已运行


深度思考 · 1s

全部修复！最终验证一下 20 张表的数据一致性:

StarRocks AI Function + Agent Skills = 对话式智能分析

数据不出库，AI 分析在 SQL 内完成；运维操作对话触发，零界面切换

应用架构：



核心流程：



04 / EMR AI NATIVE 展望

- EMR AI助手 全面对接 IM 应用，支持自定义推送范围和巡检范围
 - EMR Serverless Spark 多模态处理 GA
 - EMR Serverless Starrocks 向量化检索 GA
 - EMR Serverless Starrocks 全文检索 GA
 - EMR Serverless Spark 多模态算子市场GA
 - EMR AI助手 支持成本与资源优化
-

THANKS