Agent 评测如何落地

可信标准与双 Loop 演进实践

高诗梦 美团 · 专家工程师

负责美团 AI Agent 评测平台
协助业务建设 Agent 评测体系

今天一起回答三个问题

01 **评什么？** →
业务目标与完整任务交付

02 **怎样评得可信？** →
分数涨了，Agent 真的变好了吗？

03 **怎样持续改进？** →
持续评 Agent，谁来检查评测本身？

用户没说，为什么变成了“你提到”？

用户原话

“某景区漂流门票”

未提及同行人或学生身份

这类问题，怎么发现和解决？

评测 上线前发现并拦截

归因 沿 Trace 核查原因

回测 确认修复，没有改坏其他任务



搭一个 Agent 越来越容易，把它推到全量仍然很难

BUILD BARRIER ↓

搭建门槛持续下降

↑ **模型能力持续进化**

格式输出、工具调用等能力更多由模型承担，减少 Prompt 打磨与工程兜底。

↑ **框架与协议持续完善**

规划、记忆、工具与状态逐步组件化，接工具、加 Skill 更省力。

↗ **落地场景更多、更发散**

两条趋势共同降低搭建门槛，推动 Agent 进入更多业务场景。



SCALE BARRIER

三道规模化障碍

01 **停在 Demo**

演示时挺好，一接真实流量，各种问法、脏数据、没考虑到的场景就来了。团队一直打补丁，项目却很难往前走。

02 **卡在扩量**

出了问题，不知道该改哪里；想改，又怕把原来做对的地方改坏。于是改也担心，不改也不行。

03 **说不清价值**

模型换了，Prompt 也改了，感觉效果越来越好，但到底给业务带来了什么改善，拿不出证据，后续投入就很难继续。

评测分数涨了，就能扩大流量吗？

定标准 · 做回测 · 线上验证，为业务决策提供依据。

评测是在 Agent 能力和业务结果之间搭桥

定义质量、可信测量、反馈改进，贯穿 Agent 从冷启动到全量运营的整个生命周期。

BUSINESS GOAL

业务目标

以店长经营分析 Agent 为例

少花时间整理数据，
更快看懂经营问题

定义预期

构建 Agent

PRODUCT IDEAL

产品理想态

数据取全、分析有依据，
结果用得起来

检验差距

评测 Agent

ACTUAL BEHAVIOR

Agent 实际表现

数据取全了吗？分析有依据吗？
结果可用吗？

01

冷启动

明确业务价值与任务目标，
定义成功标准，
建立核心场景种子评测集。

02

上线扩量

检验真实流量中的效果，
根据线上 Case 补充样本，
修正标准和评测方法。

03

全量运营

随业务与用户需求变化，
重新审视业务目标与评测目标，
持续校准评测体系。

> 评测把业务目标转成可检验的标准，为上线、扩量和持续改进提供依据。

Agent 评测的对象，是完成任务的整个系统

模型进入真实业务后，任务成败还取决于它与工具、环境和流程的配合。

评测类型	主要评测对象	核心问题
传统机器学习评测	单模型的预测表现	预测得准不准
大模型能力评测	模型的通用与专项能力	模型能力强不强
Agent 评测	**模型、工具与流程构成的任务系统**	**任务能否稳定完成**

任务系统 = 模型 + Prompt / Skill + 工具链 + 记忆与状态管理 + 业务流程

贯穿案例
店长月度经营复盘

“请结合门店数据和上月投放数据，制作一份经营分析 PPT。”

给定条件　已上传门店数据，已配置商家账号权限，投放数据查询工具可用。

系统执行　获取投放数据 → 结合门店数据分析 → 生成经营分析 PPT

评测要回答：整个任务系统能否在给定条件下，稳定交付符合业务要求的结果。

Agent 评测不只看结果，还要看行为和过程

同样完成任务

路径清晰，稳定完成



工具调用稳定 · 耗时可控 · 可重复复现

同样完成任务

反复试错，偶然命中



路径混乱 · 额外消耗 · 结果难以复现

01 结果层

任务是否完成，输出是否可用

02 过程层

规划是否合理，步骤是否稳定

03 效率层

耗时、Token、调用次数是否可接受

04 风险层

是否越权、误操作或存在安全隐患

> 要判断行为和过程，就需要可追溯的执行证据。

观测是评测的基石

Trace 关联模型调用、工具交互与关键状态，为评测和问题定位提供证据。

Agent 的 Trace 长什么样?

真实界面节选

Span	时间轴	耗时	状态
第 1 轮			
LLM 模型调用 答复	输出摘要已隐藏 · 可展开节点查看	3.9s	SUCCESS
TOOL skill-load		48ms	SUCCESS
第 2 轮			
LLM 模型调用 答复	输出摘要已隐藏 · 可展开节点查看	9.6s	SUCCESS
TOOL bash mkdir		112ms	SUCCESS
TOOL bash find		19.6s	SUCCESS

Trace 界面示例，与右侧门票案例非同一任务。
截图按列裁剪排版；具体模型名已遮去，原始耗时与状态保留。

> 有了执行证据，怎样判断任务表现好不好?

回看开场："学生"信息是怎么来的?

01 看输入：用户没说有学生

平台画像有"学生"标签，
用户这次没提到学生。

02 看参数：却写成了身份确定

分析写着"用户未提及"，
参数却是"学生 1 人、身份确定"。

把画像里的推测，当成了事实。

03 看回复：又说成了"你提到"

"你提到同行有一位学生。"
把画像信息说成了用户原话。

Trace 的价值就在这里：
我们可以追着一条信息往回查，
看它在哪一步发生了变化。

客观评测与主观评测并行

客观评测

看“准不准”

对照事实、目标状态和明确约束，
核验结果是否正确、要求是否满足。

主观评测

看“好不好”

结合用户需求与业务场景，
依据评价标准判断质量和价值。

举个例子 **同一份经营分析 PPT**

教学示例

> PPT 能否打开?
> 投放金额是否与源数据一致?
> 取数与操作是否符合授权?

> 经营变化是否解释清楚?
> 分析能否帮助店长理解问题?
> 建议是否具体、可执行?

怎么判断

核对源数据、实际产物与执行记录，
按明确规则逐项检查。

怎么判断

专家先明确评价标准，由人工或 LLM Judge 评判，
再用样例校准，减少判断分歧。

> 同一个任务，既要核验是否做对，也要判断是否有用；主观评测的标准需要先对齐。

主观评测的标准需要先对齐

否则，我们难以判断迭代后的分数上涨，是评测波动，还是真实效果提升。

沿用经营分析任务 · 教学示例

店长的月度经营分析 PPT

共同验收问题

这份 PPT 是否达到本次经营复盘的整体验收要求?

各自采用的通过依据		各自判断
产品	图表齐全，内容完整	倾向通过
运营	没有解释清楚经营变化	倾向不通过
研发	数字与源数据都能对上	倾向通过
QA	原因判断缺少核查证据	无法确认因果结论

各方采用的验收依据不同，先统一标准，再检验人人一致。

真正困难的不是“没有人会评”，
而是“不同的人评得不一样，
机器和人评得也不一样”。

先让不同人独立判断

人人一致

统一各方评测标准，降低判断方差

再让 Judge 独立判断

人机一致

机器评测与人工评测一致，
支撑规模化提效

标准需要对齐，首先要明确谁对标准负责。

人人一致，先明确谁对标准负责

1 个“独裁者”好过 10 个“民主者”

谁来承担这个角色?

最懂业务和评测的人

可以来自产品、算法或运营，
结合评测经验与行业专家判断。

需要拉齐的参与方

产品 / 运营 / 研发 / QA

征求并整合意见	多方征求意见，整合指标与 Rubric， 让团队遵循同一套评测体系。
分歧时拍板	项目方观念无法对齐时作最终裁决， 避免各自为政与内部拉扯。
组织目标与标准演进	依据真实 Good / Bad Case 修正评测目标， 同步更新规则、正反例与评测样本。

负责人拉齐标准，真实业务 Case 驱动评测目标与标准演进。

人人一致：把共同标准变成可复现的判断

团队采用同一版标准，用背靠背标注暴露分歧，再裁决、细化与复测。

01

独立盲标

依据同一版标准，
独立判断同一批评测样本，
分别记录标签与依据。

02

对照分歧与依据

逐条核对不同判断，
区分规则理解不同、
规则不清或证据缺失。

03

负责人裁决并细化

整合意见、明确判定口径，
把模糊指标下钻为 Rubric，
尽量转成是／否／未知。

04

新样本复测

换一批评测样本独立标注，
检查每条 Rubric 的一致率
与 UNKNOWN 占比。

经营分析示例 · 数字都对，这份报告就算“分析有帮助”吗?

教学设定，非实测结果

报告写道：“本月广告费增加 20%，营收增长 10%，说明加广告带动了营收增长。”

同一指标，两种判断

A 判是：“两个数字都对。”
B 判否：“还没证明营收增长
是加广告带来的。”

对照各自的理由

A 只检查了数字对不对。
B 还看原因有没有证据。
规则没写清这两项都要看。

负责人明确共同要求

数字要对，原因也要有依据。
没证据时写“可能有关，
还需验证”，不能写成定论。

换新报告，分别判断

新报告仅有降价与营收数据：
X“全靠降价” → 两人均判否
Y“可能有关，待验证”：均判是

人能按同一标准稳定判断后，如何让机器也做到一致?

人机一致：让机器复现人的判断

用两个例子，看看如何把模糊标准拆成可判断的检查项。

某外呼 Agent 口语化示例 · 4 / 4 · 再次推进进入下一页 →

重播

例子 2 · 某外呼 Agent：把“口语化”拆成具体检查项

“回复够不够口语化”，不能只凭感觉打分

模糊标准　请判断模型回复是否口语化，并按 0 - 10 分打分。

下钻方向	具体检查项	判断方式
称呼对象	模型是否用“您”称呼通话对象?	是／否
口语表达	是否使用“甭客气”“明儿见”等口语交流词汇?	是／否
语气词	是否包含“吧”“呢”“那个”等语气词?	是／否

这些是示例检查项，需要按业务场景校准；出现某个词，不等于整体表达自然。

标准对齐之后，如何在真实业务中持续检验和改进评测?

Agent 评测是一门实践科学

标准要靠真实业务来检验，改动要靠验证来证明效果。

第一轮，从这里开始

高频核心场景

少量关键标准
一批种子样本

先让最小闭环转起来
遇到真实问题，再补能力



先用少量关键标准跑通闭环，让真实 Case 持续推动评测体系演进。

DACon
DataFun.

业务需要一套怎样的评测体系?

4

四个模块

- 离线评测
- 在线评测与监控
- Case 挖掘与归因
- 观测基建

3

三种能力

- 发现问题
- 定位问题
- 驱动演进

2

两条 Loop

- Agent 迭代
- 评测体系迭代

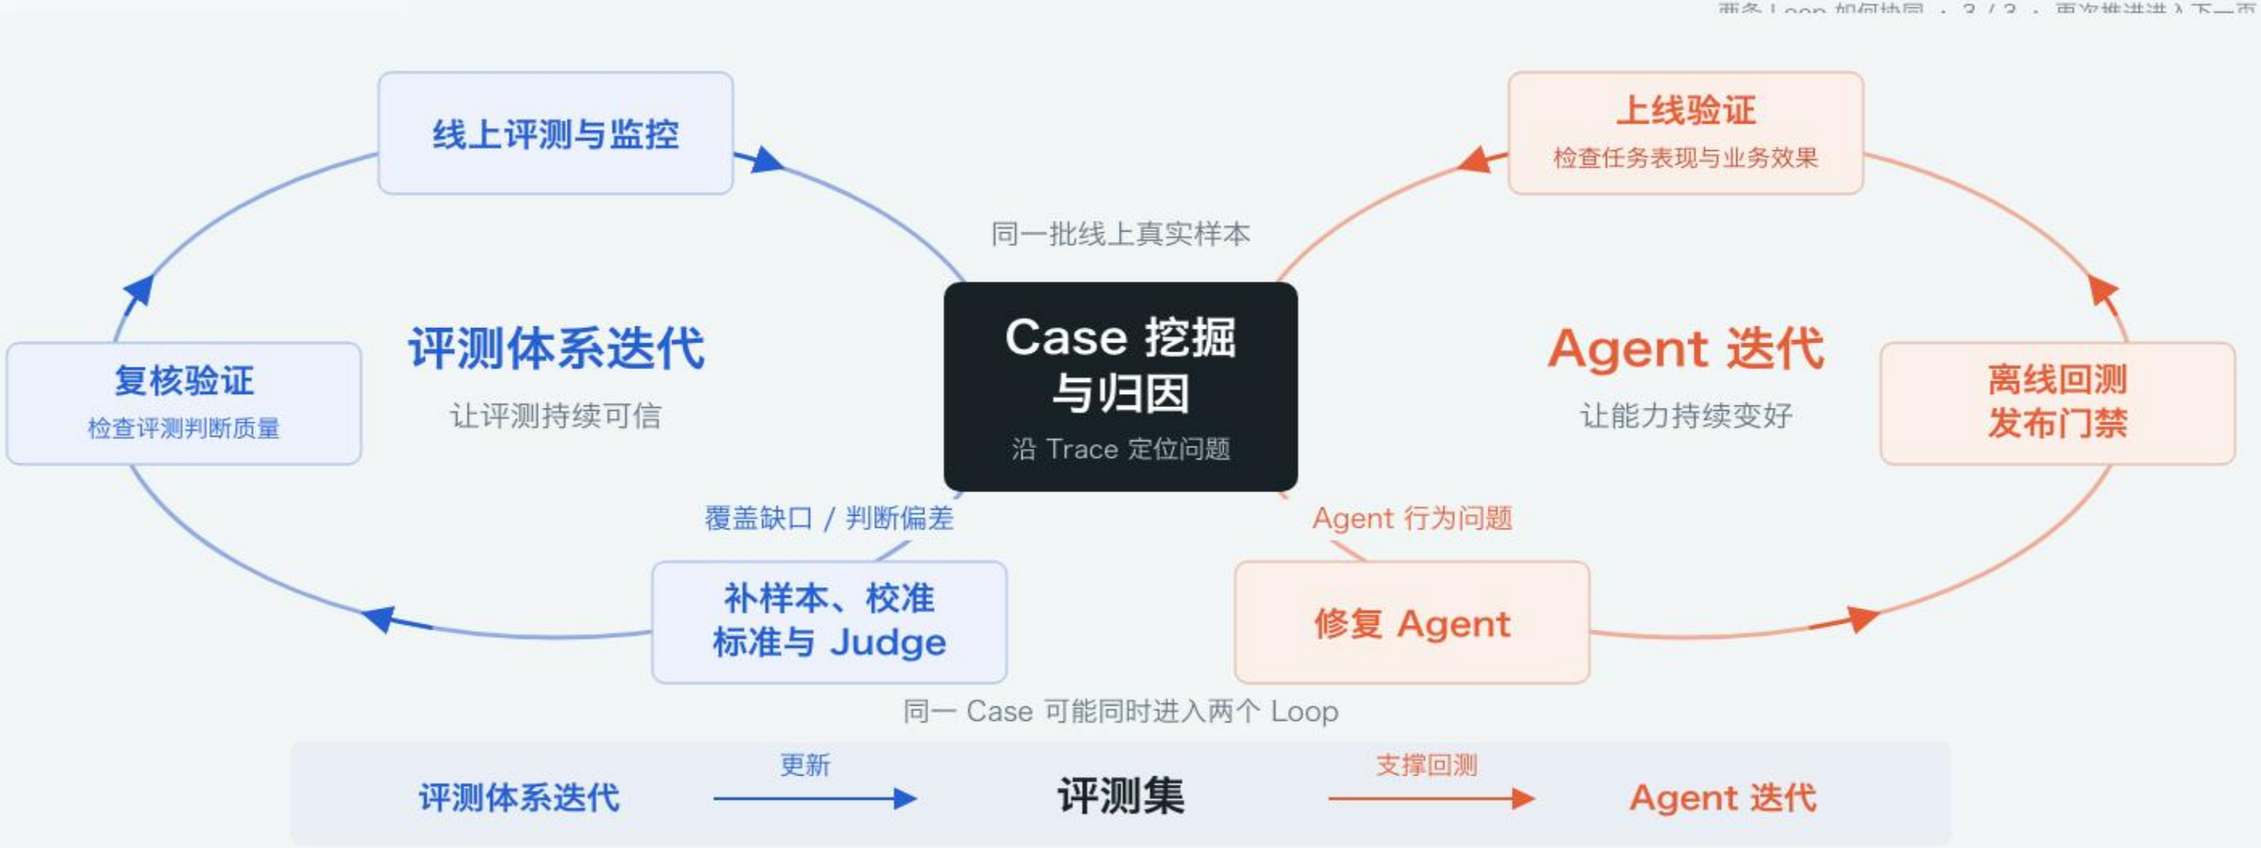
1

一套资产

- 评测集:
  样本、预期与标准

评测怎样驱动持续演进? 接下来看两条 Loop 如何改进 Agent、校准评测体系。

为什么改进 Agent，需要两条 Loop?



Agent 改完后，怎样在上线前确认变好了，也没有把原来做对的任务改坏?

离线评测：在受控条件下检验 Agent

用预先准备的评测集，在受控的执行环境中运行 Agent，依据明确标准判断任务表现。

评测集

预先准备任务
明确输入与成功标准

→

Agent 执行

在受控环境中运行
记录过程与交付物

→

按标准评判

检查结果与关键过程
形成可复核的判断

→

结果与问题

判断任务表现
识别不足与改进方向

多次独立运行，观察通过率与波动；每次恢复约定的初始状态。

典型用途

版本变更后的回测

模型、Prompt、知识库
或 Skill 变更后，对比新旧版本

Agent vN ↔ Agent vN+1

同样本、同标准、同初始环境
记录 Agent、评测集与环境版本

→

判断是否发布或灰度

检查核心链路失败、高风险问题
旧能力退化与业务风险容忍度

离线评测用什么任务来检验 Agent？一套评测集应该包含什么，又该如何组织？

评测集的构成与分类

用途分类 · 2 / 2 · → 下一页

任务输入

用户需求、上下文与任务约束

参考答案／预期结果

目标产物、最终状态与必要行为

评价标准

指标、Rubric 与通过条件

执行与管理：配套初始环境、工具权限和数据快照，记录样本与标准的版本。

分类	主要收录	核心用途
必过集	核心链路、质量底线与高风险场景	检查底线要求，支撑发布门禁
黄金集	经过复核、预期与标准清晰的核心任务	提供质量参照，比较版本表现
挑战集	多约束、长交互及复杂边界任务	检验困难任务，观察能力边界与提升
错题集	历史失败及经复核的正确预期	验证问题修复，防止再次发生
需求专项集	围绕新需求、新工具或新能力的样本	检验本次变更，支撑需求验收

> 不同集合按用途组织，同一条样本可以属于多个集合。**管理边界：**调优样本与验收留出样本分开管理；留出样本不参与 Prompt 调优或 Judge 校准。

离线守住已知，在线发现未知

固定评测集未覆盖的场景，反复回测也测不到；需要在线评测发现新 Case，再补入离线评测集。

商家经营分析 · 教学示例

评测集覆盖的任务

“根据本店数据，制作一份经营分析 PPT。”

回测通过：已覆盖任务达到约定要求

≠

线上新出现的需求

“帮我对比三家门店的数据。”

跨门店比较尚未纳入评测集

尚未覆盖：能否完成，还没有验证

评测集不会自动跟着真实需求一起变化

继续重跑旧任务，也不会补上跨门店比较的验证。

让线上发现持续补充离线评测

发现线上新 Case → 补充离线评测集 → 回测验证

在线评测结合监控、反馈与采样发现新场景，经复核与归因后补充评测集。

上线以后，如何知道 Agent 做得怎么样?

将评测标准应用到线上运行，结合持续监控，发现值得分析的任务。

评测结果也可形成质量指标，纳入持续监控

在线评测　线上任务是否符合评测标准?

沿用适用的 Rubric 与校验规则，检查结果、过程、效率和风险。

影子模式	候选版本面对真实请求，做得怎么样? 复制请求给候选版本执行，结果不返回用户
A/B 实验	新版本是否带来实际收益? 分流真实请求，对比任务质量与业务指标
周期巡检	线上核心能力是否保持稳定? 用代表性固定任务，定期检查线上 Agent

在线监控　表现有没有变化?

运行变化	工具失败率、耗时、成本 是否出现异常?
质量变化	任务通过率、巡检结果 是否出现下降?
需求变化	任务类型与输入分布 是否出现变化?

评测结果与问题样本　　异常线索

Case 挖掘　哪些具体任务值得进一步分析?

结合评测结果、监控异常、用户反馈、业务规则与主动采样，筛选代表 Case。

产出：值得分析的任务及其输入、交付物与执行记录

下一页：定位与改进 →

Case 挖掘与归因：把线上发现转成可验证的改进

解决的问题：发现问题后怎样定位和修正?

触发时机 异常信号触发 / 例行采样

线上有问题线索，也要主动寻找遗漏。

	核心能力	具体产出
01	**高价值 Case 挖掘**	从四类渠道筛出的代表样本
02	**问题复现与证据组织**	任务输入、关键状态、工具响应与版本
03	**失败模式归并**	问题簇、发生频率、影响范围与处理优先级
04	**分层定位与归因验证**	有证据和验证结果支持的原因判断
05	**修复协作与资产沉淀**	诊断单、责任方、复测结果与回归样本

核心作用

定位问题，驱动
两条 Loop 持续演进

Agent 效果迭代

修复行为与执行问题
回测并验证真实效果

评测体系迭代

补充样本，校准标准与 Judge
复核判断，沉淀评测资产

接下来展开 Case 挖掘与归因：怎样找到任务、沿证据查清原因?

Case 挖掘与归因：找到任务，再查清原因

挖掘筛选值得分析的任务；归因沿执行证据定位问题，为修复和验证明确方向。

Case 从哪里来?

用户反馈
从投诉、纠错和建议中找线索。

监控与巡检
从运行、质量与需求异常中筛选。

业务规则
聚焦高风险、高价值任务复核。

随机真实采样
主动抽样，补充其他渠道盲区。

归因该怎么做?

01

铺开执行全链路

把 Agent 的执行过程展开。

串起计划（如有）、工具调用、数据流、关键状态与交付物。

02

沿 Trace 逐一排查

像看日志查 bug 一样。

检查各环节输入、输出与异常，对照任务要求，定位偏差。

03

定位核心问题环节

结合证据形成原因判断。

区分 Agent 行为问题与评测标准问题，明确修复方向。

归因高度依赖 Trace 观测基建。
人工可以排查，机器也可以辅助完成。

产出：问题环节、证据、修复方向与责任方、验证计划。
相似 Case 归并与优先级排序，可减少重复分析。

挖掘找到值得分析的 Case；归因查清原因，推动两条 Loop。

经营分析 Agent 评测案例

沿用店长经营复盘：对比三家门店近两个月的经营与投放表现，交付复盘 PPT。

01	Agent 评测评什么?	明确任务与成功标准， 验收完整交付。
02	评测怎么评得可信?	统一业务标准， 检验人人一致与人机一致。
03	怎么持续改进评测体系和 Agent?	沿证据归因，分别改动， 验证效果并回流资产。

接下来，沿同一个任务，完整走一遍评测、校准与持续改进。

三店经营复盘：Agent 评测评什么?

评测完整任务：明确结果、过程、效率与风险的验收要求，再核验实际交付。

> **店长问：**“帮我对比三家门店近两个月的经营与投放表现，给出下月建议，并生成复盘 PPT。”
>
> 初始条件：经营数据已上传，账号已授权，投放查询工具可用；仅分析，不修改投放配置。

这份经营复盘，具体怎么验收?

结果	PPT 是否可打开? 是否覆盖经营、投放分析和下月建议? 结论是否有依据、建议能否落地?
过程	数据取对了吗？三店是否按同一口径比较?
效率	多久完成？是否反复调用工具、浪费 Token?
风险	有没有越权取数，或擅自修改投放配置?

四个维度共同验收任务，兼顾客观与主观质量。

Agent 报告摘录：

“C 店营收 120 万元最高，下月增投 C 店。”

核验依据：源数据摘录 万元

门店	源数据金额	金额口径
A 店	90	扣除退款后的净营收
B 店	95	扣除退款后的净营收
C 店	120	退款前成交额，退款 40

教学约定：净营收 = 成交额 − 退款额，其他口径一致。

客观核验：口径混用，“C 店最高”不成立。

C 净营收 = 120 − 40 = 80；A 90、B 95、C 80。

> **本例客观验收规则：**三店同口径比较 · 正确扣除退款 · 排名结论与数据一致。

DACon
DataFun.

这份经营复盘，怎么评得可信?

主观评测：报告给出的建议好不好?

> **假设口径已修正，报告这样建议：**“B 店净营收最高，建议下月增加 B 店投放。”

同一版标准，怎样让人和 Judge 稳定执行?

01 评测负责人定标准

先定建议的依据、约束、执行与验证要求。
再看本例：净营收排名不足以支持增投。
实际适配性未知时，不给确定性行动结论。

02 先检验人人一致

两位评审按同版 Rubric 独立盲标同批建议。
比较各项判定与依据，定位分歧。
负责人裁决并细化标准，再用新样本复测。

03 再检验人机一致

Judge 按同版 Rubric 评同批建议。
对照人工裁决，分析不一致样本。
调整提示词或 Rubric，留出样本复测。

本例重点：净营收第一，不等于值得增投。
先把“好建议”说清楚，再看人和 Judge 能否评得一致。

> 共同标准明确什么表现算好；人人一致和人机一致检验标准能否被稳定执行。

C 店排名错、报告建议缺依据：怎么改？

C 店排名错误已有 Trace 线索；上页建议缺依据，生成过程还要查。

改 Agent：先算对，再给建议

C 店排名
报告统一按净营收排名：净营收＝成交额－退款。

报告建议怎么生成
核对数据依据、业务目标与约束，写清怎么做、怎么验证；证据不足时说明待确认。

修后怎么验：同一输入对照新旧版本；
检查排名是否正确、建议是否有依据且可执行。

改评测：让两类问题被识别

C 店排名
检查净营收计算与同口径排名规则，核对原评测当时是否检出。

报告建议怎么评
按依据、目标与约束、执行方案、效果验证四项 Rubric 检查；先对齐人工判断，再检查 Judge。

改后怎么验：已知口径题检验客观规则；
用留出报告建议对照人工裁决检验 Judge。

下次更新，重测这两类问题

C 店：能否算出净营收 80 万并正确排名？
报告建议：能否有依据、顾及约束、可执行且可验证？证据不足时能否说明待确认？

> 每次改动，都重测这些问题，也检查原有任务有没有退步。

DACon
DataFun.

业务如何把双 Loop 持续跑起来

以经营规划分析 Agent 为例：每日评样本，每周检查 Judge，每两周综合评 Agent。

每日
评线上样本
共同输入

清洗线上数据 → 对话、Trace 与节点记录
Judge 按指标评测 → 机器标签与错误类型
关联原始记录 → 通过 Trace ID 落库
→ **可追溯的评测数据**：供每周抽检、双周汇总

每周
检查 Judge
评测体系 Loop

抽取机标样本 → 人工复核同一批样本
比较人机判断 → 一级标签与错误类型
检查分歧与衰退 → 核对规则与统计口径
→ **Judge 可靠性判断**：校准问题与分歧样本

每两周
综合评 Agent
Agent 迭代 Loop

汇总两周数据 → 端到端与过程评测
人工补标与质检 → 融合机标、人标与质检
报告与 Bad Case → 研发分领域 RCA
→ **Agent 调优方向**：重点场景、问题与修复依据

评测体系 Loop
按需校准 Rubric / Judge → 下一轮每日机评

Agent 迭代 Loop
修复与回测 → 新运行数据与回归样本

每天积累证据，每周检查评测，每两周决定 Agent 如何改进。再次推进进入下一页。

用一张表找到评测体系的短板与错配

模块	维度	L0 准备阶段	L1 冷启动阶段	L2 扩量推全阶段	L3 自进化阶段
观测基建	观测	只有入参出参日志	有完整 trace，可人工回放	结构化埋点，支持自动化提取	含环境快照，可自动判定 outcome
离线评测	评测集	没有固定评测集	有端到端种子集，人工维护	分层评测集，含黄金集与错题集	线上 case 自动回流，版本化管理
	评测标准	凭感觉判断	有rubric	rubric 二元化，人人一致率达标	人机一致率达标，机评规模化
	回测门禁	不做回测	发版前手工跑一次	回测自动化，有分层门禁	嵌入 CI/CD，不通过无法发布
在线评测与在线监控	在线评测	无	有人工抽查	有周期性巡检，含报警	巡检 + AB + 影子模式组合使用
	在线监控	无	有基础成功率指标	含成本、行为分布等多维指标	指标与版本、AB 打通，可自动归因
case 挖掘与归因	case 挖掘	靠用户投诉	有 bad case 收集渠道	四类来源齐备，有 case 池	自动挖掘 + 自动分类入池
	归因	不做归因	人工逐条分析	有归因分层与例会机制	机器辅助归因，结论自动分派

冷启动建立最小闭环，扩量补齐真实场景，全量运营持续校准。不要追求所有维度都达到 L3，先补当前阶段的短板。

一套成熟的评测体系，既要持续测量 Agent，也要持续校准自己

01 评测是在 Agent 能力和业务结果之间搭桥。

02 人人一致，让标准可信；人机一致，让评测规模化。

03 Agent 评测是一门实践科学。

04 一个 Loop 改进 Agent，一个 Loop 校准评测。

MEASURE · ALIGN · EVOLVE 把评测做成能够持续自我校准的工程体系



高诗梦

美团 · 专家工程师

负责美团 AI Agent 评测平台

协助业务建设 Agent 评测体系

欢迎交流 Agent 评测实践