从“答得对”到“看得透”

高德智能问数产品：从BI底座到Agent底座的迭代之路

林宇航

高德商业智能部 | 数据产品高级专家

2026年10月24日

目录

CONTENT

01 用户工作

02 规模化转折

03 Agent底座

04 从L2走向L3

05 迭代进展

06 复盘与未来

用户要完成的，是一段完整的数据工作

即时取数只是起点，工作要在判断与交付中完成



提出问题

明确目标与范围

拿到数据

找到口径与结果

持续跟踪

观察变化与节奏

解释变化

拆维度、找证据

形成判断

交付可讨论结论

一次数据工作往往经历多轮追问与修正，价值随链路向右递增

用户工作链：问题提出、数据获取、持续跟踪、变化解释与判断交付

“答得对”是起点，“看得透”才是价值增量

L0 – L4：AI承担的判断逐级增加，人从操作者转为把关者

L0
手动取数

写SQL、导出Excel
人工跑数

行业 · 已淘汰

—

L1
自助看数

报表看板、拖拽分析
自助BI

行业 · 已成熟

我们的服务

BI看板
与数据集

我们的起点

L2
智能问数

自然语言问数
可靠取数、口径命中

行业 · 当前主流

我们的服务

即时问数
报告撰写

100%业务域覆盖

L3
智能诊断

诊断归因、趋势预测
风险预警

行业 · 前沿阵地

我们的服务

风险预警
钉钉推送归因诊断报告

W35部分场景验证
9月全域覆盖

L4
自主决策

Agent BI、处方性分析
自主执行

行业 · 共同空白

我们的服务

经营大脑

场景验证中

上排：行业分级（L0 – L4） | 下排：我们的服务与进展（截至W35；L3全域覆盖截至2026年9月）

RAG+NL2SQL+OLAP引擎，是早期L2的合理起点

在范围明确的阶段，优先复用已有BI资产



资产起点

补充报表、指标与业务知识

生成SQL，查询数据

承接复杂指标与同环比计算

回答用户问题

知识补全、查询生成与指标计算各自承担明确责任

早期L2路线：复用BI资产，以RAG补知识、NL2SQL取数、OLAP完成已定义计算

明确范围内，MVP验证了早期路线

资产范围

39

张ADS表

15

张看板

阶段结果

89.4%

L2回答成功率

90%

端到端准确率

早期MVP在明确范围内完成了可用性验证

历史阶段快照｜资产数量与评测指标按各自单位阅读

规模扩展暴露了路线边界

两组独立阶段快照

业务经营单元A

331

张表

50%

端到端准确率

业务经营单元B

70

张表

80%

端到端准确率

单域MVP的成功，没有自然复制到更大范围

两组独立历史快照｜对应不同业务范围与评测批次

阶段复盘识别出四类规模化瓶颈

复杂问数：一次召回装不下，中途也补不进

规模扩展

01	一次性召回	复杂问题需要的知识难以在开场一次拿全
02	多步链路	实体、口径与约束在步骤间逐渐损失
03	复杂跨表计算	任务超出预设链路后，扩展成本上升
04	逐case维护	业务扩展持续增加规则与特殊处理

关键判断：复杂问数无法由单次任务完成

路线选择：继续修补RAG，还是重构为Agent



从RAG到Agent，换的不是一个更强的模型，而是技术路线：
从“检索后生成”，到“规划、执行、校验”的闭环

决策标准：多步任务、复杂计算、中间结果复用、执行反馈与规模化维护

新方案总览：执行闭环、知识供给与质量控制

分两步：先换执行方式（执行闭环＋知识供给），再补质量护栏（语义 · 评测 · Harness）

业务触点与服务 — 从一次回答到持续交付

即时问数	报告	告警
问题进入，结果返回	按固定节奏交付	监测异常，主动触达

Skill与知识 KNOWLEDGE

按任务装入当前步骤需要的方法、口径和操作经验

领域路由　步骤方法　例外处理

DataAgent工作层 TASK LOOP

组织步骤、调用工具、管理任务状态

规划 → 执行 → 检查 → 再规划

证据与过程 TRACE

让每一步都能回到来源与上下文

- 数据来源
- 时间范围与口径
- 结构化中间结果
- 执行记录与修正

过程可回看，结果可解释

业务语义层 SEMANTIC

统一指标、实体、关系和校验规则

口径一致　对象清晰　规则可用

数据与执行底座 DATA & RUNTIME

保留BI看板，并提供受治理的数据资产、查询计算和受控运行环境

稳定观察　数据集　查询工具　受控执行

质量与治理 HARNESS

权限与审计

Trace追踪

Verify验证

评测回归

人工纠偏

贯穿每一层

问数执行底座已覆盖全部业务域，归因诊断全域覆盖；L4自主决策场景验证中

执行闭环：基于CodeAgent架构的DataAgent

把一次回答改造成可执行、可观察、可回环的任务循环

第一步 | 换执行方式
做完即见效



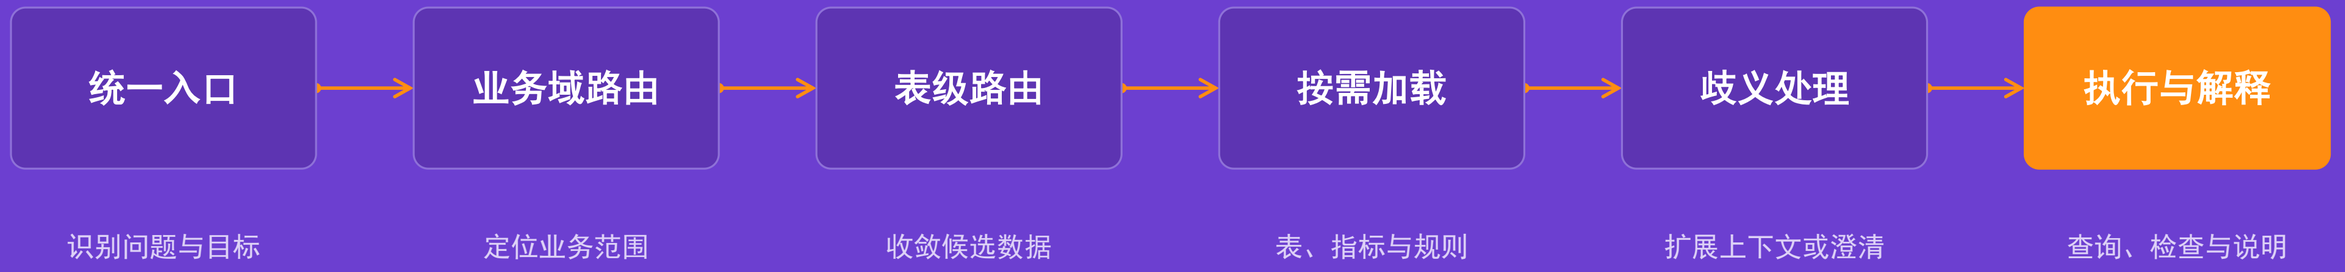
复杂任务被拆成可执行、可检查、可回到前序步骤修正的链路

任务循环：计划、执行、检查与回环 | 项目重点落在业务适配、知识组织与验证

知识供给：Skill让知识按任务逐步展开

知识随着任务逐层展开，当前步骤只加载当前所需

第一步 | 换执行方式
做完即见效



Skill = 知识路由 + 程序性方法

语义告诉Agent需要理解什么，Skill告诉Agent去哪里找、按什么步骤做

团队取数Skill：定位业务域与数据表，补齐口径，生成并检查SQL，执行后说明来源与范围

同一批数据表上复测，新路线经受住了检验

执行闭环与知识供给落地后，阶段测评达标，平滑迁移

第一步 | 换执行方式
阶段成果

业务经营单元A 331张表 · 改造前50%	**93.6%**	阶段性准确率
业务经营单元B 70张表 · 改造前80%	**96.7%**	阶段性准确率
整体	**约95%**	问答准确率

5月底架构升级：平滑迁移，整体用户未发生流失

业务经营单元A、B与P7为同一业务范围前后对比 | 整体为问答准确率

代码运行成功，还要经过业务语义校验

代码执行解决计算正确，语义底座解决上下文正确

第二步｜补质量护栏
需要持续投入

计算侧｜代码执行

01 计算逻辑可运行

02 跨表步骤可复现

03 中间结果可传递

上下文侧｜语义底座

01 实体与角色选对

02 指标口径一致

03 时间、维度与证据匹配

可验证答案

“解决”指主要责任分工｜最终结果共同经过上下文、计算与证据检查

语义从知识片段变成生产资产

语义资产开始进入可生产、可审核、可持续消费的链路

第二步 | 补质量护栏
需要持续投入

早期供给

01

元数据
业务知识
路由规则

零散知识进入任务

文档MVP

02

约两个月运行

验证分级、生产、质检、准入与消费

平台化

03

8月31日首版

连接知识库，承载版本与持续消费

供给侧语义工程与智能问数产品并行推进

平台化让语义具备来源、质量门槛、版本和消费方式

质量控制：语义资产、评测与Harness三类护栏

三类护栏需要持续投入，共同约束每一次任务结果

第二步 | 补质量护栏
需要持续投入

可靠任务结果

语义资产

理解什么

实体、指标、口径与业务规则

评测体系

怎么判断对错

看任务结果，扩域和改底座都靠它回归

Agent+Skill Harness

执行过程怎么控制

编排、权限、状态、重试、观测、降级与转人工

评测看的是整体：模型、语义资产、Skill与运行系统共同工作的任务结果

职责框架 | Skill属于Agent内部的知识路由层（见P12），不单列为护栏

L2持续服务：同一个问题，每次都算对

把问答固化成任务：问什么、用什么口径、怎么算，一次定义

三种交付方式

即时问数
用户临时提问，一次交付

报告
按主题、按周期定时交付

告警
条件触发→见下页（L3）

背后是同一个数据任务

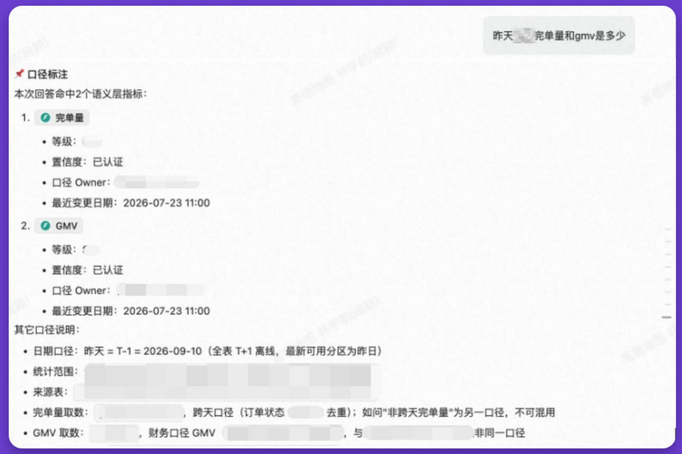
任务固定下来

- 问什么：对象、指标与判断标准
- 口径：实体、时间范围、过滤条件
- 怎么算：步骤、代码与中间结果

每次更新都要稳定算对

每次都算对

- 评测回归：改底座、扩业务域都重测
- Harness：状态保存、失败重试、异常降级
- 每次交付都带上口径与来源



示例：回答附带口径标注（已打码）

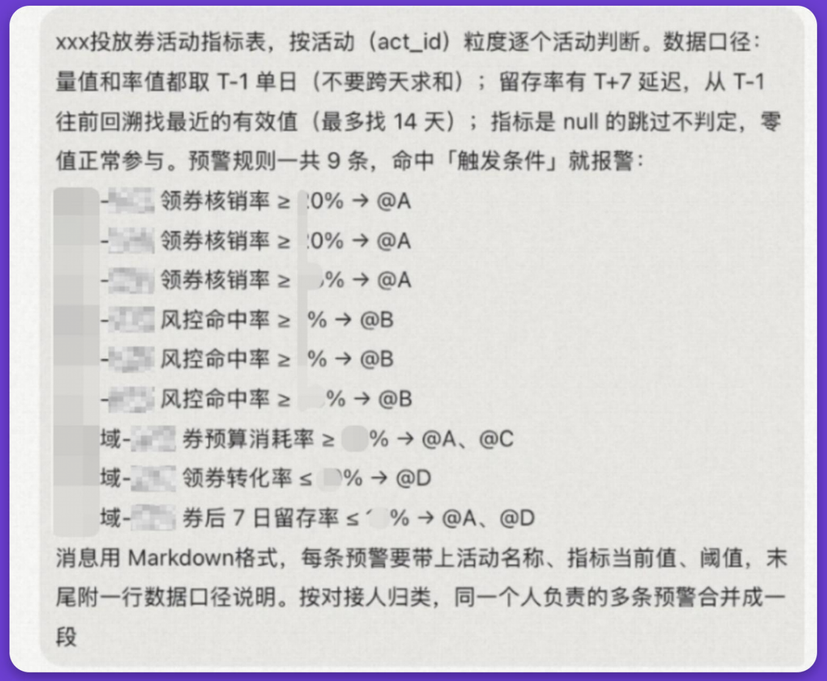
下一步：
通过MCP / Skill把这些任务带进办公工作流（外部参考：千问办公）

状态：即时问数已验证 | 报告、告警已上线 | 办公工作流为下一步方向，千问办公仅作外部参考

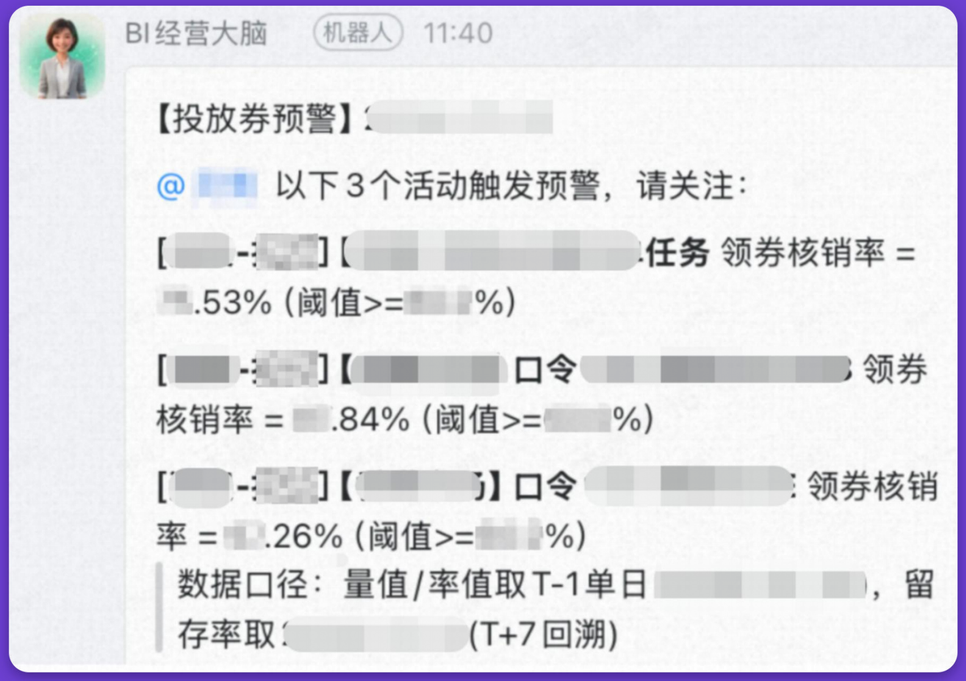
L3主动告警：指标越线，系统先找到人

一段话定义规则，系统每天盯数，命中条件就推送，并附上口径

告警丨一段话定义规则，钉钉机器人按条件推送



① 用一段话写清口径、阈值和接收人



② 命中条件，钉钉机器人推送，并附上数据口径

截图均已脱敏，仅展示规则配置与推送形式

L3归因诊断：从发现异常到解释原因

每一步留下任务、数据与判断证据，用户可以回看和纠偏



已落地的方法 | 结论与证据强度匹配 | 高风险判断保留人工复核

L3实践：一次经营分析的完整链路

同一套分析链路：生成前校验，过程中验证，证据不足就回退

归因诊断实践 | 思路与链路

三层报告 | 同一方法

日报 · 快
昨天发生了什么？
现象描述 + 异常标记

周报 · 准
为什么偏离目标？
根因定位 + 维度拆解

月报 · 全
经营是否健康？
全面归因 + 行动建议

生成前 | 数据校验 子项加总 = 总量 · 跨维度对齐 · 指标合理区间 · 上下游层级 · 基数异常

01 **看大盘**
环比、目标完成率、是否触发阈值

02 **拆结构**
沿主要业务维度交叉定位

03 **做归因**
规模效应 + 效率效应 = 总变动

04 **做验证**
关联指标：正向 / 负向 / 无联动 / 背离

05 **给结论**
现象 · 主因 · 验证 · 置信度高 / 中 / 低

↺ 校验失败或指标背离：退回“拆结构”；证据不足转成验证任务

生成后 | 输出扫描 按敏感表述与合规规则过滤，保证输出干净

归因规矩 | 先排除可解释的波动

- 只用数据集内的维度，不从外部编原因
- 已知政策带来的变化，不做归因
- 基期过小，标注“受基数影响”

人工纠偏 | 保留边界

- 补充业务背景，排除已知例外
- 修正回到后续拆解与验证
- 证据不足时保留不确定性

归因诊断实践 | 不含经营数值 | 报告（触点）+ Skill（方法）+ 业务语义层（口径）+ Harness（质量门）

上线4个月：用户留下来了，体验也在变好

真实采用

周活跃用户（WAU）

41 → 420（增长约10倍）

上线初期 → 截至8/31

深度用户占比（每周使用≥3天）

20% → 47%（提升27个百分点）

上线初期 → 截至8/31

次周留存率

36% → 66%（提升30个百分点）

上线初期 → 截至8/31

稳定性与体验

问数准确性

80% → 95%（提升15个百分点）

上线初期 → 截至8/31

P90查询时长

787秒 → 280秒（缩短507秒）

上线初期 → 截至8/31

5月底架构升级：平滑迁移，整体用户未发生流失

统计窗口：上线初期至8/31（正式上线4个月）｜深度用户为每周使用≥3天｜时延指标为P90查询时长

三次真实踩坑，形成了三条经验判断

每一条都来自真实踩坑，也是下一轮设计的输入

经验判断	不注意会怎样	应该怎么做
单域成功 ≠ 规模化成功 效果依赖知识边界；范围一变，原来的验证结论就要重来	沿用小范围的成功经验，扩域后准确率明显下滑，规则和case越补越重	**扩域前重新评测，按任务复杂度分层看结果**
计算正确 ≠ 业务理解正确 SQL能跑通，只证明计算可复现，不证明实体、口径和时间理解对了	答案可执行、看起来合理，却答非所问，错误更难被发现	**语义资产校准上下文，关键结论回到证据，Harness管住执行**
独立入口 ≠ 高频工作入口 用户用不用，取决于产品是否进入他已有的工作节奏	用户偶尔来问一次，产品停在尝鲜阶段，难以成为日常工具	**把能力做成报告、告警等持续服务，再进入办公工作流**

三条判断按不同成熟度落地，并继续用真实任务与阶段评测校验

底座决定上限，下一程是L4自主决策

L2智能问数
答对一个数
100%业务域覆盖

→

L3智能诊断
看透一个问题
全域覆盖

→

L4自主决策
支撑一次决策
场景验证中

01 从RAG到Agent，换的不是一个更强的模型，而是技术路线：从“检索后生成”，到“规划、执行、校验”的闭环

02 代码执行解决计算正确，语义底座解决上下文正确

03 Agent让模型有了手脚，语义资产、评测体系和Harness决定它会不会走错路

从答对一个数到看透一个问题，底座决定上限，我们仍在路上。

L4方向：通过MCP / Skill进入办公工作流，在人工把关下辅助决策与执行 | 千问办公为外部参考

Q&A

谢谢聆听，欢迎交流