从多云底座到 Agent Ready

企业 DataAgent 架构升级与高端零售落地实践

演讲嘉宾：

谈总

某全球头部高端零售集团
中国数据技术负责人

原攀峰

数新智能 CTO

数据 · 平台

跨云数据平台技术

数据分析和处理能力飞速增长　留给我们的是物理世界的限制
数据——准备它、搬运它、治理它。



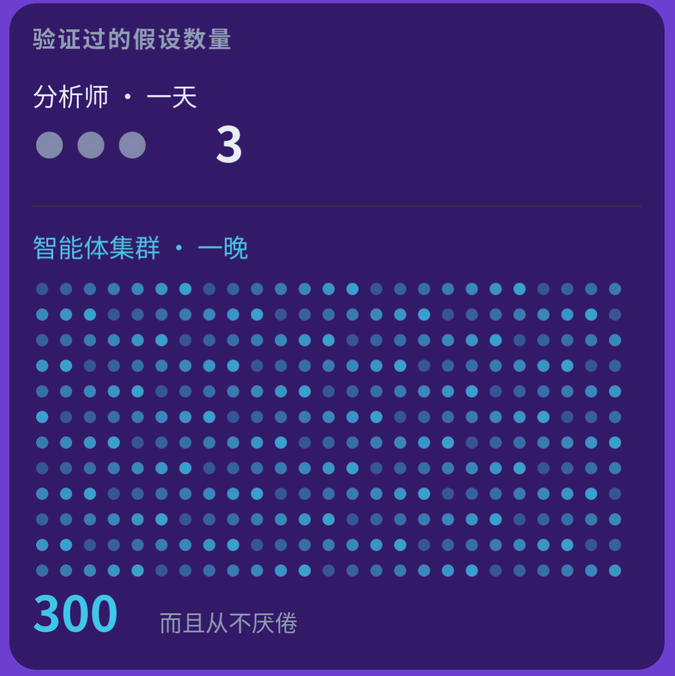
谈总

某全球头部高端零售集团
中国数据技术负责人

趋势 01

数据分析能力大大加强 数据“饥饿”

- AI 最强的地方，恰好是分析最苦的地方：**大批量、重复性的脑力活**。
  - 画像、关联、对账、找异常、扫假设、写结论
- 人一天验三个假设，智能体集群一晚上验三百个，而且从不厌倦。
- 稀缺能力从“你会不会写查询”，变成**“问题问得对不对、数字可不可信、接下来怎么办”**。
- 分析不再是工单队列，而变成**一直在跑的后台服务**。



对答案的需求爆发，对**可直接分析的数据**的需求涨得更快。

行业数据痛点：数据合规与准备

- 智能体又贪吃又浪费：读的数据量是人类分析师的 **10–100×**。
- 它要的不是看板，而是一块**准备充分的底座**：
  - 语义口径机器可读 · 契约与表结构稳定
  - 新鲜度、血缘、质量**以数据形式**暴露，而不是口口相传
  - 文档、日志、事件、表，收进同一个可寻址平面
  - 读路径便宜、高吞吐、高并发（列式与开放表格式）
- 交付物随之改变：从给人看的报表，到**给智能体用的数据产品**。



> 数据搬运不会变少，它会变成**产品本身**。

趋势 03

现实世界的限制：跨云带宽 & 跨境的法规

- 算力弹性了，**字节没有**。距离、带宽、出网费重新成为硬约束。
- 为什么现在疼：算力在一朵云，底账数据在另一朵云；叠加数据驻留要求和 GPU 紧缺，跨云成了默认。
- 把 100 TB 搬过云，是**时间和钱的问题**，不是一个配置开关。
- 于是工程重新回到基本功：
  - 能**把算力搬到数据边**就搬，只复制值得复制的
  - 用 CDC 和增量同步，替代整份全量拷贝
  - 压缩、列裁剪、去重、分层缓存、错峰窗口
  - 把**数据引力**写成明确决策，并定期复盘



架构师的核心问题又变回“字节在哪里，搬一次值多少钱”。

解决方案：数据团队专注交付数据

- 治理一直正确，也一直太贵。**AI 改变了成本曲线：**识别 PII、从代码日志推血缘、生成策略与测试、发现漂移——持续、跨云。
- 跨云统一的**策略与目录平面**：身份、访问、驻留、留存、审计
  治理变成**在跑的软件**，而不是一个委员会。

过去	现在
我们交付分析	我们交付**受治理的数据**
看板与报表	数据产品、契约、API
消费者是人	主要消费者是智能体
治理 = 评审会	治理 = 自动化策略平面



> 软件让 AI 写，分析让 AI 做。我们的活，是把数据做到**可用、可搬、可信**。

小结

请记住三件事

01

软件正在成为公共基础建设——数据变得不足

02

智能体规模的分析，需要智能体规模的**数据准备**

03

带宽与治理是新的硬约束——也是我们新的产品

软件让 AI 写，分析让 AI 做。我们的活，是把数据做到**可用、可搬、可信**。

下一部分：企业 DataAgent 架构与落地实践

企业 DataAgent 架构升级：Agent-Ready 底座与工程落地

原攀峰

数新智能 CTO

多云部署，只是多云底座最基本的要求

多云底座挑战

多云适配与部署

异构数据源和引擎适配

不同云的数据中心之间形成新的数据孤岛

多云数据传输

离线 / 实时 / 全量 / 增量

跨云跨区域数据传输控制与加速

跨区域数据稳定生产

任务编排和稳定调度

任务代码版本管理

跨区域任务发布与依赖管理

数据资产管理与共享

数据指标口径管理，血缘与质量分析

逻辑模型与物理模型协同管理

数据安全与合规要求

平台权限、数据权限、数据加密、数据脱敏、平台审计等

不同国家地区的数据合规要求

多云底座是解决AI时代数据的可用、可搬、可信难题的必经之路。

Agent不是某一步卡住，是六个环节每一个都卡

真实企业研发全生命周期：一个简单需求，Agent 到处断链

全景断点归因

贯穿任务示例：业务要求产出《跨区调货异常损耗监控看板》，看看 Agent 在哪里翻车：

归因分类：语义可懂缺失 4 次 · 执行可控缺失 1 次 · 效果可迭代缺失 1 次

① 探数环节

不知道口径是否存在

搜出 20 张同名表，不知道哪张是生产源，直接用废弃临时表

归因：语义可懂缺失

② 建模环节

不知道如何复用维度

重复新建地区维表，导致烟囱膨胀，同一客户在两表 ID 不一致

归因：语义可懂缺失

③ 开发环节

幻觉 SQL 与方言错误

自己臆造字段名，多表 JOIN 发生 Fan-out 扇出，指标被放大 10 倍

归因：语义可懂缺失

④ 测试环节

不知道“什么叫正确”

无法自动生成基线对账断言，无法识别退货场景的负值合法性

归因：语义可懂缺失

⑤ 发布环节

不敢发布 · 影响面不明

不知下游有哪些关键报表依赖，且无沙箱防护，可能误删生产表

归因：执行可控缺失

⑥ 运维环节

报错看不懂 · 无法自愈

底层引擎抛出千万行栈，无归因闭环，失败即任务终止

归因：效果可迭代缺失

【语义可懂】在 6 个环节中连续断掉 4 次，它是 DataAgent 落地失败的重要原因之一。

单靠 Prompt 无法挽救系统性缺陷

Agent-Ready 的四条判据，缺一不可

业务侧的四条诉求：从业务愿景到技术验收标准的严密映射

CRITERION 01

多云可用

异构寻址与计算下推

算力与数据必须能够被 Agent 统一透明寻址，算子按引擎能力自适应映射。

回扣业务诉求：

多云多中心，拒绝烟囱

CRITERION 02

语义可懂

口径显式化与确定性编译

业务口径与关系拓扑被显式定义，检索子图组装，编译器消灭毒 SQL。

回扣业务诉求：

口径机器读懂，拒绝幻觉

CRITERION 03

执行可控

沙箱隔离与生产底线防线

人机权限等效，编译期注入行级权限，生产高危动作强制触发卡点审批。

回扣业务诉求：

合规是硬边界，不是配置项

CRITERION 04

效果可迭代

失败归因与语义资产反哺

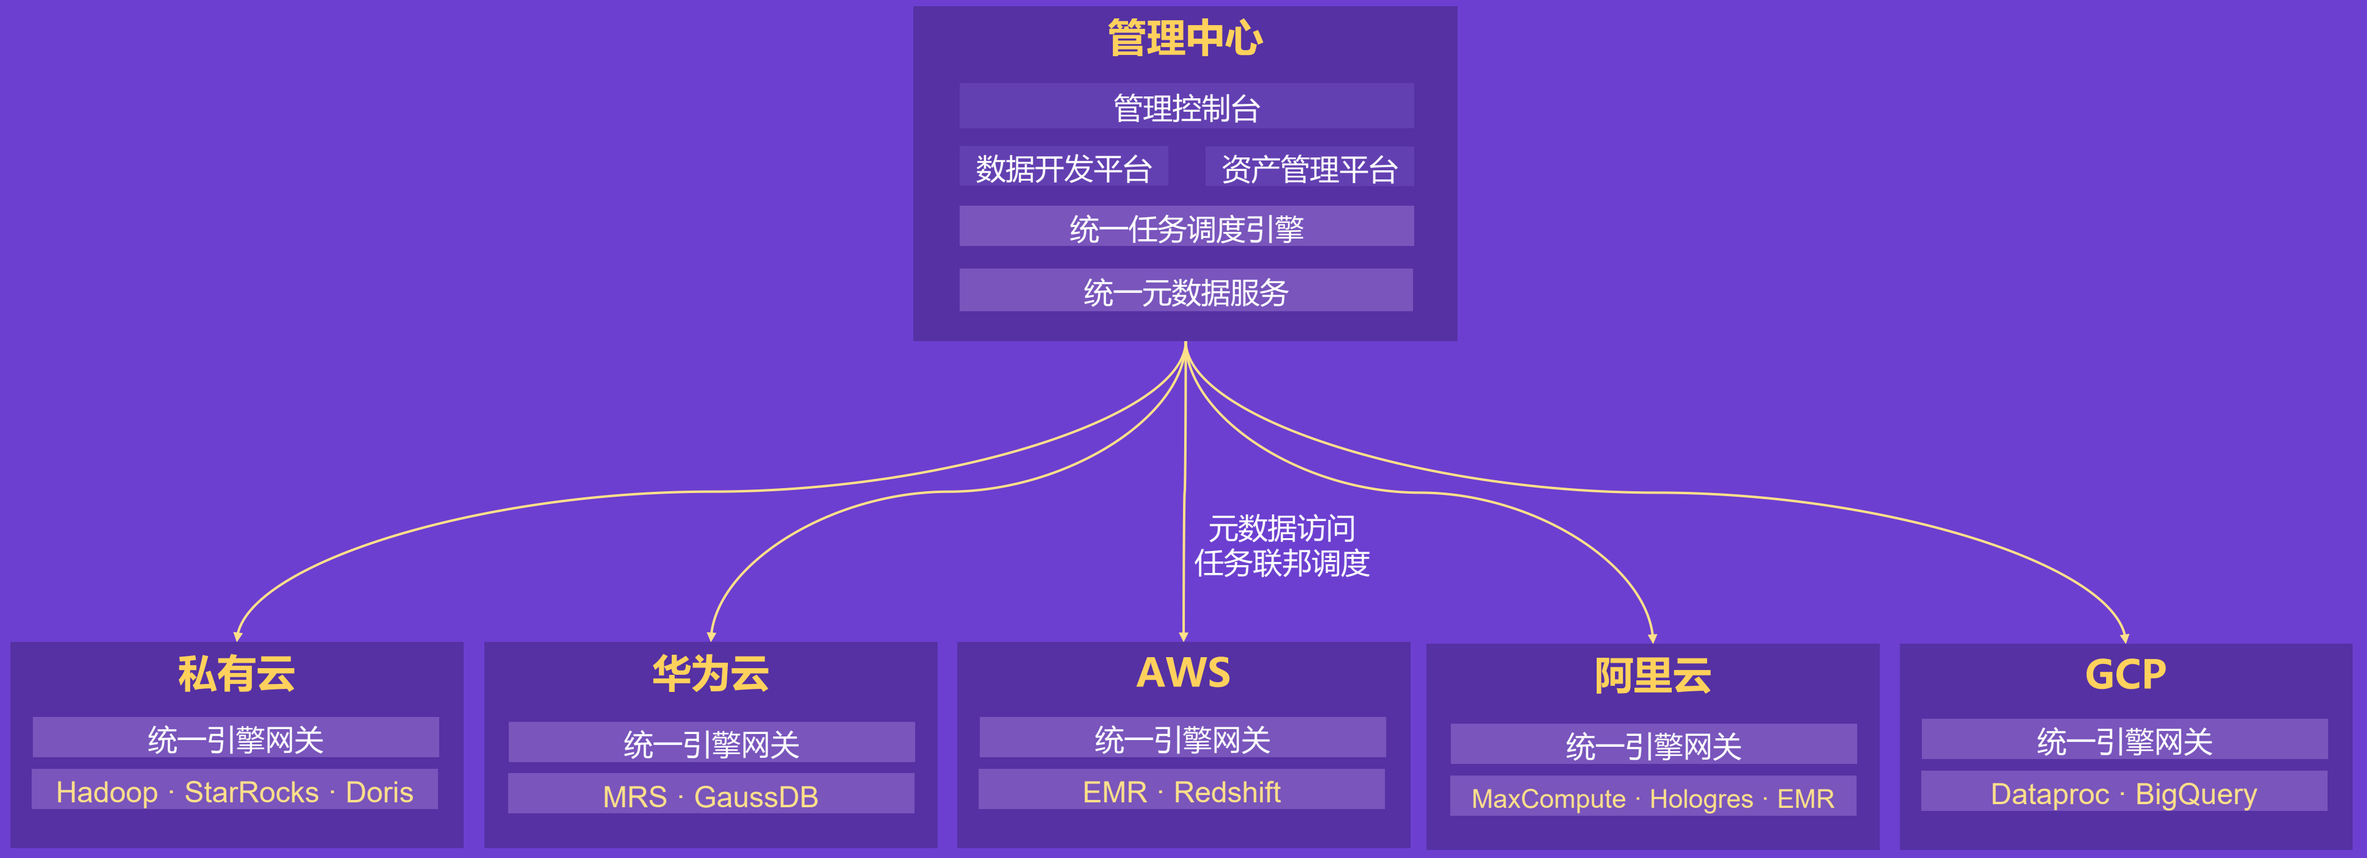
失败具备明确归因分流回路，自动化反哺语义模型与技能库，持续演进。

回扣业务诉求：

不能上线即巅峰，持续复利

模型不是瓶颈，底座才是 —— 这四条判据是每一个想做 DataAgent 的企业必须回填的答卷。

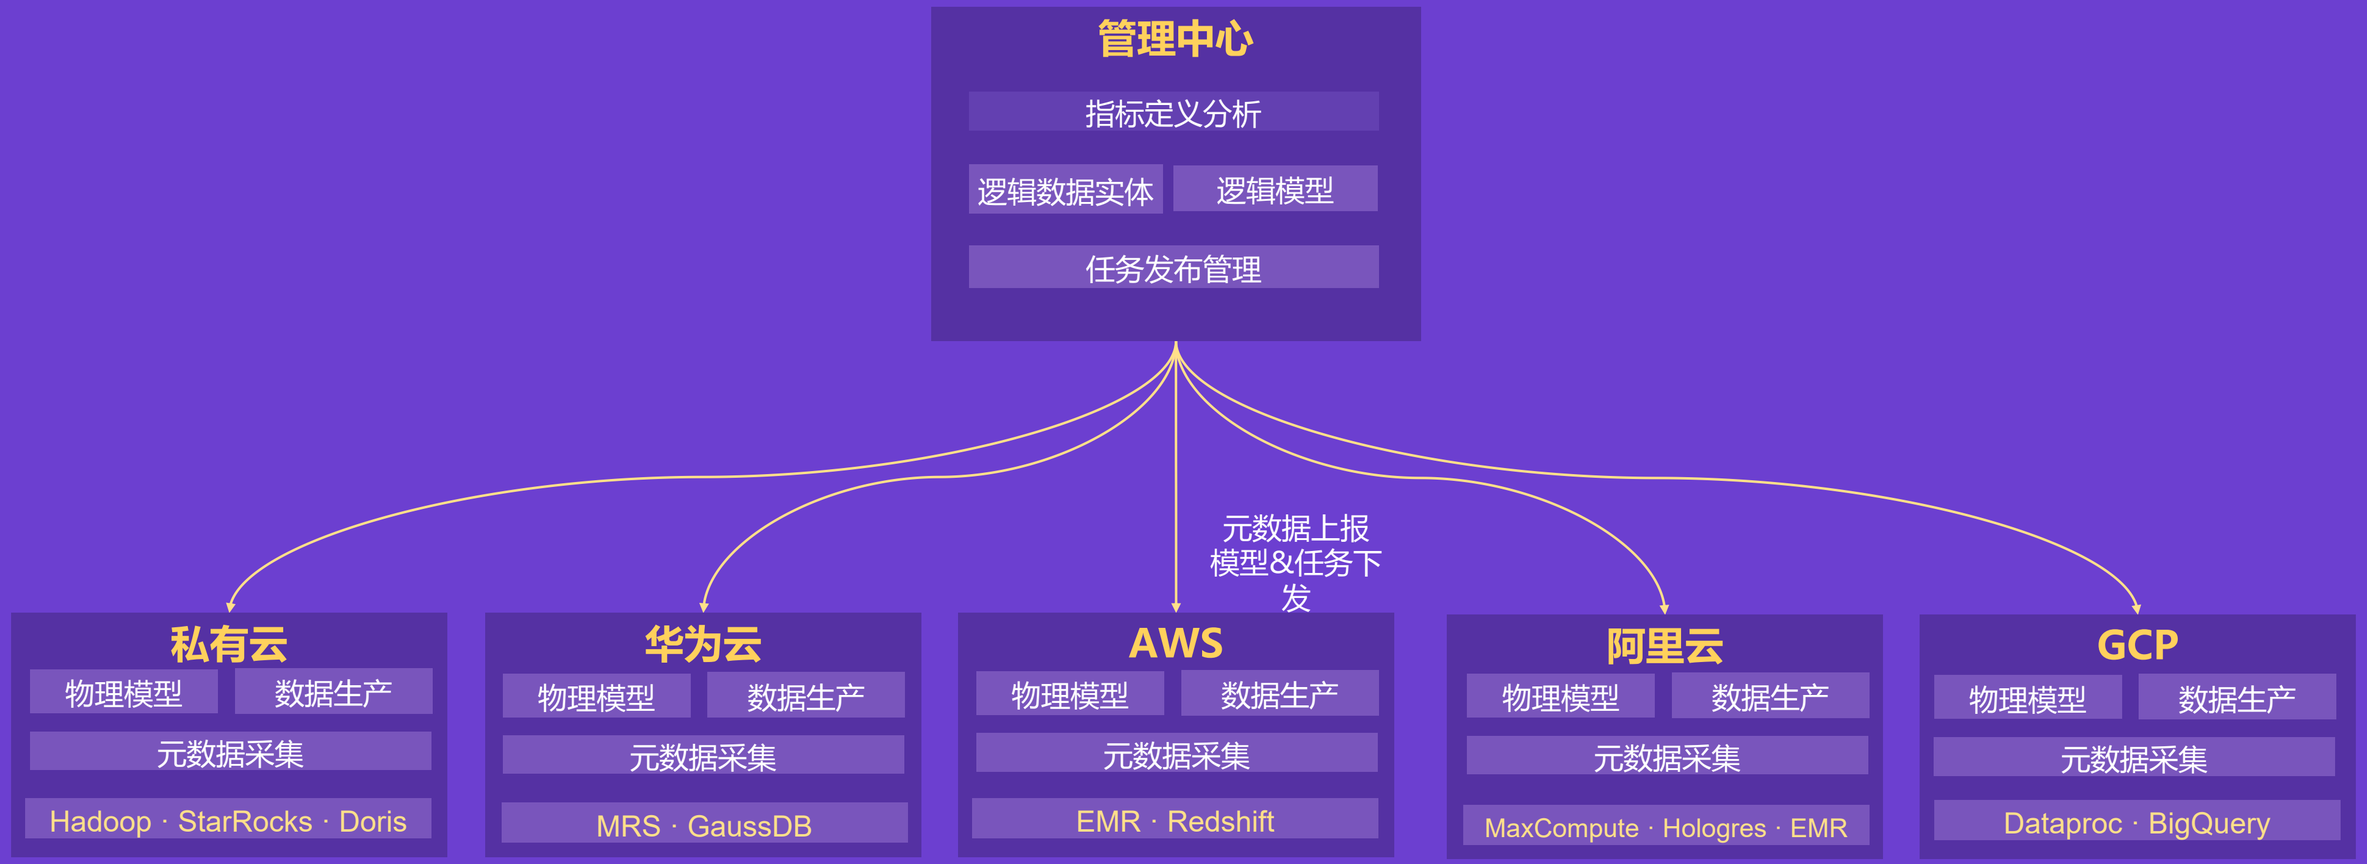
多云统一纳管与任务编排调度



跨云数据同步带宽流量控制



多云全域资产，集中式和联邦式融合治理



多云的解法：基于集散控制架构的多云多中心数据智能平台

承认异构现实：Agent 只发出逻辑意图，多云多中心底座负责纳管、集成、调度、查询与治理

AI

DataAgent 逻辑意图输出 (Logical Query Intent)

“计算北美区近30天退货率与跨仓调拨延迟，按渠道聚合” (无需声明物理方言与底层库表结构)

{ 声明式 JSON }

多云多中心数据智能底座

① 多云数据底座纳管

开放式插件架构

适配主流大数据与 MPP 底座，覆盖云厂商、三方厂商及开源自建场景

② 统一任务编排调度

统一编排 · 多区域运行

中心区域统一管理任务代码版本与多区域发布，提效全球多地域数据中心建设

③ 多源异构数据集成

云上云下数据源

插件化多同步引擎；离线 / 实时 / 全量 / 增量 / 整库 / 多表；跨区域传输加速

④ 全域数据资产管理

中心治理 · 边缘计算

融合集中式与联邦式管理优势，灵活适配企业资产管理基础与组织架构

⑤ 跨源查询分析

跨数据中心 · 跨异构源

跨中心、跨异构数据源一次查询完成分析，解决数据安全合规访问

私有云	华为云	AWS	阿里云	GCP
Hadoop · StarRocks · Doris 等	MRS · GaussDB 等	EMR · Redshift 等	MaxCompute · Hologres 等	Dataproc · BigQuery 等
开源自建+数新智能	云厂商+三方厂商+数新智能	云厂商+三方厂商+数新智能	云厂商+三方厂商+数新智能	云厂商+三方厂商+数新智能

★ **系统调用机制**：网关先探测引擎能力再原生下推，失败自动回退 ANSI SQL 降级执行，绝不中断 Agent 会话。

Agent 只面对一个入口

我们检索的不是文档，是 Schema 与口径

全链路流程图：自然语言意图 ➔ 双通道图检索 ➔ 确定性编译器流水线 ➔ 生产 SQL 交付

Spider 2.0: 裸 SQL <20% ➔ 语义层 54%~90%

① 查询理解 NLU

LLM

输入：**“各州净利润排名”**

实体识别 · 字面值提取 · 时间表达式 · HyDE

种子实体

② 双通道召回

Hybrid RRF

A 实体链接：name / synonym 精确命中

B 混合召回：Dense + BM25 + ValueIndex

RRF + 精排

③ GraphRAG 子图扩展

Apache Ossie

`Model ➔ Dataset ➔ Field ➔ Metric`

PPR 补 Join 中间表 · PCST 最小连通子图 · LLM Selector

连通语义子图

◆ ④ 确定性编译引擎

Zero LLM SQL · 把语义查询编译为可执行 SQL

1 校验归一化	2 Join Path 求解	3 Fan-out 保护 ★
4 时间语义展开	5 行权物理注入 ★	6 方言模板渲染

SQL 产物

⑤ 生产级 SQL 交付

✓ 交付

语法自校验通过 · 口径幻觉消灭

30% ➔ 90%

代码准确率

编译期自校验

结构匹配率 − 执行准确率

= 编译器自身错误率

LLM 只负责理解意图 | **双通道召回 锁定实体锚点** | **GraphRAG 保障拓扑连通** | **编译器 100% 确定性生成 SQL**

★ **核心分工原则：LLM 只做理解，SQL 由编译器确定性生成——彻底消灭毒 SQL。**

零 LLM SQL 幻觉

API 是给人调的，工具是给 Agent 想的

Skills 技能生态：分层、边界定义、动态加载与 MCP 供应链隔离

经验：建表挂调度 8 步 → 1 步

反模式

API 1:1 包成 MCP

一次建表 = 8 步工具轨迹

- Step 1 · API 调用 ✓
- Step 2 · API 调用 ✓
- **Step 3 · API 调用 ✕ 出错**
- Step 4 · API 调用 受污染
- Step 5 · API 调用 受污染
- Step 6 · API 调用 受污染
- Step 7 · API 调用 受污染
- Step 8 · API 调用 受污染

错一步，后面全受污染

8 步 ↓ 1 步

◆ 分层工具体系

会变的进 Memory · 不变的进 Skill · 能执行的进 Tool

Skills SOP 渐进披露

不变的经验，触发后才载入

`description` `SKILL.md` `scripts/`

流程工具 ★ 存储过程式

建表 + 挂依赖 + 配调度 → 固化为一个工具

单次往返

原子工具 & CLI 底层 API

复杂入参封装为 CLI 风格

`CLI` `few-shot`

search_tools 动态发现

启动只注入
核心工具 + 搜索路由

语义检索
命中当前意图

按需注入
Top-K 完整 Schema

猜中未加载工具 → 引导先检索

隔离接入

第三方 MCP 隔离沙箱

一律视作不可信输入

独立容器 · 禁宿主网络 | 网关鉴权 · 版本锁定 | 返回内容 · 注入清洗

★ 把后端 API 一对一包成 MCP 是行业最普遍的反模式——高频链路固化在服务端，让模型专注决策。

高频链路服务端固化

通用摘要会把表名压没，数据场景不允许

上下文构建与压缩 · 异步笔记索引 · 两跳检索策略与防污染

脱敏深度对比

◆ 同一个会话 · 两种压缩

到阈值后，谁还记得表名？

前 20 轮已确认的 5 个事实

`dwd_ord_detail_di` | `dim_region_v2` | `ship_dt` | `NOT IN (CANCELLED, REFUNDED)` | `region × brand × day`

	压缩后的上下文	第 24 轮追问 “按月拆”
L1 同步摘要 行业常规做法	*“基于订单明细与区域维表，按发货日期统计净销售额，排除已取消订单，按区域和品牌聚合。”* ✕ _v2、表名、REFUNDED 全部丢失	猜回废弃的 dim_region ✕ SQL 能跑，数字全错
L2 异步笔记 现网主力 · 用户无感	`[n07]` dwd_ord_detail_di ← msg#7 `[n09]` dim_region_v2 (v1 废弃) ← msg#9 `[n12]` ship_dt (非 order_dt) ← msg#12 `[n15]` NOT IN (CANCELLED,REFUNDED) `[n19]` region×brand×day ← msg#19	复用笔记，仅改 day ➔ month ✓ 100% 正确

三级压缩进化：L1 同步摘要 → **L2 异步笔记 · 现网主力** → L3 向量化 · 前沿预留

◆ 推理闭环

两跳检索 · 记忆防污染

1 第一跳 · 查本体口径

先命中 Apache Ossie 度量与事实表

口径收敛后

2 第二跳 · 查数据样本

ValueIndex 校验取值 + 历史成功 SQL

会话沙箱 · 随任务销毁

失败的中间 SQL | 报错信息

✕ 禁止写入

组织长期记忆

没有治理的记忆，就是 Agent 的谣言库

★ 数据场景的标识符一个字都不能错——摘要不能压掉表名；第一跳不查数据，先查口径。

压缩最高境界：用户无感

Agent 的权限永远是发起人权限的子集

沙箱隔离 + 漏斗式五层安全防护栏：行级权限编译期物理注入，绝非 Prompt 约束

人机权限严格等效

◆ 权限等效

开发者权限 · RBAC

Agent 权限

⊂ 发起人权限子集

- ✓ 透传开发者 Token
- ✓ 继承数仓 RBAC 权限
- ✓ 系统不提供任何提权路径

放权是挣来的，不是默认给的

◆ 漏斗式五层防护栏

逐层收窄 · 层层留痕

Agent 动作请求

↓

L1 Input Guard · 输入防护
提示词注入拦截 · 越权意图预检

L2 Tool Guard · 参数校验
入参类型校验 · 操作白名单

L3 SQL Guard · 编译期注入
`row_filter injected @ compile`

L4 Harness 容器沙箱
1 Task = 1 容器 · 只读 · 断公网 · 短 TTL

L5 Output Guard · 脱敏审计
PII 遮蔽 · 出境阻断 · Trace 回放

↓

安全执行 · 全链可回放

◆ 生产红线

HITL

高危动作 Agent 无权自动执行

- DROP / TRUNCATE 高危 DDL
- 生产调度作业上下线
- 跨集群核心维表覆写

↓ 强制拦截

审批卡片

3 秒呈现改动与影响面
负责开发者显式放行

拒绝 | 批准放行

★ 权限铁律：Agent 的权限永远是发起人权限的子集——行级权限由编译器注入，不靠 Prompt 约束。

先紧后松 · 授权留痕

每一次失败，都要变成平台的语义资产

闭环迭代飞轮：轨迹采集 ➔ 归因分类 ➔ 分流修复 ➔ 评测门禁 ➔ 灰度上架

◆ 人在环 · 闭环迭代飞轮

没有评测门禁的迭代，不是进步是随机漫步

1 轨迹采集

复用 LLM 网关既有 Trace

Token · Tool · 全链路

失败轨迹

2 失败归因

语义 | 技能 | 权限 | 引擎 | 幻觉

按因分流

3 三分支精准修复

分支 1 · 语义缺失 → P17

回写 Apache Ossie 本体

补同义词 / 字段映射 · Owner 审核

分支 2 · 技能缺失 → P18

提炼 SOP，沉淀新 Skill

高频错误轨迹 → 服务端流程工具

沉淀

◆ 平台语义资产

30% ➔ 90%

标准评测集（200 条） · 代码准确率

下一轮 · 越跑越准

5 灰度上架

通过后进入团队共享库

下一个人不再踩同一个坑

通过

4 评测门禁

分层回归：检索 / 编译 / 端到端

不过门禁，不准上架

修复提交

分支 3 · 引擎差异 → P16

方言规则与回退补丁

补兼容模板 · 更新能力探测表

★ **每一次失败都沉淀成语义资产——Agent 不是缺表，是缺“这张表到底是什么意思”。**

失败即资产

数新智能CyberOS：一站式跨云、多中心、多模态 AI + DATA 智能操作系统

从数据底座、AI 能力到智能体，打通“算力—数据—AI—Agent—业务执行”的智能闭环

CyberAsset · 赛博资产平台：资产管理 | 资产共享

CyberAgent · 赛博智能体平台：Data Agent | Model Agent | Knowledge Agent

CyberOntology · 赛博本体平台：语义建模与设计 | 语义图谱与检索 | 仿真推演 | 服务开放

赛博数据平台 CyberData

集成 · 开发 · 运维 · 治理 · 分析 · 服务

数据资产	数据建模	数据开发	数据分析	数据服务

异构数据源管理 | 异构引擎管理

数据供给 →

← 模型服务

赛博智能平台 CyberAI

机器学习 · 大模型 · MaaS

机器学习训推	大模型训推	算力管理	智能体构建
可视化建模	模型仓库	算力调度	知识库管理
交互式建模	模型微调	算力虚拟化	语料切片
模型发布	模型发布	资源监控	智能体开发

赛博数智底座 CyberEngine

统一元数据服务 | 统一数据集成 | 统一任务调度 | 统一引擎网关服务

私有云	华为云	AWS	阿里云	Google Cloud	.....
数新智能 Spark, Flink, Ray, StarRocks	数新智能 Spark, Flink, Ray, StarRocks	数新智能 Spark, Flink, Ray, StarRocks	数新智能 Spark, Flink, Ray, StarRocks	数新智能 Spark, Flink, Ray, StarRocks	.....
开源自建 Hadoop, StarRocks, Doris	云厂商 MRS, GaussDB	云厂商 EMR, Redshift	云厂商 MaxCompute, Hologres, EMR	云厂商 Dataproc, BigQuery	.....
三方厂商 CDH, CDP, StarRocks, Doris, ElasticSearch	三方厂商 CDP, StarRocks, Doris, OceanBase, ElasticSearch	三方厂商 CDP, Databricks, Snowflake, Warebase, StarRocks, Doris	三方厂商 OceanBase, CDP, StarRocks, Doris	三方厂商 CDP, Databricks, Snowflake, OceanBase, StarRocks, Doris	.....

基于 Harness 框架的企业级 DataAgent 分层操作系统

立体架构分层：底层统一算力、中层显式语义与可控沙箱、顶层纵深防御拦截

系统全景蓝图

L1 用户交互与编排管控层 Interaction & Orchestration Deck

ACP 流式协议 (JSON-RPC 2.0 + SSE)

生产红线强卡点 (HITL)

Data Studio / Chat UI
全屏代码沉浸编辑 · Step-by-Step 方案图谱确认 · 侧边多轮对话交互

➜ Task Router 开发任务路由器
精准解析开发意图 · 动态 Skills 路由分发 · 规范与规则规约中心

4 段 Guardrail 拦截面 纵深防御
① Input | ② Tool | ③ SQL | ④ Output

⇅ **垂直可信调用总线 (Vertical Trust Bus)**: 透传开发者 Token 身份 · 继承 RBAC 权限 · 零提权通道

`1 Task = 1 Runtime = 1 Container Sandbox`

L2 Harness 智能体引擎与核心能力层 Harness Core & Sandboxes

隔离沙箱：Docker/K8s 容器完即销毁

★ 4 大数据开发 AI 核心模块池

1. **SQL 全生命周期**
生成/纠错/优化/Linter
2. **资产智能推荐**
指标反查/缺表诊断/ODS
3. **巡检诊断自愈**
StackTrace/根因推演
4. **质量规则推荐**
双跑对账/断言阈值生成

★ 受控执行外壳与 LLM 网关

- **Skills SOP (三层渐进披露)** 不变的进 Skill
- **search_tools 动态按需加载** 拒绝全量稀释
- **LLM 网关 & 可观测 Trace** Token 计量归因

★ 4 层动态进化记忆体

1. **会话上下文**: 随任务消亡
2. **个人偏好**: SQL纠错习惯
3. **组织规范**: 团队模板规约
4. **企业知识**: Apache Ossie

L3 CyberData 数据底座 Platform · Kernel · Multi-Cloud Engines

L2 的每一次工具调用都落在这里

能力探测 + 算子下推 + 降级回退

统一 Auth 鉴权
OAuth2/JWT 透传 · 行级权限 · Quota 管控

CyberData 平台能力	数据资产	数据建模	数据开发	数据分析	数据服务	异构源 / 引擎管理
CyberKernel 内核服务	统一元数据服务	统一数据集成	统一任务调度	统一引擎网关		
CyberEngine 多云引擎	私有云 · 开源自建	华为云 · MRS	亚马逊云 · EMR	阿里云 · MaxCompute	Google Cloud · BigQuery	

持久化解耦存储
State / Trace / Logs 异步落盘 · NAS / S3

★ 手机 OS 不是把 PC OS 缩小一圈——应用形态变了，底座操作系统就必须重写！

底层统一 · 中间可懂 · 上面可控

数新智能 × 华为云 案例分享 · 跨云多中心AI数据平台



迁移前

亚马逊云 + 阿里云
DataWorks / MaxCompute
EMR Serverless 多底座分散

迁移后

华为云 + AWS 一主二卫星
CyberData 统一纳管调度
新加坡主节点协同全球卫星节点

一主二卫星 · 统一纳管

新加坡华为云 MRS 主集群 + 俄罗斯华为云、印度 AWS 卫星集群，一套界面跨云跨地域调度、运维、查询

零学习成本 · 无感切换

页面布局、开发流程、运维操作全场景对齐主流平台逻辑，脚本编写、发布、补数操作无改动

自动化迁移 · 双跑校验

四大自动化迁移能力，85% 脚本免人工修改；新旧平台双轨并行 + 数据自动校验，割接任务不停

AI 赋能 · Data Agent

平台内置 Agent 覆盖代码生成、纠错、优化与日志诊断，结合 MaaS 大模型服务持续提效

某顶级奢侈品集团数据管理平台建设

跨云数据市场平台是一个统一的控制平面，旨在桥接阿里云和海外云平台，实现跨云边界之间的受治理、自助式数据共享。
该平台解决了客户当前数据生态系统中的关键摩擦点：碎片化的数据发现、手动的审批链、不透明的跨境数据移动以及缺乏带宽治理。

统一数据发现
MaxCompute/海外数据底座表元数据和授权信息接入和自动收集，通过配置化方式更新阿里云内授权给品牌的视图schema

低代码数据接入
通过AI/配置化方式接入海外数据底座，为海外云到阿里云的数据传输设置项目级配额，实现实时监控、告警以及自动限流/排队

治理访问与审批
工作流上下架、数据资产审批、阿里云内跨租户授权、跨云数据访问审批、企业访问管理集成等

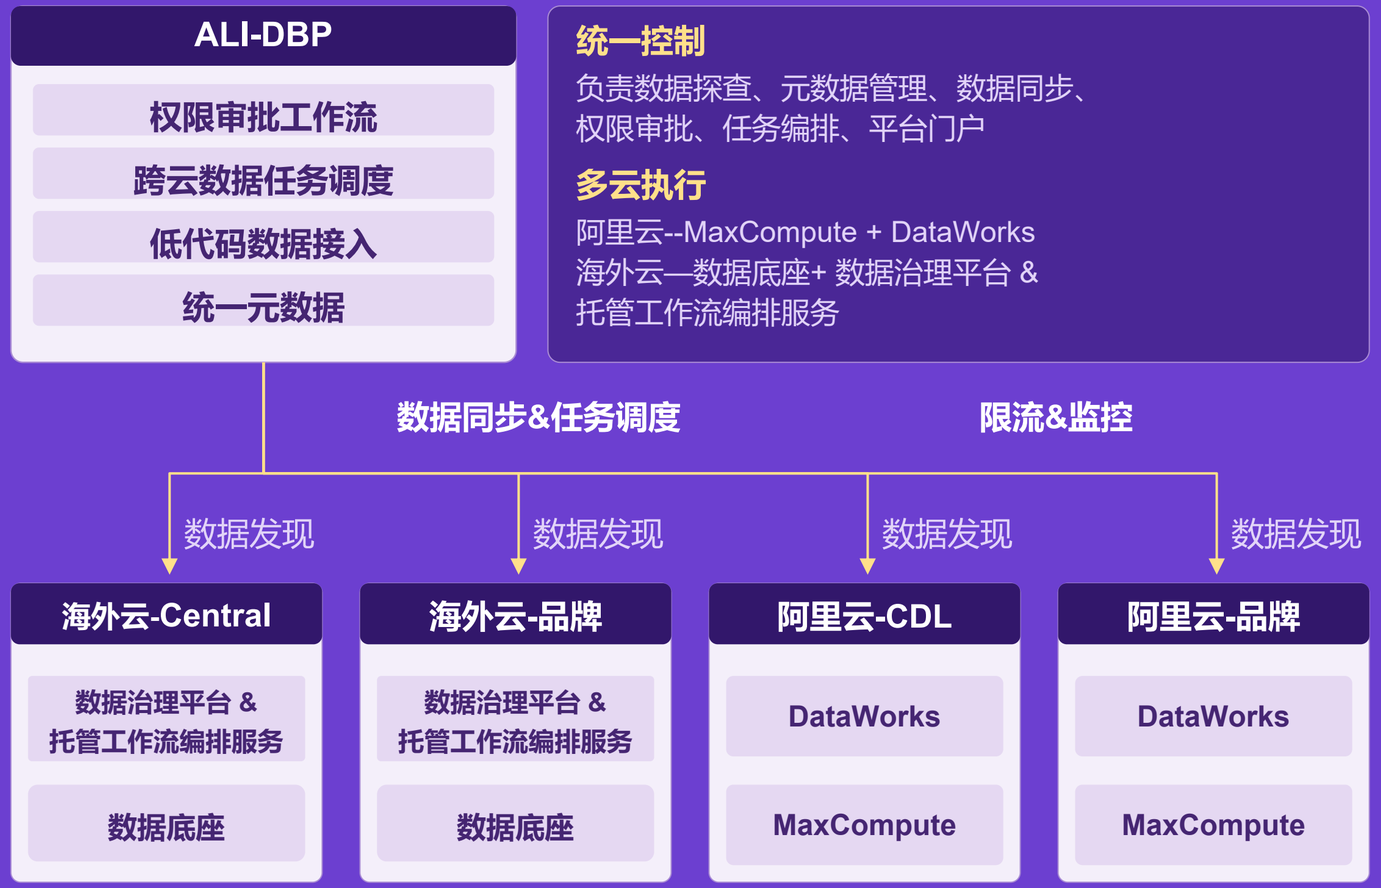
平台运营
编排跨云数据工作流，实现任务依赖管理和跨云调度协调，支持子空间/租户隔离和数据源/MC/项目注册

统一元数据管理&AI数据探查

数据集成&流控

数据安全&权限管理

统一的数据任务调度&门户



全球化Data+AI：安踏集团全球一站式数据智能平台

支持集团 DATA 战略

搭建集团统一数据平台，完成集团资产数据治理，沉淀集团高价值资产。

支持集团 AI 战略

在商品选品、库存管理、智能定价、营销推荐、物流配送、售后服务的六个核心环节部署AI工具，渗透率超一半。



六个环节每一个都有数，最后叠成端到端交付周期降低70%

某全球头部高端零售集团真实落地效果：严密证据链，拒绝空洞口号

生产环境真实统计

全链路六大环节量化成效证据链 (每一个数字都有出处)

① **探数环节**	双通道语义与元数据秒级反查	**约 70%** (定性评估)
② **建模环节**	维度推荐与口径自动复用	**1.2 → 3.5 次** (重复建表降 2/3)
③ **开发环节 ★**	语义查询确定性编译 + 沙箱自愈	**30% → 90%** (200条评测集)
④ **测试环节**	自动生成质量规则与双跑基线	**90% 覆盖率** (核心资产表)
⑤ **发布环节 ⚠**	血缘影响面分析 + 生产红线 HITL	**< 5%** (3个月质量统计)
⑥ **运维环节**	StackTrace 推演与自愈重跑	**+50%** (人工事后打标)

端到端交付效率

从业务提需求到报表正式上线投产

+233%

从 10 个工作日缩减至 3 个工作日内

统计口径说明：探数环节“约 70%”为定性评估。整体交付周期由 10 天缩短至 3 天，周期减少 70%，对应同等时间内交付效率提升约 233%。

这张图和刚才那张作业面图是同一张；六个环节每一个都有数，1.2 → 3.5 次意味着重复造轮减少了整整三分之二！

一条真实任务链，从提问到上线

中企出海 / 全球品牌入华真实场景：从自然语言到生产级发布全生命周期

脱敏任务实录

Step 1 · 意图与探数

> 用户输入：

“统计北美区近30天各渠道退货损耗，关联区域维表与SKU主数据”

> Agent 探数决策：

- 检索 Ossie 模型：命中 Metric[return_loss]
- 维表对齐：选用 dim_region_v2 (Match: 98%)
- 判定缺表：触发 ODS 接入 SOP 引导

★ 关键观察：第一步引用标准口径，不是凭空猜表

Step 2 · 方案图谱确认

《ETL 加工方案图谱》

HITL 卡点

目标表: dws_return_loss_di (按天分区)

Join 路径: store_sales ➔ store (多对一)

过滤规则: status NOT IN ('CANCELLED')

✓ 开发人员点击放行 ➔ 触发编译器

★ 架构收敛：口径在写代码前 100% 达成共识

Step 3 · 编译与发布

> 编译器生成产物：

SparkSQL 代码生成（带 Fan-out 保护）

> 发布前预检（Dry-run）：

- 语法自校验：Linter PASS
- 行权注入：region IN ('NA_WEST', 'NA_EAST')
- 影响面分析：覆盖下游 3 个报表

★ 结果：任务安全上线，总耗时从 3 天降至 30 分钟

★ 引用了显式口径，没有黑盒生成，人随时在驾驶位掌握方向盘！

透明 · 可控 · 可信

总结与前瞻

适用边界清单 · 三条落地方法论 · RSI 递归自我改进前沿探索

理性评估 · 拒绝捧杀

✓ 什么场景现在就能上 (SWEET SPOT)

- **口径相对清晰**：有基本的数据字典或资深业务分析师可做 Owner 核对
- **有存量 SQL 代码可挖**：运行超过 1 年的成熟数仓，可利用 CodeWiki 提取语义
- **企业内部研发与分析提效**：内部工程师人在环使用，容错空间充足
- **多引擎异构开发**：需要跨 Hive / Spark / Doris 抹平方言差异的场景

× 什么场景建议再等等 (DON'T TOUCH YET)

- **口径零沉淀的冷启动项目**：业务方自己都没想好定义，模型只会放大人性混乱
- **对外强实时端到端服务客户**：零人在环直接暴露给消费端用户（容错极低）
- **缺乏沙箱防护的生产裸跑**：没有容器隔离与 HITL 审批，随时面临删库风险
- **无评测门禁的盲目自迭代**：缺乏回归基准，自进化极易沦为自污染

三条实操方法论

1. **先补语义，再谈自动化**：口径未收敛前，不要妄想让大模型写代码。
2. **高频低风险切入**：从 SQL 补全、语法改错、质量规则推荐等单点逐渐泛化。
3. **没有评测门禁不开自动化**：不设基线回归的发布等于随机漫步。

未来规划与演进

RSI 递归改进的是能力集，而非模型权重

Agent 递归优化的是自己下次执行依赖的 Skill 脚本、语义图谱与调度策略。

☑ ① 评测集门禁

▣ ② 沙箱试运行

◉ ③ 人在环审批

“模型不是瓶颈，底座才是”

四条判据自查清单	多云可用　语义可懂　执行可控　效果可迭代
六个环节生产作业面	探数 → 建模 → 开发 → 测试 → 发布 → 运维

“底座越 Agent-Ready，上面的 Agent 自我改进的空间就越大。”

Q & A 交流环节

基于华为云的多云大数据管理服务解决方案

HUAWEI

行业数据应用

大数据应用场景

金融	制造	零售
金融基础库 金融监管	大屏&报表 客户洞察	经营分析 客户运营
实时数仓 多维分析	大数据分析 自助取数	库存管理 ……

API服务

API构建	API发布	API调用监控

数据治理服务

规范设计	数据资产	数据质量	数据集成	数据开发	迁移服务	数据安全	运维管理
数仓规划 数据标准 数仓建模 指标开发	元数据采集 数据检索 数据血缘 热度分析	数据监控 健康检查 质量报告	数据同步 数据转换	离线开发 在线开发 联邦查询 交互式分析	组件部署 数据对比 业务切换	数据分类分级 数据脱敏 数据权限管理 数据风险审计	任务运维 监控告警

伙伴工具

提供一站式工具 + 服务，打通数据到业务的最后一公里

CyberData　　CyberEngine

原厂工具

Migration4DWS　　Migration4MRS

华为云大数据服务

DWS　　MRS　　DataArts

华为PaaS

RDS　DMS　ROMA　SFS　OBS　DBSS　Gauss　…

华为云底座

HCS
计算、网络、存储

HC
计算、网络、存储

轻量化

THANKS

演讲嘉宾：**谈总** × **原攀峰**