从外购到自研
从向量RAG到Agentic语音智能体

企业对话机器人的完整演进之路

演讲嘉宾：武文斌

小赢科技 · 模型应用开发负责人

DACon

DataFun.

目录

CONTENT

目录

CONTENT

01 背景介绍

个人经历 · 三个场景的一道共同难题 · 外购三笔账

02 技术选型对比

五代技术路线 · 自主性光谱 · 四类方案对比与决策标准

03 方案落地细节

总体架构 · RAG · 工具调用 · 有边界自主 · 合规可靠性 · 记忆与评测

04 方案收益展示

一套底座四场景裁剪 · 四项核心指标 · ROI 与一线反馈

05 技术迭代亮点

MCP 标准化接入 · 语音全链路流式 · 最新优化指标 · 展望

01 背景介绍

个人经历 · 场景痛点 · 自研动因

关于我：一条五代演进主线，三大场景实战

武文斌

小赢科技 · 模型应用开发负责人

· 负责公司多款 AI 应用落地

· 覆盖客服、贷后、营销

· 聚焦垂直领域对话机器人研发

· 主导从外采到自研的完整演进

一条演进主线

从外采 BERT 题库起步，历经自研向量检索、RAG + 大模型、大模型 Agent，到今天的语音机器人——五代一步一个脚印，每一步都踩在真实业务上，而不是为了追技术时髦换代。

三大场景实战

客服 IM / IVR、营销外呼、贷后外呼全场景落地——既懂技术栈选型与工程落地，也懂一线业务约束与金融合规红线；方案必须能上岗，而不能只停在 Demo。

今天的分享

主导对话机器人从「外采 FAQ」到「自研大模型」再到「语音机器人」的完整演进；是真实工程实践、选型边界与踩坑总结，而不是纸上方案。

三个场景，一道共同难题：外购三笔账，一个自研决定

量大 · 重复 · 时效强 · 要合规——机器人最擅长解决的事

客服场景

· 海量高度重复咨询：还款、退款……
· 人工成本高，夜间与高峰无法实时响应
· 要求：秒级、7×24、常见问题自动闭环
· 痛点：排队长、口径不一、培训周期长
· 价值：IM+IVR 双通道承接，人工专注疑难

营销场景

· 外呼名单成千上万，人工逐一拨打效率低
· 大量时间耗在无人接听与低意向客户上
· 要求：批量触达、意向分级、高意向转人工
· 痛点：人效难放大、话术漂移、转化难追踪
· 价值：预测式外呼 + 意向识别，人机接力

贷后场景

· 还款提醒、逾期触达量大且急
· 话术必须严格合规，全程留痕可审计
· 要求：批量准时触达、话术白名单、可调取
· 痛点：口径失控风险高、人工难 7×24 覆盖
· 价值：标准话术引擎 + 全程录音归档

外购三笔账——这是我们启动自研的根本动因

成本曲线

· 按通/按分钟计费随量线性上涨
· 同等规模自研推理成本 ≈ 外购 30%
· 放量后结构性成本失控
· 投资回收期目标 ≤ 6 个月
· 外购适合验证，不适合主航道

流程控制权

· 黑盒平台难沉复杂 SOP 与合规话术
· 核心交易/账户/风控接口无法闭环
· 变更依赖厂商排期，以周计
· 自研后迭代周期压缩到天级
· 关键路径可预置、可灰度、可回滚

数据闭环权

· 会话与失败案例沉淀在厂商侧
· 无法回流为评测集与训练资产
· 护城河留在别人家里
· 自研后每一通失败都变成资产
· 评测门禁与飞轮真正转起来

02 技术选型对比

五代演进 · 自主性光谱 · 决策标准

技术路线：五代机器人演进

每一步都不是推翻重来——每代的短板正是下一代的出发点

第一代

外采 BERT 题库

BERT + FAQ 题库

✔ 上线快、范围内答得准

✘ 换说法就失败、逐条维护

自主性：几乎无

→ 要语义理解

第二代

自研向量检索

Embedding + ANN

✔ 理解语义、免逐条维护

✘ 回答生硬像搜索引擎

自主性：低

→ 要自然表达

第三代

RAG + 大模型

检索 + Rerank + LLM

✔ 回答自然、有据可查

✘ 依赖检索质量、只答不办

自主性：较低

→ 从回答到办事

第四代

大模型 Agent

Function Calling + MCP

✔ 会对话、更能办业务

✘ 成本与安全需管控

自主性：受控

→ 从打字到说话

第五代

语音机器人

流式 ASR+LLM+TTS

✔ 能听会说、体验自然

✘ 实时性要求极高

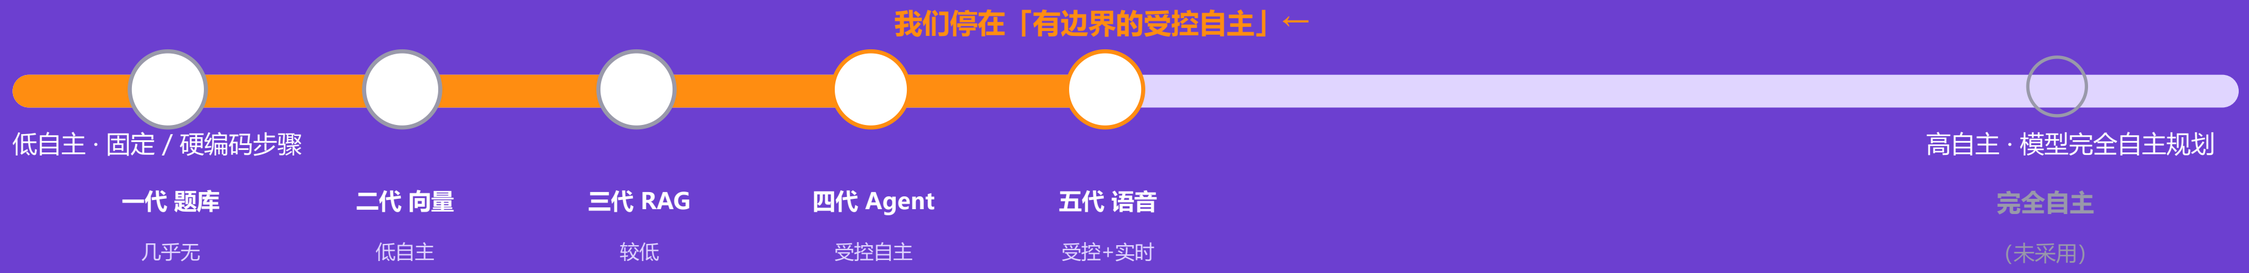
自主性：受控+实时

当前：全链路流式攻坚

关键跃迁： ②→③ 引入大模型（检索匹配 → 理解+生成）　③→④ 引入工具调用（回答问题 → 办业务）　④→⑤ 全链路流式（文字 → 语音）

一条主线：自主性光谱

Agentic 不是“是/否”，而是一条自主性光谱



第三代 · RAG「回答问题」

· 流程：用户提问 → 向量检索知识库 → 大模型生成带出处的回答 → 输出答案 · 结束

· 特征：流程预置、单次问答、无状态

· 大模型角色：只负责「表达」，不会调用业务系统

· 边界：无法跨轮履约，也不会主动办业务

· 适用：咨询类、知识问答、制度解释

第四代 · Agent「办业务」

· 流程：理解意图·规划任务 → Tools 调用业务系统 → 拿到结果·继续对话 → 把事办完

· 特征：感知 → 规划 → 执行循环

· 大模型角色：成为「决策脑」，自主选择工具与参数

· 跃迁：从“嘴”到“脑”，但仍是受控自主

· 适用：退款、查订、改资等可闭环办理

自主性并非越高越好——我们最终停在「有边界的自主」，离完全自主仍有距离

四类方案横向对比 + 外购 vs 自研决策标准

没有银弹：RAG 打底 + Agent 增强，按业务阶段渐进演进

对比维度	规则/FAQ	语义检索	RAG	纯大模型
回答准确率	题库内准、泛化差	中等	高、有据可查	高但不稳定
维护成本	极高、逐条维护	低	中（维护知识库）	低
知识时效性	差	好	好	差（训练截止）
幻觉风险	无	低	低、带出处	高
可解释/可审计	强	中	强（引用溯源）	弱

我们的选型：RAG 打底 + Agent 增强

成本：每代投入匹配当时业务收益；安全：能力越大管控越要跟上；时效：先解决有无，再升级体验。

什么时候该启动自研?

命中两条以上：

- **业务差异化**
  流程/话术构成竞争壁垒
- **调用规模化**
  调用费随量线性上涨
- **深系统耦合**
  需直连交易/账户/风控
- **强合规审计**
  敏感动作须可干预可回溯

自研节奏：知识库 → 流程 → 决策 → 交互，每步独立验证

03 方案落地细节

总体架构 · RAG · 工具调用 · 自主性边界 · 合规 · 记忆与评测

Agentic 总体架构：四层 + 一条可观测侧栏

自上而下：多渠道统一接入 → 大脑感知·规划·执行 → 标准化能力供给 → 业务系统安全调用

接入层	客服 IM SDK	IVR 电话网关	外呼平台	ASR / TTS 引擎	会话管理·路由	可观测
Agent 编排层	意图识别	任务规划 Planner	工具选择与调用	多轮记忆 Memory	反思/自检	兜底·转人工
能力层	RAG 知识库	Tools 标准封装	MCP Client/Server	话术与流程引擎	权限与合规策略	追踪
业务与数据层	订单系统	退款 / 支付	CRM 客户	外呼名单·风控	审计日志·留痕	错误分析
						幻觉抽检
						调用准确率
						时延成本

可观测侧栏贯穿四层，支撑 Build → Analyze 迭代闭环：没有 Trace 的 Agent 无法排障，也无法证明改动不回退。

能力底座：RAG 不是“接个向量库”

切分、混合检索、重排、强制引用、评估门禁——五件事决定知识问答的上限

Query 理解
改写 · 纠错 · 指代消解

→

混合召回
向量 + BM25 + 元数据过滤

→

Rerank 精排
Cross-Encoder + 业务重排

→

Grounded 生成
强制引用 · 无据拒答

切分：按“问答原子”

· 制度条款不按固定 token 切断
· 保住完整语义单元，宁可多一块不可切半句
· 切分粒度直接决定检索质量上限
· 配套：标题层级 / 生效时间随块入库

元数据硬过滤

· 产品线 · 渠道 · 生效时间 · 合规标签
· 先过滤再召回，杜绝过期知识
· 杜绝跨产品污染与串话术
· 过滤规则与知识版本一并可审计

引用与拒答

· 回答必须挂引用片段
· 召回不足时拒答或转人工
· 原则：宁可少说，不可乱说
· 强制引用是压制幻觉的主开关

评估闭环： 离线评测集（真实 badcase + 对抗样本）持续度量 召回率 / 引用率 / 幻觉率；

切分策略、Embedding 模型、Prompt 每次变更，先过评测门禁再上线——改动必须可证明不回退。

上线后继续抽检引用挂载率与拒答正确率，badcase 回流评测集，形成飞轮。

工具调用：让 Agent 从「会说」到「会做」

由大模型决定“要不要调、调哪个、传什么参数”；执行始终在受控运行时内

① 工具化封装 —— 业务接口 → 标准 Tool Schema

```
name:        query_order
description: 按用户ID查询近90天订单，用于退款/售后前置
parameters:
  user_id:  string  必填·会话注入·模型不可改
  status:   enum    [全部|待付款|已完成|退款中]
  limit:    integer 默认5, 最大20
returns:    订单列表 JSON（金额/状态/可退标识）
risk_level: read-only  ← 风险分级标签
```

工具即“说明书”：封装前参数靠猜、返回非结构化 → 调错率高；严格 Schema 后，模型选得准，工具调错率 18% → 4%。

② 调用回路 —— 决策交给模型 · 执行保持受控

1. 大模型判断需要外部能力
2. 生成结构化调用（函数名 + 参数 JSON）
3. 受控运行时执行工具 / 业务接口
4. 结果回传大模型
5. 整合结果 · 继续对话或回复

“感知 → 规划 → 调用 → 观察”在一次对话中循环多次，直到把事办完——自主而不越界。

我们的选择：有边界的自主 Agent

自主性并非越高越好——强合规、强时效领域，半自主往往才是最佳平衡点

领域限制

· 金融客服 / 贷后是强专业、强合规领域，容错率低
· 敏感动作（退款、改资料、承诺还款）必须可干预、可回溯
· 不能放任全自主——一次幻觉承诺可能直接变成客诉与合规风险
· 做法：工具白名单默认 deny，敏感动作二次确认 + 全程留痕
· 边界写进 Schema 与策略，而不是写进口号

时效限制

· 语音场景要求秒级响应，用户对“卡住”极度敏感
· 过长的自主规划链路会推高端到端时延
· 关键路径（FAQ、身份核验、高频办理）需预置 / 固化
· 把自主用在刀刃上：复杂多步任务才走 Planner
· 时延预算先于“看起来更智能”

解决问题

以“办成业务”为目标

能力服务于真实场景

不以 demo 效果为导向

自主

既定边界内自主规划

自主选择工具与参数

但执行始终受控

可控

关键步骤可干预可回退

人在环路兜底

失败可降级可转人工

合规

权限分级 · 敏感确认

全程留痕可审计

监管可按会话调取

实践体会：在强合规、强时效领域，「有边界的自主」比「完全自主」更快落地、也更可信。

安全合规 · 可靠性 · 成本：能干但不乱来，失败可兜底

三件套：权限分级 + 敏感确认 + 全程留痕；有限重试 + 转人工；路由 + 缓存 + 瘦身

安全与合规管控

· 工具调用 → 权限分级校验

按场景 / 角色 / 工具风险级

· 敏感操作（退款 / 改资料）

→ 用户二次确认后才执行

· 全程留痕可审计

监管可按会话 ID 直接调取

· 示例：「查订单 → 退款」

两次调用、一次确认、全程可追溯

· 工具白名单默认 deny

资金 / 隐私类动作逐案开通

可靠性

· 执行失败 → 有限重试

≤ 2 次 · 指数退避

· 仍失败 → 兜底话术

记录异常，不中断对话

· 再不行 → 转人工接力

携带完整上下文，用户不用再说一遍

· 原则：任何一环失败

用户感知的是「稳妥」

不是「报错」或「卡住」

· Trace 贯穿全程

便于复盘与回归门禁

成本

· 分级模型路由

FAQ / 改写 / 分类走小模型

复杂规划才用强模型

· 热点预缓存

还款日、活动话术、高频投诉点

命中即答，时延与成本双降

· 上下文瘦身

记忆只保留必要上下文

关键路径并行化

· 原则

时延优先于 token 成本

能缓存就不推模型

两条暗线：分层记忆体系 × 评测与数据飞轮

左边解决“记什么、记多久”；右边解决“每次变更怎么证明不回退”

分层记忆（按 TTL 管理，不堆 Prompt）

- **Working** 当前轮意图与槽位 TTL：秒~分钟
- **Episodic** 本通会话事件轨迹 TTL：会话级
- **Semantic** 用户长期画像与偏好 TTL：天~月
- **Procedural** SOP / Skill / 合规模板 TTL：版本化

写入只存结论、敏感字段脱敏后入记忆；Planner 按需读取，转人工时打包移交全量上下文，用户不用再说一遍。

评测闭环与数据飞轮

- **线上埋点** 全链路 Trace，badcase 自动归集
- **评测集建设** 真实 badcase + 对抗样本 + 场景回放
- **变更门禁** Prompt/SOP/模型变更先过回归再上线
- **迭代生效** 知识库、话术、路由策略持续更新 ↻

度量：召回率 / 引用率 / 幻觉率 / 调用准确率 / 一次办结率；核心指标：人机对话完成率。自研让每一通失败会话都变成资产。

04 方案收益展示

四场景上岗 · 四项核心指标 · ROI 与一线反馈

同一套底座，四大场景已经上岗

只裁剪四个维度，不重建系统 —— 新场景接入从“开新项目”变为“配新策略” —— 同步支持海外业务场景

裁剪维度	客服 IM	客服 IVR / 语音	营销外呼	贷后外呼
意图路由	咨询+办业务混合 多轮澄清	短句意图 快速定位确认	意向分级 高 / 中 / 低	还款意愿识别 异议处理
工具组合	查订单·退款 权益·工单	查询类为主 +少量办理	名单·产品信息 转人工	账单·还款计划 承诺记录
合规策略	敏感操作 二次确认	身份核验前置	频次限制 免打扰	话术白名单 全程录音留痕
交互链路	文本流式输出	ASR+LLM+TTS 全链路流式·打断	外呼+意向识别 +转接	外呼+合规 话术引擎

已上岗： 客服 IM（四代文本链路）· 客服 IVR（五代语音链路）· 客服外呼（意向识别+转人工）· 贷后外呼（合规管控链路）

四项核心数据：解决率 · 响应 · 成本 · 质量

每项指标标注统计口径 · 近 30 天线上全量

① 常见问题自动解决率

72%

口径 无人工介入闭环的常见咨询占比

方法 近 30 天 IM + IVR 全量会话

对照 上线前纯人工基线

意义

最直观的「替代人工」效果

夜间与高峰不再排长队

人工可专注疑难与安抚

② 平均首次响应时长

1.2 秒

口径 用户发起到机器人首响（P50）

方法 近 30 天全量采样

意义

用户体感最强的体验指标

从分钟级压缩到秒级

高峰也不再“等不起”

③ 综合成本下降幅度

70%

口径 单工单综合成本（含培训/管理）

对照 纯人工基线

意义

管理层最关心的 ROI

结构性成本出清

外购调用费退出主路径

自研放量后进入正循环

④ 幻觉率 / 客诉率下降

-62% / -38%

口径 答案抽检错误率 · 万会话客诉数

对照 强制引用改造前后

意义

证明 AI 不只省钱，还保质

引用溯源压制幻觉

合规与口碑同步改善

投入产出：ROI 总结与一线反馈

给管理者看 ROI，给同行看一线变化

更多量化收益

· 夜间 / 高峰承接量

10 万会话 / 日

· 机器人独立完成会话占比

72%

· 人工转接率

下降 25%

· 单会话平均

4.2 轮 / 31 秒

· 覆盖业务场景

4 个场景

投入产出比（ROI）

· 综合投入产出比

≈ 1 : 3.5

· 人力成本下降

70%

· 单人日均处理会话

提升 3.2 倍

· 投资回收期

约 8 个月

· 结论

自研在放量后进入正循环

外购调用费结构性出清

一线反馈

· 「机器人已成为一线团队的标配同事。」

· 人工从重复应答

转向疑难问题处理

与更有温度的服务

· 新场景接入

从「开新项目」

变为「配新策略」

· 经验可复制

同一底座裁剪即可上线

· 管理侧

指标可解释、可复盘

05 技术迭代亮点

MCP 标准化接入 · 语音全链路流式 · 最新优化指标 · 展望

亮点① 第四代 Agent：MCP 标准化接入

MCP（模型上下文协议）是工具的统一接入标准——工具的“万能插座”



统一协议：工具发现 · 调用 · 鉴权 · 结果回传全部标准化，新系统即插即用

接入成本：N × M → N + M

· 从“每个模型 × 每个系统”逐个定制，降为“模型 + 系统”标准集成

· 单系统接入工时：15 人日 → 3 人日

· 工具发现 · 调用 · 鉴权 · 结果回传全部标准化，新系统即插即用

· 不再为每个大模型重写适配层，也不再为每个系统重写胶水代码

网络效应：工具越多，标准越值钱

· 一次封装、多模型多场景复用；生态工具可直接接入，边际成本递减

· 已接入 MCP 工具 / 系统数：12 个

· 工具越多，标准越值钱——这是平台化的关键杠杆

· 新场景上线：配策略 + 挂工具即可，不必开新项目

亮点② 第五代语音机器人：三段接力 + 自然打断

全链路流式 · barge-in 即停即听；语音只是新外壳，大脑复用前四代

麦克风收音
RTP 音频流

→

流式 ASR
语音 → 文字

→

LLM 对话大脑
复用前四代能力

→

流式 TTS
文字 → 人声

→

线路播放
边合成边播

barge-in 自然打断： 用户一插话即停 TTS、取消当前生成、清空待播队列、切回聆听

方言 / 口音
领域语料微调
按区域灰度上线

环境噪声
前端降噪
+ 回声消除

业务专有词
热词增强
金额双通道校验

端点误判
VAD 阈值调优
语义完整性判停

链路放大效应：ASR 错一个字 → 意图偏 → 检索偏 → 话术偏。识别层 ROI 最高，优先投入。

关键认知：语音机器人 = 第四代 Agent 大脑 + 全链路流式外壳，能力复用、不做重复建设。

语音全链路时序图：流式处理与自然打断

五角色时序：用户 / 语音网关·VAD / 流式ASR / LLM Agent / 流式TTS



时延预算 = ASR 尾点 + NLU + 话术润色 + TTS 首包 —— 全链路流式，端到端首响压到秒级

亮点③ 最新优化指标：从问答到办事、从打字到说话

上方为语音链路时延预算瀑布（NLU / 话术润色分拆），下方为近期关键指标

语音链路时延预算（LLM 阶段拆为 NLU + 话术润色）



链路合计约 1120ms；线上端到端首响 P50 ≈ 1.2 秒（含电话网络与抖动缓冲）

工具调用准确率

93% ↑ 8 pct

“办事”维度：调用更准、返工更少

工具 Schema 改造后的直接收益

调错率从 15% 压到 7%

新系统接入不再重写适配层

语音链路首响时延

1.2 秒 ↓ 35%

“说话”维度：首响压到秒级

NLU + 话术润色分阶段流式

用户体感从“卡”变“顺”

全链路流式 + 预缓存生效

多轮对话成功率

85% ↑ 12 pct

复杂任务一次办成比例提升

SOP 约束 + 记忆分层落地

显著降低中途失败

转人工上下文完整移交

打断响应 / 鲁棒性

300 ms 方言可用

嘈杂口音场景稳定表现

VAD 调优 + 热词增强

识别层优先投入

链路放大前先治根因

未来展望：更像人 · 更自然 · 更聪明

拟人化

情感 TTS · 音色定制 · 语气语速自适应

全双工

随时打断、边听边想边说；语音+数字人多模态

Agent RL

以任务成功率/满意度为奖励，优化工具调用与多轮规划

多 Agent 协作

规划-执行-审核分工，自我反思纠错，稳步扩大自主范围

企业对话机器人的竞争，不在“会不会调用大模型”，而在能否把检索、流程、记忆、校验与语音时延，做成一套可治理的系统能力。

THANKS

演讲嘉宾：武文斌

小赢科技 · 模型应用开发负责人