DACon *** 主论坛

# 模型 + 全栈工程
# 才是护城河

## 从医疗 Agent 到全行业启示

胡浩源 京东健康 AI 副总裁

对生命的敬畏，必须写进系统的完成条件。

# 胡浩源 Leo

京东健康 AI 副总裁

产业经历

*****—*** 蚂蚁集团**

金融 AI 总负责人，负责 Finix 金融大模型与蚂小财 AI 智能体

*****—*** 菜鸟网络**

AI 负责人，阿里巴巴资深算法专家 / 总监

*****—*** 淘宝 / 天猫**

高级算法专家

******* 篇正式发表论文

ICML、NeurIPS、KDD、ACL

Management Science 等

**SIGKDD 领域主席**

Applied Data Science Track

曾任浙江大学客座研究员、上海财经大学硕士生导师、浙江工业大学客座教授

# 榜单第一，只是起点

京医千询 *** 专业能力评测

| *** | *** | *** | *** | ***% |
| --- | --- | --- | --- | --- |
| 十科正高职称考试<br>同时同地，现场考试 | HealthBench<br>Hard 得分 | HealthBench<br>Total 得分 | MedBench v***<br>榜单得分 | 自建三维影像<br>评测准确率 |

**真正的考题，是把一项医疗任务完整交付。**

# 模型会答，系统要把事办成

以病例资料整理为医生可接手的会诊材料为例

| 环节 | 必须核验的对象 | 典型失败 |
| --- | --- | --- |
| **证据** | 原始来源、版本、患者适用条件 | 把未知病情当作已确认 |
| **执行** | 动作参数与工具的真实返回 | 工具失败后仍声称完成 |
| **产物** | 当前文件、图表和正文的一致性 | 分析已更新，正文引用旧数字 |
| **接手** | 依据、未决项和医生的修改记录 | 交出结论，却丢失判断上下文 |

**模型的领先，必须兑现为交付的领先。**

# 模型没换，交付提升 *** 分

内部对照：同一 Qwen***-***B，*** 道科研任务，固定 GPT-*** Judge

***

基础 MedWork

***

补充 Read / Write / Edit

| 出现该类错误的任务数 | 补充前 | 补充后 |
| --- | --- | --- |
| 修改未核对 / 前后不一致 | *** | *** |
| 统计严重误读 | *** | *** |
| 遗漏关键数字 | *** | *** |

**长程任务的累积风险**

简化算例：每步独立成功率 ***%，连续 *** 步且无恢复机制

$***^{***} \approx ***\%$

# 为完整交付，重构技术栈

| 层次 | 系统 | 任务中的职责 |
| --- | --- | --- |
| **交付层** | MedWork | 接收目标，支持医生核对和采纳 |
| **执行层** | Harness + Infra | 管理状态，核验执行并恢复失败 |
| **模型层** | 京医千询 / MedCode | 专业理解、任务规划与动作生成 |
| **知识层** | MedWiki | 组织证据，保留版本和适用条件 |

**医学评测贯穿各层，失败反馈分别进入模型训练与系统改进。**

# 评测，是模型与 Harness 进化的北极星

先定义什么叫做对，才知道算力该投向哪里。 京东健康 × 上海人工智能实验室

| 评测 | 检查什么 | 数据与范围 |
| --- | --- | --- |
| MedEviBench | 证据溯源、安全质控与逻辑表达 | MedBench v*** 专项赛道 |
| MedRealMM | 真实多模态问诊 | *** 条样本、*** 科室、*** 个模型 |
| 三维影像评测 | 完整 CT / MRI 的证据与判断 | 真实放射报告与三维影像 |

**医生逐例修订并批准 Rubric，自动 Judge 按标准评价。**

临床共建：广附一呼吸团队，*** 余选择题与 *** 道 Rubric 问答；

北肿沈琳团队，*** 道病例决策题；重附一周新雨团队，*** 项临床导向系统评价。

# 把指南写成程序，把条件变成检查

## 病例事实与医学规则分别表示

*** 抽取类型化事实，保留未知项

*** 核对适用条件，绑定指南原文

*** 执行规则与动作，读取真实返回

*** 输出限定动作与依据，交医生复核

规则可以测试和回归。

事实抽取与规则编写仍可能出错。

联合 TNM 静态评测

| 同一 Qwen***-***B | 结果 |
| --- | --- |
| 无指南 | ***% |
| 提示词指南 | ***% |
| MEDCODE | ***% |

LungCURE-EN 原发布 *** 病例。

T、N、M 全对才计分。

# 一套专业模型，支撑多个业务

**MedCode** 专业理解、任务规划与最终验收

**med-jev** 高频、局部操作；各业务方法由 Skill 组织

能力筛选与消融 / 训练范围收敛 / 精准蒸馏 / RL 能力与时延对齐 / 灰度验证

## *** 至 ***

主模型调用次数减少 ***%

*** 个动作场景，两种设置各运行 *** 次；

另有决策模型请求。

## +***

分，业务评分

Base ***；Teacher ***；Student ***

通用能力与 Base 相差在 ±***% 以内。

蒸馏数据 ***–***K；RL 约 ***K；问答 tp*** ≤ *** 秒。

# 循证问答，必须走到证据闭环

## MedWiki 定义知识与条件

对象：疾病、分期、人群、干预、证据

关系：支持、适用、排除、引用

条目：原文、版本、证据等级与位置

状态：已确认、未知、不适用

## Agentic Search 沿缺口查证

语义匹配结合医学实体与条件约束

追查支持、反驳及版本依赖

按证据覆盖与未决冲突分配搜索深度

缺证据继续查，缺事实请人补充

**用 Agentic Search，把相关性检索推进到证据闭环。**

# Harness：把算力变成做事能力

| | |
|---|---|
| 持续状态 | 保留目标、进度、未决项与当前产物 |
| 统一工具契约 | 训练、推理和评测复用环境，核对真实返回 |
| 模型与上下文 | Model Mesh 统一供给，按任务装配知识、记忆与状态 |
| 高频决策下沉 | 主模型聚焦规划和验收，局部操作交由快速模型 |

*** 项技能

*** 个线上业务

*** ×

*** 条分类任务单次对照提速

# *** 万 Token，为一份可验收的成果

选题与搜索 / 证据与分析 / 图表与文件 / 渲染与布局 / 成稿与修订

## 方法配置

*** 个定制化文件

*** 个预设 Python 脚本

*** 篇子任务说明文档

## 交付门控

内容完整，数据与图表相互对应

路径可用，交付文件真实生成

编译成功，渲染与布局检查通过

**每一项都通过，任务才算完成。**

**长程执行规模：***+ 步自主循环　***+ 步工具调用　***K 上下文**

# 下一次进步，不必等下一轮训练

| 对象 | 怎样改变 | 验收对象 |
| --- | --- | --- |
| 模型参数 $\theta$ | SFT、RL 与教师分布监督 | 模型与通用能力回归 |
| 本次状态 $x$ | 按真实返回更新进度与产物 | 当前任务的一致性与完成条件 |
| 外部方法 $S$ | 更新 Skill、规则与工具 | 候选版本回归与专业验收 |

**让每一次真实失败，推动下一次系统改进。**

专家定位问题，人机共同分流；改进 Rubric、Skill 或 Harness，验收后复用。

# 专家怎样取证，模型就怎样学




***+

医生操作与判断轨迹

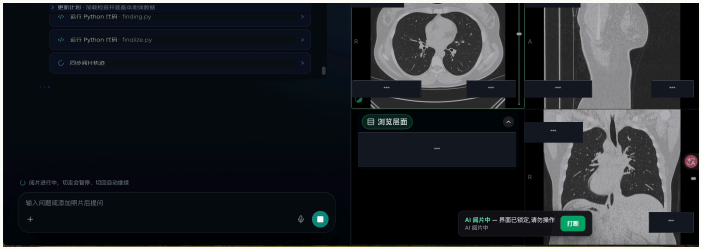
选择序列，三视图观察
分割 / ROI，调窗

提交答案，审阅并修正轨迹

工具：`pick image`
输入：`series_index`

返回：模态、期相与形状

# 把接管权交给医生，把过程留在系统




## 交接必须保留

### 证据

出处、版本与适用条件

### 过程

实际操作与真实返回

### 未决项

缺失资料与尚未确认的前提

# 把榜单领先，变成医院里的交付

### 病历书写

*****%**

病历无修改采纳比例

**<***%**

病历生成幻觉率

广医一呼吸项目阶段观察；
医生保留最终核对与采纳权。

### 疑难病例会诊

*****%**

MedWork MDT 一致率

| | |
|---|---|
| GPT***-sol | ***% |
| Claude***-opus | ***% |
| Kimi-K*** | ***% |
| DeepSeekV***-pro | ***% |

较 GPT***-sol 高 *** 个百分点。

### 论文完成质量

*******

MedWork Research 评分

*****_*****

同主题已发表论文评分区间

生成论文的完成质量评分，
已进入已发表论文的参考区间。

# 模型可以买，验收过的方法买不到

## 算力既增强模型，也改进整个执行系统。

| | |
|---|---|
| **观察** | 记录真实任务轨迹、工具返回与专家反馈 |
| **改进** | 训练模型，或修改 Prompt、Skill、规则与工具 |
| **验收** | 在同类任务比较版本，完成业务回归与必要专业人审 |
| **复用** | 只让通过验收的方法进入下一次任务 |

**模型可以采购，经过业务验收的方法需要持续积累。**

全行业启示

# 对生命的敬畏，
# 必须写进系统的完成条件。

业务对象和适用条件怎样表示？
动作与真实返回怎样接起来？
谁来接手，按什么标准验收？

**把能力交给医生，把更多时间留给患者。**

下一讲　刘斌 · 百度　《本体连接真实世界：让 Agent 走进企业核心工作流》