敦煌网：从"选最强模型"到"做最优组合”
——企业模型路由与治理实践

选型、路由、成本与治理

演讲嘉宾：窦东员

EXECUTIVE TAKEAWAY

企业 AI 的竞争力，来自可控的模型组合

把“模型选择”从一次采购决策，升级为持续优化的系统能力。

- 能力画像：用任务维度而非品牌做比较
- 智能路由：在任务边界择模，单轮次执行不换模
- 统一治理:让成本、风险与体验进入同一闭环

管理应关注的，不是：“谁最强”，
而是：是否能在质量、成本、速度、可用性与合规之间，动态取得最优平衡。

DACon
DataFun.

Agenda

01 —— **问题挑战** 为什么单模型策略难以持续

02 —— **多模型组合策略** 如何选型、路由与保持一致性

03 —— **成本优化 ROI** 如何建立投入与价值的共同语言

04 —— **统一治理** 如何让系统可观测、可控、可演进

05 —— **案例与行动** 如何从示意走向四阶段落地

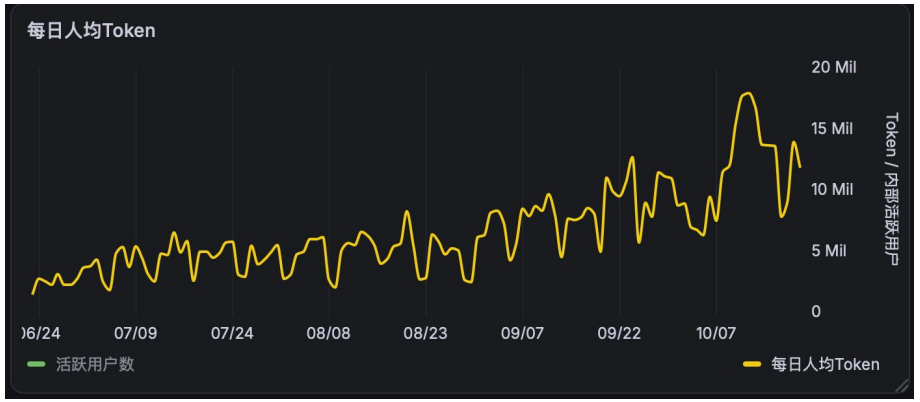
智能路由上线前后：用量持续上涨，整体账单降至约 60%

8月20日左右上线智能路由后，每百万 Token 花费明显下降；在使用人数、调用次数持续增加的同时，总账单降至之前的约 60%

A · 业务用量趋势

使用人数、调用次数与人均用量上涨

活跃人数与调用次数持续增长，每日人均 Token 从 ~2M 攀升至峰值近 18M



8月20日前：人均 2M–6M / 日

8月20日后：持续涨至 12M–18M

B · 单位成本趋势

8月20日上线后单价明显下降

8月20日左右上线智能路由，每百万 Token 花费由 $1.2+ 降至 ~$0.3



8月20日前：$1.2–$2.3 / 百万

8月20日后：明显降至 ~$0.3 / 百万

结论

在使用人数、调用次数增加的同时，整体账单反而下降至之前的约 60%。

8月20日左右智能路由上线 → 每百万 Token 花费显著下降，在支撑业务规模与人均用量增长的同时实现总成本缩减。

统一大模型网关与模型调度

生产应用

DHwork

DHcoder

ChatBI

飞天
大模型

跨境电商领域
多模态模型

AI Gateway（统一接入/鉴权/计费/审计）

文本模型

DeepSeek
GLM
……

多模态

通用视觉模型
……

视频模型

Seedance
……

声音模型

Minimax
Doubao
……

IDC 私有部署

云环境私有部署

公共商用模型接口



触达与协同入口

XX协同办公

Agent 市场

Skill 市场

MCP 市场

DACon

DataFun.

单模型策略，难以同时满足五个目标

模型能力差异扩大后，“一把尺子”会把局部最优放大为系统性约束

1 **质量**
高难推理 / 代码 / 多模态

2 **成本**
按任务价值匹配投入

3 **速度**
交互体验与吞吐

4 **可用性**
故障与区域波动

5 **合规**
数据与安全边界

核心问题

不是寻找唯一“最强模型”，
而是根据性价比，为不同任务边界选择、路由恰当模型，并让选择可解释、可追踪、可治理。

DACon
DataFun.

能力矩阵让“适配”成为可比较的管理语言

按任务能力、运行约束与风险边界评价模型池；分值为内部评估维度示意，非外部排名

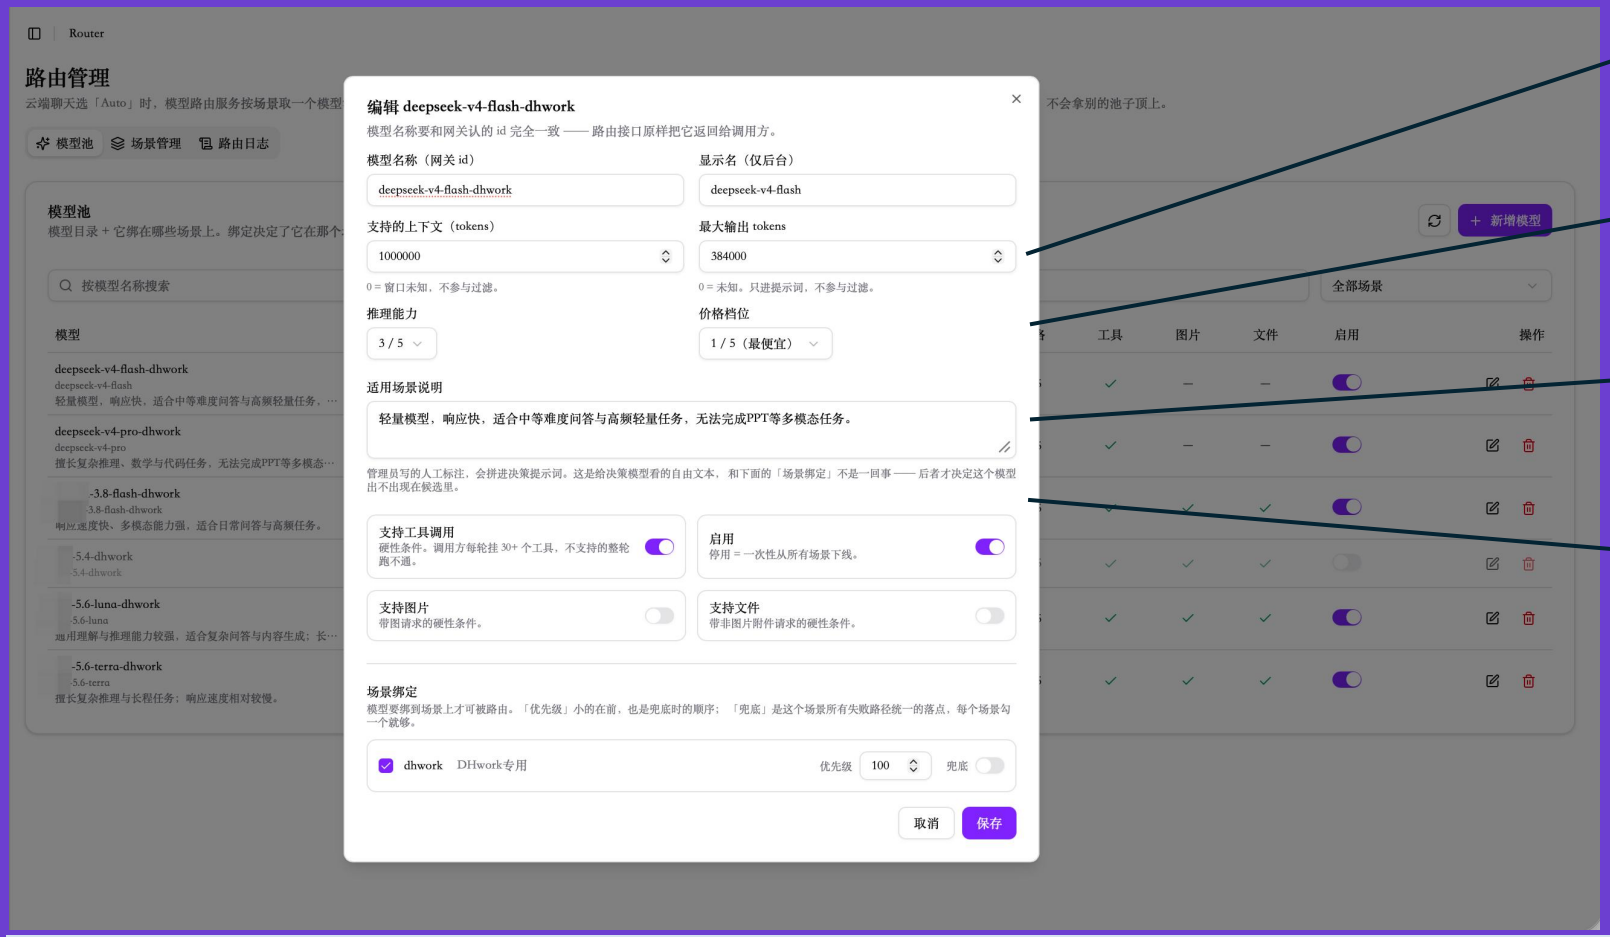
场景	模型 A 深度推理	模型 B 通用效率	模型 C 多模态	模型 D 低成本
上下文 / 知识问答	4 5	4 4	4 5	4 5
复杂推理	5 5	5 4	5 5	5 5
代码 / 工具调用	5 5	5 5	5 5	5 5
多模态理解	4 4	4 1	4 4	4 4
翻译 / 结构化输出	4 4	4 4	4 4	5 4
……	4 4	4 4	4 4	5 1

模型能力画像 = 任务选择的共同底座

DACon DataFun.

能力矩阵让“适配”成为可比较的管理语言

按照任务需求，结合模型能力、成本等特性，选择最优模型方案

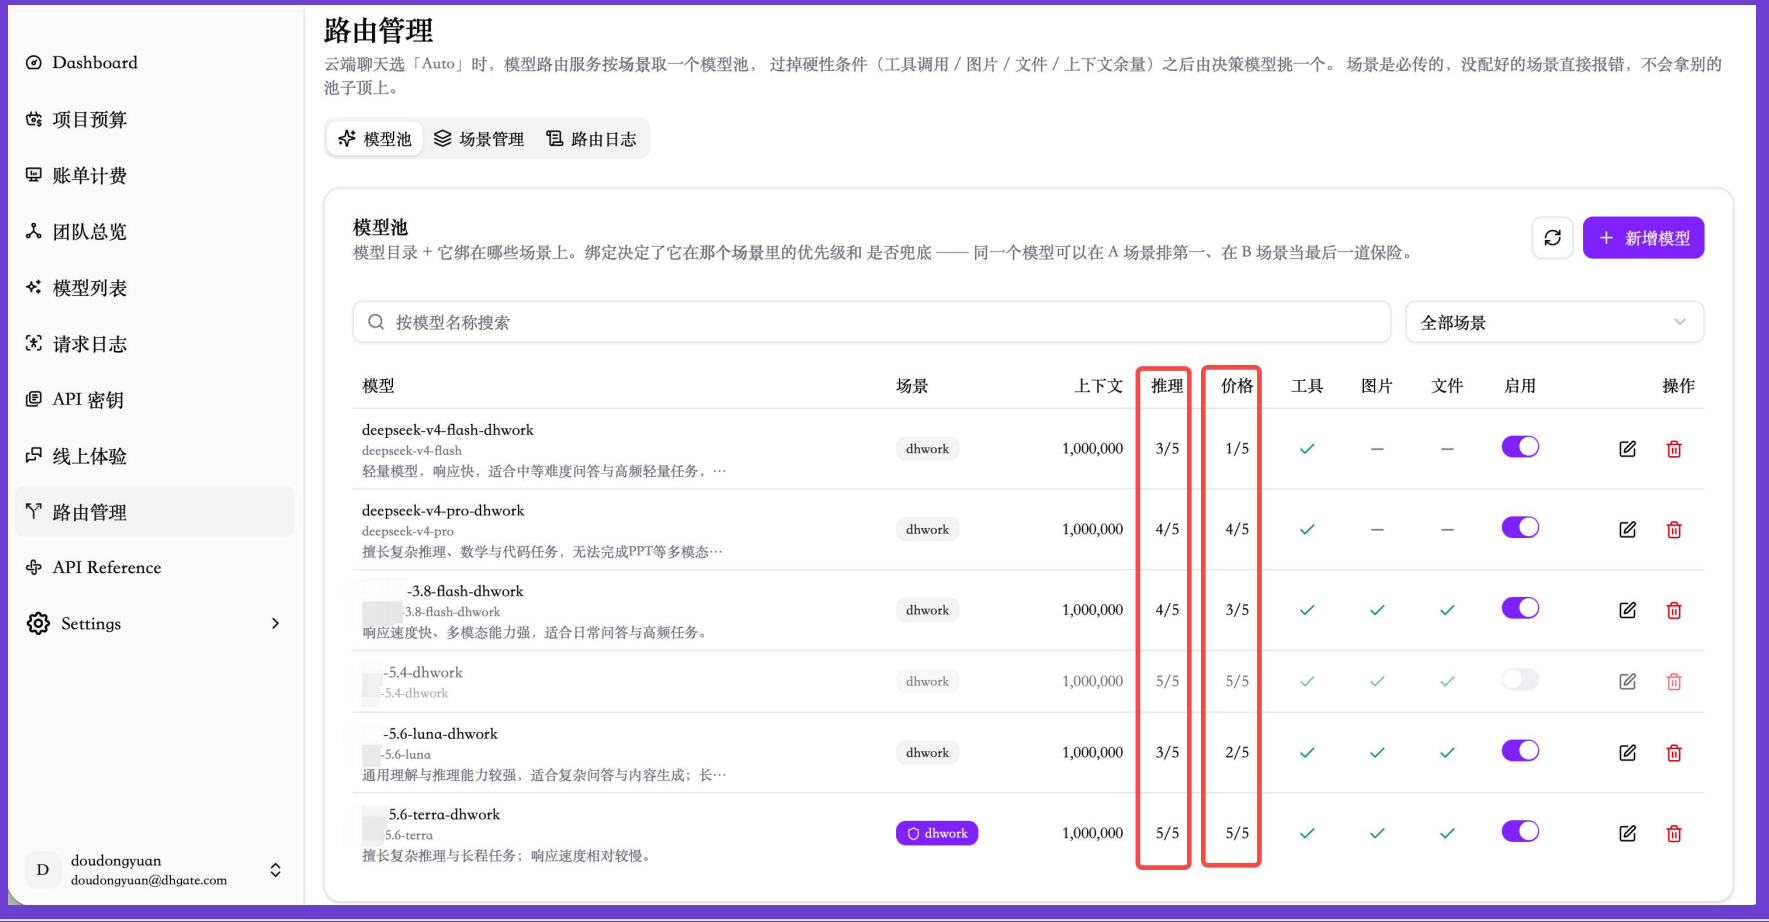


1. 上下文长度
2. 推理 vs 价格
3. 适用场景说明
4. 工具能力

DACon
DataFun.

能力矩阵让“适配”成为可比较的管理语言

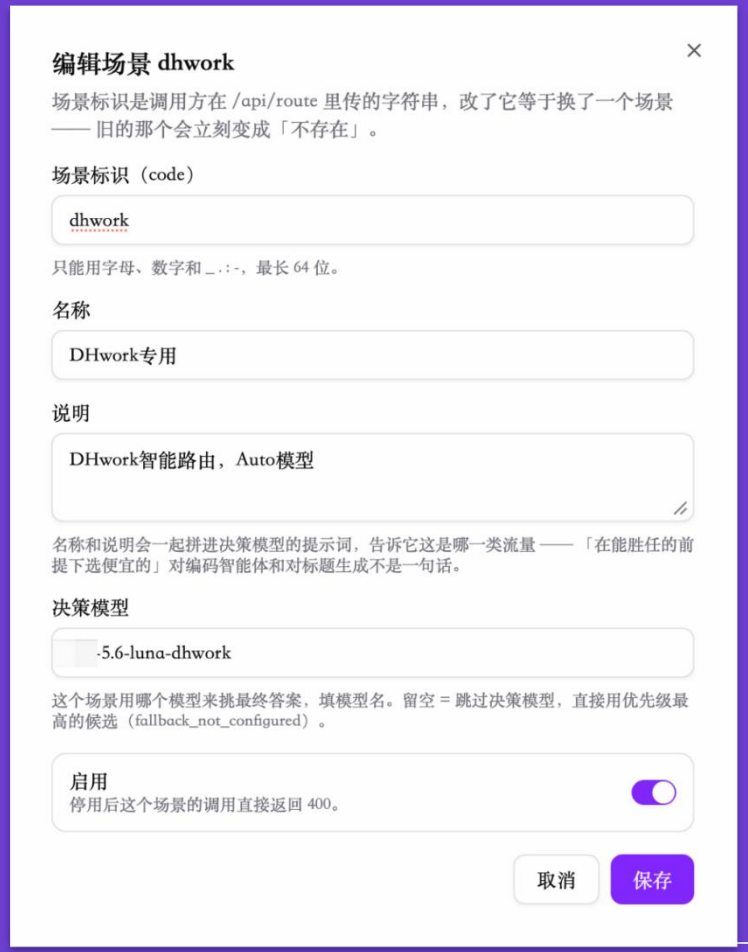
按照任务需求，结合模型能力、成本等特性，选择最优模型方案

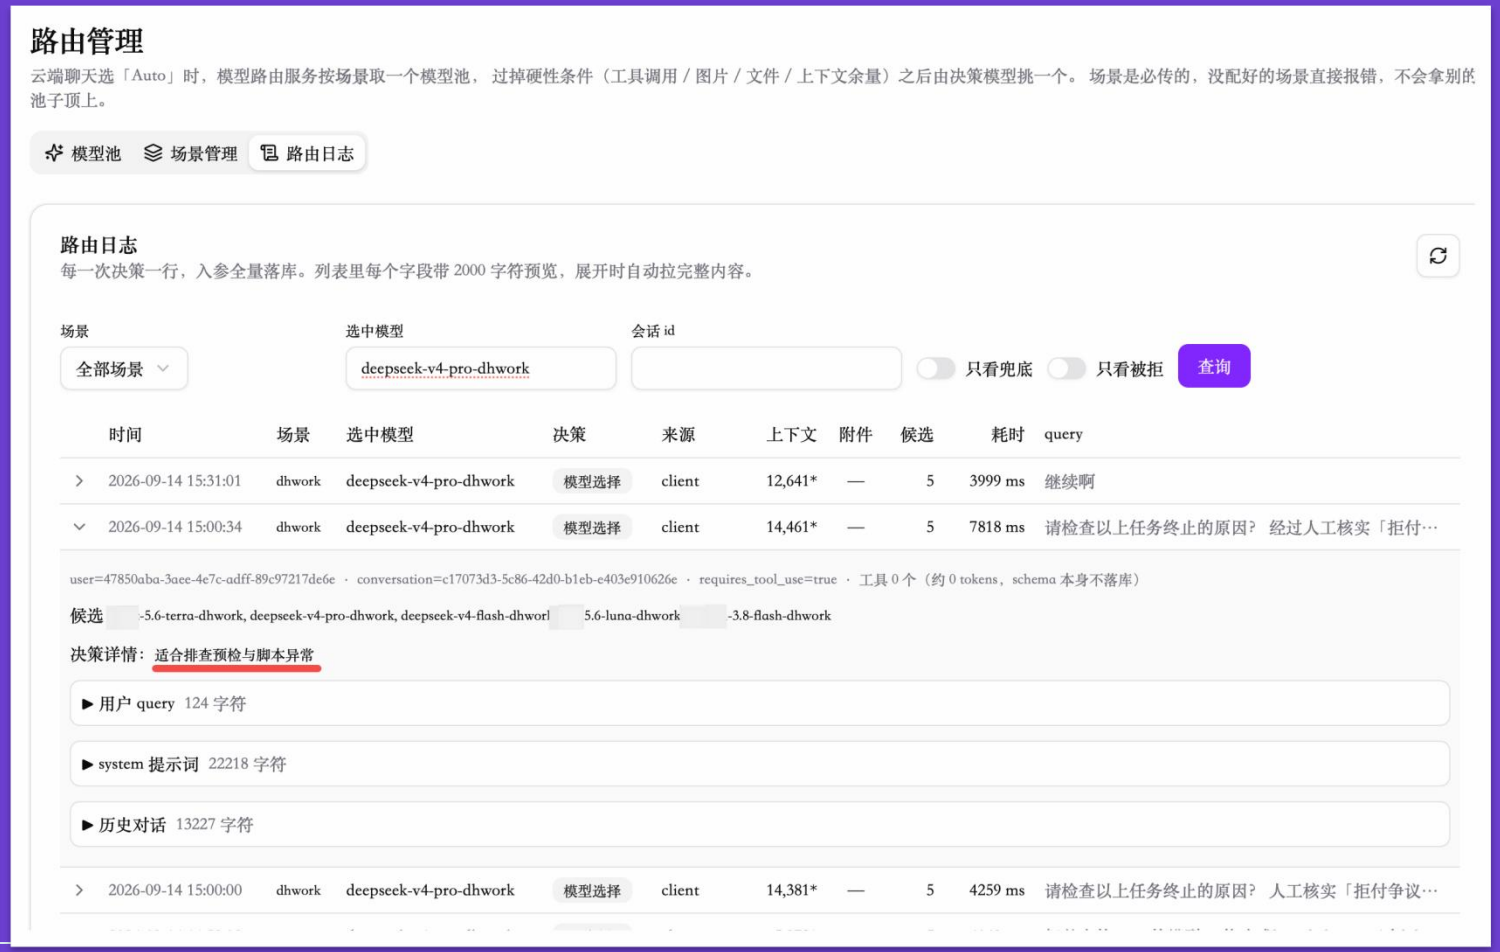


DACon
DataFun.

能力矩阵让“适配”成为可比较的管理语言

按照任务需求，结合模型能力、成本等特性，选择最优模型方案





DACon
DataFun.

先定义任务边界，再做模型选型

任务边界是质量、风险和成本的共同控制点；不让“模型品牌”代替业务判断

1
任务分类
推理 · 代码 · 对话 · 多模态

2
运行约束
时延 · 预算 · 地域 · 可用性

3
风险边界
数据分级 · 工具权限 · 合规

4
模型池匹配
能力画像 · 版本 · 降级策略

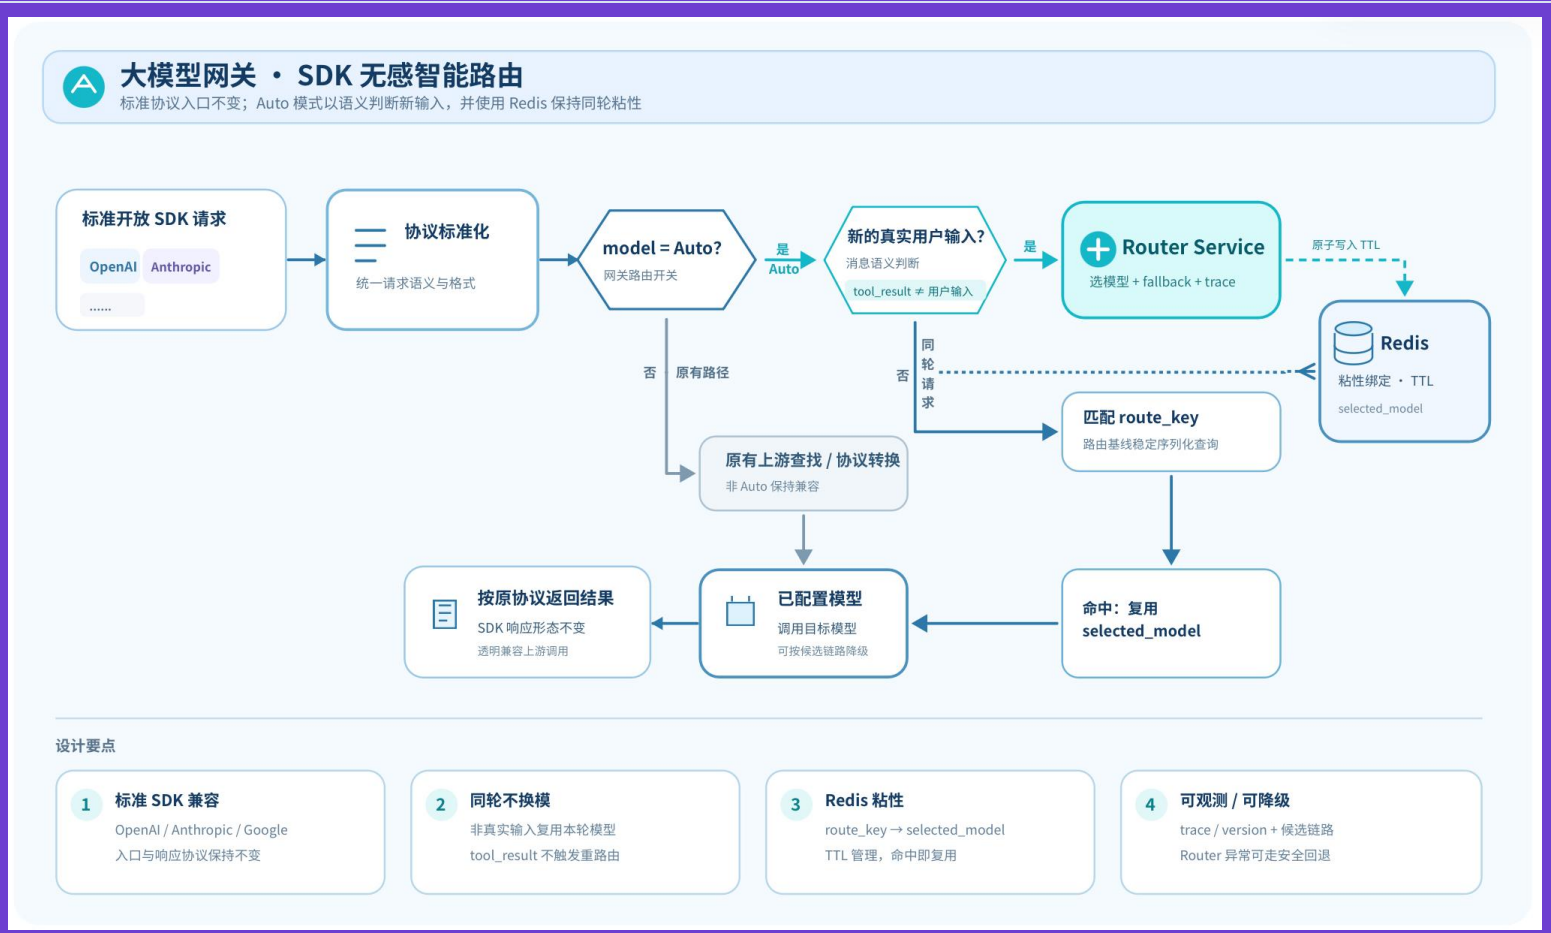
关键原则

在任务边界内选择模型，在单轮次执行过程中保持模型一致。

DACon
DataFun.

一次执行只选一次：Redis 让连续调用不“换脑”

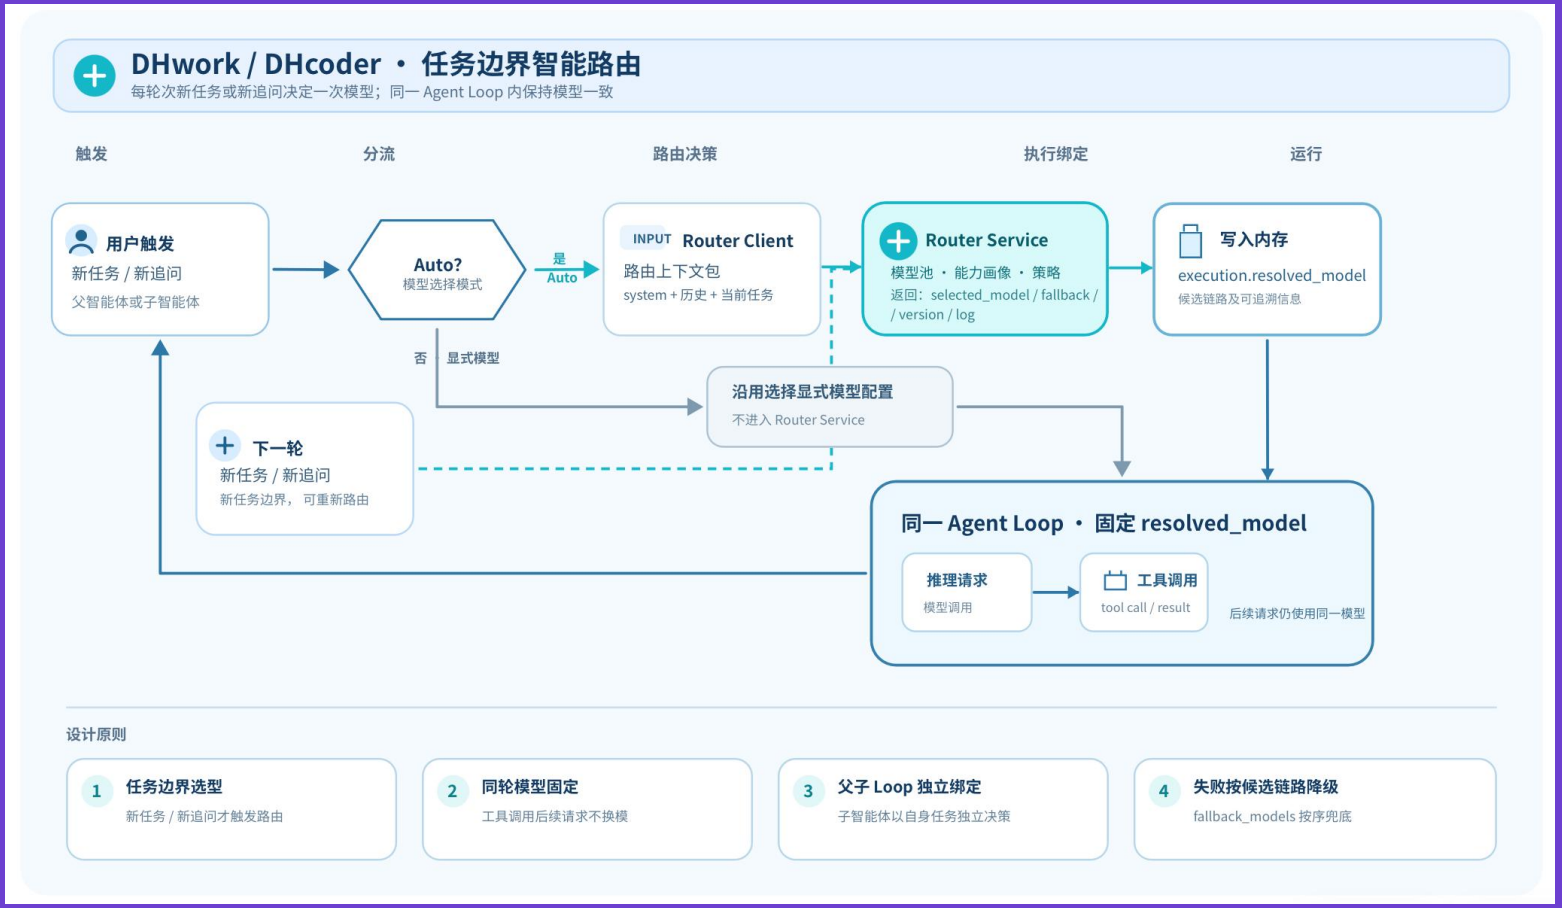
主 / 子智能体各自固定模型；网关工具续请求复用粘性绑定，避免中途切换带来的上下文与行为漂移



DACon
DataFun.

Auto 智能决策与显式选择必须分离

Auto 模式才进入 Router；显式模型保持原有链路，既保障体验，也降低迁移风险



DACon
DataFun.

独立 Router Service，覆盖 端和应用服务

以统一决策内核服务不同入口：先改善 Agent 体验，再扩展为企业级调用控制面

端应用

DHwork

主 / 子 Agent Auto 路由
Loop 内固定模型

独立 Router Service

能力画像 · 决策策略
模型池版本 · fallback
trace / reason code

统一决策内核

应用服务

大模型网关

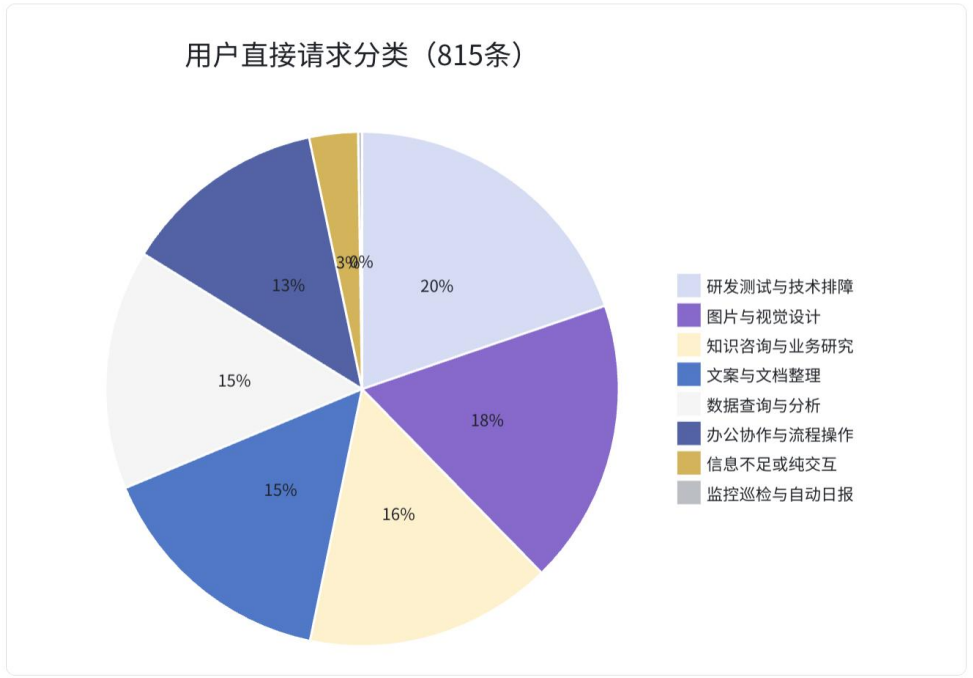
跨应用入口
工具续请求 Redis 命中

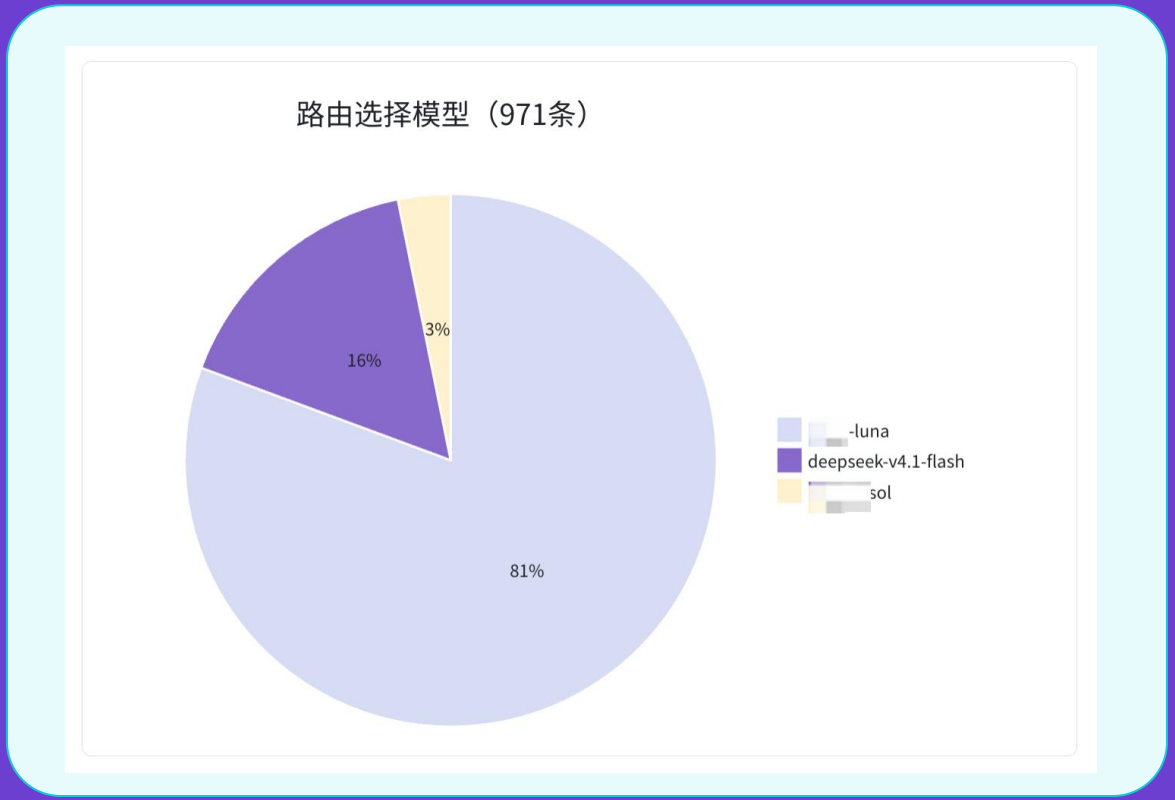
业务优先级：先验证“选得对”，再规模化“管得住”。

DACon
DataFun.

Auto 智能决策效果统计

随机抽取一天数据，815轮用户对话路由效果分析





Luna是当前主力模型：全量记录占80.64%。
DeepSeek在定时任务中占74.39%（61/82），在用户直接请求中仅占9.08%（74/815）。

DACon
DataFun.

ROI 智能路由的直接成本节省

从最强模型到最优组合的直接成本节省

💡 **相比全部使用 Sol，智能路由估算节省成本 92.61%，路由后成本约为原来的 7.39%。**

方案	相对成本（全 Sol = 100）
全部使用 Sol	100
智能路由	7.39
全部使用 Luna	5.00

DACon DataFun.

ROI 不应只看单价，而要看“单位有效产出”

没有真实财务数据时，用可审计的框架建立对话，而不是用未经验证的数字承诺

¥

成本投入

模型调用费
平台与运维
治理与合规

↑

价值产出

任务成功率
人工节省
体验与时效

✓

质量校正

返工成本
风险事件
降级损失

管理口径

单位有效任务成本 =（调用成本 + 平台成本 + 返工 / 风险校正）÷ 可验证的有效任务数

搭配“质量阈值、P95 时延、失败率、降级率”共同观察，避免以低价换低效。

DACon
DataFun.

纯低价模型的隐形成本，可能由人的精力买单

场景：10个复杂模块自动化重构与单元测试修复；仅 CI/CD 与合规审查均通过才算有效任务。

只看 Token 单价 → 看工程总账

A · 纯低价通用模型

首轮通过率	有效任务成本
35%	¥13.16

平均重试 3.2 次

API ¥160	返工约 ¥13,000	总成本 ¥13,160

B · 智能路由

首轮通过率	有效任务成本
88%	¥1.70

通过路由，把强能力用在真正需要的任务上

API ¥450	返工约 ¥1,200	路由 ¥50	总成本 ¥1,700

结论

一次“看似便宜”的调用，可能换来多轮修复、测试与审查；应以单位有效任务成本决策。

工程总账 = 调用成本 + 返工成本 + 审核与风险校正

DACon DataFun.

最优组合，不是所有请求都用最强模型

场景：每月 10,000 笔高风险客诉与赔付政策智能初审；正确、依据准确且不触发二次仲裁/合规追责才算有效。

A · 单一大模型统包

把所有请求交给同一强模型

¥0.55 单位有效任务成本

调用 ¥5,000 + 风险校正 ¥500 **总 ¥5,500**

P95 5.2 秒

B · 智能路由

按任务难度分配能力：85% 常规 · 15% 疑难强推理

85% 常规轻量模型　　15% 疑难强推理

常规 ¥425 + 疑难 ¥1,125 + 风险 ¥700 + 网关 ¥100 **总 ¥2,350**

¥0.24 / 有效任务　　P95 1.1 秒

结论

ROI 不是单价最低，而是能力、风险、时延与成本的组合最优。

轻量模型承接高频常规任务；强推理模型聚焦疑难任务，形成更低的有效成本与更快的 P95。

DACon　DataFun.

统一分层治理层，把“可用”变成“可信、可管、可演进”

治理不是上线后的附加项，而是多模型组合能够规模化运营的前提



DACon
DataFun.

以五项验收，把“能路由”升级为“可上线”

验收覆盖正确选择、执行一致性、粘性续接、兼容回归与故障可控

01	**有效模型池选择**	任务与能力画像匹配，输出可解释
02	**应用主 / 子 Loop 固定**	同一 Loop 内不因工具调用中途换模
03	**网关续请求 Redis 命中**	命中后不重路由，保留执行一致性
04	**显式模型回归**	用户显式指定模型时，链路行为保持一致
05	**失败可观测、可降级**	trace 追溯原因，fallback / 限流可生效

上线门槛：可解释 · 可复现 · 可回退

DACon

DataFun.

四阶段推进：先建立事实，再扩大收益面

每一阶段都有明确的能力目标与可验收产出，避免“一次性大改造”

01

能力评估

任务地图、能力画像、模型池准入

02

路由建设

Auto / 显式分离、Router、Redis 粘性

03

治理完善

观测、安全、灰度、降级与验收

04

规模优化

成本策略、模型池迭代、运营闭环

推进原则：从高价值、低风险的任务开始；每次扩大范围，都以指标与验收作为下一阶段的入口。

DACon DataFun.

一条业务请求，在合规边界内获得合适的模型服务

以下为实施设计示意，不代表真实客户、真实数据或已实现成效



适用前提：先厘清数据边界、任务质量标准和人工兜底机制，再定义试点成功条件。

DACon
DataFun.

CLOSING

把模型能力，转化为企业可运营的能力

选对

以任务边界与能力画像定义“适配”

跑稳

以一致性、粘性路由与降级保证执行

管住

以统一治理与验收机制支持规模化

建议：确定首批高价值应用场景・建立能力画像与模型池・启动 Router 最小闭环试点。

谢谢

总结

THANKS

演讲嘉宾：窦东员