Apache Ossie 语义层在蚂蚁的落地实践

演讲嘉宾：
蚂蚁语义层平台负责人 - 王小军

目录

CONTENT

01 问题与破题：从业务歧义到语义契约

02 语义层建设：打造持续可信的语义层

03 实践落地：语义层的应用与效果

04 总结与展望

从业务到数据：理解语义层的六个问题

蚂蚁集团 ANT GROUP

数据语义分层模型

业务世界 · Business World

- 背景：行业 / 范围 / 目标 / 角色
- 运作：活动 / 流程 / 制度
- 依据：访谈 / 观察 / 单据 / 系统记录
- 事实：交易 / 事件 / 状态变化

↓ 理解与抽象

L4 业务模型：流程 / 实体 / 规则 / 术语

↓ 概念抽象

L3 本体与知识图谱

- 本体：概念模型 — 实体类型 / 概念属性 / 关系 / 约束
- ↓ 实例化
- 知识图谱：实例与事实网络 — 对象 / 属性 / 关系事实 / 来源

↓ 分析建模

L2 语义模型

- 指标模型 — 度量 / 聚合 / 限定条件 / 时间口径 / 分析维度 / 派生复合
- ↓ 引用字段与关联路径
- 明细模型 — 逻辑表 / 字段 / 粒度 / 主外键 / 关联条件与基数 / 映射

↓ 物理实现

L1 物理模型：物理表 / 字段类型 / 分区 / 索引 / 存储

应用消费：BI / Notebook / API / AI Agent

六个问题，展开建设决策

WHAT	是什么	什么是语义层，由什么组成？
WHY	为什么建	解决哪些问题，带来什么价值？
WHERE	建在哪里	企业统一数据资产库 OR 业务团队资产库
WHEN	什么时候建	什么情况下值得建，需要哪些前提？
WHO	谁建、谁用、谁负责	谁定义业务含义，谁实现、谁维护？
HOW	如何建	如何从需求走到可用、可持续维护的服务？

注：箭头表示设计与映射关系，不代表数据必须逐层流经；建设语义模型不以完整知识图谱为前提。

蚂蚁数据语义层平台建设概览

蚂蚁集团 ANT GROUP

DataAgent | 语义模型驱动数据研发 | BI | 自助分析 | 数据治理

统一提供语义上下文

语义层上下文服务　　周调用量 2500

语义模型　　250+ 语义模型

覆盖 30+ 业务域

支付宝　财富业务　数据科技

数字支付　芝麻信用　医疗健康

经营管理　平台技术　+更多

15000+ 业务指标　　1500+ 数据集

语义驱动数据研发

需求澄清 → 语义定义 → 实现生成 → 一致性验证

存量资产逆向建模

资产盘点 → 知识提取 → 语义建模 → 校验确认

资产知识图谱

数据资产　　业务知识

今天讨论：如何从 0 到 1 构建可被人和 Agent 可信消费的语义资产

01 问题与破题：从业务歧义到语义契约

SQL 能执行，答案为什么仍然错?

从“语法正确”到“业务正确”，中间还缺一层语义

蚂蚁集团 ANT GROUP

01 问题与拆解

用户问题

> 5 月 5 日，
> 角标渠道
> 公域算法渗透率
> 是多少?

问题拆解

时间	5 月 5 日
渠道	角标
流量	公域
指标	算法渗透率

原问句未说明

年份、PV / UV、行业

02 生成所需的输入

表 Schema

字段、类型、结构

渠道与范围 · string

channel_l1	一级渠道
channel_l2	二级渠道
type	流量分类
hy_name_l1	一级行业，含 ALL

曝光 · bigint　　次数 / 用户数；近1天

algo_expo_pv_1d / expo_pv_1d

algo_expo_uv_1d / expo_uv_1d

时间 · string　dt：yyyyMMdd

解决问题所需的语义知识

在同一 Schema 基础上补充

① 渠道层级	角标是二级渠道 上级为首页宫格
② 指标口径	默认 PV；明确询问 用户 / UV 时切换
③ 默认范围 与粒度	未指定行业， 取 ALL 汇总行 不与行业明细混算

④ 计算约定：百分数、两位小数
零分母返回 NULL

03 SQL 对比

本例错误 SQL

直接生成

```
SELECT algo_expo_uv_1d, expo_uv_1d,                    ②
       ROUND(algo_expo_uv_1d * 1.0                     ④a
             / expo_uv_1d , 4)                         ④b
         AS algo_penetration_rate
FROM traffic_efficiency_dataset
WHERE dt = '20260505'
  AND channel_l1 = '角标'                              ①

  AND type = '公域' ;
                                                       ③
```

同一差异同色，不同差异异色　层级　口径　范围　格式　零分母

正确 SQL

符合本例业务约定　　融合知识生成

```
SELECT algo_expo_pv_1d, expo_pv_1d,                    ②
       ROUND(algo_expo_pv_1d * 100.0                   ④a
             / NULLIF(expo_pv_1d, 0), 2)               ④b
         AS algo_penetration_rate
FROM traffic_efficiency_dataset
WHERE dt = '20260505'
  AND channel_l1 = '首页宫格'                          ①
  AND channel_l2 = '角标'
  AND type = '公域'
  AND hy_name_l1 = 'ALL';                              ③
```

空白色带：上路缺少的条件或保护结构

04 错误原因分析

错误原因分析

需要回答的问题

① 角标属于哪一级?
上级是谁?
缺少渠道层级映射

② PV、UV 都合法，
此次用哪个?
缺少默认口径与切换条件

③ 未指定行业，取哪些行?
如何避免混算?
缺少默认范围
与汇总粒度约定

④ 如何表达百分比、
处理零分母?
输出约定与边界行为需明确

字段齐全，
业务选择仍需依据。

05 结论

结论

语义知识

正确回答业务问题
需要充分的语义知识

语义模型：结构化的业务语义契约

开放的语义协议，统一数据、指标与 AI 上下文，驱动智能化应用

需要表达的语义知识

信息类型	必须表达的内容
数据基础与物理映射	Dataset、Field、数据源、主键
语义要素	Metric、Dimension、业务名称与含义
数据关系拓扑	Relationship、Join 关系、基数和依赖路径
计算与约束	公式、Filter、时间逻辑、聚合和使用限制
AI 可消费上下文	同义词、指令、示例、陷阱、已验证查询

Apache Ossie 语义模型协议

Apache Ossie 协议的优势

1. **核心语义对象表达**
   统一 Dataset/Field/Dimension/Metric 等核心对象，精确定义业务含义与计算逻辑。
2. **AI-Ready 上下文注入**
   提供可直接被 AI 理解与消费的上下文，提升问答、分析与生成的准确性和可控性。
3. **结构化的关系定义**
   明确 Join 关系、基数与依赖路径，确保数据关联清晰、可追溯、可验证。
4. **业界共识**
   基于开放协作形成的共识语义模型，促进跨组织、跨平台的协作与复用。
5. **中立标准可交换**
   与具体厂商或实现无关，支持跨系统、跨工具间标准化交换与集成。
6. **可版本管理**
   语义包可版本化管理，支持变更追踪、回滚与兼容演进。
7. **可扩展可演进**
   模块化设计，支持自定义扩展与未来能力演进，适配多样化业务场景。

把分散的业务知识，沉淀为人、AI 与系统共同遵循的语义契约。

语义模型示例: 渠道算法渗透率模型

概念模型描述业务，语义模型锚定语义，物理模型提供执行路径

业务背景

运营配置投放单元向目标人群推送服务，评估算法推荐效果。
人群标签命中算法标签名单，曝光归类为算法曝光。
核心问题：某天、某渠道的算法推荐渗透了多少流量？

渠道层级

首页宫格 → 角标 / 卡片 / 胶囊

角标是首页宫格下的二级渠道；本页分析公域流量。

算法渗透率 = 算法曝光量 ÷ 总曝光量

概念模型

业务流程

配置投放 → 用户触达和展示 → 用户响应 → 效果评估

- 配置投放：关联目标人群
- 用户触达和展示：产出：曝光 PV / UV
- 用户响应：点击 PV / UV
- 效果评估：计算：算法渗透率

业务对象

用户 · 目标人群
投放单元 → 人群标签
→ 算法标签名单
标签命中后归类为算法曝光

维度

渠道 · 流量类型 · 行业
首页宫格 / 角标两级渠道
公域流量与行业范围
按日期与维度组合分析曝光

概念约束

曝光是事实；渠道、日期、流量类型与行业是分析视角。
算法曝光由标签命中归类，不另造一套曝光事实。
渗透率在效果评估时按同一范围的分子、分母计算。
从概念模型到右侧语义定义：将对象、规则与度量编码为可执行口径。

用户触达和展示 → 曝光事件入 DWD

语义模型

L1 数据集

流量曝光明细表
明细数据集 · 模型基础
一行 = 一次曝光事件
对应 DWD 曝光事件

流量曝光汇总表
维度组合的曝光汇总

渗透率结果表
预计算渗透率

L2 原子 / 维度 / 限定

原子指标
曝光次数
统计曝光事件数
明细表上的基础聚合

维度
日期 · 渠道
流量类型 · 行业

业务限定
算法曝光 · 算法标记
角标渠道 / 公域流量
全部行业

L3 派生指标

派生指标
算法曝光次数
曝光次数 + 算法曝光
限定 → 算法曝光次数

定义依赖
曝光次数提供基础计数。
算法曝光限定参与派生。
两者组合得到
算法曝光次数。
限定条件是可复用语义，
不是另一张事实表。

L4 复合指标

复合指标
算法渗透率（曝光次数口径）
算法曝光次数 ÷ 曝光次数
默认 PV · 零分母保护

AI Context
默认年份：2026；默认口径：PV
行业未提及：取 ALL 汇总
角标：二级渠道，上级首页宫格
汇总表 / 结果表等价执行
粒度匹配时使用等价物理执行路径

用户问题映射到语义模型定义节点

日期维度
日期 · 2026-05-05
值：20260505
时间语义

角标渠道
channel_l1 = 首页宫格
channel_l2 = 角标
业务限定

公域流量
type = 公域
限定流量类型
业务限定

全部行业
hy_name_l1 = ALL
未指定行业时补齐
业务限定

算法渗透率
曝光次数口径
复合指标 · 默认 PV
分子 ÷ 分母

时间
5 月 5 日
→ 2026-05-05

渠道
角标
→ 首页宫格 / 角标

流量类型
公域
→ type = 公域

行业范围
未提及
→ ALL 汇总

指标
算法渗透率
→ 默认 PV

明细 SQL · 口径源头

DWS SQL · 预聚合

ADM SQL · 结果读取

物理模型

traffic_detail · DWD
一行 = 一次曝光事件
expo_event_id · is_algo · user_id · dt

按维度聚合

traffic_efficiency_dataset
DWS · 渠道、行业、日期组合汇总
expo_pv_1d · algo_expo_pv_1d

预计算渗透率

adm_traffic_algo_penetration
ADM · 某日某渠道的渗透率
algo_penetration_rate_pv

真实表映射
角标曝光记录 · 人群算法归类
算法标签名单 · 投放单元 · 流量大盘
具体表名与字段见结构稿正文

用户问题理解

问题要素映射到上方定义节点

用户问题
5 月 5 日，角标渠道公域
算法渗透率是多少？
显式条件 + 默认口径 + 未提及范围

同一语义口径
匹配不同物理执行路径

结论：语义模型将字段、口径、范围和计算方式编码为可执行定义，让问题理解与物理执行共享一套业务语义。

定义了语义标准，然后呢？

从「协议能表达」到「模型可信」，再到「让可信续生效」

协议标准 → 质量标准 → 三大关键能力

协议标准

定义“能表达什么”

Apache Ossie + Ant-OSI

- Dataset
- Dimension
- Filter
- Metric
- Relationship
- AI Context

统一语义对象与表达结构

- 符合协议 ≠ 业务可信
- 仍可能粒度错、关系扇出
- 口径偏差、默认规则缺失

符合协议，结果就一定正确吗？

质量标准

定义“什么叫可信”

质量画像：识别质量短板

硬性门禁：失败则阻断发布

场景验收：验证真实任务可用

用基准问题 + 权威答案
判断模型是否达到可信要求

- 标准本身不会生产模型
- 不会自动执行验证、处理变化
- 也不会按任务交付语义

可信要求明确了，
谁来落实并持续保障？

三大关键能力（履约层）

让契约在实际任务中持续生效

01 / 构建（语义供给）| 规模化构建

- 语义散落在存量资产中，逐项建模成本高
- 模型从哪里来，如何规模化构建？

02 / 治理 | 质量验证 + 持续保鲜

- 质量要求需要执行验证，业务变化会让模型失效
- 如何验证可信，并在变化后保持可信？

03 / 消费 | 最小充分交付

- 可信模型仍需按任务选取、补齐并正确使用
- 如何按任务交付，让 Agent 可靠使用？

语义契约 由 协议标准 + 质量标准 约束

语义模型（契约层）

消费反馈 → 供给 / 治理

只有语义模型的协议和质量标准不够，还需要配套的工程链路

协议和质量标准定义契约， 供给、治理、消费 让契约持续生效。

02 语义层建设：打造持续可信的语义层

企业级可信语义层平台架构图（1 + 3 + N）

模型定义可信契约，工程能力让契约持续生效，支撑多场景智能应用

蚂蚁集团 ANT GROUP

可信 — 可验证、可追溯 | 可用 — 高质量、可控可用 | 可持续 — 持续保鲜、闭环进化

接入层 / 表现层

N 个消费场景

- 自助取数门户：拖拽取数 | 即席分析
- Data Agent：智能问数 | 口径查询
- 数据研发：驱动数据研发 | 口径校验
- BI / 自助分析：可视化分析 | 看板
- 资产治理：指标口径 | 血缘治理
- 更多场景 …

供给 + 治理 + 消费

1+3 核心能力

1+3

② 语义治理层（验证质量，持续保鲜）

质量工程（左移验证，右移守门）

- 质检与发布阻断器
- 基准问题 & 回归测试集
- G1 ~ G4 发布门禁

持续保鲜（让模型不静默过期）

- 变更感知（探针/监听）
- 自动巡检（质量探测）
- Owner 审核（工单流）
- 生命周期管理（版本/状态）
- 模型下线（归档/冻结）

发布管理与版本库

草稿 Draft → 候选 Candidate → 已发布 Published → 废弃 Deprecated

1 核心：标准 + 语义模型（契约核心）

模型协议（契约对象）

- Dataset 数据集
- Dimension 维度
- Filter 限定
- Metric 指标
- Relationship 关系
- AI Context AI 上下文

六维质量标准（Q1 ~ Q6）

- Q1 结构正确性
- Q2 建模语义正确性
- Q3 业务语义正确性
- Q4 业务语义完整性
- Q5 业务语义确定性
- Q6 可治理性与可追溯性

发布门禁（G1 ~ G4）

- Q1 结构校验
- Q2 语义校验
- G3 业务校验
- G4 可治理性校验

③ 语义消费层（按任务交付）

消费入口（多协议适配）

- MCP Server
- Skill 插件
- RESTful API
- BI 连接器

消费服务（按任务交付）

- 语义检索
- 最小充分语义子图
- 模型查询
- 查询规划
- 查询翻译（SQL/DSL）
- 查询解释（可解释性）

消费约束（防幻觉与安全）

- 消歧与澄清（Clarify）
- 细粒度权限校验（RBAC/ABAC）
- 无依据拒答拦截器（No Evidence No Answer）

① 语义供给层（从证据生产）— SDD 规约驱动，AI + 人工协同

协议定义（SDD 规约） → 元数据抽取（表/字段/DDL/ETL） → 业务术语抽取（词条/同义词） → 指标口径抽取（指标/口径/计算） → 维度关系抽取（层级/主外键） → Join Path 推理（最优路径） → SQL 语义解析（查询意图） → 报表语义解析（报表结构/指标） → AI 辅助补全（LLM/Agent） → 人工审核确认（人工确认口径）

证据仓库 & 知识中枢

元数据与知识基础层

技术元数据（结构化 & 半结构化）

- 表/字段 元数据
- DDL/ETL 脚本
- SQL 日志（查询/日志）
- 报表（模板/定义）
- 血缘关系（Lineage）

业务知识库（非结构化 & 向量化）

- 业务文档（PDF/Word）
- 业务词条（术语/同义词）
- FAQ（问答对）
- 指令偏好（Prompt/规则）
- 业务规则（政策/制度）

存储引擎

- 向量数据库（ZSearch）
- 图数据库（Geabase）
- 全文索引（ZSearch）

消费反馈回流机制（闭环进化）

信号来源（自动收集）

- 未命中（TopK=0）
- 执行失败（Timeout/错误）
- 用户纠正（人工反馈）
- 低质量结果（评分/踩）
- …

信号聚合与分类 → 根因分析与验证 → 回流路由（闭环处理）

- 回流构建层：触发重新抽取/补全证据
- 回流治理层：触发版本修订/质量改进

横切关注点 / 支撑体系

- 全链路可观测性：日志 / 指标 / 链路追踪
- 安全与权限：身份认证 / 访问控制
- 变更与交付：版本基线 / 自动校验 / 发布回滚
- 可观测与统计：日志 / 指标 / 使用统计
- 血缘与溯源：来源 / 决策 / 操作留痕
- 责任与协同：OWNER / 确信

核心结论 以“可信语义模型”为唯一契约，通过“构建—治理—消费”的工程体系与闭环反馈，确保 AI Agent 可消费、持续保鲜、可追溯可证，支撑多场景智能应用落地。

供给与交付链路（向上） ⇢ 反馈与闭环链路（右侧）

核心: 语义模型协议扩展 | 企业业务知识的结构化表达

Apache Ossie 公共骨架 + Ant-OSI 企业扩展

Apache Ossie | 标准协议

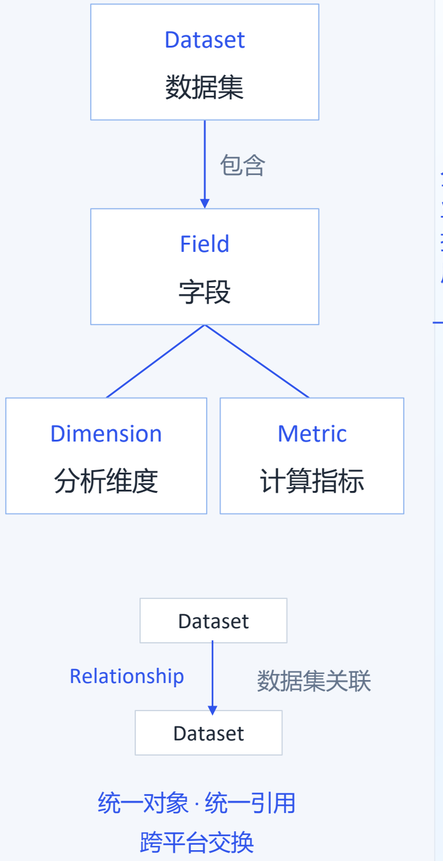

Ant-OSI | 企业扩展协议

企业扩展

具体扩展字段：增强语义模型的表达能力

关联路径

多条路径并存
需明确连接方式
与关系基数

multiplicity
join_path

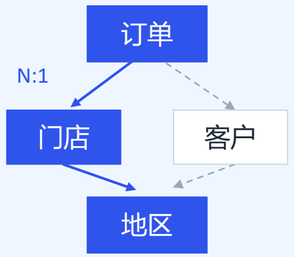

约束 Join
识别扇出风险

粒度汇总

明细与汇总混存
需识别每行
对应的数据粒度

Granularity
FIXED / ROLLUP
分组集 / CUBE

选对粒度
避免重复汇总

指标计算

公式依赖与窗口
以及聚合边界
需要明确声明

Window
additivity
alternatives

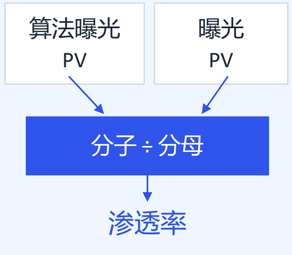

按口径重算
避免直接平均

AI 上下文

同一问法
存在不同口径
需声明选择规则

instructions
synonyms
pitfalls

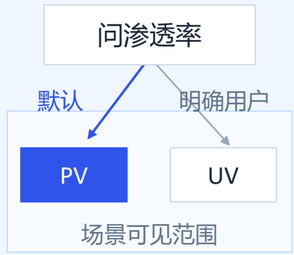

默认 PV
问用户才选 UV

模块复用

公共维度与限定
重复维护
口径容易分叉

公共维度 / 限定
Metric Refs
imports

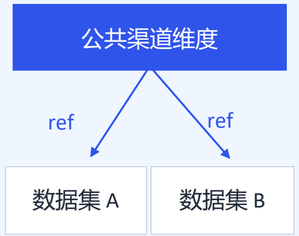

一处定义
多处引用

证据溯源

自动生成的定义
需要来源
和推导依据

explainability
证据 / 推导 /
置信信息

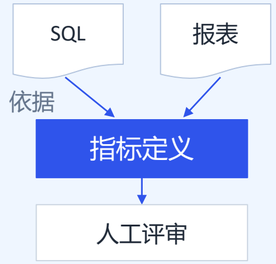

定义有据
评审可查

协议声明业务约束，构建、治理与消费共同使用这份契约

模型协议扩展示例：模块复用、粒度声明与等价定义

公共定义可复用，混合粒度可识别，同一口径可有多种物理实现

01 模块复用

imports

公共语义定义一次，多个业务模型引用

公共语义模型

公共维度 | 渠道 | 行业

公共过滤器 | 视频内容 | 优质内容

基础指标 | 发布数量

imports 引用

内容运营模型

最近7天
优质视频发布量

发布数量
+
视频内容
+ 优质内容

分析维度：渠道

行业分析模型

最近7天
各行业视频发布量

发布数量
+
视频内容

时间：最近7天

分析维度：行业

统一公共定义，减少口径漂移

02 粒度声明

Granularity Model

一张汇总表，多种粒度；查询时明确选择

粒度声明 FIXED：统计日

GROUPING SETS：{渠道, 行业} / {渠道} / {}

渠道 × 行业 | 渠道汇总 | 全局汇总

内容发布汇总表

2025-05-20

渠道	行业	发布数量	汇总标记
抖音	娱乐	12,345	NONE
抖音	科技	8,765	NONE
抖音	NULL	21,110	SUBTOTAL
快手	娱乐	9,876	NONE
快手	科技	6,543	NONE
快手	NULL	16,419	SUBTOTAL
NULL	NULL	37,529	TOTAL

按汇总标记选择查询粒度

明细	渠道汇总	全局汇总
NONE	SUBTOTAL	TOTAL
渠道 × 行业	各渠道汇总	全局合计

显式选择粒度，避免重复汇总

03 等价定义

Equivalent Definitions

同一个指标口径，对应多种物理实现

内容发文次数（近30日）

pub_ctt_cnt_main_30d

原子指标	内容发文次数
业务限定	主指标口径
时间窗口	近30日

等价实现 · 按需选用

A 明细层物理实现

public_nd.pub_ctt_cnt_30d

数据集：public_nd

B 汇总层物理实现

public_aggr_nd.pub_ctt_cnt_30d

数据集：public_aggr_nd

同限定 · 同窗口 · 查询粒度与覆盖范围匹配

保持业务口径，适配不同物理表

注：示例非完整协议代码。imports 表示模型依赖。

将 Ant-OSI 实践成果反馈给 Ossie 社区

将 Ant-OSI 扩展中经过真实业务验证的语义协议反馈回社区，帮助 Ossie 走向企业级生产

⚠ 一、痛点：现有规范暴露三个问题

过滤逻辑重复

同一条件硬编码到多个指标 SQL，规则变化时逐个修改，口径容易分叉

维度语义不一致

同一概念多数据集独立维护类型、枚举、描述，难以保证跨团队一致

派生指标难复用

重复编写基础指标 SQL，可能遗漏基础指标已有的过滤条件

二、设计原则

单一事实来源

公共逻辑只定义一次，修改后自动作用于所有引用方

语义一致

减少复制粘贴造成的口径偏差

组合优先

通过资产引用完成组合，模型平坦易读，避免复杂嵌套

显式优先

不设数据集默认过滤；跨数据集必须有 join_path

渐进采用

所有新增能力均为可选项，不使用时与现有 Ossie 完全兼容

对齐业界

参考 dbt MetricFlow、Cube.js 和 LookML，保持 Ossie 轻量抽象

★ 四、提案优点

- ✓ **可复用**：过滤、维度和指标定义一次，多处引用
- ✓ **可追踪**：显式 join_path 和依赖图，依赖可直接追踪
- ✓ **可静校**：静态校验循环引用、未知引用和缺失路径
- ✓ **向后兼容**：显式、平坦且渐进采用，为未来扩展预留空间

三、核心提案

1 Shared Filters

模型顶层定义具名、多 SQL 方言的过滤条件，Metric 通过 ${filter_name} 引用。跨数据集引用必须显式提供 join_path，编译器据此生成 JOIN。Shared Filter 是指标定义的一部分，**不依赖查询方主动附加**，稳定保证指标口径。

2 Shared Dimensions

模型顶层集中定义业务维度（逻辑类型、枚举、业务说明、AI context）。Field 通过 dimension.ref 绑定同一维度。Field 描述物理列，Shared Dimension 描述业务概念，**两者不继承、不覆盖**，保证跨数据源一致语义。

3 Metric References

Metric 表达式使用 ${metric_name} 引用同一模型中的其他指标。编译器构建依赖图、按拓扑顺序展开并检测循环。派生指标**默认继承基础指标的过滤条件**，再与自身过滤用 AND 合并，避免组合指标绕过原有业务限制。

```
# 派生指标示例
expression: "${gross_revenue} - ${refund_amount}"
```

链接

Proposal

Proposed Ossie Semantics — Shared Filters, Shared Dimensions & Metric References

Discussion

github.com/apache/ossie/discussions/342

核心: 语义模型质量标准

从定义可执行，到计算与业务正确、规则齐全、选用明确，再到持续治理与追溯

语义模型的六维质量标准

Q1 结构正确性

指标的引用与层级关系完整且有效。

- 引用的指标存在
- 表/字段可解析
- 层级关系无断链
- ...

Q2 建模语义正确性

聚合与计算逻辑不失真。

- 聚合路径正确
- 粒度与意图匹配
- 无重复计数/漏计
- ...

Q3 业务语义正确性

结果与权威口径保持一致。

- 对齐权威指标口径
- 统计范围与业务规则一致
- 时间基准与业务定义一致
- ...

Q4 业务语义完整性

边界、规则与异常处理齐全。

- 对齐规则定义全
- 异常/零分母处理
- 时间与范围说明
- ...

Q5 业务语义确定性

候选语义唯一明确，可被理解与选用。

- 避免歧义可区分
- 命名与注释清晰
- 示问验证可理解
- ...

Q6 治理与追溯性

版本变更可追溯，证据链可验证。

- 有完善变更记录
- 证据与来源可查
- 责任人与发布清晰
- ...

1 定义可执行 → 2 计算结构正确 → 3 符合权威口径 → 4 任务规则齐全 → 5 理解与选用明确 → 6 持续治理与追溯

判定示例 · 均未达标

- **Q1** 引用有效：引用的指标在模型及依赖中均未定义
  来源有效：模型引用了已删除的源字段。
- **Q2** 聚合正确：订单总额按明细行重复求和。
  关联基数：一对多误设一对一，金额被放大。
- **Q3** 公式口径：权威定义要求 PV，模型却用 UV。
  时间基准：应按收入确认日，却按下单日统计。
- **Q4** 边界规则：比率指标未声明零分母处理方式。
  排除条件：业务要求排除内部订单，模型却遗漏。
- **Q5** 候选区分：自然月和滚动 30 日均称“月活”，无选用指引。
  别名定位：常用简称“月活”无法定位对应指标。
- **Q6** 版本记录：公式已更新，却没有版本号和变更记录。
  责任归属：数据负责人已离职，模型仍无人接管

六维分别判定，证据分别记录，缺陷逐项暴露。

评价范围：声明的业务与任务范围。Q3 须对照权威口径，依据不足时标记“待核实”。

关键能力一: 规模化语义供给 | 盘活存量、约束新增

多源证据生成候选，关键语义由人确认，持续交付可信语义资产

证据约束方案，决策约束实现，验证约束交付，发布保持独立

1. 逆向建模: 自下而上，基于存量资产逆向还原语义模型

先还原数据如何产生，再抽取业务语义，经过跨表融合和模型映射，形成有证据、可验证的语义模型

元数据与知识基础

结构化资产信息

表 / 字段与 DDL

ETL / SQL / 加工依赖关系

查询历史与报表

非结构化业务知识

业务文档、术语词条与指标定义

FAQ、业务规则

权威答案

指令与偏好

已有语义模型

数据集与关联关系

维度、业务限定与指标

AI 上下文与物理映射

来源与版本统一管理

分层挖掘过程

L4 语义模型挖掘与融合

存量复用、多源合并、缺失新建,关键口径由人确认

场景与边界确定 → 存量模型盘点 → 语义要素映射 → 候选方案生成 → 人工确认 → 模型生成

L3 多表语义知识挖掘

关系挖掘：主外键发现 → 关联候选生成 → 基数与条件核验

知识融合：候选项汇集 → 同一性判断（来源、语义时序） → 语义融合

汇合

L2 表级语义知识挖掘

阶段一：SQL 解析 → 表/字段加工链路追溯 → 确认语义锚点与链路边界

阶段二：共享证据上下文 → 分类语义知识抽取（子智能体并发挖掘） → 依赖补算与单表知识融合（跨知识类型融合） → 交叉校验

L1 资产知识挖掘

工程挖掘：结构解析、数据探查、消费模式归纳

资产发现与圈选 → 多源信息采集 → 工程挖掘 → 标准化与索引库

产出物

- 数据集 / 关联关系 / 维度
- 业务限定
- 原子 / 派生 / 复合指标
- AI 上下文：指令 / 同义词 示例 / 业务规则
- 溯源证据 / 确认状态

- 统一业务对象 / 活动 / 维度
- 术语；指标口径及差异
- 资产关联 / 多表物理映射
- 融合决策

- 完整加工链路与证据定位
- 表类型 / 加载类型 / 业务域
- 业务范围；对象 / 活动 / 术语
- 维度值 / 度量与指标
- 粒度 / 规则 / 记录含义

资产知识图谱

- 资产基本元数据 / 数据知识
- 资产产出知识 / 消费知识
- 资产血缘：表级 / 字段级

质量校验

检查流程

静态检查 → 证据核验 → 场景验收 → 质量判定

校验输出

六维质量画像 / 门禁结果

- 场景适用范围
- 缺陷与补证清单

质量反馈：对应层补证 / 修正；输入缺失时回溯基础

整体交付：语义模型 + 溯源证据 + 质量报告

公共能力

共同支撑

标准与规范

术语命名 · 建模口径 · 质量验收

知识检索

资产 / 模型 · 语义检索 · 证据定位

知识挖掘框架

采集适配 · 任务编排 · 缓存续跑

证据驱动

来源版本 · 确认状态

安全与权限

角色权限 · 访问控制

蚂蚁集团 ANT GROUP

2. SDD 规约驱动：以 OpenSpec 思想重构语义建模

以证据支撑建模、以规约固化决策，让语义模型可审查、可验证、可追溯

适用场景：精准解决四大建模困境

01 方法论缺失

- **标准化建模指导：**结构化范式将隐性经验转化为可复用流程

02 交互机制缺失

- **人机协同与意图确认：**显式审批门强制澄清歧义、确认拓扑决策

03 流程遵从性差

- **多步骤长链路约束：**五步闭环 + 分层验证强制 SOP，杜绝流程失控

04 可解释性缺失

- **审计溯源与高效评审：**Archive 封存完整证据链，依据全程可追溯

SDD 的定义

SDD 定义

建立**可审查的结构化规约**，实现"证据约束方案、决策约束实现、验证约束交付"。

OpenSpec 借鉴

继承"先形成**可审查契约**，再实施并归档"，事实基础从代码扩展至**数据资产**。

SDD 对 OpenSpec 的适配与演进

维度	OpenSpec	SDD / SemSpec
事实基础	现有代码 + 主 Spec	资产证据 + 用户确认 + 现有模型
方案决策	设计评审达成共识	候选方案须**显式人工审批**
持久契约	Markdown 主 Spec	**Ant-OSI YAML** 机器可读
实施归档	改代码，合并规格增量	改**模型**，仅**封存决策记录**
发布边界	非核心流程	Push **独立隔离**，需**单独授权**

SDD 规约驱动的构建流程

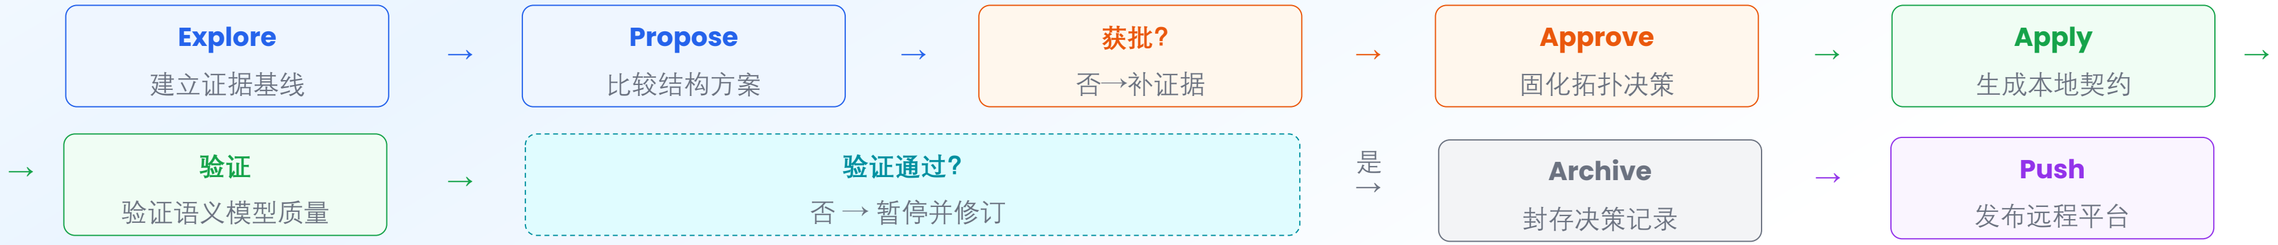

核心洞察：SDD 并非重新发明流程，而是保留 OpenSpec 变更协议思想，针对语义建模风险重构事实来源与审批机制；多痛点场景价值最大化，**单对象微调直接修改更高效**。

3. 正向建模: 语义模型驱动的资产研发范式

将业务需求沉淀为语义模型，驱动数据研发与资产验收，确保业务口径全链路一致

统一语义 · 驱动实现 · 保障质量 · 安全发布 · 持续演进

语义模型从事后说明书升级为数据研发的源头标准与控制中枢

关键能力二: 发布只是起点，持续保鲜才能让语义长期可信

三类变化触发在役巡检，经影响分析、Owner 决策与自动回归形成可回滚闭环

变化来源：
上游资产变化 → 业务口径变化 → 消费需求与反馈变化

01 触发入口
- 模型变更
- 自动巡检
- 血缘依赖变更
- 消费反馈

02 问题发现
- 检查范围确定
- 上下文采集
- 模板校验
- 措施判定

03 修复建议
- 模板匹配
- 修复推导
- 变更内容

04 变更修复
- 自动修复
- 人工修复
- 变更快照 / Diff

05 回归测试
- 质量门禁
- 用例评测

全通过才提交审批

06 Owner 审批
- 批准 / 驳回
- 重新修复

批准才可发布

07 发布上线
- 记录版本基线
- 生产监控

等待下一轮保鲜触发

触发事件
- 来源对象 / 触发原因
- 发生时间 / 关联证据
- 同对象重复信号合并

问题发现详细过程

1. 检查范围确定
- 变更通知 → 初步影响分析
- 定期巡检 → 按策略圈定
- 消费反馈 → 定位相关模型

输出：候选对象与检查项

2. 上下文采集
- 资产知识 | 语义要素
- 要素证据来源 | 变更上下文
- 依赖关系 | 消费反馈

输出：校验所需上下文

3. 模型校验
- 质量：完整、正确、确定
- 保鲜：资产、口径、消费对齐

输出：问题证据与实际影响

4. 发现结果
- 待定 | 补证 | 人工确认
- 变更 | 降级 | 下线建议
- 优先级、责任人、处理边界

输出：问题诊断报告

血缘影响：表 / 字段 / DDL / ETL → 语义对象 / 指标 / Join Path → 报表 / Agent / 查询计划 → 测试用例 / 权威答案

巡检处置：正常 / 待确认 / 待修复 / 下线建议（须审批）
健康状态可恢复，不是生命周期。

治理底座

语义模型生命周期：草稿 → 待审核 → 已发布 → 待下线 → 已下线
仅“已发布”可用于线上消费。

受控下线：
无访问 / 高失败 / 底表下线 / Owner 失效 / 低质量 / 标准替代
保留历史版本、替代对象、原因、影响范围与迁移说明。

持续对齐底层数据、业务口径与使用需求 → 可发现 · 可理解 · 可信任 · 可消费

质量工程是出厂检验；
持续保鲜是在役巡检。

让语义
持续创造价值

关键能力三：语义模型消费 | 按任务交付最小充分语义

从业务问题到查询结果：理解与检索 → 组装任务语义包 → 确信、映射与执行

01 问题理解

用户问题 → 识别目标与边界

领域识别 → 意图角色识别
target：查询目标
adjunct：查询限定
type：查询目标类型

03 检索与候选生成

片段识别 → 候选提及
→ 候选实体生成
语义模型校准 → 语义模型重排

输出：候选语义模型与候选语义要素

04 子图生成 · 两种可选方案

方案一 要素检索 → 连通子图与依赖闭包 → 剔除无关对象

方案二 拉取候选语义模型 → Agentic 模型推理

任务语义包示例 · 仅保留当前任务所需内容

指标与公式	PV 指标 → 指标公式 → 公式依赖
路由规则	默认 PV；明确询问用户 / UV 时切换 UV
查询限定	5 月 5 日 · 公域 · 首页宫格 → 角标（包含）
默认规则	行业未指定 → 行业维度取汇总值 ALL
来源与依赖	权威来源 · 适用边界 · 依赖数据集
当前用户权限	对象权限 · 数据权限

07 查询生成 · 明确物理实现

来源表 / JoinPath / 过滤字段及表达式
聚合字段与规则 / 时间字段与范围 / 汇总字段

语义翻译 或 LLM 生成 SQL
→ 可执行查询语句

01	02	03	04	05	06	07	08	09
问题理解	**任务规划**	**语义模型检索**	**最小充分语义子图**	**确信**	**语义映射**	**查询生成**	**执行查询**	**结果解析与校验**
识别目标与边界	规划步骤与语义需求	召回并校准候选对象	按任务裁剪并补全依据	比较 · 消歧 · 澄清 · 拒答	明确业务口径	明确物理实现	按当前用户权限执行	核对口径并解释结果

02 任务规划

确定任务步骤
明确各步骤所需语义信息
形成检索与子图组装的任务边界

05 确信与异常处理

比较候选、消除歧义后继续语义映射

信息不足：澄清 → 用户补充 → 返回理解与检索
无法回答 / 无权访问：拒答 → 终止并说明原因

06 语义映射

目标口径 → 指标 → 限定
→ 时间窗口 → 维度
明确业务语义与计算口径

08 执行查询

按当前用户权限执行
由确定性机制校验
对象权限和数据权限

09 结果解析与校验

核对业务口径与执行约束
解析查询结果并给出解释
确认结果与任务意图一致

权限贯穿检索、组装与执行；最小：剔除无关对象；充分：保留必要依赖、关系与约束。

日期年份由任务上下文确定，必要时澄清。

设计理由	整份 YAML / 全库 Schema	只给指标名 / 一段描述	最小：控制对象范围	充分：补齐执行依据
	无关对象增加噪声、Token 消耗与误选概率	易遗漏关系、过滤、物理实现与权限	仅暴露当前任务所需对象，降低 Token 与误选	补齐依赖、关系、规则、限定、物理实现与权限

上下文按任务裁剪，执行所需的语义必须完整。

语义消费：语义模型检索 与 最小充分语义子图

从业务问题到查询结果：理解与检索 → 组装任务语义包 → 确信、映射与执行

语义模型检索

按用户意图定位候选模型与要素，再补齐依赖、关系和规则，形成任务所需的候选语义模型

索引链路（预构建/更新）

索引构建（预构建/更新）
- 模型/数据集/
- 字段/物理表/
- 维度/过滤/指标

索引入库（文本索引+向量索引）
- 文本索引
- 向量索引

索引库（统一存储与服务）
- 文本索引（倒排/BM25）
- 向量索引（Embedding）
- 元数据与权限信息

支撑召回

检索链路（用户提问触发）

用户问题（原始提问）
- 原始提问文本
- 上下文（可选）
- 用户身份

01 片段识别（语义解析）
- 语义解析
- 意图识别
- 领域识别
- 关键信息抽取

02 候选提及（分词）
- 分词+N-GRAM
- 关键词提取
- 同义词/别名
- 候选短语生成

03 要素召回（并行检索/混合检索）
- 范围过滤
- BM25 // 向量
- 结果标准化
- 按要素类型归类

04 模型校正（合并去重）
- 按模型合并
- 去重（实体/别名）
- 关系补全
- 版本对齐

05 模型重排（Rerank）
- 枚举值匹配
- 相关性评分
- Rerank 排序
- 截断 TopK

06 检索输出（候选模型+命中要素+匹配依据）
- 候选模型列表
- 命中要素集合
- 匹配依据/得分
- 任务意图
- 模型版本
- 未决项清单

生成最小充分语义子图

两条核心路径：一次性展开组装，或围绕缺口渐进补全；统一校验后交付任务语义包

检索输出 → 种子

候选模型 · 命中要素
任务意图 · 匹配依据

锁定任务范围
模型 / 粒度 / 时空 / 权限

路径 A：一次性组装

展开依赖
模型 → 字段 → 物理表

补齐关系
关联键 / 连接路径

补齐规则
口径 / 过滤 / 计算逻辑

裁剪无关对象
仅保留任务必需对象

生成候选子图
固化节点、边与规则

路径 B：Agentic 渐进披露

读取定义
展开当前模型与要素

识别缺口
依赖 / 关系 / 规则

批量补查
召回缺失对象与约束

合并复核
去重 / 对齐 / 更新子图

已充分?
是
否：继续补查，直至收敛

统一校验
- 01 需求覆盖
- 02 依赖完整
- 03 组合成立
- 04 边界明确

通过

任务语义包
最小充分子图 · 要素与关系
规则 / 口径 / 计算逻辑
来源版本 · 适用范围与约束

失败

缺口 / 冲突处理

补查 / 澄清
更新种子与范围

策略拒答
无覆盖 / 无权限

可补全 → 回到路径 B；不可补全 → 拒答

来源与版本 / 适用范围 / 当前用户身份与访问约束：贯穿检索与组装全过程，确保数据可追溯、权限可控、合规可审。

03 实践落地：语义层的应用与效果

Ant OSI：产品能力全景

以语义模型为核心，构建具备供给、治理、消费能力的规模化语义基础设施

当前已具备 语义资产全生命周期产品能力

实线 = 当前产品能力

发现与组织
先找到可信模型与权威口径

- OSI 列表与架构域目录
- 指标列表与维度列表
- 模型分组、标签与筛选
- 负责人、版本与资产规模

避免重复建设 · 明确权威来源

构建与发布
多入口生产，统一校验上架

- YAML 文件上传
- AI Skill 辅助生成
- 在线编辑与同步生成
- 格式 / 语义 / 血缘 / 冲突校验

AI 生成草稿 · 人工确认定义

理解与管理
一份定义服务不同角色

- 模型 / 指标 / 维度详情
- OSI 概览与关系图谱
- 业务知识与 AI Context
- YAML 原文、SQL 与血缘

业务可读 · 技术可查 · AI 可用

消费与分发
让可信语义进入真实任务

- MCP / Skill / OpenAPI
- SemanticView 场景化分发
- 下游数据集同步
- 调用统计与消费明细

从“登记过”走向“真正被使用”

版本与变更
让语义资产持续可信

- 版本记录、Diff 与回滚
- 上游变更感知与影响分析
- 负责人待办与审批
- 下游通知与消费保护

有 Owner · 可追溯 · 可保鲜

核心：ANT OSI 可信语义模型

统一、可执行、可交换的业务语义契约

数据集 | 指标 | 维度 | 业务限定 | 关系 | AI Context | Owner / 版本 | 血缘 / 变更上下文

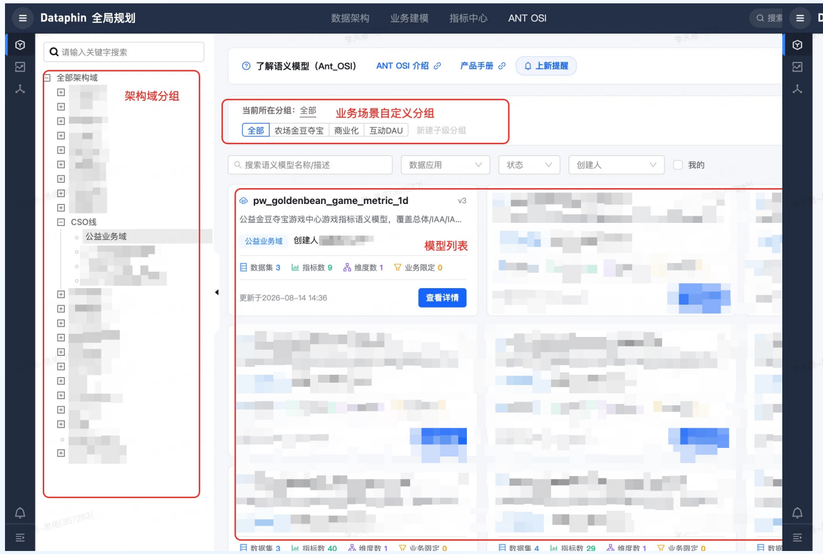

发现与组织

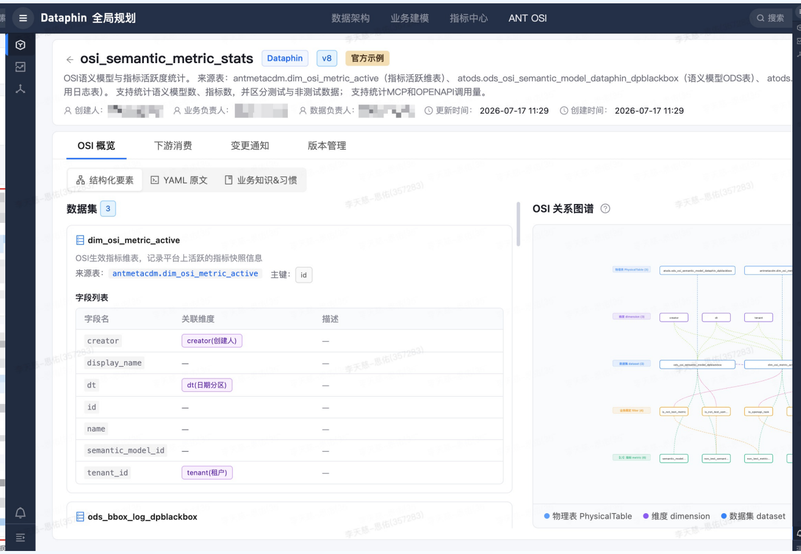

理解与管理

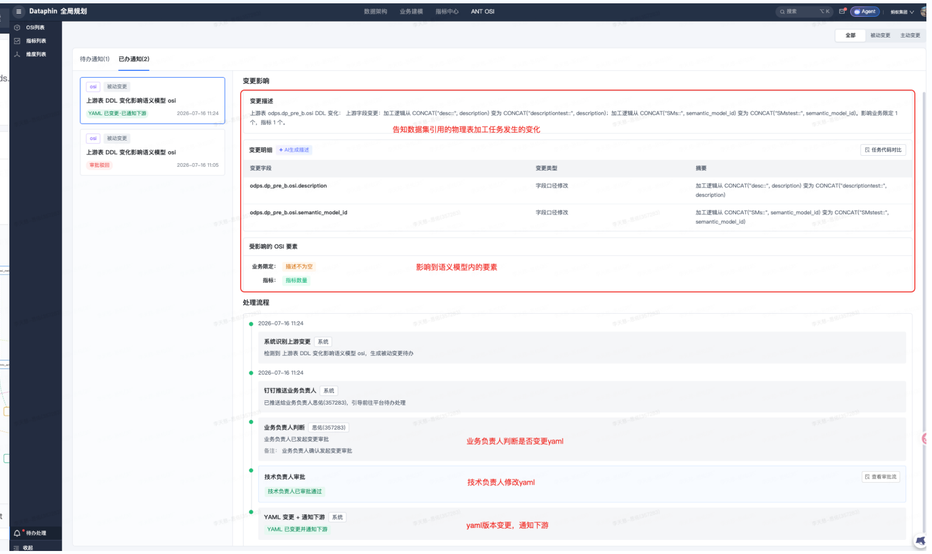

变更感知

蚂蚁集团 ANT GROUP

实证结果：从 200+ 模型到 88% 准确率

以语义模型为核心，构建具备供给、治理、消费能力的规模化语义基础设施

> **主结论**：语义供给已从孤立 PoC 进入跨域规模；内部评测进一步显示，语义模型与业务知识将 SQL 正确率从 **60%** 提升到 **88%**，但距 **95%** 业务目标仍差 **7 pp**。

供给规模与效率

250+
语义模型
可检索、组合、治理的模型底座

15000+
指标
统一口径覆盖真实分析对象

1500+
数据集
连接语义与物理数据

30+
架构域
跨团队、跨主题域覆盖

天级 → 小时级
建模效率
传统天级 → AI 辅助小时级

内部评测 · 生成 SQL 正确率阶梯

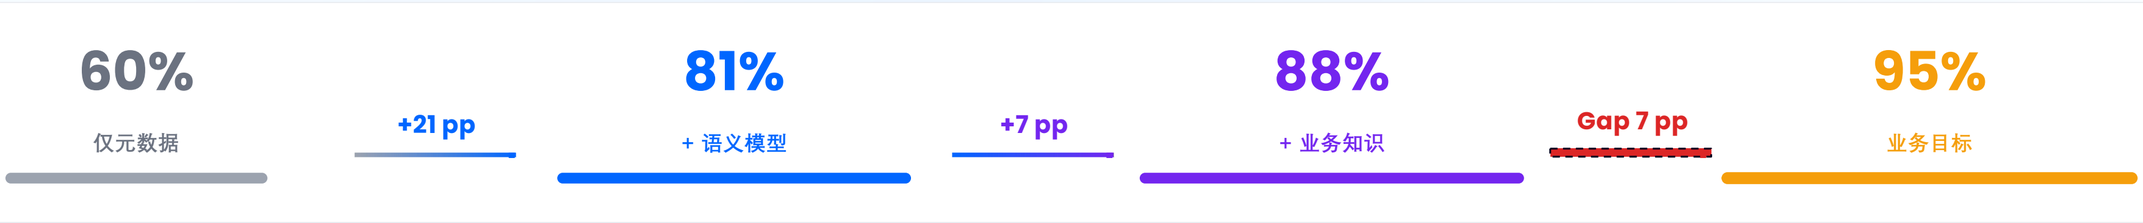

LLM: OpenAI **gpt-5.6-sol / medium** · 评测集: 业务方常问数据问题, n=100 · 指标: 生成 SQL 正确率

收益机制

指标对齐（权威口径） **+ 数据集定位**（粒度） **+ 规则补全**（默认值 / 排除项） **+ 路径规划**（受控 Join Path） **+ …**

> **消费侧结果**：取数周期在缩短的同时，结果更可信；结果可追溯到指标、维度、过滤、数据来源和口径。

外部证据：业务语义上下文显著提升数据问答可靠性

配对研究显示 +17 ~ +27 pp 是常态区间；厂商公开评测方向一致但两类证据必须分层解读。

> **主结论**：同一模型、同一问题集的配对研究显示，权威业务上下文通常带来 **+17 ~ +27 pp** 的准确率提升；厂商公开评测也呈现同一方向，但两类证据必须分层解读。

第一层 | 高置信度配对证据

研究 / 场景	Baseline	+业务上下文	提升
Cube 2026 Contoso Retail, n=99	45.5–50.5%	**67.7–68.7%**	+17.2 ~ +23.2
Bayer 药物警戒, n=60	8.3%	**78.3%**	**+70.0**
BIRD 大规模 NL2SQL	34.88%	**54.89%**	**+20.01**
data.world 企业保险	16.7%	**54.2%**	**+37.5**
Luo et al. 临床问答	37%	**98%**	**+61**

Cube: 三前沿模型加语义层后统计上不可区分; Bayer: 仅缩Schema不够，上下文是关键变量; BIRD: 人类专家也获益+20.59 pp; data.world: 幻觉减少，错误更易追踪; Luo: 幻觉率同时从约63%降至1.7%

第二层 | 厂商公开结果（方向性佐证）

厂商 / 产品	评测结果	解读边界
dbt Labs	**90.0%** → **98.2%** **84.1%** → **100.0%**	高基线仍有收益 厂商评测
Snowflake Cortex Analyst	约45% → **>90%** n=150	内部 BI 测试集
AtScale	语义层 **92.5%** 高复杂度 0% → **70%**	总体无可比 baseline
Databricks AI/BI Genie	**53%** → **80%** → **100%** n=15	小样本；展示覆盖深度的阶梯收益
Tiger Data	加 Semantic Catalog 后 **+27 pp**	未披露绝对起止值

语义覆盖越深 → 准确率越高 → 失败从静默幻觉转向拒答或可追溯错误

+ 17 ~ +27 pp 是多数独立评测的常态区间，**+60 ~ +70 pp** 是专业场景极值；不同领域、指标和实现不合并求平均。

架构启示：优先建设权威业务上下文及其覆盖深度，让模型在被正确定义的问题空间中工作；模型升级、RAG、微调和提示工程应建立在这一基础上。

Semantic Layers for Reliable LLM-Powered Data Analytics: A Paired Benchmark of Accuracy and Hallucination Across Three Frontier Models · https://arxiv.org/abs/2604.25149 · 厂商结果来自各自公开技术博客和产品文档，详见参考文献；不等同于同行评审结果。

实践一：模型构建 -- 语义模型构建示例

通过简化案例，展示如何遵循方法论，从存量资产出发，逐步形成结构化语义模型

资产上游链路

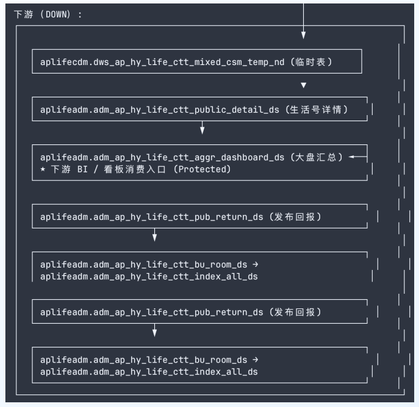

资产下游链路

#	表名	层级	角色	说明
1	aplifecdm.dws_ap_hy_life_ctt_mixed_csm_nd	DWS	主数据集	内容消费汇总 Cube 表，按多维 ROLLUP 聚合
2	aplifecdm.dws_ap_hy_life_ctt_mixed_csm_1d	DWS	明细数据集	用户粒度日汇总，含 user_id/ctt_id，支持 COUNT DISTINCT
3	aplifecdm.dim_ap_hy_life_ctt_public_ext_info_dd	DIM	维度表	生活号扩展信息（名称、是否特色、账号质量等）

梳理链路上的明细/汇总/应用表

指标类别	指标	加工口径（来源：加工 SQL CTE 6 dim_agg_csm）
消费活跃	csm_ctt_dau	COUNT(CASE WHEN csm_ctt_cnt_1d > 0 THEN 1 END)
	csm_ctt_wau	COUNT(CASE WHEN csm_ctt_cnt_7d > 0 THEN 1 END)
	csm_ctt_mau	COUNT(CASE WHEN csm_ctt_cnt_30d > 0 THEN 1 END)
	csm_ctt_mtd_mau	COUNT(CASE WHEN csm_ctt_cnt_mtd > 0 THEN 1 END)
消费次数	csm_ctt_cnt_1d/7d/30d	SUM(csm_ctt_cnt_1d) for respective windows
消费时长	csm_ctt_time_1d/7d/30d	SUM(csm_ctt_time_1d) / 1000（毫秒→秒）
有效消费	csm_ctt_5s_dau/wau/mau/...	同消费类，条件为 _5s > 0
播放活跃	play_dau/wau/mau/...	同消费类，条件为 play_ctt_cnt > 0
特色播放	tese_play_ctt_cnt	SUM(CASE WHEN is_tese='Y' THEN play_ctt_cnt_1d END)
5s用户播放	user_5s_play_ctt_cnt/ time	SUM(CASE WHEN csm_ctt_cnt_1d_5s > 0 THEN play_ctt_cnt_1d END)
消费内容数	csm_ctt_num	COUNT(CASE WHEN csm_ctt_cnt_1d_5s > 0 THEN 1 END)（ctt_id 粒度）

存量指标口径梳理

输入：基于 xxx 表构建语义模型

根据加工 SQL 和 1d 表（用户粒度日汇总，含 user_id 和 ctt_id）的结构，抽取纯原子指标。

🔑 数据层级关系

```
1d 表（dws_ap_hy_life_ctt_mixed_csm_1d）
  ├── 粒度：用户+内容+日（有 user_id、ctt_id）
  ├── 角色：明细基表 → 用于定义 L1 原子指标的聚合表达式
  └── 关键度量字段：csm_ctt_cnt_1d, csm_ctt_time_1d, csm_ctt_cnt_1d_5s,
                    play_ctt_cnt_1d, play_ctt_time_1d, ...

nd 表（dws_ap_hy_life_ctt_mixed_csm_nd）
  ├── 粒度：维度组合+日（Cube 预聚合）
  ├── 角色：主数据集 → 直接承载 L3 派生指标的物理字段
  └── 加工方式：从 1d 表 ROLLUP 聚合
```

L1 虚拟原子指标（纯概念基座）

#	名称	类型	虚拟表达式	概念层来源
1	csm_user_cnt	虚拟	"-- virtual: 内容消费用户数，基座为 COUNT(DISTINCT user_id)"	从 1d 表 COUNT(CASE WHEN csm_ctt_cnt_1d > 0 THEN 1 END)
2	csm_ctt_cnt	虚拟	"-- virtual: 内容消费次数，基座为 SUM(csm_ctt_cnt_1d)"	从 1d 表 SUM(csm_ctt_cnt_1d)
3	csm_ctt_time	虚拟	"-- virtual: 内容消费时长(秒)，基座为 SUM(csm_ctt_time_1d)/1000"	从 1d 表 SUM(csm_ctt_time_1d) / 1000
4	csm_ctt_cnt_5s	虚拟	"-- virtual: 5s+有效消费次数，基座为 SUM(csm_ctt_cnt_1d_5s)"	从 1d 表 SUM(csm_ctt_cnt_1d_5s)
5	csm_ctt_time_5s	虚拟	"-- virtual: 5s+有效消费时长(秒)，基座为 SUM(csm_ctt_time_1d_5s)/1000"	从 1d 表 SUM(csm_ctt_time_1d_5s) / 1000
6	play_user_cnt	虚拟	"-- virtual: 内容播放用户数，基座为 COUNT(DISTINCT user_id)"	从 1d 表 COUNT(CASE WHEN play_ctt_cnt_1d > 0 THEN 1 END)
7	play_ctt_cnt	虚拟	"-- virtual: 内容播放次数，基座为 SUM(play_ctt_cnt_1d)"	从 1d 表 SUM(play_ctt_cnt_1d)
8	play_ctt_time	虚拟	"-- virtual: 内容播放时长(秒)，基座为 SUM(play_ctt_time_1d)"	从 1d 表 SUM(play_ctt_time_1d)
9	play_ctt_cnt_5s	虚拟	"-- virtual: 5s+有效播放次数，基座为 SUM(play_ctt_cnt_1d_5s)"	从 1d 表 SUM(play_ctt_cnt_1d_5s)
10	play_ctt_time_5s	虚拟	"-- virtual: 5s+有效播放时长(秒)，基座为 SUM(play_ctt_time_1d_5s)"	从 1d 表 SUM(play_ctt_time_1d_5s)
11	csm_ctt_num	虚拟	"-- virtual: 消费内容数，基座为 COUNT(DISTINCT ctt_id)"	从 1d 表 COUNT(CASE WHEN csm_ctt_cnt_1d_5s > 0 THEN 1 END)

证据来源：加工 *SQL dim_agg_csm + content_agg_csm CTE* 中各指标的聚合逻辑直接引用 *1d* 表的 *per-user-per-day* 字段。

提取原子指标

L2 名称	L1 引用	Filter 组合	对应 nd 表物理字段族	说明
csm_user_cnt_main	${csm_user_cnt}	${is_ctt_domain}	csm_ctt_dau/wau/mau/mtd_mau	内容域消费用户数
csm_cnt_main	${csm_ctt_cnt}	${is_ctt_domain}	csm_ctt_cnt_1d/7d/30d	内容域消费次数
csm_time_main	${csm_ctt_time}	${is_ctt_domain}	csm_ctt_time_1d/7d/30d	内容域消费时长
csm_cnt_5s_main	${csm_ctt_cnt_5s}	${is_ctt_domain}	csm_ctt_cnt_1d_5s/7d_5s/30d_5s	内容域有效消费次数
csm_time_5s_main	${csm_ctt_time_5s}	${is_ctt_domain}	csm_ctt_time_1d_5s/7d_5s/30d_5s	内容域有效消费时长
play_user_cnt_main	${play_user_cnt}	${is_ctt_domain}	play_dau/wau/mau/mtd_mau	内容域播放用户数
play_cnt_main	${play_ctt_cnt}	${is_ctt_domain}	play_ctt_cnt_1d/7d/30d	内容域播放次数
play_time_main	${play_ctt_time}	${is_ctt_domain}	play_ctt_time_1d/7d/30d	内容域播放时长
play_cnt_5s_main	${play_ctt_cnt_5s}	${is_ctt_domain}	play_ctt_cnt_1d_5s/7d_5s/30d_5s	内容域有效播放次数
play_time_5s_main	${play_ctt_time_5s}	${is_ctt_domain}	play_ctt_time_1d_5s/7d_5s/30d_5s	内容域有效播放时长
csm_num_main	${csm_ctt_num}	${is_ctt_domain}	csm_ctt_num_1d/7d/30d	内容域消费内容数
tese_play_cnt_main	${play_ctt_cnt}	${is_ctt_domain} + ${is_tese}	tese_play_ctt_cnt_1d/7d/30d	内容域特色播放次数
user_5s_play_cnt_main	${play_ctt_cnt}	${is_ctt_domain} + 含 5s 消费的用户限定	user_5s_play_ctt_cnt_1d	5s用户播放次数
user_5s_play_time_main	${play_ctt_time}	${is_ctt_domain} + 含 5s 消费的用户限定	user_5s_play_ctt_time_1d	5s用户播放时长

提取派生指标

模型构建: 构建结构示例

示例：构建结果可视化

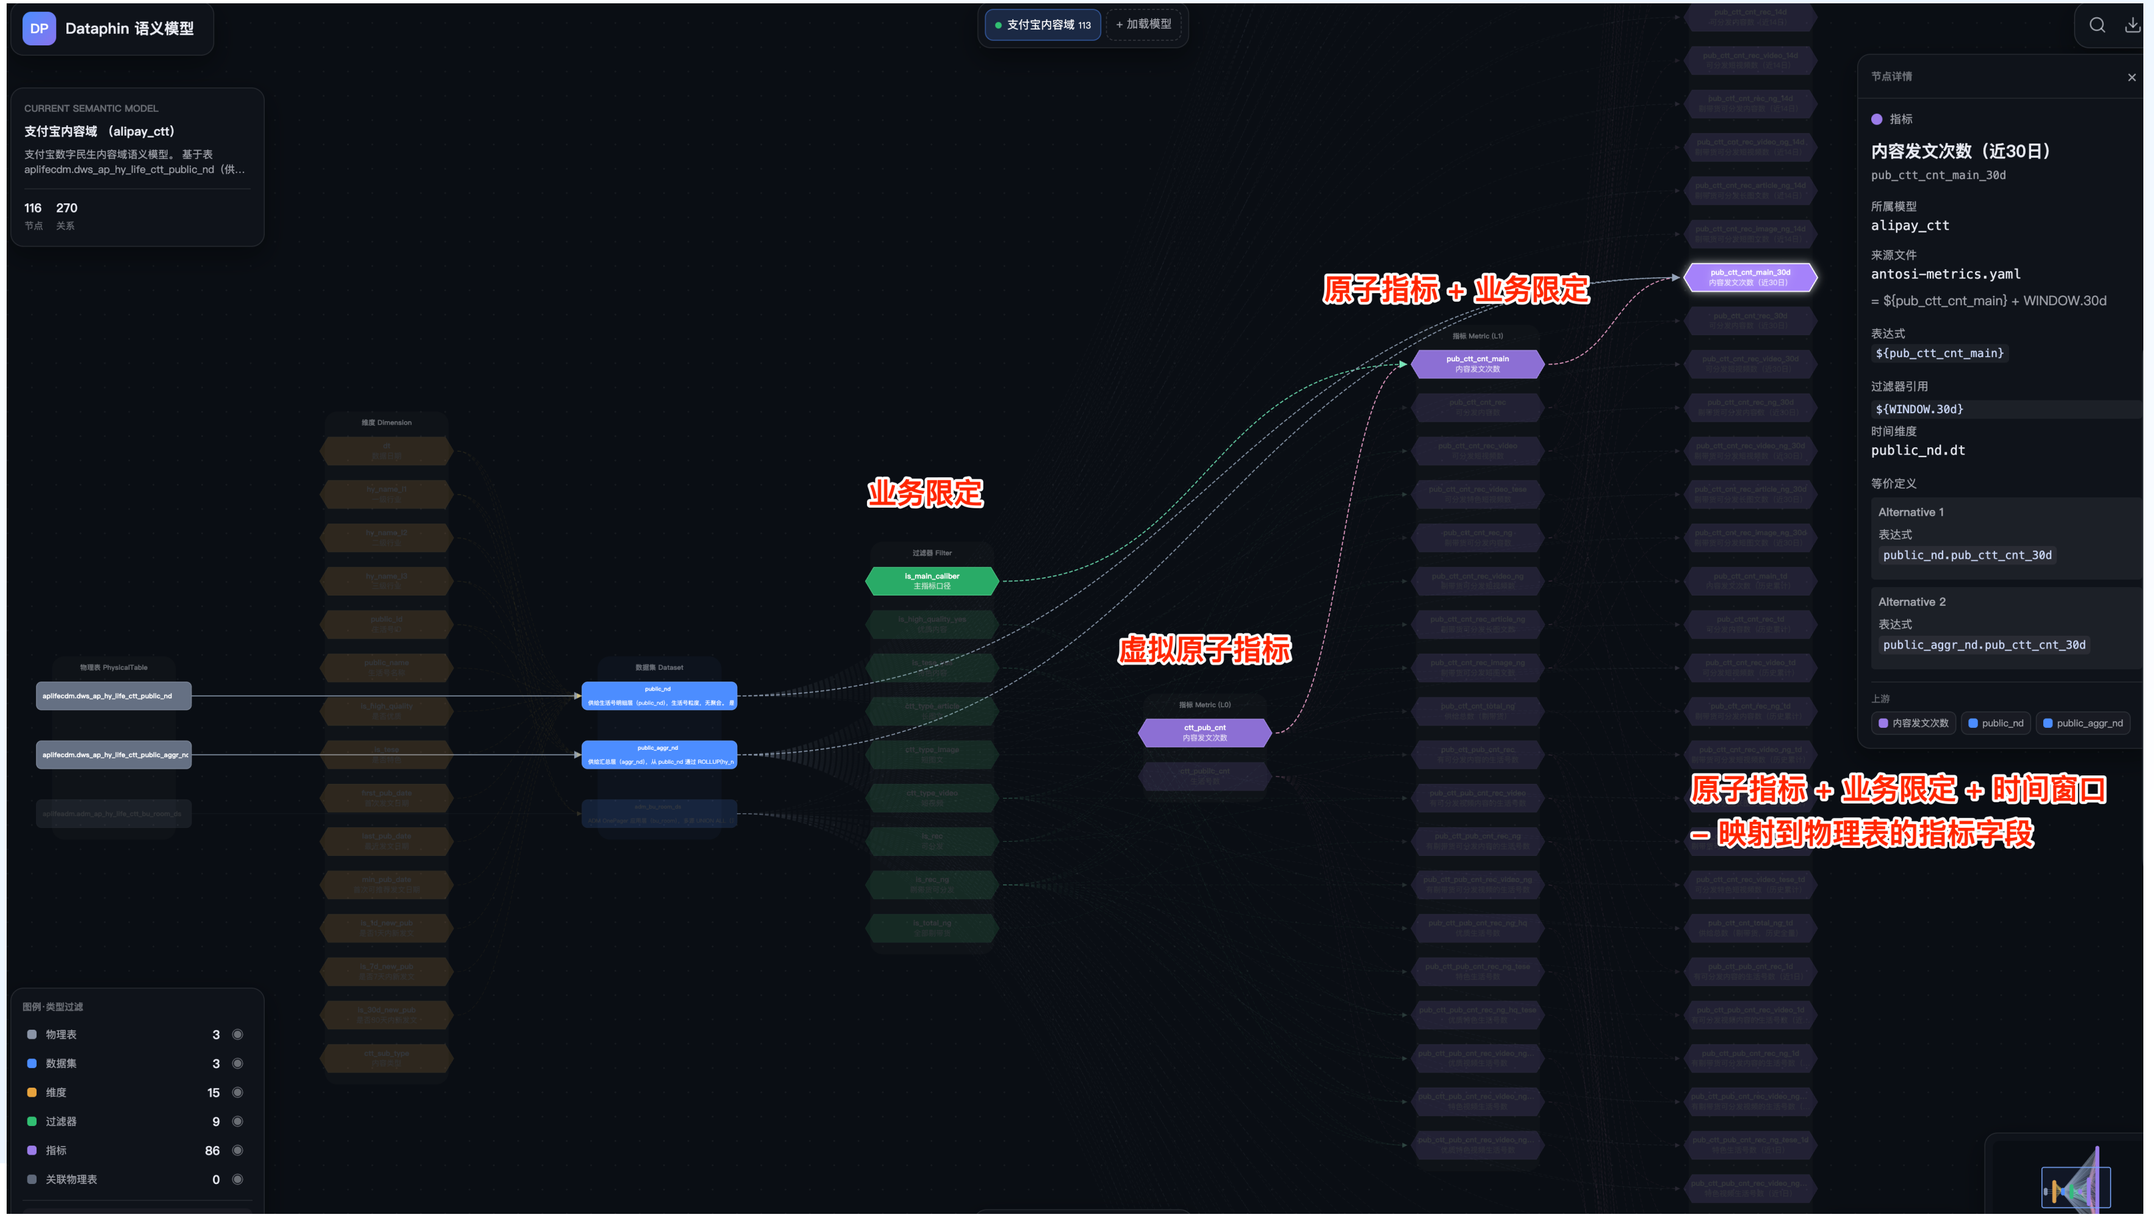

蚂蚁集团 ANT GROUP

实践二: 语义模型驱动研发——“退卡率”研发示例

不看生成了多少文件，而看业务 Spec、语义模型、SQL、质量规则、发布版本和消费反馈能否逐项对齐、双向追溯。

> 查看"两轮充电省钱卡退卡率"，并按合作方和卡有效期类型拆分。

六阶段产物链：同一规约逐步编译

阶段 1
结构化需求
Spec / 基线 / SHA
Owner确认核心口径

阶段 2
语义模型
grain=card_no
3指标+2维度
5 YAML+Manifest

阶段 3
开发实现
粒度设计/DDL/DML
Impl Manifest
禁止模型外依赖

阶段 4
质量校验
Spec-Model-SQL 一致性
+冒烟+DQC
validation=passed

阶段 5
发布变更
模型→任务→DQC
model id/task/rule可关联

阶段 6
消费反馈
报表/API/Agent 复用
反馈携带版本→semantic_explore

← 下一轮语义变更提案

阶段 #1：将模糊诉求收敛为可执行业务契约

契约要素	已确认规则	对工程的约束
指标公式	退卡率 = 退卡量 / 发卡量	分子分母必须独立保留
业务范围	biz_scene='EBIKE_CHARGE' card_type='BENEFIT_CARD'	不得静默扩展范围
事件边界	首次非CANCELLED=发卡 首次CANCELLED=退卡	进入Filter和ETL
统计去重	截止日累计; card_no去重	粒度、窗口、聚合一致
分析维度	partner_code card_validity_type, stat_date	目标表粒度确定
异常可加性	分母0→NULL; 非可加比率	先汇总分子分母再重算

指标 → 字段 → 质量 → 消费的稳定映射

业务口径	Ant-OSI 指标	SQL 输出字段	质量门禁	消费要求
累计发卡量	issued_card_count	cumulative_issued_card_count	首次非取消、去重、累计窗口、非负	作为分母并单独展示
累计退卡量	cancelled_card_count	cumulative_cancelled_card_count	首次取消、去重、不得大于累计发卡量	作为分子并单独展示
退卡率	**card_cancel_rate**	**card_cancel_rate**	公式重算、零分母NULL、[0,1]、非可加	不直接跨粒度平均

阶段 #4：质量校验结果

3指标 + 2维度全部覆盖

→ semantic_metric_validation = **passed**

→ 冒烟成功，按目标粒度返回 3 行

→ bad_rows = **0**，无重复

→ 模型先于任务发布，4 DQC 启用，全部 **SUCCESS**

任务成功的四项标准

01 **逐项对齐**：Spec → Ant-OSI → Manifest → SQL 输出字段

02 **边界落地**：只实现已声明对象，并有真实执行证据

03 **发布可关联**：model_id、task、DQC 属同一次发布

04 **反馈可定位**：保留分子分母窗口维度，可追溯版本

维度	传统模式	语义驱动模式
研发周期	约1工作日	约1小时

04 总结与展望

踩坑教训：从“重构建”到“体系化质量保障”

模型数量增长，会放大缺失规则、重复定义与过期口径的影响；质量需要进入构建和日常运营

问题暴露 → 深刻教训 → 问题归因

01 问题暴露：越建越多，越用越错

信息缺失	→	默认规则空白，Agent 猜测 默认 PV / 行业 ALL / 零分母未定义
覆盖过期	→	字段、枚举、口径已变化 旧定义仍在用；变化未触发复检
聚合错误	→	平均比率 / 累加快照，数字失真 Join 扇出，结果数字失真
口径冲突	→	部门定义各自“正确” 权威口径与适用范围不清
相似混淆	→	PV / UV、累计 / 新增难选择 描述存在，选择依据仍然不足
语义重复	→	限定与维度复制多份 修改不同步，定义逐渐分叉

只建不管，无法支撑可信消费

02 深刻教训：宁缺勿滥，知识内嵌

候选模型 → 验证 → 可发布模型

模型内嵌知识：默认口径　边界规则

AI 提取候选规则 → 业务 Owner 确认关键规则

衡量重点	从“生成了多少”转向“哪些经过验证”
质量上限	模型质量决定 NL2SQL 的可达上限
优先发布	范围清楚、证据充分、有人持续维护
修复沉淀	每次生产修复 → 下次发布的检查项

体系化质保，降低人工兜底成本

03 问题归因：标准与保鲜双重缺失

构建侧　文件合法 ≠ 业务正确

缺少：自动化业务校验、准入底线
场景验收基线

后果：规则不全、计算有误，也能发布

运行侧　一次正确 ≠ 持续有效

缺少：周期巡检、消费反馈、变更感知
影响分析、问题归属、修复回归与退出

后果：旧定义被消费，人工反复兜底同类错误

质量必须进入构建与日常运营

把教训与归因转为工程要求

后续动作 / 四位一体质量保障体系

三项并列协同，不表示串行执行

A 建立质量标准

诊断	准入	验收
Q1–Q6	G1–G4	场景验收

缺失	→	Q4 完整性
混淆	→	Q5 确定性
聚合	→	Q2 与 G2
口径	→	权威定义 / 适用范围
重复	→	复用 / 引用依赖

证据：质量检查与验收结果

产出：可判定的发布标准

B 加强构建校验

检查 → 验算 / 测试 → 门禁

失败：阻断发布　通过：场景验收

检查：默认值 / 粒度 / 关系 / 去重
异常边界 / 权限均纳入校验
声明：粒度、基数、可加性
验算：真实数据核对结果
测试：默认、边界用例与自然语言改写
依赖：公共对象引用一致性
证据：验算结果与用例记录

产出：拦截带病上线

C 建立巡检与反馈机制

发现 → 定位 → Owner → 修复 → 回归 → 检查项

触发：字段 / 枚举 / 口径变化
周期巡检 / 消费反馈
定位与归属：血缘分析 → 业务 Owner
修复与复检：更新规则 → 问题集回归
退出分支：低质退出；重复合并与迁移
生产修复 → 检查项，回流 A / B
证据：反馈、修复与回归记录

产出：持续保鲜与迭代

共同准则：优先发布范围清楚、证据充分、有人维护的模型；每次生产修复，都沉淀为下一次发布的检查项。

检查项回流 A / B：生产修复沉淀为下一次发布检查

没有质量保障体系的语义模型，上线即负债。

最佳实践：场景驱动、高价值优先、人机共治

从真实问题开始，让契约进入真实查询，再用反馈修订下一版模型。

落地路径

经验 → 行动 → 产出

01 选对场景

① 场景驱动 · ② 高价值优先

行动：优先高频、高价值或高争议的核心指标
盘点可复用资产；明确首批范围、Owner 与非目标
产出：核心指标清单与 Owner；
权威答案与基准问题集
原则：先验证首批可信资产，再扩覆盖范围

02 建对口径

③ AI 辅助与人工决策结合

行动：AI 提取证据、生成候选、检查缺失
人作关键决策，将决定写入可执行契约
产出：可追溯模型与决策记录；
门禁与业务验收证据

03 进入消费

④ 接入真实任务链路

行动：报表、API、Agent 复用同一语义契约
记录对象使用、查询失败、歧义与用户纠正
产出：可执行查询与解释；
版本化消费记录与真实问题台账

04 持续运营

⑤ 建立长期运营机制

行动：变更感知与周期巡检；Owner 处置、回归与版本更新
评估持续低质、无人维护或已被替代对象的退出
产出：长期回归集与保鲜状态；
修复闭环、迁移与下线记录

消费反馈 + 变更 / 巡检发现

六个关键节点

人做决策，AI 与平台执行

节点 / 谁做决策	决策内容 / 执行支持
方案选择 业务 / 建模负责人	决定模型边界与方案取舍 AI 提出候选方案
存量融合 数据 / 治理 Owner	决定资产复用、合并与冲突取舍 AI 盘点与冲突检测
核心口径确认 业务 Owner	确认公式、时间、默认值、例外与非目标 AI 生成契约草稿
风险接受 业务 / 数据负责人	确认剩余风险 工具提供验证证据
权限审批 权限责任人	批准访问范围 平台落实访问控制
发布验收 业务 / 发布负责人	依据测试、版本和交付证据确认可用 平台回归与发布回查

AI / 工具：提取、生成、校验、回归；人：确认口径、风险、权限与发布。
贯穿建设与运营，按变更触发；非固定审批顺序。

一次反馈如何关闭

消费问题：模型版本、对象、查询条件、预期 / 实际结果

运营发现：变更感知、周期巡检

Owner 判断
根因与影响范围

→ 修订
模型 / 实现 / 选择规则

→ 回归通过
原问题及相邻边界

→ 更新发布 → 验证消费结果
符合预期才关闭问题

→ 回到 03

回归未通过 / 消费结果仍不符合预期 → 返回 Owner 判断与修订，不关闭

条件性退出 → 持续低质 / 无人维护 / 已被替代 → 影响评估 → 迁移安排与历史保留 → 退出消费

修订契约 ↗ 02 建对口径

调整范围 ↗ 01 选对场景

相关决定 → 对应人工责任检查点

成效看四项

覆盖 | 正确性 | 真实使用 | 问题闭环

资产数量只能描述规模

AI 把证据变成草稿，人把草稿变成可信定义，平台让定义持续生效。

展望未来：拓展知识边界，持续提升语义可信度

贯通业务认知、资产知识与组织经验，以真实消费反馈驱动语义模型持续优化

蚂蚁集团 ANT GROUP

融合业务本体

业务概念不统一，跨域理解难

- 业务对象与关系建模
- 跨域概念映射
- 本体与语义模型关联

目标 统一业务语言、让 AI 理解业务

01

深化资产知识图谱

资产知识不够广，理解不够深

- 扩展资产知识覆盖
- 深挖加工逻辑与口径
- 补充质量与使用知识

目标 理解资产、选对数据

02

现有基础

可信语义层

统一语义 · 可信消费

增强业务知识与经验沉淀

知识分散，隐性经验依赖个人

- 汇聚显性业务知识
- 挖掘隐性规则与经验
- 权威确认与按需供给

目标 让组织经验可复用

03

深化反馈驱动的语义自迭代

反馈难闭环，同类问题易复发

- 反馈采集与根因诊断
- 最小修复与分级审核
- 回归验证与受控发布

目标 自动持续提升模型质量

04

让业务可理解、资产可复用、知识可传承、模型可演进

THANKS