让 Data Agent 的每个回答都有据可查
—— 企业级可信问数的工程闭环

李明皇

Datastrato 资深软件工程师

Apache Gravitino PMC Member

Datastrato

Datastrato

目录

CONTENTS

01 从“能问数”到“可信问数”

02 Gravitino Semantic Model：语义与治理

03 Data Agent：可信执行与结果证据

04 Semantic Generator：构建、审核与维护

05 实践复盘与落地路径

业务问题：BIRD 问数案例

2012 年 2 月，消费超过 528.3 的客户占比是多少？

Original question | 英文原题

In February 2012, what percentage of customers consumed more than 528.3?

BIRD evidence | 原题附加提示

February 2012 refers to '201202' in yearmonth.date;
The first 4 strings of the Date values in the yearmonth table can represent year;
The 5th and 6th string of the date can refer to month.

案例来源：BIRD #1493 | 公开 Text-to-SQL 评测基准。

Datastrato

基础问数链路

通用 Agent + 问数 Skill + MCP 数据工具

业务问题

2012 年 2 月，
消费超过 528.3 的
客户占比是多少？

承接 BIRD #1493
（含原题提示）

自然语言
问题

通用 Agent

理解问题 · 规划步骤 · 组织查询 · 整理答案

- LLM / Agent Runtime
- **问数 Skill**（可选）
  查询步骤 · 检查规则 · 输出规范
- MCP Client
- Memory / Reasoning

MCP

发现工具
调用工具
获取结果

MCP 数据工具

查看表结构 · 执行查询 · 返回结果

- MCP Server
- Schema Explorer
  （表结构 / 字段 / 示例）
- Query Execution
  （执行 SQL）
- Metadata & Catalog
  （元数据 / 权限 / 审计）
- ...

SQL 查询

查询结果

数据平台（示例）

执行 SQL · 返回结果

Hive　Trino
Iceberg　MySQL
PostgreSQL　...

典型执行流程

1. **了解数据**
   - 发现相关表和字段
   - 理解业务上下文
2. **生成并检查 SQL**
   - 基于 schema 和问数 Skill 生成 SQL
   - 检查语法与逻辑，必要时修正
3. **调用查询工具**
   - 通过 MCP 调用工具执行
   - 获取查询结果（必要时基于错误修正）
4. **整理回答**
   - 将结果转为用户可理解的自然语言回答
   - 补充关键数据与说明

查询成功，是否就满足企业使用要求？

Datastrato

企业级可信问数

查询成功只是起点 —— 还需要明确业务口径、授权范围、结果可追溯、并能持续维护

业务问题

2012 年 2 月，
消费超过 528.3 的
客户占比是多少？

假设该结果将作为
企业正式报表的依据

1 统计谁？ 业务口径要明确

同一个问题，不同的口径会得到不同的结果

口径 A：当月消费客户中的占比

当月消费超过 528.3 的客户数 / 当月有消费的客户数

只统计当月有消费的客户

口径 B：全部客户中的占比

当月消费超过 528.3 的客户数 / 截至当月的全部客户数

统计全部客户
（包含当月未消费的客户）

2 谁在查？ 授权范围要落实

同一份定义，不同用户看到的结果可能不同，但都可以正确

华东区域经理	只能查看华东区域客户	按照相同口径计算得到华东的占比
华南区域经理	只能查看华南区域客户	按照相同口径计算得到华南的占比
总部人员	可查看全国客户	按照相同口径计算得到全国的占比

3 如何核对？ 结果需要可追溯

- 这个占比的分子、分母分别是多少？
- 依据的是哪份已确认的业务定义？
- 能否找到实际使用的 SQL、数据范围和计算结果？

4 怎么维护？ 口径与权限变化后如何生效

- 如果业务口径调整（例如分母从当月消费客户改为全部客户），哪些报表和使用方需要更新？
- 如果用户的授权范围发生变化，如何确认新的权限已在查询中生效，并完成回归验证？

可信，不是人人得到同一个数，而是答案符合明确的业务口径与授权范围。

Apache Gravitino：统一元数据管理

连接多源数据资产，提供统一的元数据模型、接口与治理能力。

Datastrato

使用方

通过统一入口
访问和管理元数据

数据应用

- **Data Agent**：问数应用 / 智能助手
- **BI / 分析应用**：数据分析 / 数据产品

查询与处理引擎

Apache Spark · Trino · Apache Flink · Daft

元数据访问与管理 REST API · Iceberg REST · Lance REST · MCP Server · Java / Python SDK

Apache Gravitino

统一元数据管理平台

- **多源接入**：目录联邦 · 连接器；跨系统元数据访问
- **统一管理**：统一对象模型与接口；表 / 分区统计 · 血缘事件集成
- **统一治理**：所有者 · 角色与授权；标签 · 策略关联 · 元数据审计

Metalake → Catalog → Schema
Table / View / Function · Fileset · ML Model · Topic · SemanticModel

连接器：访问和管理源系统元数据

数据来源

对接现有平台，
管理元数据

湖仓与表格式

Hive · Iceberg · Paimon · AWS Glue · Lance · Hudi · Delta Lake

关系型与分析数据库

MySQL · PostgreSQL · ClickHouse · Doris · StarRocks

文件与对象存储

HDFS · Amazon S3 · GCS · ADLS · 阿里云 OSS · 腾讯云 COS

消息队列

Apache Kafka

带来的价值

- **减少重复适配**：应用共享统一元数据入口
- **统一管理入口**：一致的对象模型与访问方式
- **支撑可信问数**：为语义定义、权限管理和审计提供基础

在统一元数据管理的基础上，如何进一步管理业务语义？

Gravitino Semantic Model

以 Ossie 兼容结构表达业务语义，在 Gravitino 中统一管理与治理。

Datastrato

Datasets / Fields | Relationships | Metrics | AI Context | Custom Extensions

Gravitino 治理（复用统一治理机制） | 所有者 Owner | 版本与变更 Version | 标签 Tag | 授权 Policy / RBAC | 审计 Audit

源表 Schema

DDL 节选

```
CREATE TABLE yearmonth (
  CustomerID INTEGER NOT NULL
    REFERENCES customers,
  Date TEXT NOT NULL,
  Consumption REAL,
  PRIMARY KEY (Date, CustomerID)
);

CREATE TABLE customers (
  CustomerID INTEGER PRIMARY KEY,
  ...
);
```

保留关键字段与关联，省略其他约束

原始 Evidence · BIRD #1493

February 2012 refers to '201202' in yearmonth.date; The first 4 strings of the Date values in the yearmonth table can represent year; The 5th and 6th string of the date can refer to month.

BIRD · debit_card_specializing

语义建模

Gravitino Semantic Model

Catalog → Schema → Semantic Model

customer_spend

数据集与维度 yearmonth：客户 × 月份，主键 Date + CustomerID

字段名	数据类型	业务含义
CustomerID	Integer	客户唯一标识
Date	String	统计月份（YYYYMM），时间维度
Consumption	Float	客户月度消费金额

customers：客户数据集，主键 CustomerID

客户月记录数

技术名称	customer_month_count
计算表达式	COUNT(yearmonth.CustomerID)
业务含义	每个客户每月计一次，不同月份分别计数

AI Context

使用说明	用于客户月记录规模；按月统计时表示该月有记录的客户数。
同义词	客户月记录数、客户月数
示例	各月份分别有多少客户记录？

独立客户数

技术名称	distinct_customer_count
计算表达式	COUNT(DISTINCT yearmonth.CustomerID)
业务含义	所选范围内有记录的客户，同一客户只计一次

AI Context

使用说明	用于单月或跨月的独立客户规模；期间去重数不能由各月去重数直接相加。
同义词	独立客户数、去重客户数
示例	这个季度有记录的独立客户有多少？

Relationships | yearmonth.CustomerID → customers.CustomerID（多对一）

Custom Extensions | vendor_name + data：厂商特定扩展信息 结构说明

从自然语言到可执行 SQL

Data Agent 的职责分工：理解与规划、语义编译、执行与返回

Datastrato

Gravitino Semantic Model

- **指标** 业务度量与计算定义
- **维度** 业务实体与属性
- **关系** 表关联与语义映射
- **AI Context** 业务术语与上下文

发现与理解语义

提供计算定义与关联

用户问题

Data Agent

理解与规划

- 理解问题与发现语义
- 选择指标、维度与过滤条件
- 形成结构化查询请求

LLM：语义选择与任务规划

结构化请求

Semantic Compiler

校验与编译

- 校验请求与模型成员引用
- 依据语义定义组织计算与关联
- 生成引擎可执行 SQL

程序：确定性编译

SQL

Query Engine

执行与返回

- 执行查询与计算
- 返回数据与执行状态
- 保留查询记录

引擎：数据计算

查询结果返回 Agent

2012 年 2 月，消费超过 528.3 的客户占比是多少？ | 数据集：yearmonth | query 参数

分子：同月且满足金额条件

```
{
  "filters": {"logic": "all", "filters": [
      {"field": "Date", "operator": "=", "value": "201202"},
      {"field": "Consumption", "operator": ">", "value": 528.3}]},
  "measures": [{"field": "customer_month_count"}]
}
```

分母：同月客户范围

```
{
  "filters": {"logic": "all", "filters": [
      {"field": "Date", "operator": "=", "value": "201202"}]},
  "measures": [{"field": "customer_month_count"}]
}
```

两次查询返回计数 → Python 计算：分子 ÷ 分母 × 100 → Agent 组织答案

链路观测与执行记录 | 工具调用 • 请求参数 • 实际 SQL • 结果引用 • 耗时与错误

Data Agent 的流程编排：在约束中保留探索能力

限定业务范围，识别分析任务，选择合适的执行流程

Datastrato

1 业务域上下文

数据资产与语义模型
可用数据表、语义关系
与计算逻辑

业务术语与指标口径
业务定义、口径规则
与指标体系

分析范围与可访问资源
可分析的业务域、
数据范围与工具资源

限定候选范围 · 按需加载定义

提供
业务上下文

2 分层识别与流程路由

用户问题

追问 / 修正 / 已确认条件

能力范围识别
判断问题是否在业务域与能力范围内

- 语义解释
- 产品帮助与闲聊
- 超出职责提示

问数分析
在业务范围内的分析问题

分析任务识别
将问题拆解为可执行的分析任务

- 指标取数
- 对比与拆解
- 诊断与探索

复杂问题可组合多个任务

执行策略选择
基于任务类型、上下文与资源，选择合适的执行策略

- **已验证回答**
  匹配 → 确认与填参 → 既定流程
- **即时分析**
  组织查询 → 编译与计算
- **探索式分析**
  动态选择下一步

3 受约束的探索

继续

选择下一步
基于当前问题、上下文与证据

执行分析步骤
调用工具、生成并执行查询

更新证据与状态
收集结果、记录推理与中间结论

继续 / 结束

结束

输出已有发现
给出可解释的结论与依据

- **工具：** 按任务提供，继承业务范围
- **执行：** 语义口径与程序计算
- **收敛：** 证据、预算与停止条件

业务域不替代权限校验；权限约束贯穿发现与执行

让 LLM 决定分析方向，让程序保证执行，让证据支撑结论

DAOon

DataFun.

把约束落到工具与执行流程中

用程序拦截可检查的错误，为业务判断保留核验依据。

Datastrato

1 明确操作与输入

让工具知道：对什么结果，做什么操作

示例

月度去重计数 → 季度独立客户数

⚠ 计数不能直接相加，需回源重算

工具契约 + 语义校验

- 区分指标查询、结果转换、派生计算
- 使用结果引用，保留来源与分组粒度
- 依据指标定义校验聚合与关联

模型提出请求，程序检查合法性

2 显式维护分析状态

把已确认条件保存在对话之外

示例

二月消费占比 → 再看三月

⚠ 同步更新分子、分母及派生结果

结构化上下文 + 依赖管理

- 保存指标、时间、过滤条件与结果引用
- LLM 提出变更，程序更新任务状态
- 标记受影响结果失效，沿依赖补算

历史摘要帮助理解，任务状态承载条件

3 控制执行与回退

工具切换不能绕过原有约束

示例

语义不支持 ≠ 执行超时

⚠ 不同错误，进入不同处理路径

工具网关 + 错误分流

- 执行超时 → 限次重试或优化
- 语义不支持 → 调整分析或澄清
- 权限拒绝 → 停止越权执行
- SQL / Python：权限、隔离与资源限制

安全执行不等于业务计算正确

工具输入与输出 · 定义与结果引用 · 调用依赖 → 支持核验与定位

约束减少错误，依据支持核验；用户意图与业务口径仍需判断。

让答案关联到实际工具调用

从关键结论出发，追溯输入条件、输出结果与调用依赖。

Datastrato

BIRD #1493 · 客户消费占比

2012 年 2 月，在当月有月度记录的客户中，

月度消费金额超过 528.3 的客户占约 66.62%。

口径与范围 ↑ 时间与条件 ↑ 数值依据 ↑

1 语义定义读取

输入

模型： yearmonth

指标： customer_month_count

输出 · 定义依据

粒度： 每客户、每月一条记录

金额： 客户月度消费金额

计数： COUNT(CustomerID)

单月主键唯一，对应当月有记录的客户

2 查询调用

分子查询

输入： Date = '201202'
Consumption > 528.3

输出： R1 = 12,208

分母查询

输入： Date = '201202'

输出： R2 = 18,324

两次查询均使用 customer_month_count

结果引用 →

3 计算调用

输入 · 结果引用

A ← R1， B ← R2

计算： A ÷ B

输出 · R3

0.66623008...

百分比展示： 66.62%

计算结果同样是工具输出

关联记录：语义定义版本 · 查询参数与 SQL · 结果引用 · 调用依赖

有据可查，才能核验；执行成功，不等于业务理解正确。

让可信问数覆盖更多业务场景

从一次可信回答，走向更多业务场景的持续可用。

Datastrato

01 换个时间与维度

“把二月改成三月，
再按客户类型拆一下。”

已有定义可复用

使用已支持的指标与维度
调整参数，沿用同一业务口径

不必重新解释计算逻辑

02 换一个业务问题

“我们业务里的授信客户占比，
也能直接问吗？”

尚未覆盖，需要补充定义

定位业务口径与数据关系
构建并审核缺失的语义定义

数据接入之后，还要理解业务

03 业务口径发生变化

“口径已经改了，
下个月还能放心问吗？”

定义变化，需要维护

更新定义，定位受影响的分析
回归检查，明确新口径适用范围

不必每次提醒系统口径已变

如何让更多问题进入可信执行路径，**而不是每扩一个场景都重新手工建模？**

Semantic Generator：LLM与确定性程序协同建模

Datastrato

从多源材料形成语义候选，经校验与审核进入正式资产。

多源业务材料

- Schema 与字段说明
- 历史 SQL 与报表定义
- 业务文档
- 已有语义模型

Semantic Generator

受限修复

确定性处理

解析材料，提取计算事实

组织对象引用与来源证据

LLM 语义推断

归纳业务含义，对齐对象

提出候选定义与待确认项

候选

程序校验与反馈

检查结构、引用与定义

保留冲突和未决项

人工审核

确认业务口径，处理冲突

批准合格候选

确认发布

已发布语义资产

Gravitino

Semantic Model

指标 · 维度 · 关系 · AI Context

- Semantic Compiler
- Data Agent

持续维护

- 元数据变更事件（Gravitino Event Listener）
- 业务反馈

→ **影响定位**：分析影响范围

→ **候选更新**：生成并调整语义候选

→ **审核发布**：人工审核并发布

→ 回到 Gravitino Semantic Model

程序提取事实，LLM归纳语义，校验与审核控制发布。

从多源材料到可复用的业务定义

程序提取计算事实，LLM完成业务语义对齐。

Datastrato

输入材料

表结构

```
yearmonth
CustomerID · Date · Consumption
PRIMARY KEY (Date, CustomerID)
```

查询片段

```
COUNT(CustomerID)
WHERE Date = '201202'
```

(查询片段，非完整 SQL)

问题与说明

2012年2月，消费金额超过528.3的客户占比

Date 使用 YYYYMM 表示月份

协同建模

确定性事实抽取

- 表与字段引用
- 复合主键与计数表达式
- 查询中的时间和金额条件

LLM 业务语义对齐

- 把计数解释为客户月记录数
- 关联时间、金额与业务概念
- 形成名称、说明和待确认项

可复用候选

指标

```
customer_month_count
COUNT(CustomerID)
```

维度

CustomerID：客户标识

Date：月份，YYYYMM

字段语义

Consumption：客户月度消费金额

候选保留来源，进入校验与审核

沉淀为语义：

计数定义、客户月粒度、字段业务含义

留在查询中：

月份 201202、金额阈值 528.3

复用业务定义，不把单次问法固化成指标。

大批量材料如何拆分、恢复与核对

按证据分配工作，按实际消息预算执行，按输入条件恢复。

Datastrato

01 去重与引用

SELECT ...　SELECT ...

sql_ref

SQL 规范化生成 sql_ref
相同查询合并来源证据

02 按证据分任务

- 表与字段：结构和局部说明
- 指标：SQL 观测 / 报表需求
- 关系：有观测信号的表对
- 文档全文不同每张表重复广播

03 按预算递归拆分

任务

子任务1　子任务2　子任务3

- 预算包含 System Prompt 与 JSON Schema
- 超限继续拆分，保留输出预算
- 原子任务仍超限则明确失败

04 恢复与汇合

检查点

结果1　结果2　结果3

- 兼容的检查点复用
- 失败任务继续执行
- 核对计划叶子与完成集合

检查点复用，先核对请求指纹

输入内容　任务类型　模型　Prompt 版本　输出 Schema　预算策略

- 同一运行或指定恢复来源，兼容条件满足后复用
- 核对缺失、重复与意外结果，覆盖完整不等于语义正确

减少重复上下文，让大任务可拆分、可恢复、可核对。

候选不完整或有冲突，LLM如何修复？

把问题转成精确反馈，限定修复范围，保留仍未解决的缺口。

Datastrato

1 结构化候选

```
candidate_index: 2
expression: COUNT(CustomerNo)
source_model: yearmonth
```

字段引用待校验

2 程序反馈

CustomerNo 不在可用字段中

可用字段：**CustomerID**

允许修复：**候选 2**

有效候选保持不变

3 受限修复

引用修正：

`COUNT(CustomerID)`

- 只修改指定项或补缺失项
- 修复后重新校验

再校验

4 候选与未决项

通过检查：进入审核

仍缺口径：保留 `definition_gaps`

需要补充依据或业务确认

指标生成支持**一次有界修复**，未解决问题不靠反复猜测**填满**。

对象归并时，按字段限定修改权限

可综合表达

`description`
`label`

→ 基于来源归纳业务含义

保持计算定义整体

`expression`
`unit`

→ 从已有候选中选择；实质分歧依留待审

引用真实存在，仍需判断是否足以支持业务结论。

让模型修复明确的问题，让缺口保持可见。

带着字段依据完成审核

把重新读材料、逐项编写，转成对具体建议和差异的核对。

Datastrato

语义候选审核

待审核

对象： customer_month_count

字段	当前值	建议值
计算定义	COUNT(CustomerID)	COUNT(CustomerID) 保持原定义
说明 description	客户数	按客户月记录计数；单月每客户一条记录 查看依据 采用建议
适用范围	待补充	单月查询对应当月有记录的客户；跨月需区分记录数与去重客户数。

修改候选后重新待审，并复核受影响的定义。

保存修改 | 批准候选

保存与批准分开

字段依据

来源对象： yearmonth

结构化位置： 主键与字段定义

```
PRIMARY KEY (Date, CustomerID)
```

查询依据

```
COUNT(CustomerID)
```

建议理由

复合主键约束客户月唯一性；
跨月计数不等于去重客户数。

待确认

业务需要记录数，还是跨月去重客户数?

查看依据
定位字段来源与结构化位置

→

采用或修改
对照建议与现有值确认处理

→

重新校验
检查受影响的定义与冲突

→

批准发布
完成审核并发布到语义资产

无变化保留比较记录；实质差异和证据缺口进入审核。

建议可追溯，修改可核对，批准与发布有明确边界。

DAOon

DataFun.

变更后，如何维护并确认生效？

围绕变化生成候选，发布后核对消费端实际读取的定义。

Datastrato

变更驱动的维护设计



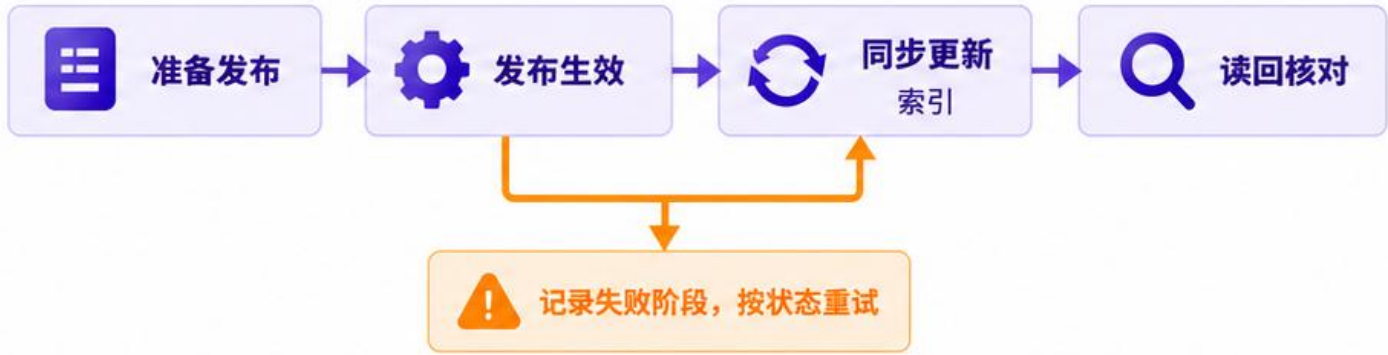
变更差异

对象 customer_month_count

当前说明：	客户数
建议说明：	客户月记录数
计算表达式：	COUNT(CustomerID)，保持不变

完善口径说明，重新审核该候选

分阶段发布与消费核对



发布完成后，还要确认消费端读到了正确版本。

读回一致性不替代问数结果回归。

业务共识是可信问数的起点

先对齐统计对象与验收口径，再让模型生成和回答。

Datastrato

客户数是多少？

全量客户
客户主数据中的唯一客户

当月客户
当月有记录的唯一客户

跨月客户
指定期间内去重后的客户

同一个词，可能对应不同的统计范围。

技术与业务共同确认

对象与粒度
统计对象、粒度层级

时间与范围
统计周期、时间范围

权威依据
数据来源、表与字段

正确答案与待确认项
期望结果、需澄清的问题

语义定义
指标、维度、口径说明

评测约定
预期结果、等价表达、澄清条件

业务口径形成共识，生成与问数才有可验收的标准。

语义层如何复用已有数仓

按业务口径与数据粒度选来源，保留已有数仓的分层价值。

Datastrato

存量数仓

加工血缘

- **ODS** 原始来源 — 追溯与核对
- **DWD + DIM** 明细事实与一致维度 — 灵活分析与下钻
- **DWS** 汇总结果 — 兼容口径下复用计算
- **ADS** 场景报表 — 限定场景直接使用

Gravitino：各层元数据与血缘

按需治理后接入

按场景选择来源

面向业务的语义模型

- 指标口径
- 可用维度
- 合法关联
- 适用范围

Data Agent

销售额：按分析需求选择建模来源

先核对订单状态、退款与统计范围。

昨天各门店销售额？	按商品类别拆分销售额？	经营日报里的销售额？
DWS 门店日汇总 复用已确认的汇总口径	DWD 订单商品明细 + DIM 商品维度 汇总未保留商品维度时使用	ADS 经营日报 沿用报表已确认的统计范围

已有汇总覆盖需求时**直接复用**，缺少分析维度时**补充明细模型**。

最终回答的评测与重复运行验证

验收用户实际看到的答案，持续补充经确认的等价表示。

Datastrato

最终回答评测流程

问题输入
业务问题与必要上下文

→

Agent 最终回答
面向用户的
最终自然语言

→

结构化抽取
AnswerStructurer
只提取回答中已有信息

抽取器不接收标准答案

→

程序匹配
与 canonical 及
已审核的答案变体匹配

例：2013年SME客户消费最高的月份

04 | April | 201304

同一问题下，经确认的等价答案表示

抽取字段： peak_month

评测资产持续维护

- 发现正确表达被误判
- 人工核验后补充答案变体
- 固定版本后重新评测

同一问题，多次独立运行

同一问题
× N 次独立运行

→

正确性：
最终结果是否匹配

稳定性：
多次运行是否持续答对

固定数据、语义模型、LLM配置与评测约定

业务验收看**最终回答**，过程记录帮助**定位错误**。

正确回答与必要澄清

评测目标：能稳定答对，也能识别必须补充的信息。

Datastrato

回答决策矩阵

	直接作答	发起澄清
信息足以作答 已有的信息可以直接得出答案	**正确回答** （结果仍需通过校验）	**多余追问** 增加用户负担
缺少作答必需信息 现有信息无法得出可靠答案	**无依据断言** 猜测缺失口径	**有效澄清** 问到决定答案的缺口

澄清也需要验收标准

用户：
这个月客户数是多少？

→

有效追问：
指全量客户，还是当月有记录的客户？

- 明确本题是否需要澄清
- 补充信息后能否继续完成回答

正确回答与有效澄清分别评估，**不能只看回答率**。

业务共建与持续迭代

明确能力边界，共同验收，让信任随可验证的改进逐步积累。

Datastrato

业务方
真实问题、权威口径、验收反馈

共同维护：
问题集 · 语义定义 · 评测集

技术方
语义建模、执行链路、问题定位

小范围试点
一个业务域，明确支持范围

共同验收
正确回答与必要澄清

逐步扩展
回归通过后增加覆盖

问题处理形成闭环

记录问题 → 定位原因 → 修订定义或实现 → 回归验证

用户反馈回到问题集与评测集

业务侧的两种体验

信任积累： 边界清楚，修复可验证。

信任消耗： 承诺过大，同类错误反复。

技术与业务持续协同，才能把一次演示变成长期可用。

Datastrato

THANKS

Apache Gravitino

https://github.com/apache/gravitino

欢迎 Star & 参与贡献

DACon

DataFun.