高德路线推荐从工业引擎到大模型 Agent 的范式跃迁

演讲嘉宾：陈超

目录

CONTENT

01 一个日常规划需求

02 理解路

03 理解人

04 理解时空

05 三次范式跃迁

01 一个日常规划需求

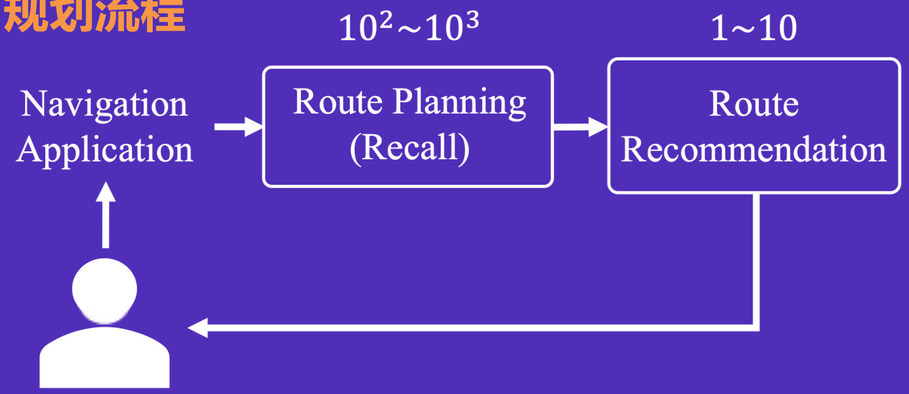
一个日常规划需求

开车去公司

输入



规划流程



路线推荐必要性

距离最短?

穿小区、低级路



环路、快速路

时间最快?



捷径运气好确实快
运气不好体验恶劣

什么是好路?

理解路

一个日常规划需求



语义理解

- 什么是顺路
- 找到加油站然后呢?
- 二环是什么?

→ 语义召回 → 语义推荐

理解人

理解时空

02 理解路

— 工业引擎如何破解路线推荐的独特难题

理解路

什么是好路?

：用户走的路就是好路

关键指标：路线重合率

路线推荐特点与难题





召回 协同过滤 (CF)
向量化召回 (DSSM)

粗排 蒸馏精排模型
细化召回模型

精排 多任务/场景学习：MMOE，STAR
特征交叉：DCN，RankMixer
用户行为序列：DIN，DISN

重排 Item交叉：attention机制
多样性：MRR，DPP，Rule
序列模型：PRM，NAR4Rec

生成式推荐 HSTU
One
FORGE

召回 道路权值计算
Dijkstra、A*
CBR
召回排序统一性

粗排 蒸馏精排模型

精排 特征交叉：要求可解释和效果兼顾
用户行为序列：非ID化序列建模

重排 Item交叉：attention不适用，局部感知
多样性：无法直接对齐用户需求
序列模型：多样性问题
去冗：规则法、阈值法，无法直接对齐用户需求

超大规模路网
实时动态信息

路线很难
唯一ID化

路线消费
强体验

业界推荐范式 —难以解决→ **路线推荐面临的问题**

理解路： 高德路线推荐工业引擎

RouteMind

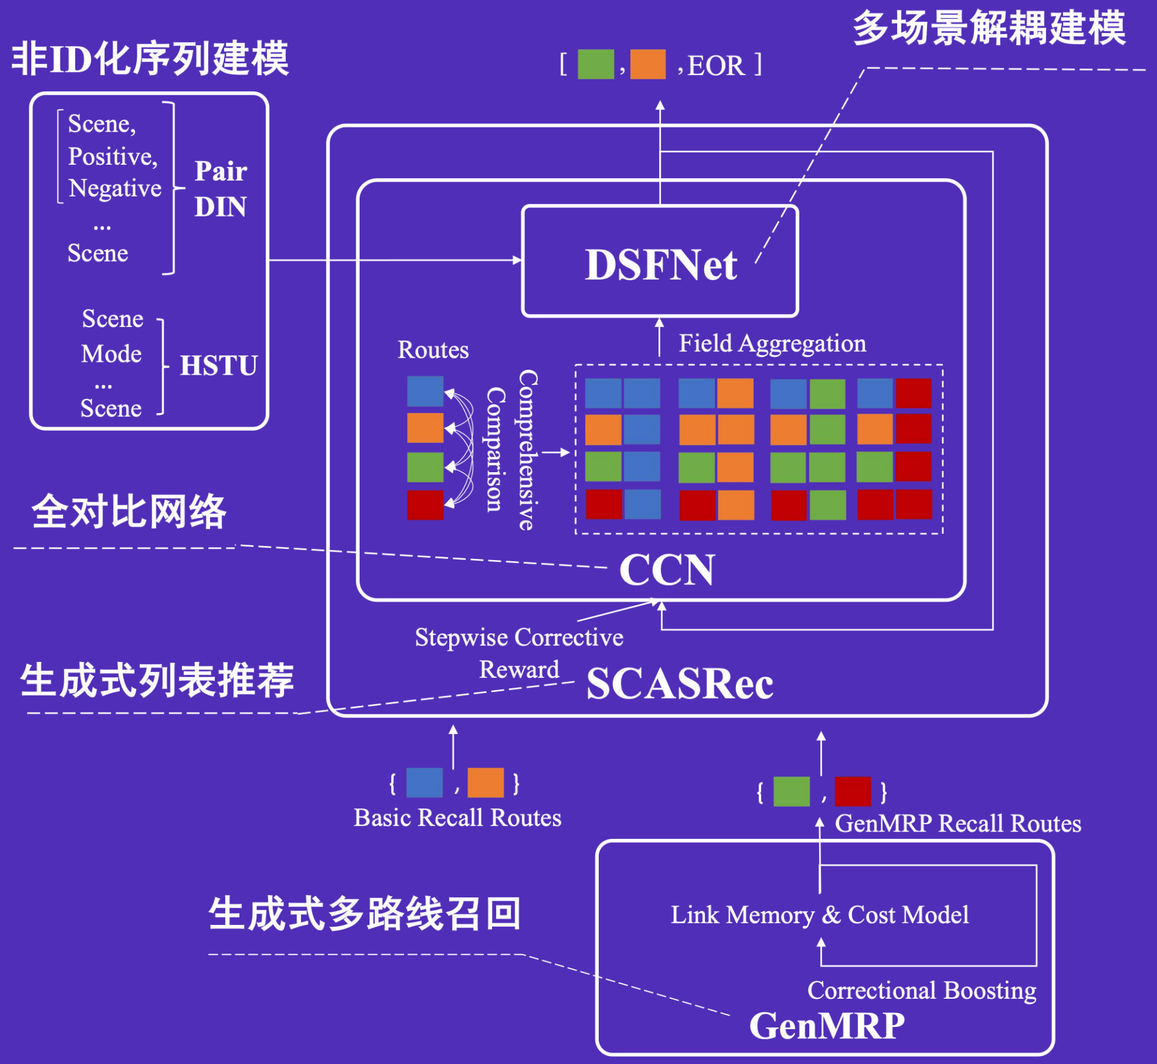
Part 1

- CCN 全对比网络 ： 解局部感知、可解释、路线对比。
- SCASRec 生成式列表推荐 ： 解多样性、冗余。
- DSFNet： 类MOE，解场景化和个性化。

Part 2

- GenMRP 生成式多路线召回 ： 解召排一致性。

RouteMind 架构



理解路：RouteMind

全对比网络

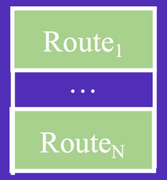
CCN (RecSys 2026)

Query-level features
Each is determined by a query

- Scenario Feature $X^s \in \mathbb{R}^{1\times F}$
- User Profile $X^u \in \mathbb{R}^{1\times F}$
- User History Sequence $X^h \in \mathbb{R}^{T\times F}$

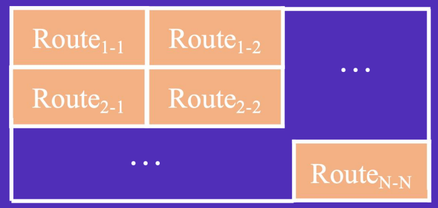
Item-level features
Each is determined by a single item

$X^r \in \mathbb{R}^{N\times F}$



Comparison-level features
Each is determined by an item pair

$X^c \in \mathbb{R}^{N\times N\times F}$

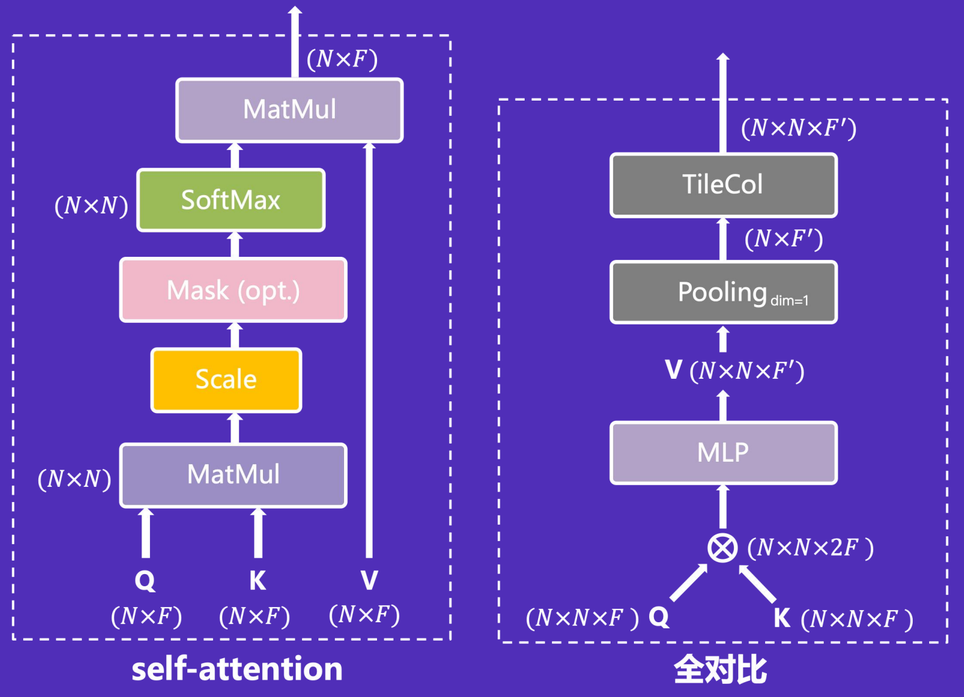


- $Route_{i-j} \neq Route_{j-i}$
- $Route_{i-j} \neq Route_{i-k}\ (j \neq k)$

两类常见维度特征与对比级特征

核心在于适配非ID化、局部感知和可解释的item交叉方法

- **对比级特征：**引入对比级特征 $N \times N \times R$ 量化任意两条路线的非重叠路段差异，增强局部感知。
- **全对比：**在候选item交叉上超越传统self-attention机制。全对比假设共现的item需要互相对比判断好坏并汇总，更适合推荐场景。
- **可解释网络：**按特征物理含义划分Field，Field 内交叉、Field 间独立。可解释性打分，用于标签感知和case调查。



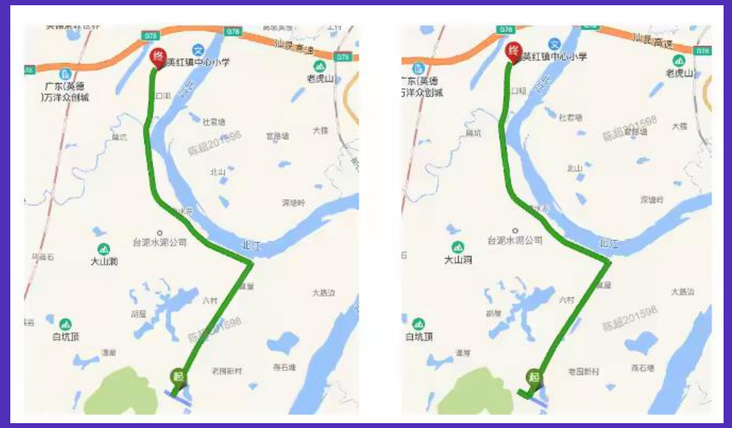
全对比与self-attention区别

理解路：RouteMind

全对比网络

CCN (RecSys 2026)

对比 case





局部感知：局部绕路识别

全对比：与不同路线对比，特征动态变化

公开数据集上SOTA

Method	AUC_1^{11}(%)	AUC_{12}^{36}(%)	AUC_{37}^{61}(%)	AUC_{62}^{72}(%)	AUC(%)
Recall	50.36	48.99	52.17	55.77	50.16
Vanilla MLP	73.55	73.71	73.70	72.09	73.62
ShareBottom (Caruana, 1997)	74.17	73.79	73.66	68.10	74.08
MMOE (Ma et al., 2018)	74.18	73.96	73.65	68.17	74.15
PLE (Tang et al., 2020)	74.21	73.93	73.87	68.43	74.16
STAR (Sheng et al., 2021)	74.18	74.01	73.72	69.54	74.13
M2M (Zhang et al., 2022)	73.57	74.04	74.17	70.64	73.67
APG (Yan et al., 2022)	72.89	72.58	73.37	70.92	72.91
HiNet (Zhou et al., 2023)	74.35	74.65	74.46	70.41	74.41
MuSeNet (Xu et al., 2023)	74.56	74.23	75.08	71.40	74.52
DSFNet (Yu et al., 2025)	74.96	75.72	75.86	72.20	75.04
DSFNet-SA	75.27	75.91	75.76	75.39	75.87
CCN (w/o PSN, X^c)	**76.67**	**76.32**	**76.40**	**75.40**	**76.72**

全量落地高德路线规划

- 驾车、新能源、公交、骑行、货车、摩托车 ...
- 各场景首路线效果提升（例：公交首选率+7pct），局部差降低（例：驾车-10%）。
- 自解释系统现为case调查的标准方案。

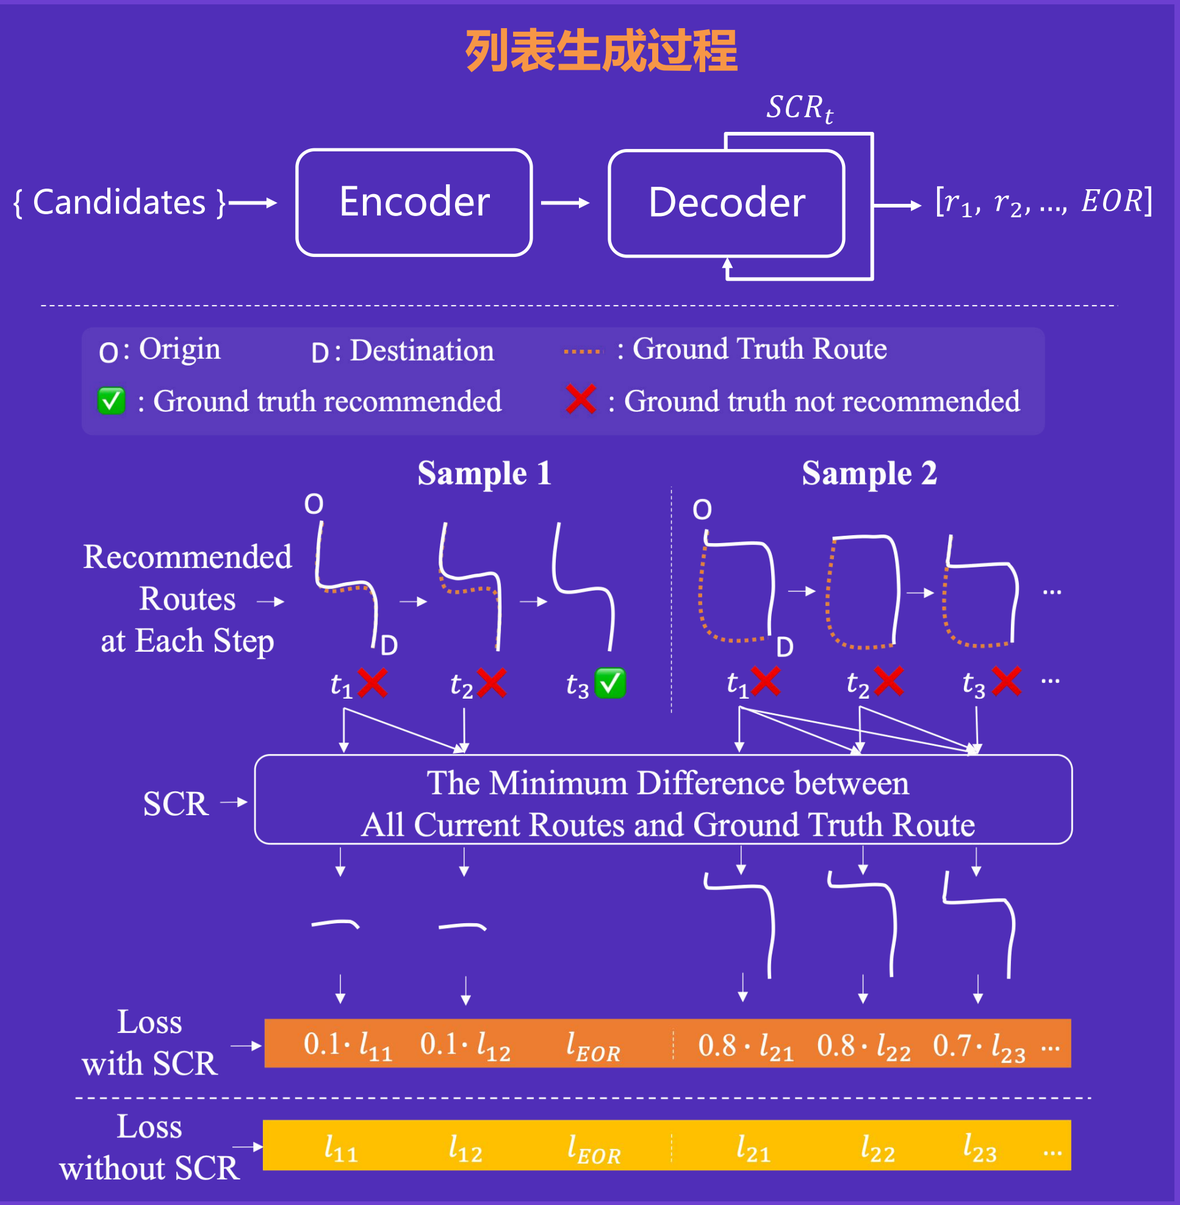
理解路：RouteMind

生成式列表推荐

SCASRec

核心在于边际路线重合率为目标的生成式列表推荐

- **多阶段统一**：统一精排、重排、去冗，避免对过多人工规则的依赖。SCASRec基于全对比进行候选集合的encoder和decoder。
- **时间步修正奖励（SCR）**：在每个时间步，以“继续推荐能带来多少额外路线重合率”为奖励信号，动态平衡质量与多样性。
- **推荐停止符（EOR）**：引入EOR作为SCR=0时的生成目标，自动停止推荐，实现去冗模型化。



理解路：RouteMind

生成式列表推荐

SCASRec

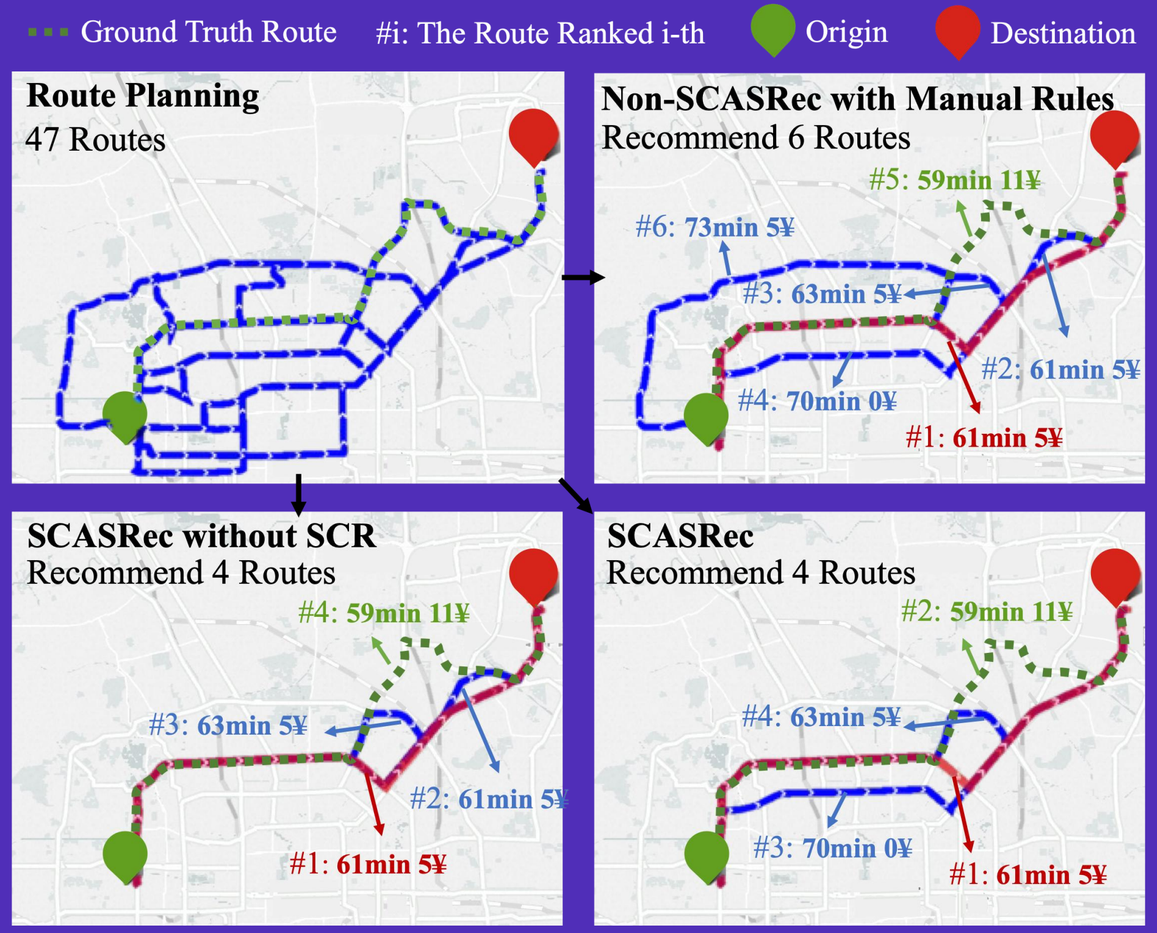
公开数据集上SOTA

Method	HR@1	HR@2	HR@3	LCR@1	LCR@2	LCR@3	MRR
MMR	37.31	70.38	94.10	58.81	76.44	84.90	0.501
DNN	35.67	71.71	94.27	57.97	76.83	84.94	0.501
DPP	38.34	70.41	94.69	59.03	76.49	85.09	0.508
PRM	36.39	72.42	94.82	58.34	77.07	85.11	0.506
Seq2Slate	36.85	73.37	94.31	58.51	77.65	85.03	0.511
NAR4Rec	**42.70**	76.87	91.28	60.46	78.11	83.85	0.487
SCASRec+RL	32.85	77.54	91.82	56.70	79.00	84.26	0.506
SCASRec	42.64	**77.65**	**94.92**	**61.11**	**79.21**	**85.23**	**0.541**

全量落地高德路线规划

- 驾车、新能源、公交、骑行、货车、摩托车 ...
- 各场景下发路线效果提升（例：驾车下发路线重合率+0.6%，多样性差-40%，差路-50%）。

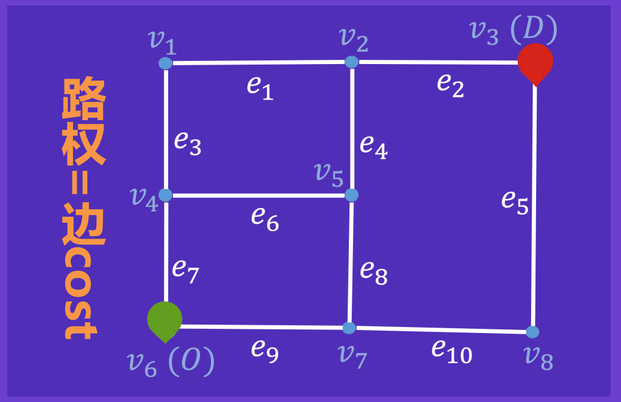
列表生成case



理解路：RouteMind

生成式路线召回

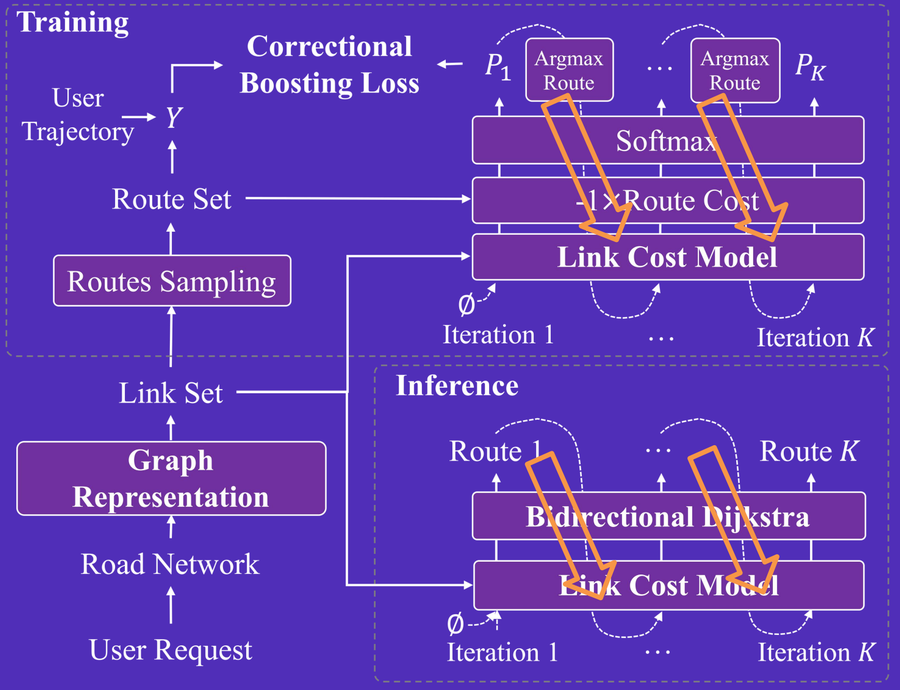
GenMRP (CIKM 2026)



核心在于边际路线重合率为目标的多轮路权生成

- **行业首个可落地请求级多路线召回模型。**基于当前环境、用户历史序列、link动静态属性、用户熟悉度、热力来动态建模道路权值。
- **校正提升机制：**以修正权值可能带来的重合度收益为导向，尽量使路线生成过程尽快覆盖用户实走，保证召回路线之间的多样性。
- **增量推理优化：**线上推理，每轮召回路线时仅更新复用次数变化的道路的权值，用微小的效果损失，换来推理耗时↓78%。

训练及推理过程



理解路：RouteMind

生成式路线召回

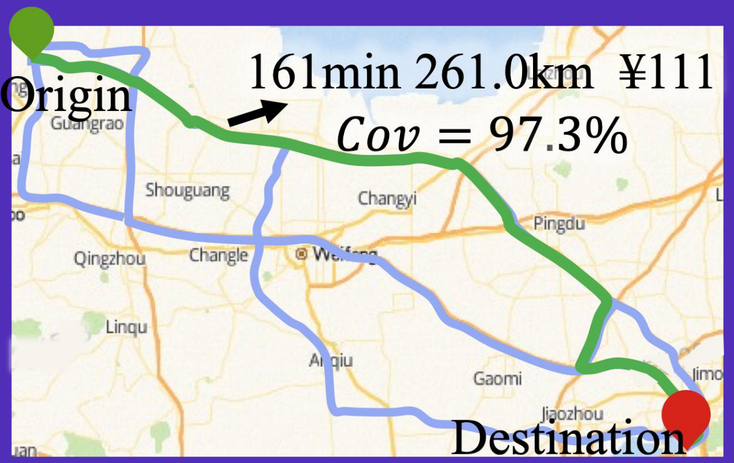
GenMRP (CIKM 2026)

公开数据集上SOTA

Method	Set_1	Set_2	Set_3	Set_4	RT(ms)
KST	79.4	76.8	78.5	76.1	18.5
KSD	76.5	73.1	75.2	72.0	22.6
KMT	72.1	67.9	71.1	67.7	22.1
KHF	35.0	80.0	41.7	79.7	21.0
2DP	75.6	74.6	74.4	73.8	49.7
DK(k=3)	74.1	72.2	73.2	70.3	43.4
GenMRP	**84.0**	**85.9**	**84.6**	**85.6**	173.5

全量落地驾车路线规划

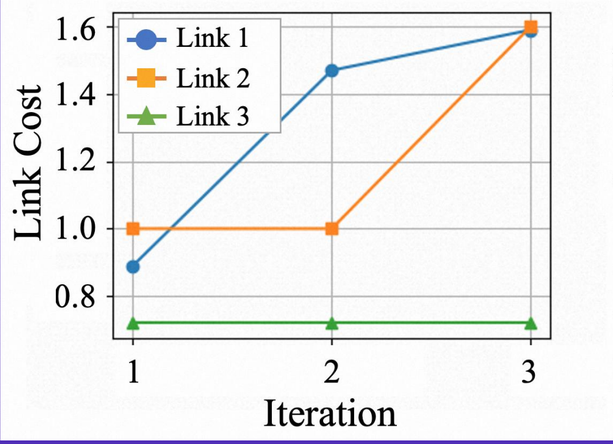
路线重合度提升 0.54%，路网重合度提升 0.67%，路线多样性指标提升 6.5%。

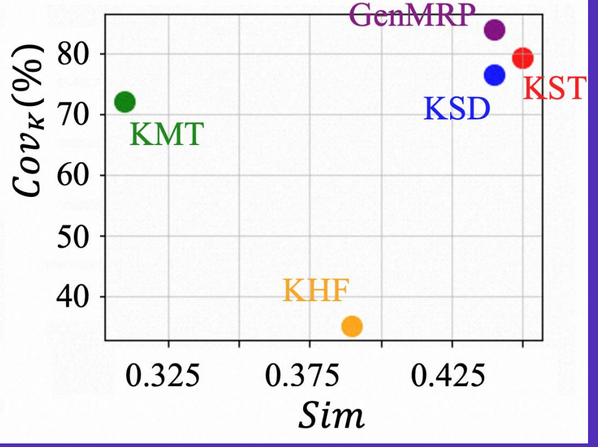


GenMRP Case
首路线及多样性均更优



Baseline





校正提升在权值上的体现
&
多样性对比

理解路



小结：CCN、SCASRec、GenMRP 把“理解路”做到了高水位，但...

系统能优化路线，但不理解人

- 自然语言需求无法直接输入。
- 复杂的时序、顺路、避让、偏好等等组合无法预先枚举。
- “人话”到“引擎约束”的翻译，是下一阶段的核心矛盾。

03 理解人

—从LLM轻量增强到路线Agent

理解人

自然语言定制路线和生成理由，是业界路线智能化的关键能力和研究方向。

我们分两阶段

LLM增强推荐 → 路线agent

Query：我要走辛店路









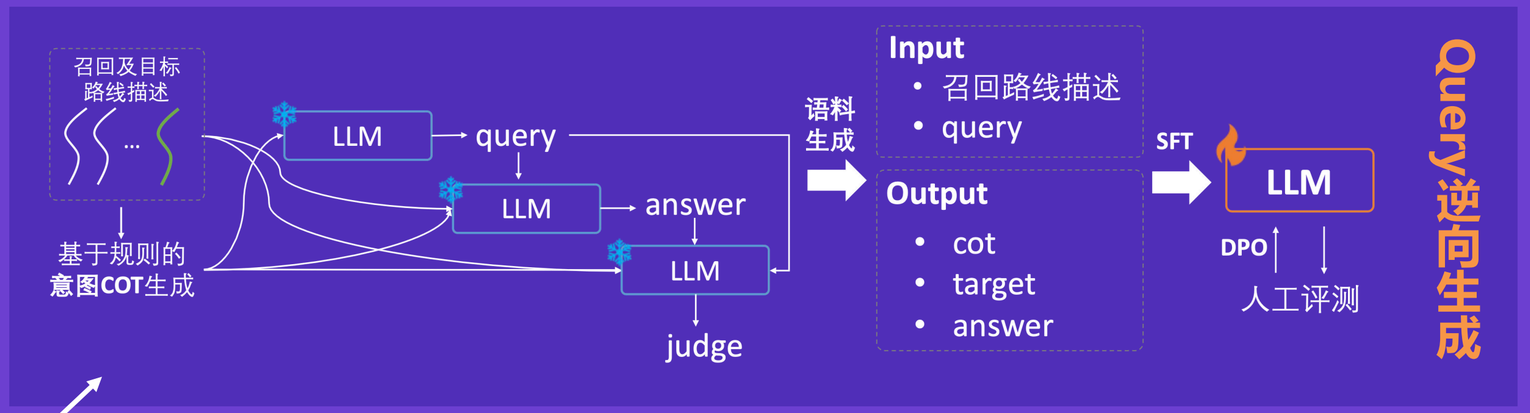


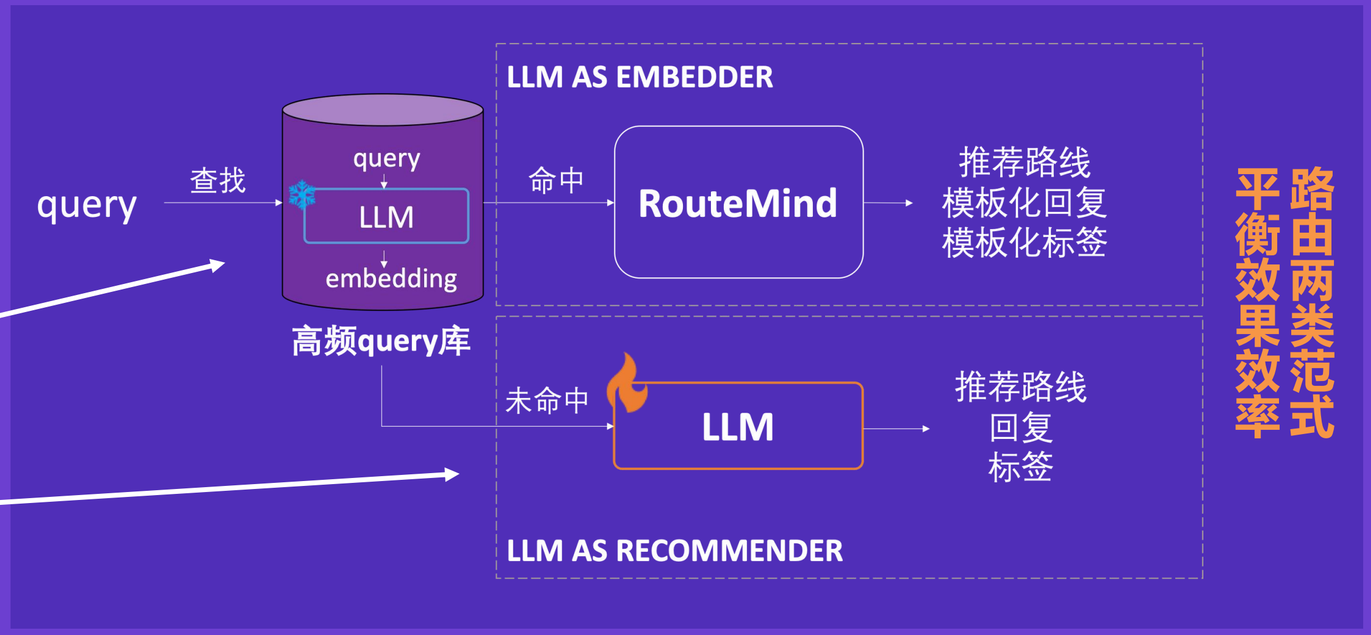
LLM增强推荐

以query逆向生成为基础的LLM+路线推荐架构

- **免训法效果差：**通用模型缺少路线知识，在效果或效率上较差。
- **模型范式取舍：LLM2Rec / Rec2LLM?** 效果和效率的平衡。

- **四阶段逆向query生成，抑制幻觉。**
- **LLM AS EMBEDDER：**用户query通过LLM进行embedding，输入到RouteMind中，负责高频简单query。
- **LLM AS RECOMMENDER**：上下文对齐到文本，LLM直接推荐路线并回复，负责复杂query。





LLM增强推荐

以query逆向生成为基础的LLM+路线推荐架构

效果及落地

- 在简单query上，语义推荐优良率达到80%。
- 定制结果接受率比普通动态推荐路线高50%。
- 接入上游agent，与车企合作。

缺陷

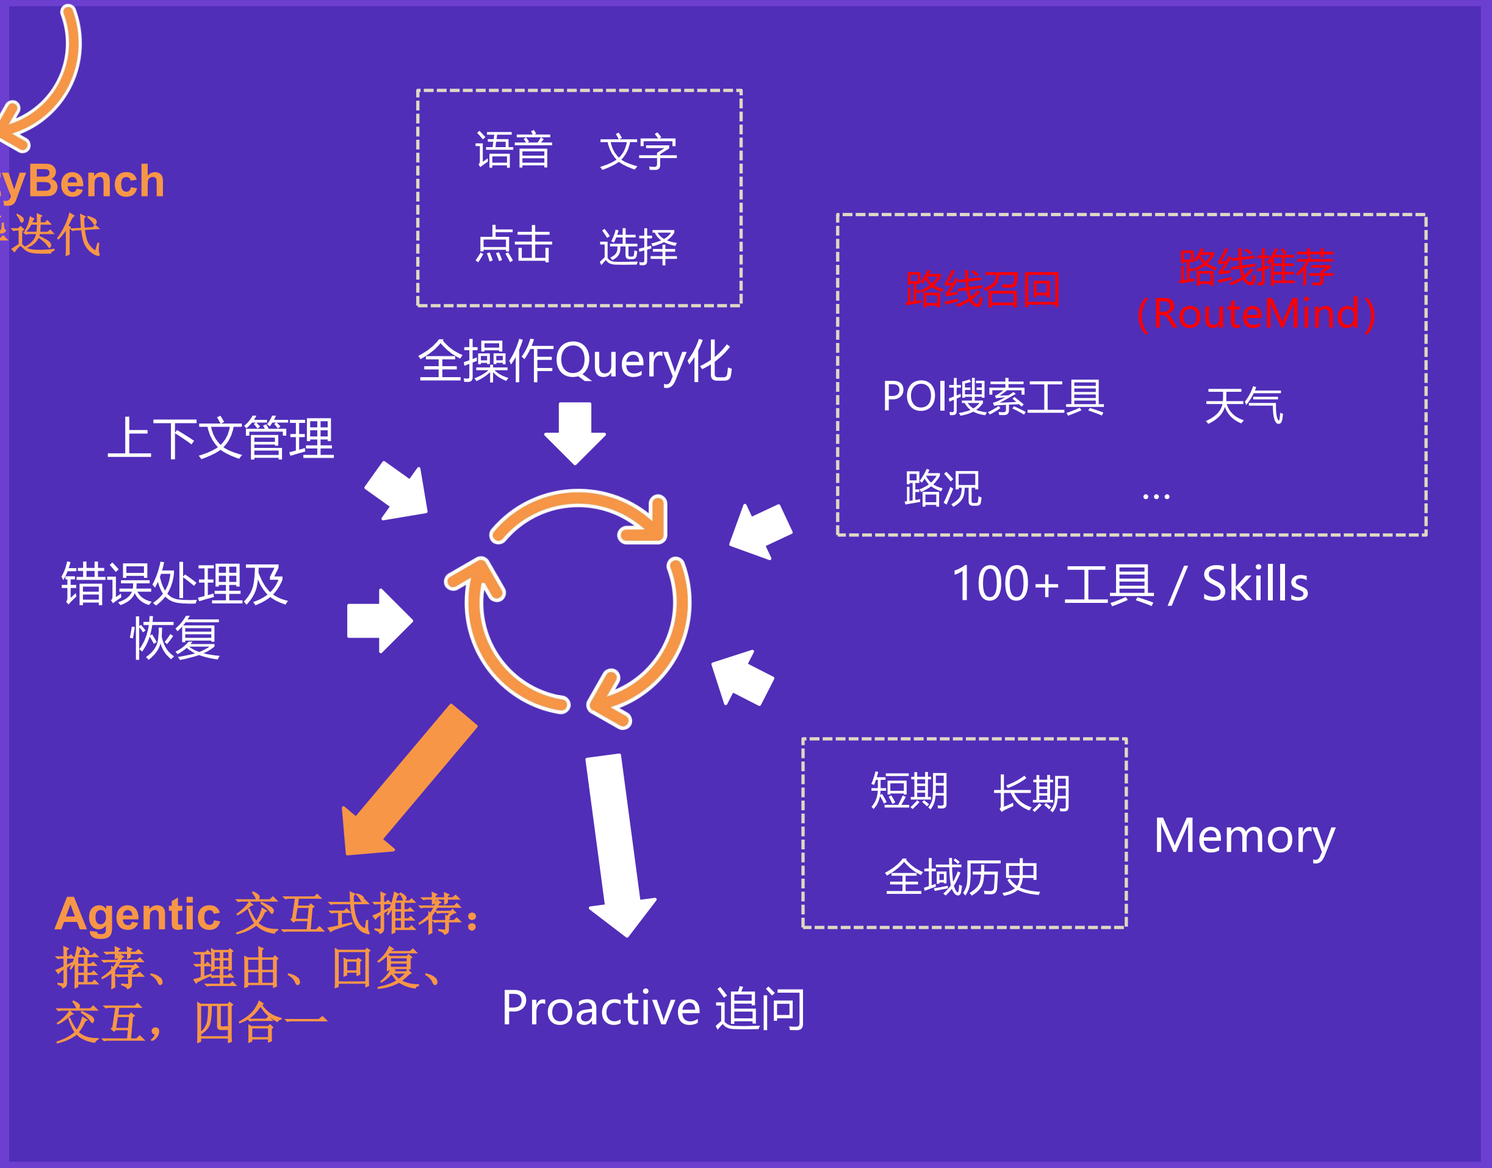
- 性能要求高，一步出结果，提升空间小。
- 泛化性差，多样性query无法满足。
- 无环境和历史上下文。
- 推荐和感知割裂，无法同步进行推荐解释。
- …

理解人

路线Agent



MobilityBench
指导迭代



理解人： 路线 Agent

Agentic 交互式推荐
推荐、理由、回复、交互，四合一

- Agent Loop 根据上下文不断进行必要的信息获取。
- 扩增工具返回候选数量，视为高质量召回。
- 最后接LLM推荐头，同步生成推荐、理由、回复、交互。



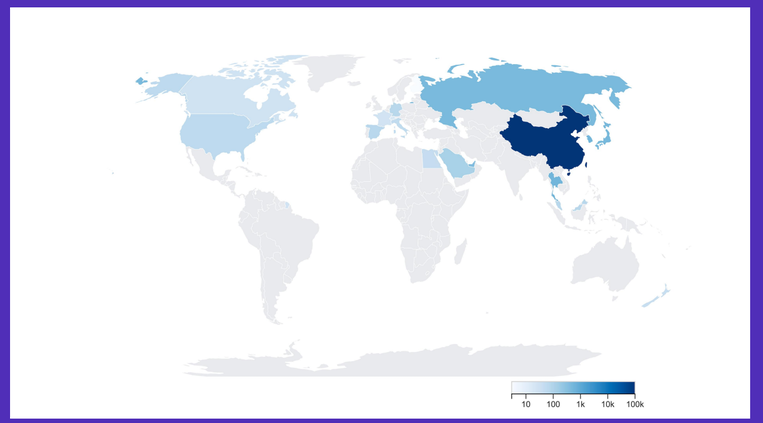
顺路加油，不走二环





理解人：路线 Agent

MobilityBench (KDD 2026)

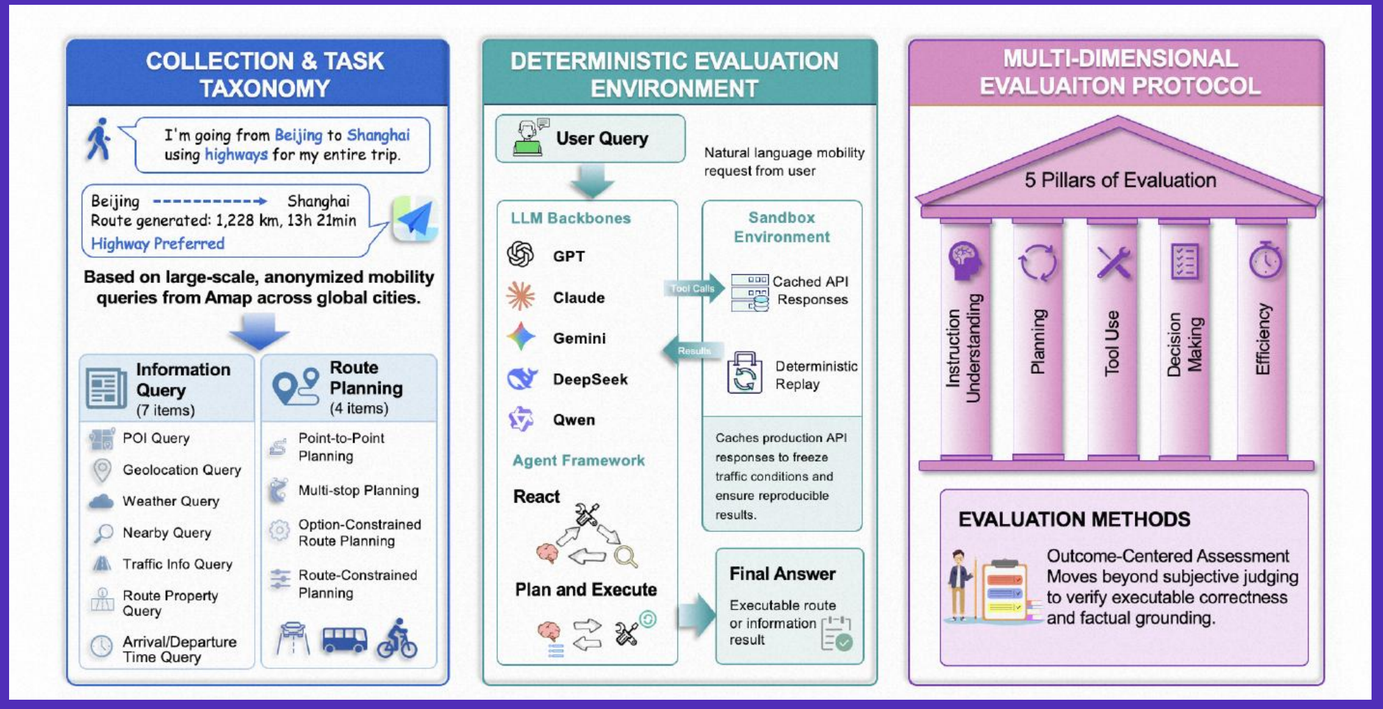


覆盖全球

首个面向真实世界出行场景的路线规划 Agent 基准

- **真实大规模数据：**从海量、脱敏的真实用户 query 中提炼 — 从最简单的"A 到 B"，到带顺路、避让、偏好、时序约束的复杂任务。
- **多维评测协议：**不仅看最终输出的“对不对”，还分别评估指令理解、规划能力、工具使用、效率等子能力。
- **确定性 API 回放沙箱：**把所有依赖的地图服务"录"下来，评测时做确定性回放，让评测可重现、可对比。

数据生成及评测方法



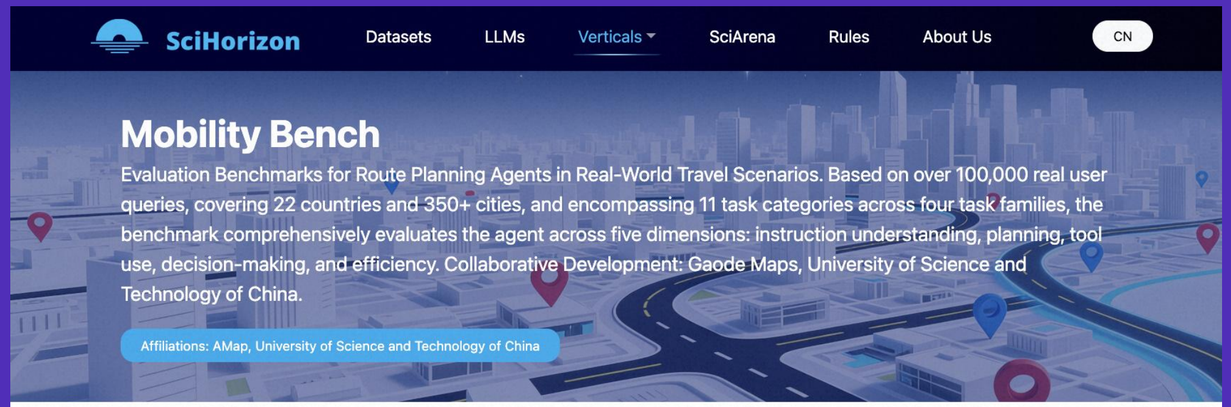
理解人：路线 Agent

MobilityBench (KDD 2026)

关键发现

- **最强模型也只做对 60+%**：真实场景下的路线规划 Agent，远没有被解决。
- **真值构造正确性验证：**用真值对 4B小模型做SFT，最终通过率直接追平 235B 级通用大模型。
- **指导线上迭代：**路线agent质量评分累计提升28.5%。
- **持续进化：**Benchmark本身也在不断更新，v2、v3，个性化、长程任务等。

数据平台



LLMs | Evaluation Framework

Large Language Model Leaderboard

Source Type: All | Open Source | Closed Source

Evaluation Results: ReAct | Plan and Execute

No.	Model Name	Source Type	Agent Framework	Instruction Understanding		Planning		Tool Use			Decision Making		
				Intent Detection	Information Extraction	Task Decomposition Precision	Task Decomposition Recall	Tool Selection Precision	Tool Selection Recall	Schema Compliance	Delivery Rate	Final Pass Rate	Inp Tok
1	Gemini-3-Pro-Preview	Closed Source	ReAct	83.54	88.75	68.7	65.11	90.74	75.04	98.7	84.38	69.09	2016
2	DeepSeek-V3.2-Exp	Open Source	ReAct	78.18	90.78	71.85	77.19	87.99	82.19	98.23	84.95	68.88	1542
3	Gemini-3-Flash-Preview	Closed Source	ReAct	84	88.16	71.95	68.34	90.37	76.46	98.31	85.18	67.9	2107
4	Qwen3-235B-A22B	Open Source	ReAct	82.13	90.51	72.23	77.75	84.13	84.66	97.24	85.95	66.69	1539

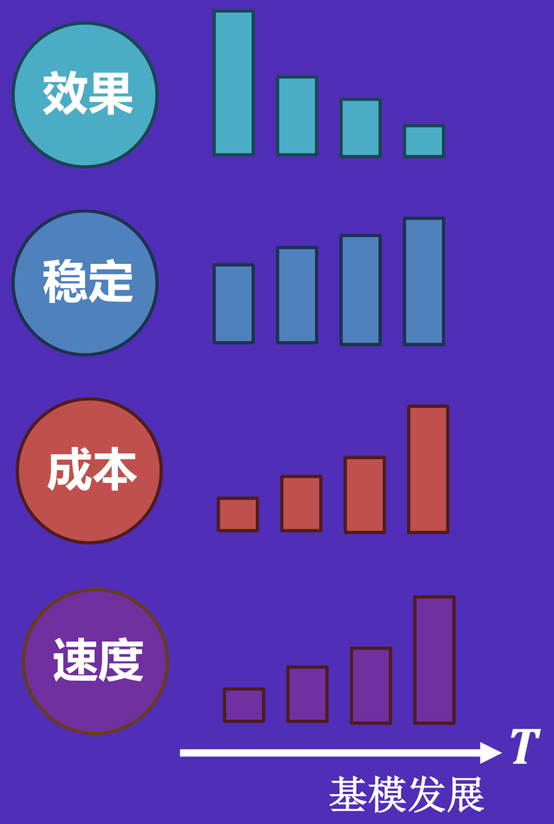
理解人： 路线 Agent

MobilityBench (KDD 2026)

后训练的目的

- **核心目标：**提升稳定性、降低推理成本、提升速度，把大量 prompt 知识与工具调用规范内化到模型。
- **效果：**减少工具调用轮次、降低对长 prompt 的依赖，让 Agent 更稳定地完成复杂任务。质量分提升 10%+，耗时降低50%+。

后训练收益预期随基模发展的变化



理解人：路线 Agent


拎着行李箱出行，
选一条不走台阶的路
高德AI定制路线 · 全程平路无台阶
全程平路无台阶，红绿灯仅2个，路线最顺畅
附近医院
找条没有台阶的路线去公园


绕景区骑行，
选一条起终点相同的路
高德AI定制路线 · 骑车兜风，骑行友好
全程环绕赛里木湖，无红绿灯干扰
随时问我
绕赛里木湖骑行一圈


十一期间走高速，
选一条走高速免费的路
高德AI定制路线 · 生成省心省钱的长途路线
ETC
十月七号晚上十点从济南出发去北京，赶不上免费怎么办？
提前下高速省50元
10月7日22:00出发时，国庆高速免费通行时段（至24:00）即将结束。若按原路线直达北京，预计10月8日凌晨03:00驶出，将产生约170元全程高速费。
北京市
408公里·5小时19分钟
导航
注意⚠️：节假日高速可能因拥堵延误，导致无法在免费截止前驶出。若优先省钱，建议全程留意导航给出的预计驶出时刻，一旦发现赶不上，就在更前面的收费站提前下高速。
提前下高速再上要多花钱吗
10月7号晚上北京堵吗


夜里走回酒店，
优先照明好、人多一点的道路
高德AI定制路线 · 途径繁华路段，照明充足
途经大栅栏西街等繁华路段，照明充足
查找休息
开始导航
找条有路灯的路线回酒店


十一新能源长途充电，
每隔一段路安排一个充电站
高德AI定制路线 · 无需手动拼接路线
从北京到上海，每两百公里安排一个充电站。
为您规划了从北京到上海，每200公里安排一个充电站的自驾路线。全程约1239公里，预计耗时14小时38分钟，共安排了6个充电站，具体站点信息如下：
沿途充电站推荐
特来电汽车充电站(沧州伊伊新能源充电站)
星星充电汽车充电站(济南高新机场路莲
发消息...

理解人

Agent 已经能理解人、推荐路线和解释了

但，上限受工具能力制约

Agent 还是在“查地图”—每一步都要调用外部的算路引擎、POI 搜索、ETA 服务等等

一个挑衅性的问题

能不能不查地图？让模型把时空知识内化，直接"想"出路线？

04 理解时空

—TransitLM 端到端生成路线

理解时空

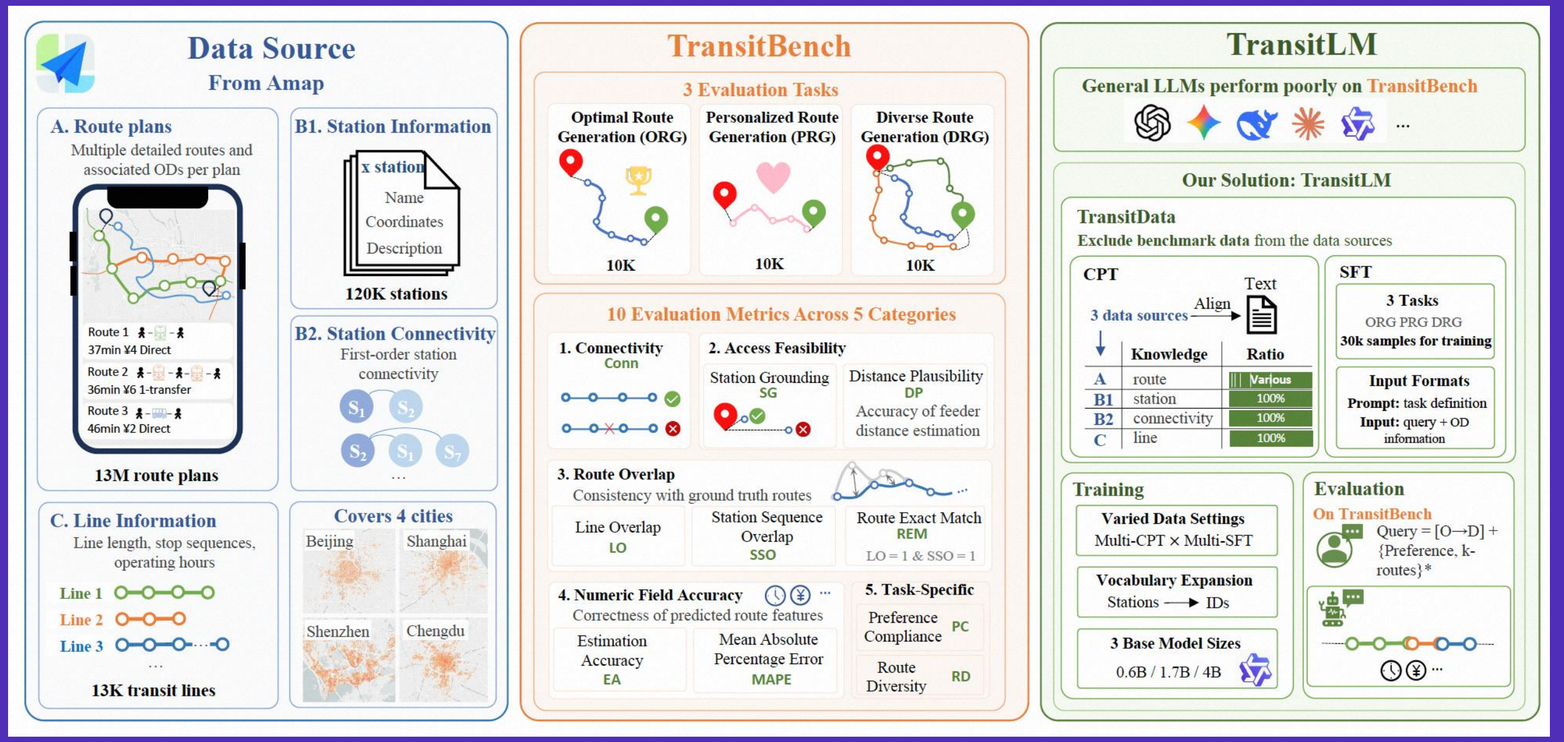
端到端路线规划

TransitLM (NeurIPS 2026)

- **路线规划传统方法：**多阶段，工业验证充分，但成本高，灵活性差。
- **通用LLM：**端到端，但缺少评估benchmarks，实验发现时空理解能力很差。

- **TransitLM：**端到端，Map-free，时空知识内化，定义benchmark。
- **数据规模**：4 城市，1300 万+ 真实公交路线记录，覆盖 12 万+ 站点、1.3 万+公交/地铁线路。
- **训练方法：**Station作为新token，CPT->SFT，覆盖最优、偏好、和多路线生成 3 任务 。
- **评测体系**：连通性、上下车站可达性、路线重合度、数值预测准确性等多个维度。

数据源 评测体系 训练范式



理解时空

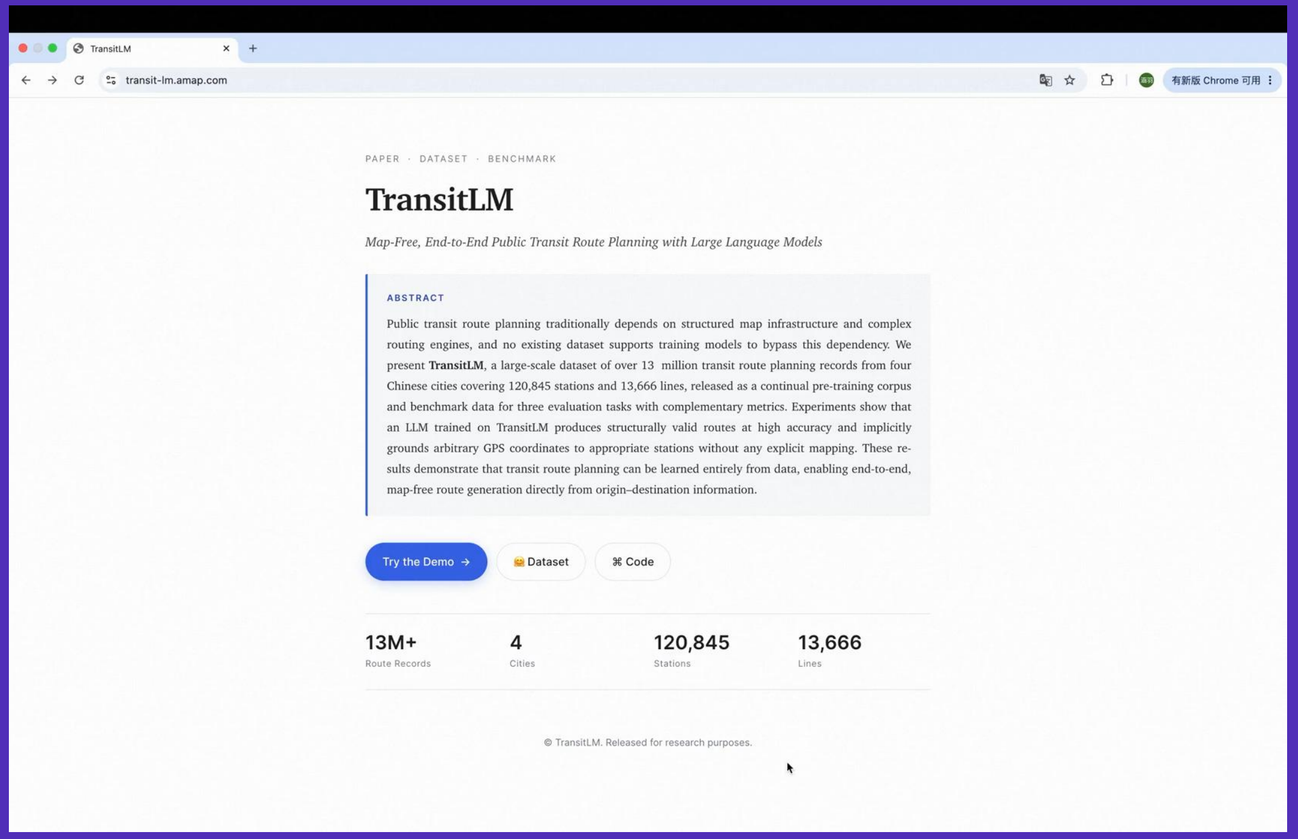
端到端路线规划

TransitLM(NeurIPS 2026)

关键发现

- **可行**：TransitLM 打平线上工业级规划服务、打平Agent + 工具范式。
- **时空知识内化**：仅输入 GPS 坐标，即可规划，无需任何显式坐标映射或地理数据库。
- **泛化性**：在各任务上，多任务SFT优于单任务效果，证实时空知识是任务无关的。

Demo演示



https://transit-lm.amap.com/

引起广泛关注



两条路线的辩证：Agent 与端到端，谁会赢？

两条都会赢，只是节奏不同

Agent 路线

优点：

- **快**：复用工具，工程可控。
- **稳**：路线由确定性的工业引擎产出，安全、可追溯。

局限：

- **依赖传统导航服务**，解决不了引擎本身的天花板。

将是路线规划的长期主流

端到端路线

优点：

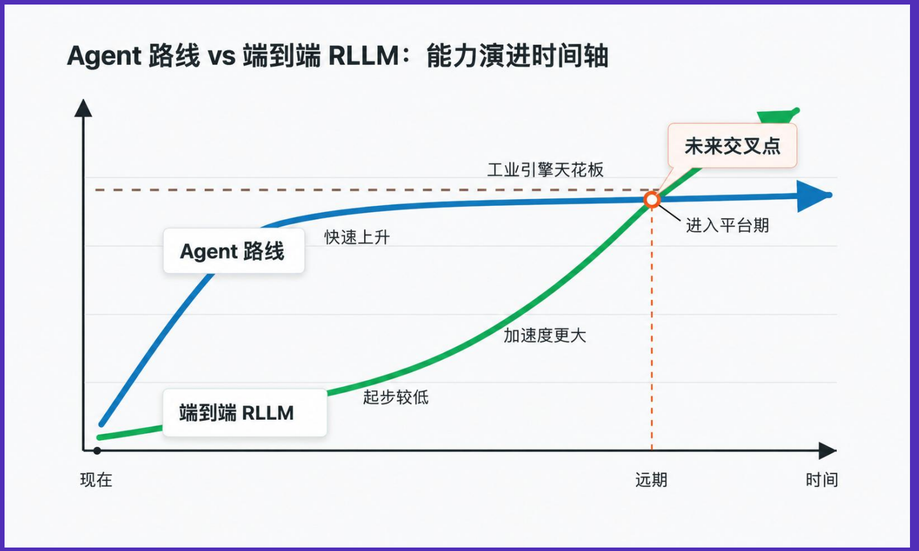
- **架构极简**：模型即系统。
- **天花板高**：时空知识内化，涌现能力强大。
- **可成长**：和数学、编程领域类似，数据越多、模型越大、效果越强。

硬骨头：

- **动态信息**：拥堵、站点增减，LLM 不擅长。
- **可控性、可解释性、安全性**：需建立一套护栏。

未来的领先方向之一

能力演进



05 三次范式跃迁

三次范式跃迁

一张表总结三次范式跃迁

高德路线推荐，正在从工业引擎、Agent 到时空基座，三步并进

阶段	核心矛盾	关键技术	范式
理解路	非 ID 化 + 强体验 + 多样性 / 召排割裂	CCN+SCASRec / GenMRP	工业引擎
理解人	自然语言需求 + Agentic 推荐 + 速度×质量 / 迭代基准	LLM2Rec+Rec2LLM / Agent / 后训练 / MobilityBench	LLM 增强 + Agent
理解时空	模型依赖外部工具 / 时空知识理解	TransitLM	端到端基座

三次范式跃迁

三个 takeaway

1 矛盾是最好的创新驱动力。

2 LLM 与推荐引擎的分工边界决定了效果上限。

3 LLM 解不了推荐系统的稀疏性。覆盖所有场景的推荐基座，是理想，但这条路可能比想象中更长。

未来展望

时空智能：时空领域基座模型

把地理空间编码进一个统一的大模型，道路、POI、路线、事件、拥堵 ...
满足任何时空需求、回答任何时空问题

THANKS

演讲嘉宾：陈超