非结构化文档的内容理解与样式还原
——从RAG知识供给到PDF转Docx的工程实践

演讲嘉宾：
常鸿宇

目录

CONTENT

01 非结构化文档解析的应用场景与挑战

02 通用文档解析系统设计与方法路线

03 系统组件划分与垂直场景定制优化

04 从PDF到Docx：页面样式还原

05 样式还原难点与踩坑记录

06 总结与展望

讲师介绍

常鸿宇

360人工智能研究院 算法资深工程师

从事NLP相关研究6年，主要研究方向为信息抽取，多模态内容理解，非结构化文档解析。

参与文档智能相关工作2年余，涵盖方案选型、模型训练、工程落地全链路。相关系统支撑集团内部多项业务，以及涵盖航空、制药、交通等各类政企项目十余项。相关会议论文2篇，相关已授权专利2项。

Part1 | 非结构化文档解析的应用场景与挑战

知识库问答

根据用户提供的场景（文档），为LLM提供相关的信息以对用户Query进行响应

结构化服务对象：

LLM

文档结构化目标：

- 内容信息完整
- 结构化表示恰当

挑战：

1. 解析的内容完整准确
2. 内容信息的完整性，结构化的过程中不能丢失原本蕴含的信息
3. 不同的元素如何进行恰当的结构化表示，如表格、公式、图片

文档二次编辑

将一个PDF文档转为可以编辑的Docx文档，以供用户进行二次编辑，或支持文档原位翻译等后续处理能力。

结构化服务对象：

人类

文档结构化目标：

- 内容完整
- 样式准确

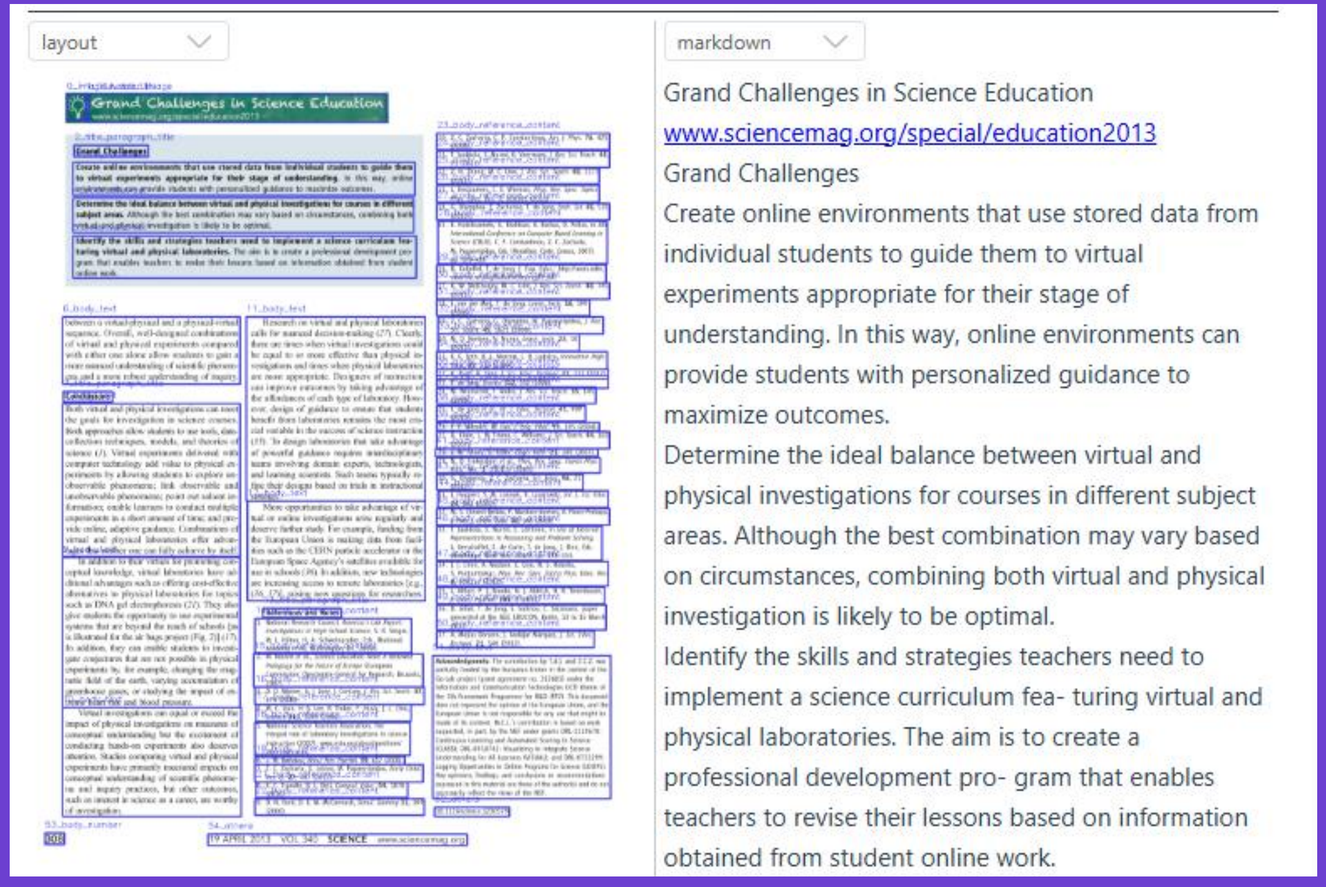
挑战：

1. 如何保障生成的Docx文档“结构合规”
2. 如何保障生成的Docx文档“视觉相似”

解析决定知识库的天花板，还原决定二次编辑的体验。

Part1 | 非结构化文档解析的应用场景与挑战

知识库问答：获取文档内容Markdown



文档二次编辑：获取Docx文件



Part2 | 通用文档解析系统设计与方法路线

Pipeline式

End2End式

复合式

离线阶段	在线阶段
1.文档解析 Data Ingestion	5.查询处理与路由 Query Processing
2.文本分块 Chunking	6.检索召回 Retrieval
3.向量化嵌入 Embedding	7.上下文注入/提示构造 Prompt Engineering
4.向量索引存储 Vector Database	8.大模型生成 LLM Generation

通用文档解析的目标：

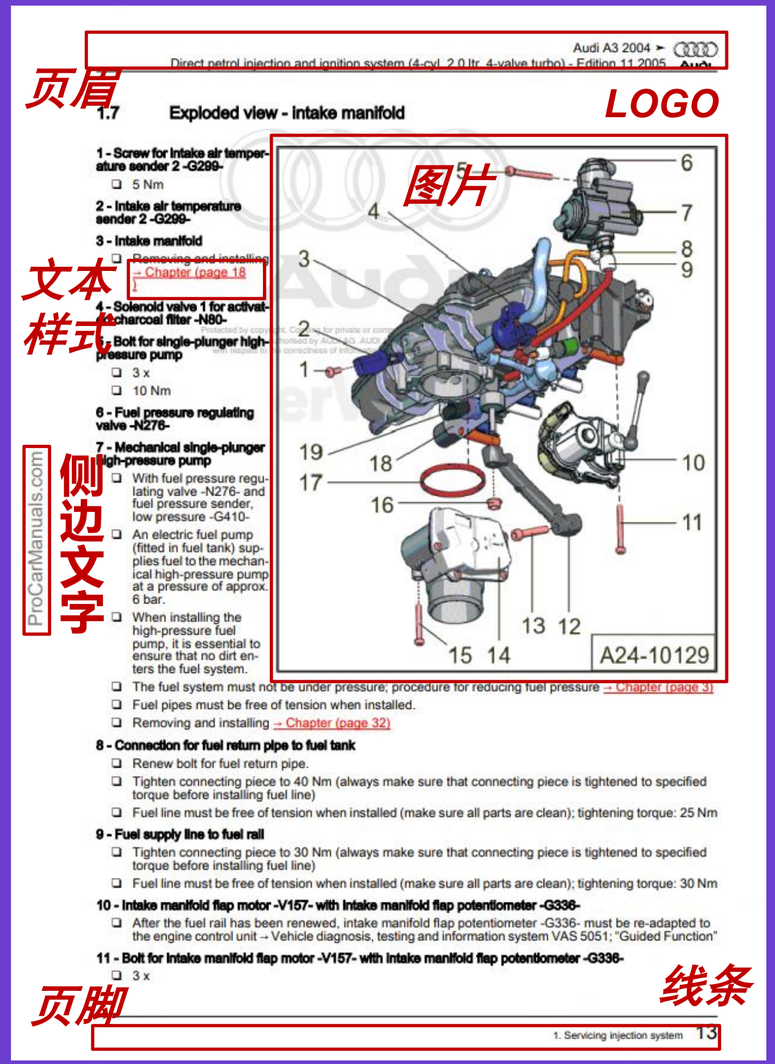
将非结构化的输入结构化、序列化

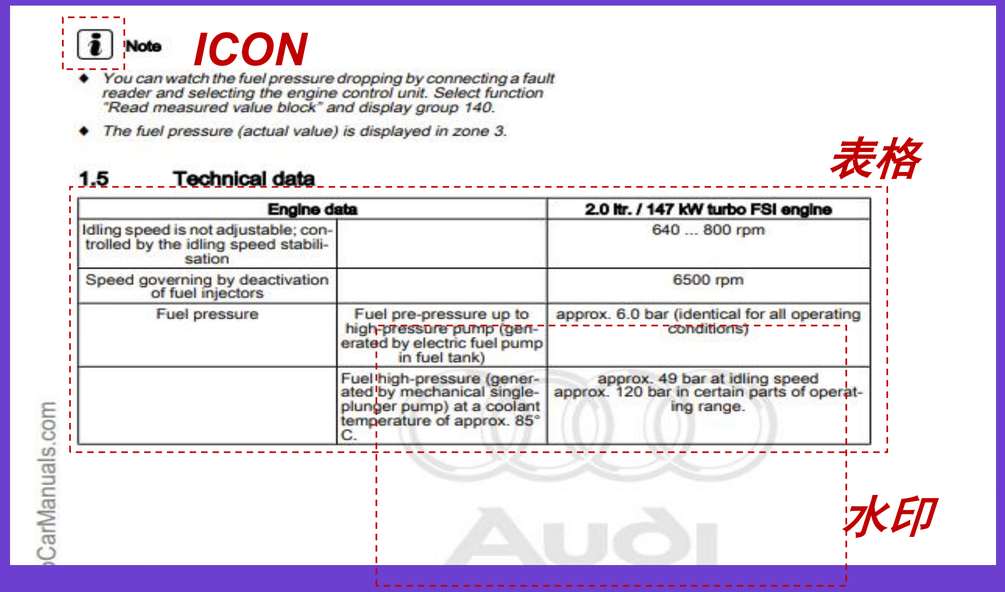
技术要求：

文档转Markdown

解析错一厘，生成误千里。

Part1 | 非结构化文档解析的应用场景与挑战





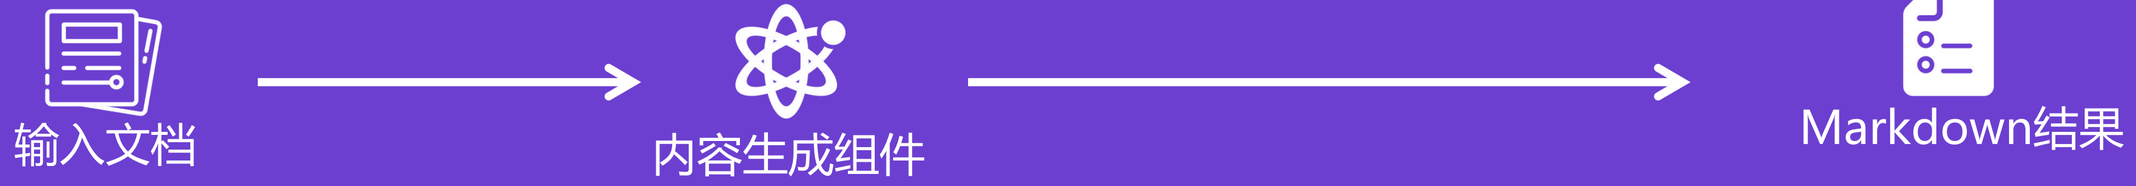
元素\场景	知识库问答	文档二次编辑
文本样式	不需要保留	需要保留
图片	需要对图片内容提炼	原位插入即可
表格	表达表格结构即可(HTML)	需要表格样式（色彩边框）
公式	Latex表达式	需要将公式渲染
页眉页脚/侧边文字	去除	按格式恢复
线条/LOGO/ICON	去除	按位置插入
水印	去除	作为背景插入
层次结构/阅读顺序	需要	不需要

Part2 | 通用文档解析系统设计与方法路线

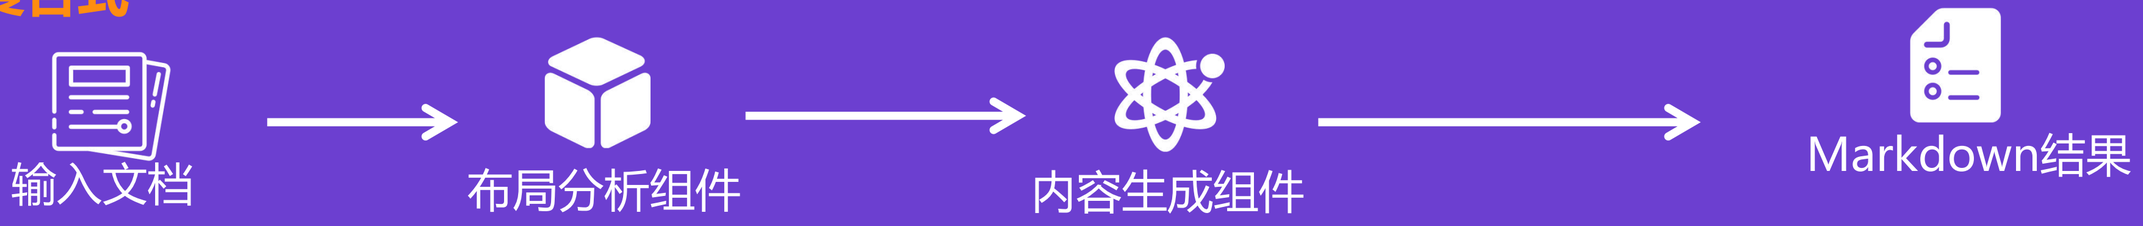
Pipeline式



End2End式



复合式



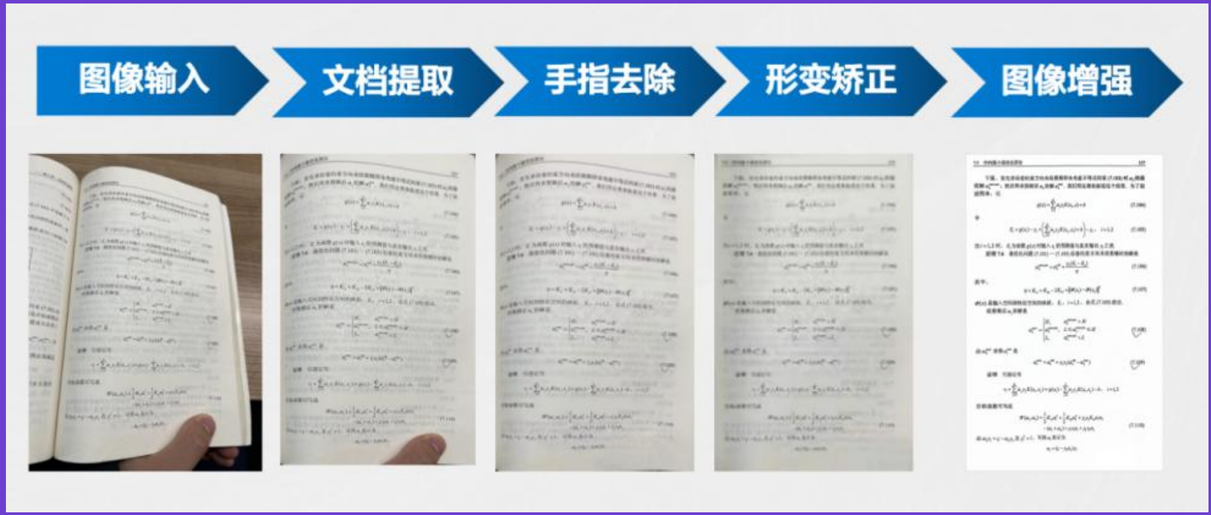
Part2 | 通用文档解析系统设计与方法路线

对比维度	Pipeline式	End2End式	复合式
技术方案	多模块串联： 布局分析→各子模块处理→拼接成完成Markdown	端到端生成： 页面图片直接生成Markdown	布局分析模块与统一的生成模型配合： 布局分析→统一的模型利用不同Prompt生成对应Markdown
优点	1. 各模块独立，可分别优化； 2. 效果总体可控，通常不会出现灾难性错误； 3. 各子模块可并行处理，执行效率高； 4. 可采用小模型快速搭建流程，对计算资源要求通常较低。	1. 流程简单，易于维护； 2. 生成式LLM对于零样本的泛化能力，可以处理复杂场景； 3. 避免长流程导致的错误累积风险。	1. 布局分析模型和生成模型独立； 2. 可通过部署多节点，同时处理一个页面的不同组件，效率优于End2End； 3. 生成式模型可以直接处理复杂场景，如文本中混杂公式。
缺点	1. 存在错误累积风险； 2. 系统相对复杂，维护成本高； 3. 处理逻辑复杂，如文本中混杂公式，表格嵌套图片，表格嵌套表格的逻辑处理。	1. 极大依赖于LLM自身效果，存在幻觉风险，复杂场景下效果不可控； 2. 内容生成模型兼具布局分析任务，优化难度高； 3. 计算资源要求较高。	1. 存在错误累积风险； 2. 生成模型组件同样存在幻觉风险； 3. 计算资源要求较高。

Part3 | 系统组件划分与垂直场景定制优化

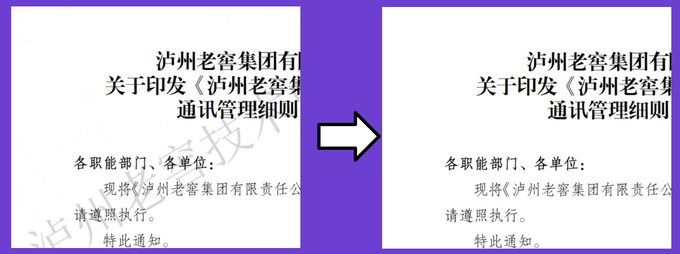
预处理增强和去水印

- 文档如果涉及到拍照版，会出现褶皱、透视等问题，直接接入后续文档处理，会出问题，因此往往需要先进行文档增强预处理。



在828个页面构成的Benchmark中评测
使用水印去除给文本CER指标带来的收益：
0.092→**0.071**
错误识别到的水印图片数量：
32→**0**

- 水印会对页面中OCR等步骤构成干扰，以及对于RAG来说属于无效信息，因此在预处理阶段需要将水印去除



水印被误识别为图片→

←水印对文字识别造成干扰

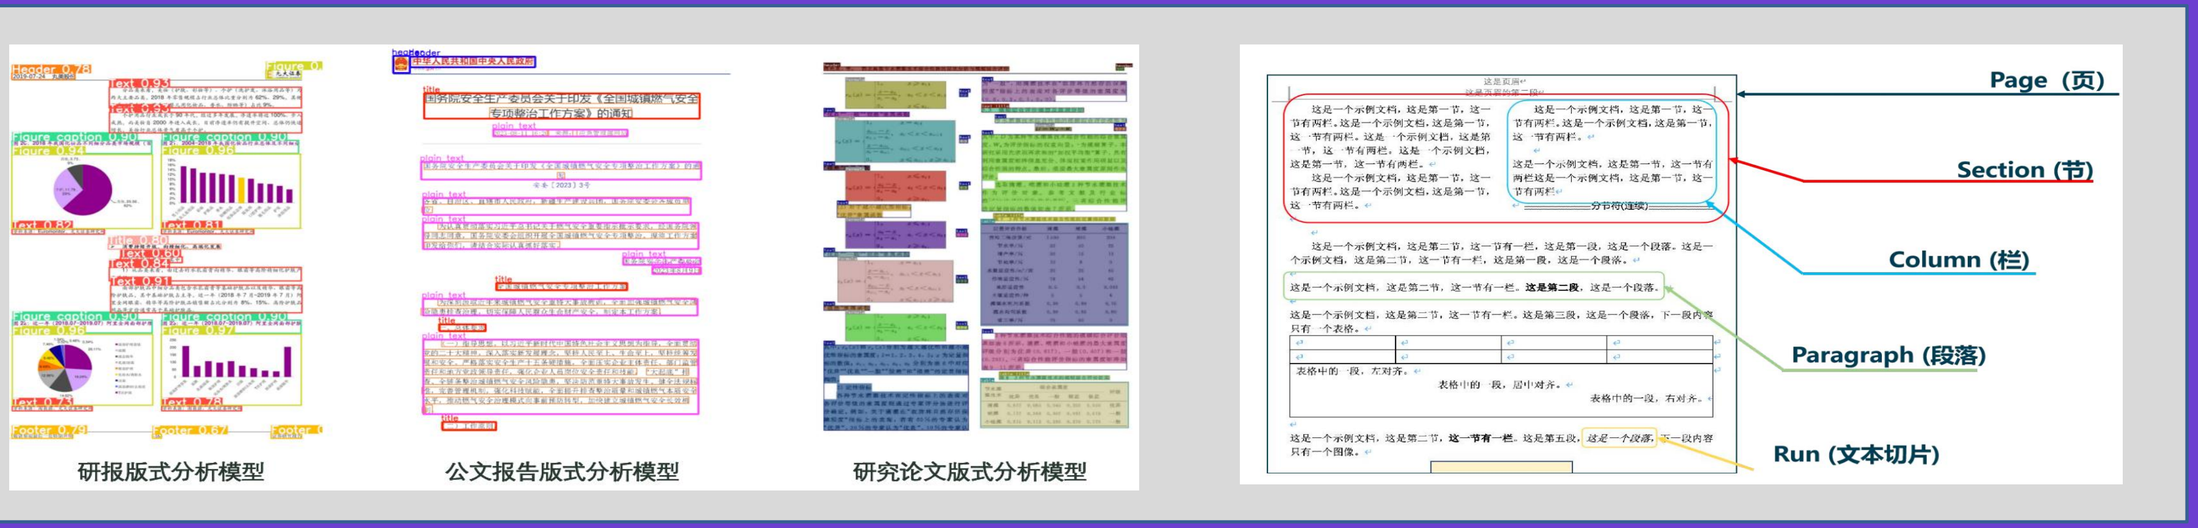


泸州老窖技术

Part3 | 系统组件划分与垂直场景定制优化

页面布局分析

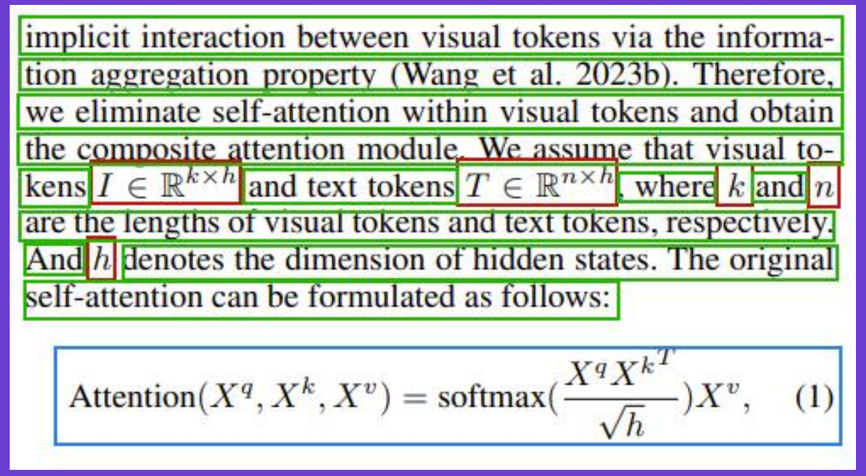
- 版式分析本质上是一个目标检测任务，用于对文档进行区域划分，核心在于标签的定义:正文、标题、图片、图片标题、表格、表格标题、页眉、页脚、注释、公式。真实的文档错综复杂，包括无线表、跨页表格、页眉、页脚、公式、图像、印章、流程图、目录树等，需要做到不漏检、不错检、识别准确。
- 主流方案包括:doclayout, pdftool-kit
- 开源地址:
  - https://github.com/360AILAB-NLP/360LayoutAnalysis,
  - https://huggingface.co/qihoo360/360LayoutAnalysis,



核心问题: 版式分析模型与文档类型强相关，本质上需要文档标注的多样性以及粒度控制

Part3 | 系统组件划分与垂直场景定制优化

OCR与公式解析



implicit interaction between visual tokens via the information aggregation property (Wang et al. 2023b). Therefore, we eliminate self-attention within visual tokens and obtain the composite attention module. We assume that visual tokens $I \in \mathbb{R}^{k\times h}$ and text tokens $T \in \mathbb{R}^{n\times h}$, where k and n are the lengths of visual tokens and text tokens, respectively. And h denotes the dimension of hidden states. The original self-attention can be formulated as follows:

$$\text{Attention}(X^q, X^k, X^v) = \text{softmax}(\frac{X^q {X^k}^T}{\sqrt{h}})X^v, \quad (1)$$

implicit interaction between visual tokens via the information aggregation property (Wang et al. 2023b). Therefore, we eliminate self- attention within visual tokens and obtain the composite attention module. We assume that visual tokens $I \in \mathbb{R}^{k\times h}$ and text tokens $T \in \mathbb{R}^{n\times h}$, where k and n are the lengths of visual tokens and text tokens, respectively. And h denotes the dimension of hidden states. The original self- attention can be formulated as follows:

$$
\text{Attention}(X^q, X^k, X^v) = \text{softmax}\left(\frac{X^q {X^k}^T}{\sqrt{h}} \right) X^v, \tag{1}
$$

Pipeline方案：

（1）Layout解析出**文本行**，**行内公式**和**行间公式**；

（2）文本行交给OCR模块处理；

（3）行内公式和行间公式交给公式解析模块处理；

（4）按照坐标对解析出来的内容进行排序，拼接成完整Markdown。

End2End方案：

直接将整段图片提供给多模态模型，多模态模型直接给出完整Markdown结果。

Benchmark上formulaNER指标表现（参考）

Pileline方案：**0.178**

End2End方案：**0.182**

Part3 | 系统组件划分与垂直场景定制优化

表格解析

Model Type	Model	Language			Table Frame Type				Special Situation				Overall
		EN	*ZH*	*Mixed*	*Full*	*Omission*	*Three*	*Zero*	*Merge Cell* (+/-)	*Formula* (+/-)	*Colorful* (+/-)	*Rotate* (+/-)	
OCR-based Models	PaddleOCR	76.8	71.8	80.1	67.9	74.3	81.1	74.5	70.6/75.2	71.3/74.1	72.7/74.0	23.3/74.6	73.6
	RapidTable	80	83.2	91.2	83	79.7	83.4	78.4	77.1/85.4	76.7/83.9	77.6/84.9	25.2/83.7	82.5
Expert VLMs	StructEqTable	72.8	75.9	83.4	72.9	76.2	76.9	88	64.5/81	69.2/76.6	72.8/76.4	30.5/76.2	75.8
	GOT-OCR	72.2	75.5	85.4	73.1	72.7	78.2	75.7	65.0/80.2	64.3/77.3	70.8/76.9	8.5/76.3	74.9
General VLMs	Qwen2-VL-7B	70.2	70.7	82.4	70.2	62.8	74.5	80.3	60.8/76.5	63.8/72.6	71.4/70.8	20.0/72.1	71
	InternVL2-8B	70.9	71.5	77.4	69.5	69.2	74.8	75.8	58.7/78.4	62.4/73.6	68.2/73.1	20.4/72.6	71.5



```
<table border="1" cellpadding="4" cellspacing="0">
    <thead>
    <tr>
        <th>Model Type</th>
        <th>Model</th>
        <th colspan="3">Language</th>
        <th colspan="4">Table Frame Type</th>
        <th colspan="4">Special Situation</th>
        <th>Overall</th>
    </tr>
... ...
```

Pipeline方案（传统方案）：

（1）表格检测与表格分类（有线/无线/缺线）；

（2）表格单元格检测/框线检测；

（3）单元格文字OCR；

（4）单元格内容与结构匹配；

（5）生成HTML。

End2End方案（多模态方案）：

输入表格图片，模型直接生成对应的HTML。

Benchmark上TEDS指标效果表现（参考）：

Pileline方案：**0.753**

End2End方案：**0.921**

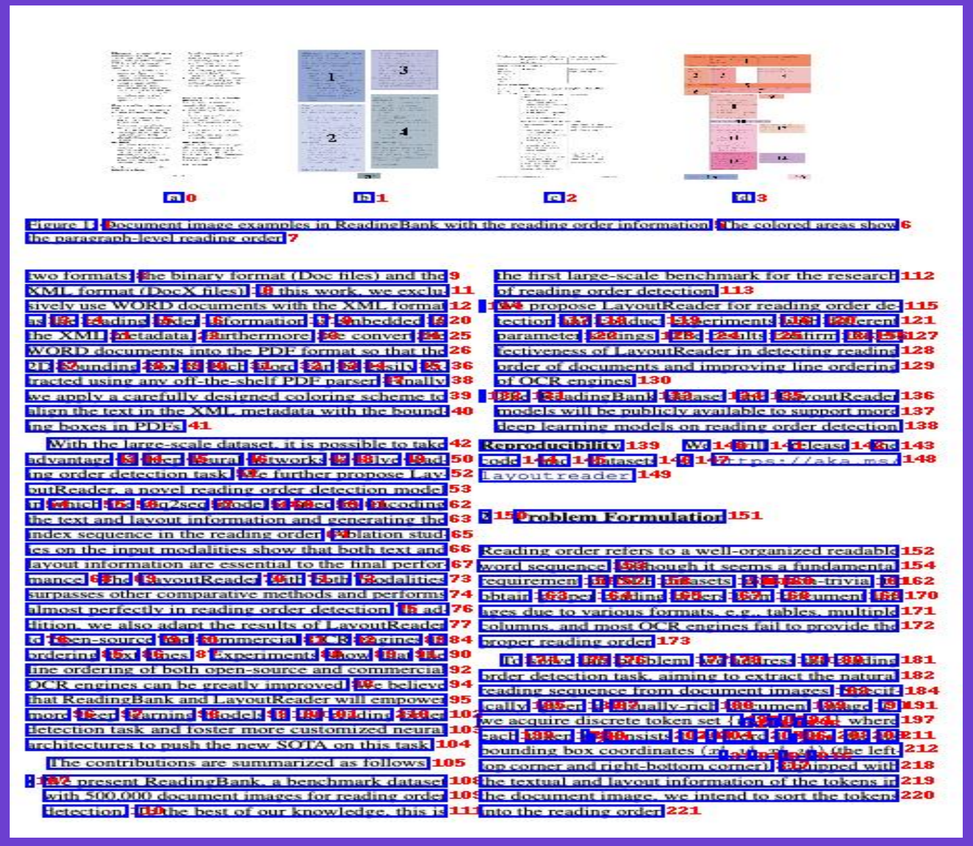
从指标上看，后者由于没有误差累积，效果明显优于前者，但前者在一些复杂场景上（表格嵌套，纵向表格，图片插入，复杂样式等）定制化更加灵活。

Part3 | 系统组件划分与垂直场景定制优化

阅读顺序与层次结构分析

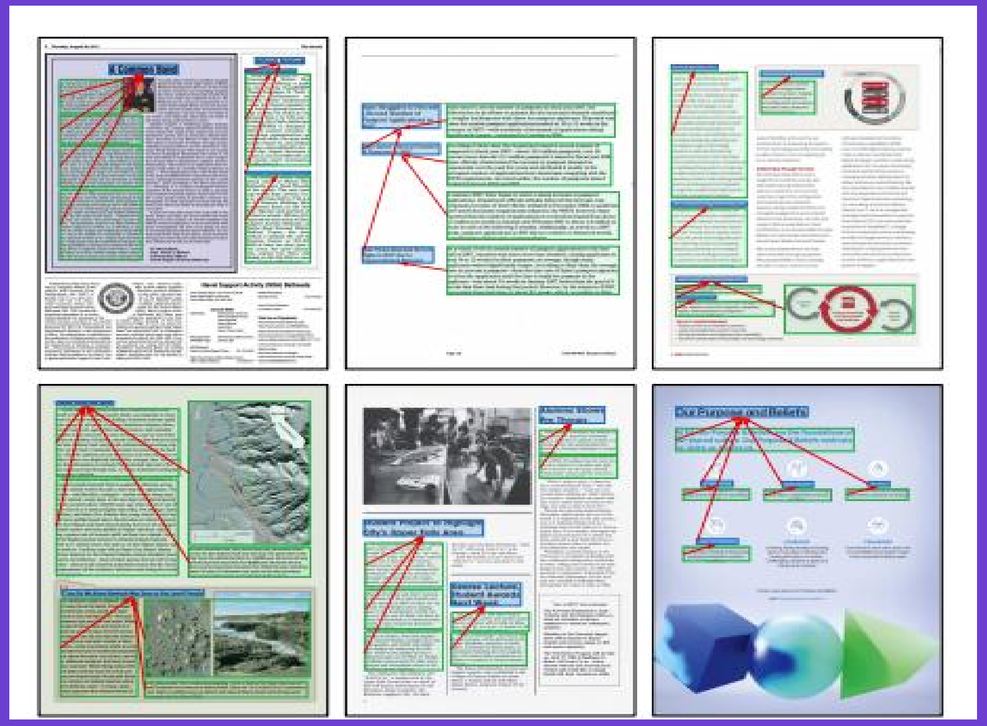
阅读顺序分析：

对每个元素的先后顺序进行排序，对于多栏文档和复杂样式场景至关重要。在Benchmark的多栏场景文档中，若不进行阅读顺序分析，会导致CER从0.130→0.479。



层次结构分析：

判断每个元素的父节点。可用于文档结构分析，层次结构召回等。在保持准确率的基础上，可减少约15%-40%的召回上下文篇幅，召回的相关段落从位置上的上下文→逻辑上的上下文。

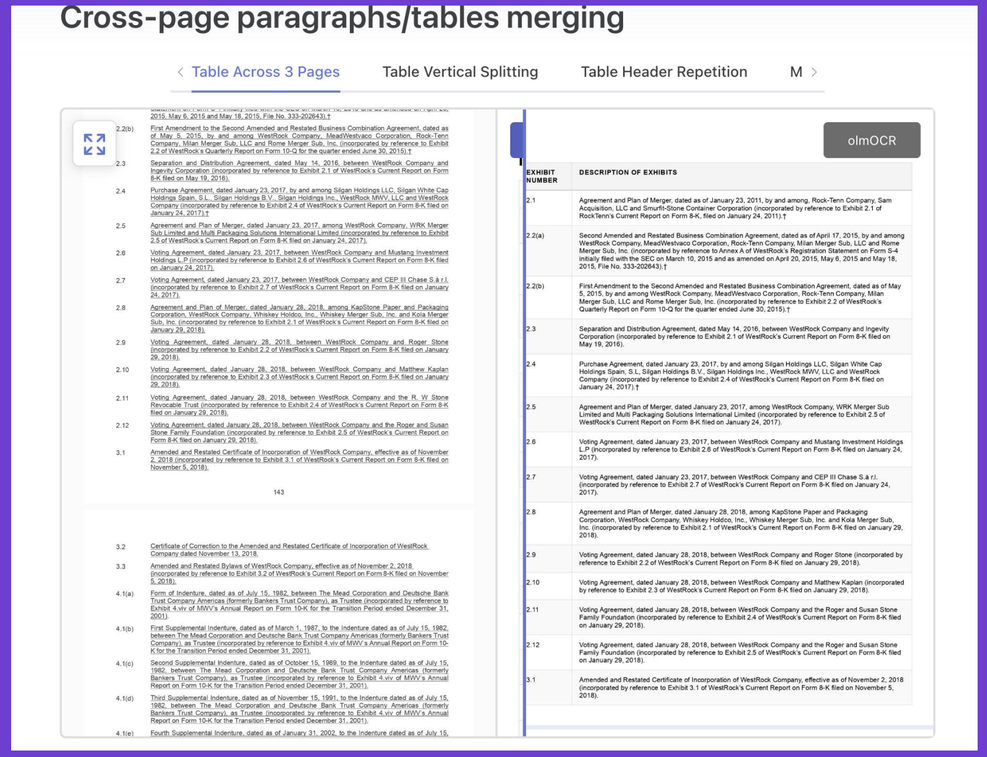


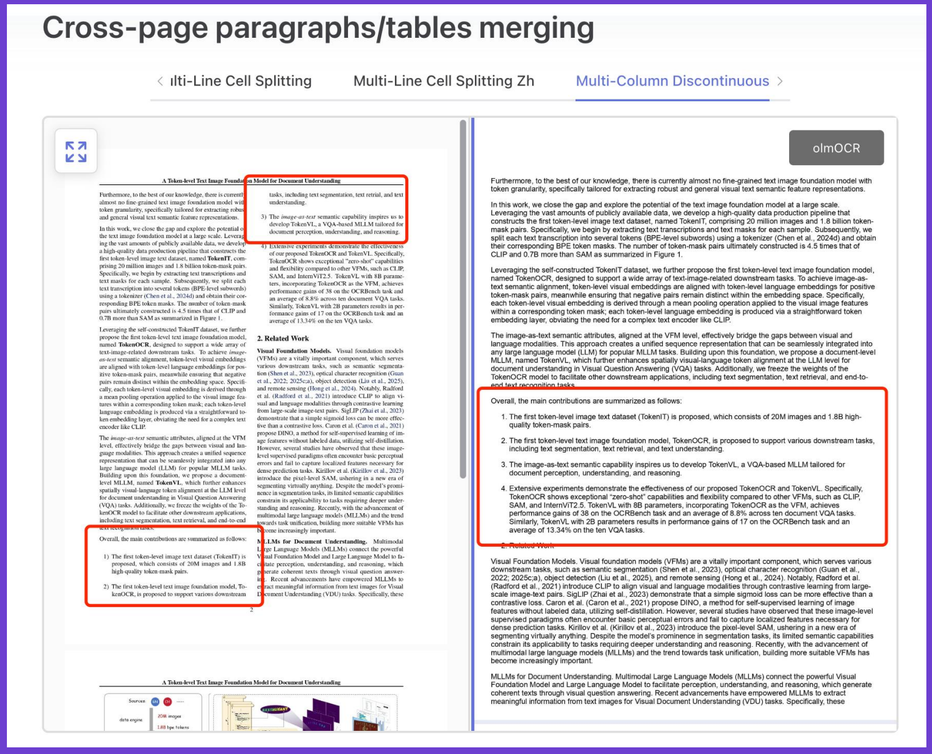
DocHieNet (Xing, et al., 2024)

Part3 | 系统组件划分与垂直场景定制优化 段落表格跨页合并

表格合并：相邻两页中表格因受限于页面大小而被截断为多张。 关键特征：表格坐标位置、单元格宽度、表头检测、内容语义连贯性。

段落合并：多见于多栏场景，跨页场景，或论文中正文内容被图表分隔。 关键特征：阅读顺序连贯、内容语义连贯性。





Benchmark中涉及到跨页段落和表格的样本中，采用合并策略后指标的影响：

文字CER：0.120→**0.082**

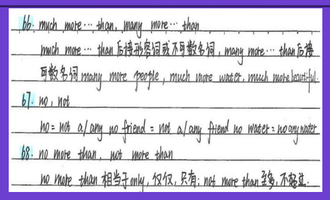
表格TEDS：0.770→**0.881**

DACon

DataFun.

Part3 | 系统组件划分与垂直场景定制优化

图片处理与垂直场景定制化解析



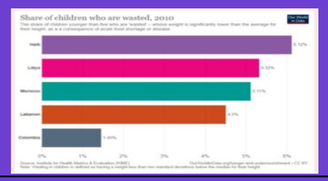
文字型图片：

提取其中的序列化文字内容



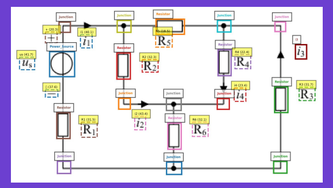
普通图片：

生成图片Caption



图表型图片：

解析成结构化Json以表示图表中蕴含的信息



特定场景，例如电路图：

元器件识别→属性识别→属性元器件匹配→Netlist生成→Netlist提供给LLM

解析没有万能流水线，只有随场景重排的协同组合拳。

针对文档中的图片，需要根据图片的种类进行特定的处理。

——在Layout阶段对不同图片设置不同的标签，或增加一个图片分类路由。

5．1．3　地形的类别划分和地形图基本等高距的确定，应分别符合下列规定：

1　应根据地面倾角（α）大小，确定地形类别。文本

平坦地：$\alpha < 3°$；

丘陵地：$3° \leqslant \alpha < 10°$；

山地：$10° \leqslant \alpha < 25°$；图片

高山地：$\alpha \geqslant 25°$。

Bad case：图片处理不当，导致内容丢失

在上面的场景中，PDF中以图片类型插入了部分内容，若将其视作普通图片处理，则会导致关键参考信息缺失，从而无法正确回答用户的问题

Part4 | 从PDF到Docx：页面样式还原

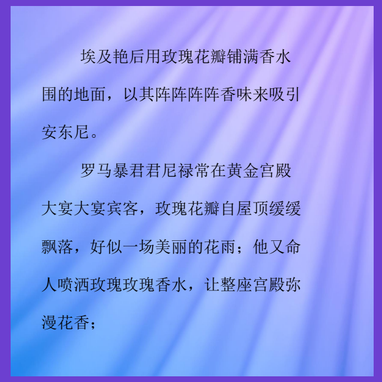
技术方案对比：视觉相似vs结构合规

对比维度	原位插入式	Pipeline式	End2End式
技术方案	直接PyMupdf之类的工具，读取PDF文档中各元素的坐标信息和内容，按照规则插入的对应的位置。	多阶段处理：先做布局分析，用布局分析的结果对PDF本身的信息进行重组。	页面图片直接生成Docx对应的代码，由代码执行生成文档。
优点	1. 视觉还原度高； 2. 整体方案较轻，效率高。	1. 页面布局分析得到确定性坐标，视觉还原度有一定保证； 2. 对于扫描件，仍然可以采用OCR等技术获取其中文字内容； 3. 执行效率通常比生成式方法高。	1. 流程简单，易于维护； 2. 生成式LLM对于零样本的泛化能力，可以处理复杂场景； 3. 避免长流程导致的错误累积风险； 4. 可以处理扫描件。
缺点	1. 无法处理扫描件（图片型PDF）； 2. 依赖于PDF本身信息的丰富程度和准确性； 3. 无法保证二次编辑结构合规。	1. 流程过长会导致误差累积； 2. 为了追求还原细节，加入过多的规则会造成规则之间的互相干扰，维护难度大； 3. 无法保证生成的docx保持一页。	1. 推理时间较长； 2. 生成模型存在幻觉风险； 3. 计算资源要求较高。

还原样式，不是复刻像素，而是重建结构。

Part4 | 从PDF到Docx：页面样式还原

Pipeline式方法：内容组件

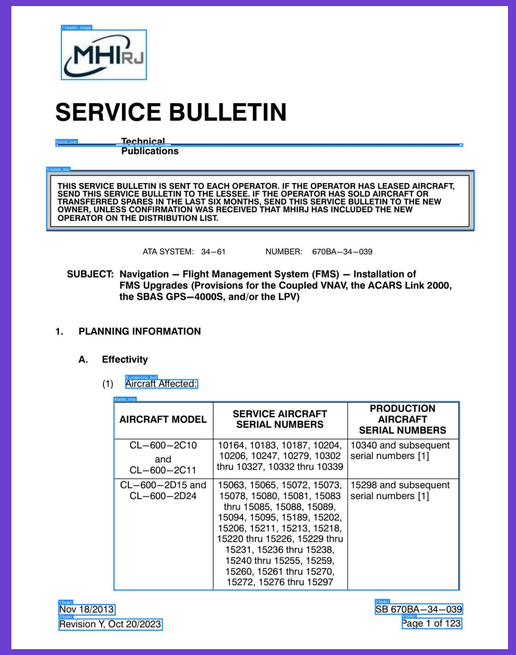


⇨



背景分离：

将页面的背景单独生成图片置于Docx底层



SERVICE BULLETIN

Technical Publications

THIS SERVICE BULLETIN IS SENT TO EACH OPERATOR. IF THE OPERATOR HAS LEASED AIRCRAFT, SEND THIS SERVICE BULLETIN TO THE LESSEE. IF THE OPERATOR HAS SOLD AIRCRAFT OR TRANSFERRED SPARES IN THE LAST SIX MONTHS, SEND THIS SERVICE BULLETIN TO THE NEW OWNER, UNLESS CONFIRMATION WAS RECEIVED THAT MHIRJ HAS INCLUDED THE NEW OPERATOR ON THE DISTRIBUTION LIST.

ATA SYSTEM: 34–61 NUMBER: 670BA–34–039

SUBJECT: Navigation – Flight Management System (FMS) – Installation of FMS Upgrades (Provisions for the Coupled VNAV, the ACARS Link 2000, the SBAS GPS–4000S, and/or the LPV)

1. PLANNING INFORMATION

A. Effectivity

(1) Aircraft Affected:

AIRCRAFT MODEL	SERVICE AIRCRAFT SERIAL NUMBERS	PRODUCTION AIRCRAFT SERIAL NUMBERS
CL–600–2C10 and CL–600–2C11	10164, 10183, 10187, 10204, 10206, 10247, 10279, 10302 thru 10327, 10332 thru 10339	10340 and subsequent serial numbers [1]
CL–600–2D15 and CL–600–2D24	15063, 15065, 15072, 15073, 15078, 15080, 15081, 15083 thru 15085, 15088, 15089, 15094, 15095, 15189, 15202, 15206, 15211, 15213, 15218, 15220 thru 15226, 15229 thru 15231, 15236 thru 15238, 15240 thru 15255, 15259, 15260, 15261 thru 15270, 15272, 15276 thru 15297	15298 and subsequent serial numbers [1]

Nov 18/2013
Revision Y, Oct 20/2023

SB 670BA–34–039
Page 1 of 123

布局分析：

区别于面向RAG系统的文档解析，页面样式还原对布局分析的要求更加细节，例如：

需要将页面中的线条，LOGO，ICON等元素保留，需要对下划线文本，删除线文本，等特殊样式的文本进行标记

Docx ⇨ {“font”: “Times New Roman”}

字体匹配/预测：

文字型PDF读取字体信息，与可用字体进行匹配，扫描型PDF对字体进行分类预测

Docx ⇨ {“color”: “0484B1”, “background”: “D8E921”}

色彩预测：

对文本或表格单元的前景色背景色进行预测。

Part4 | 从PDF到Docx：页面样式还原

End2End方法：生成内容的选择

python-docx

封装了常用的docx操作接口，例如插入段落，插入图片，段落样式、文本样式设置等。

优点：语言简练

缺点：很多功能不支持，如图片悬浮格式设置等

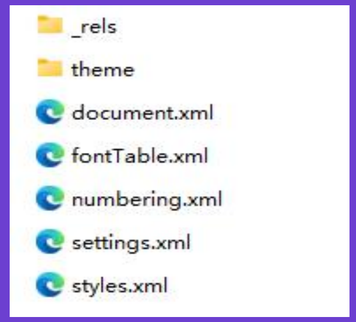
```
document = Document()
normal_pf = document.styles['Normal'].paragraph_format
normal_pf.space_before = Cm(0.0)
normal_pf.space_after = Cm(0.0)
normal_pf.line_spacing = 1.0
... ...
run_11_0 = para_11.add_run('25.第25 行“专项用途财政性资金用于支出所形成的费用”：根据《专项用途财政性资金纳税调整明细表》(A105040)填报。第3 列“调增金额”填报表A105040 第7 行第11 列金额。')
document.save(str(OUTPUT_DOCX))
```

XML

每个docx文档都是一个zip文件，可以解压看到其中的文件内容，由若干个XML文件构成。

优点：可以进行非常细节的设置

缺点：内容过长，不适合直接用于LLM生成



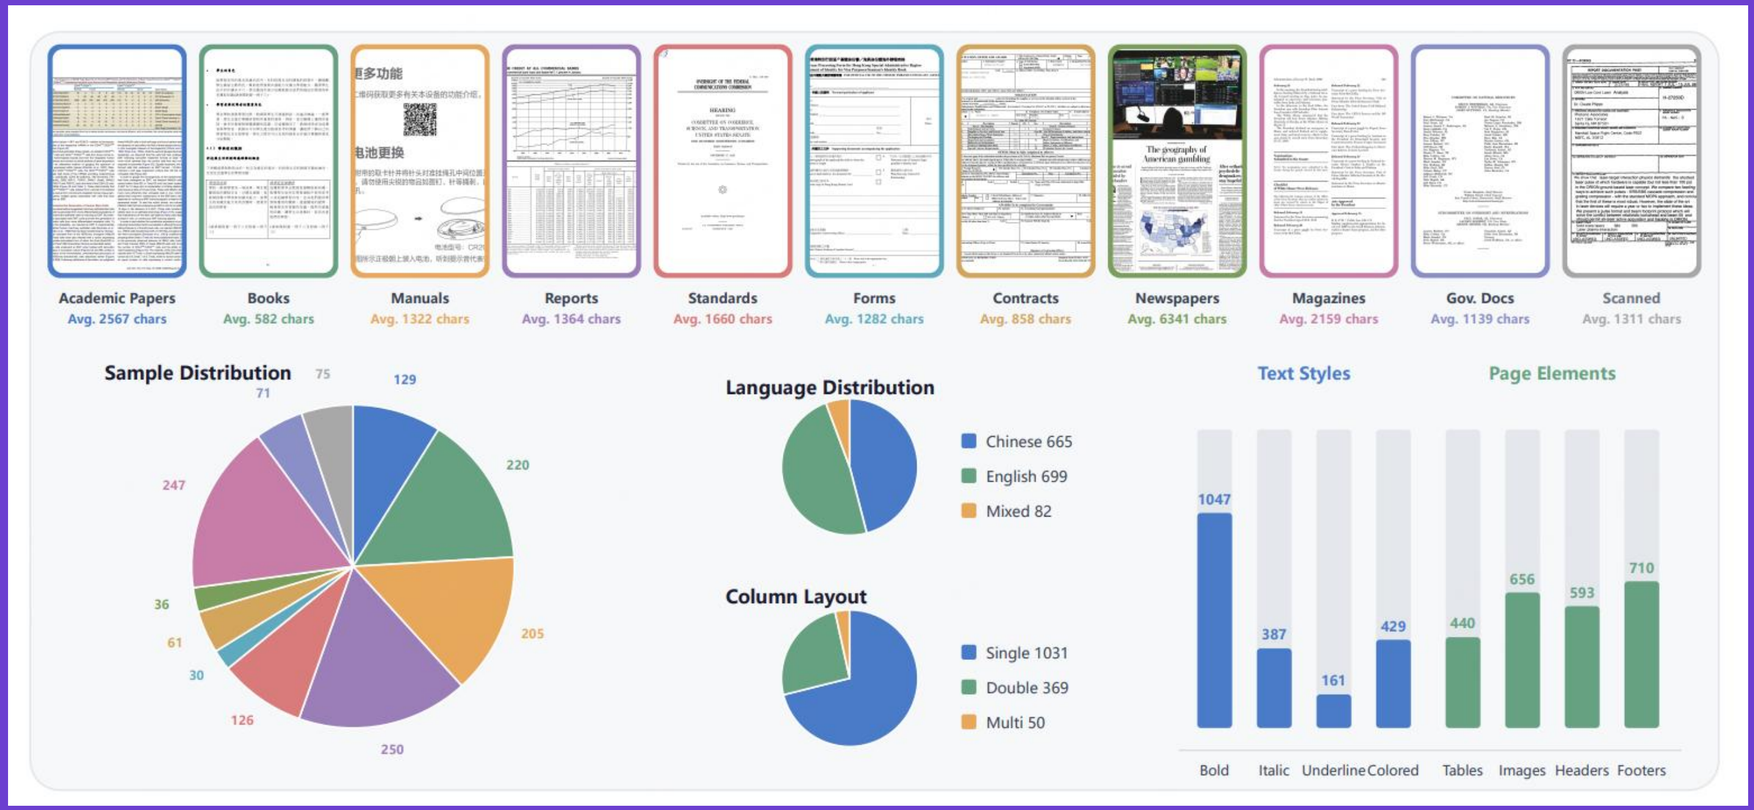
融合方案

大部分操作采用python-docx，不支持的操作自定义函数封装XML。与此同时，自定义方法可以减少训练和推理过程中的token数量，加速训练和推理。

自定义方法	功能
clear_table_borders	清除表格边框
set_cell_margins	设置单元格边距
set_run_format	设置run格式
insert_line	插入线条
insert_toc	插入目录
insert_inner_table	插入嵌套表格
... ...	... ...

Part5 | 样式还原难点与踩坑记录

评估的难点



评估方法	平均得分
Gemini 3.1 Pro	0.429
GPT-5.6 Terra	0.479
Claude Opus 5	0.509
pdf2docx	0.527
our system	0.589

Benchmark构成：

1450个页面，10类文档

评估难点：

（1）标准统一难；

（2）GT构建难；

（3）权重设置存在主观性。

评估维度：

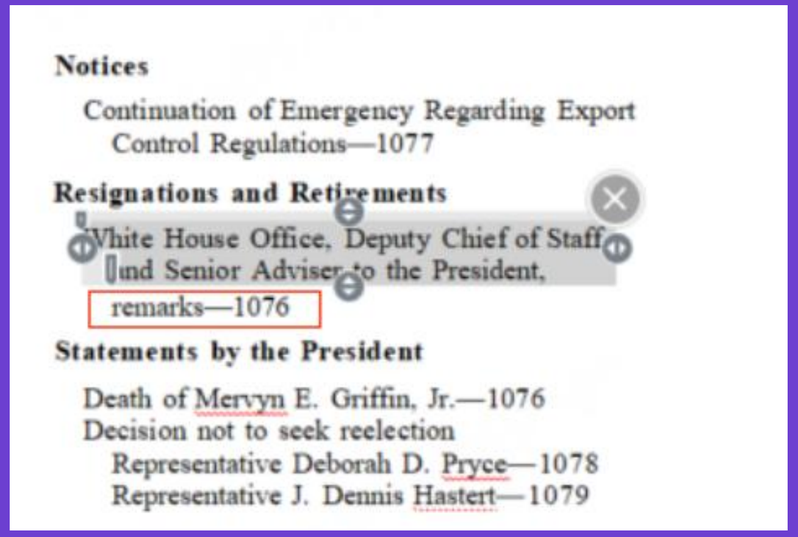
内容、样式、结构、全局（栏数、还原成功率等）4个大维度。

Part5 | 样式还原难点与踩坑记录

case1: 段落划分错误

即便还原效果看起来与原PDF相似，但是逻辑上却将应该是同一段路的文本划分为了多段。

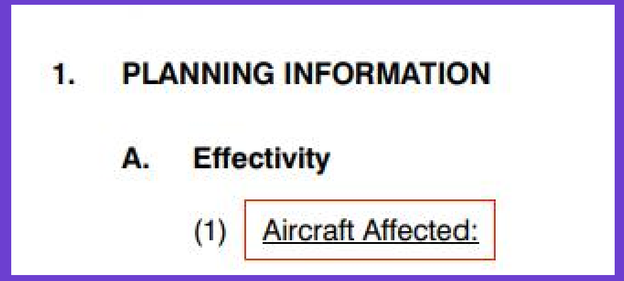
解决方法：针对特定场景优化layout模型



case2: 下划线文本难以恢复

原PDF中部分文字带有下划线，但通过PyMupdf读取到的信息中，却丢失了这一信息，将其记录为普通文字

解决方法：在layout模型类别中增加一类“下划线文本”类型



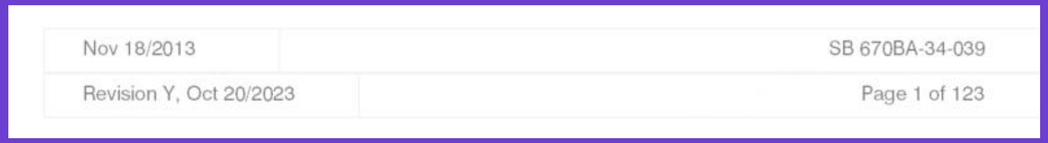
Part5 | 样式还原难点与踩坑记录

case3: 页眉页脚的位置难以控制

页眉/页脚区域只能插入一个paragraph，元素过多时，位置难以精确控制

解决方法：插入表格，以表格单元格宽度控制文本的位置

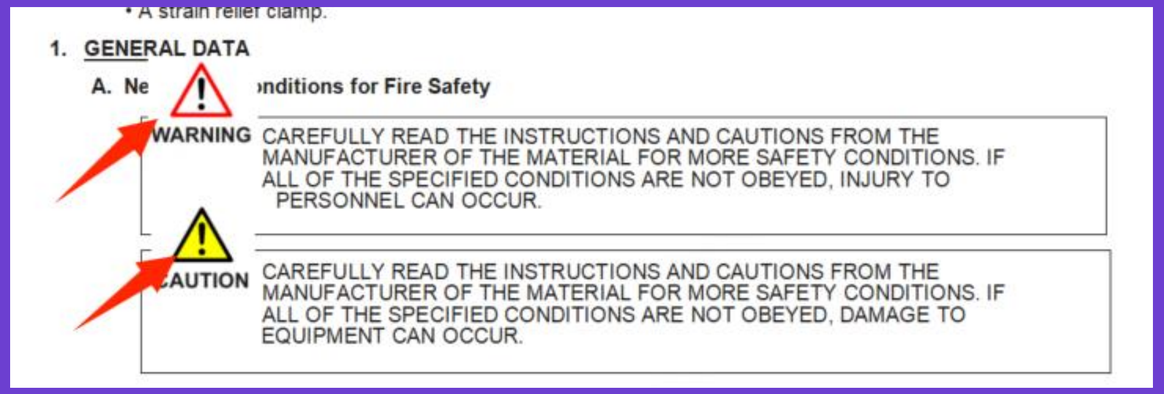




case4: 流式插入文本 VS 绝对位置图片

Docx中段落的插入是流式的，很难做到百分百位置对齐，而图片/线条若以绝对坐标插入，则会与段落之间存在高度差

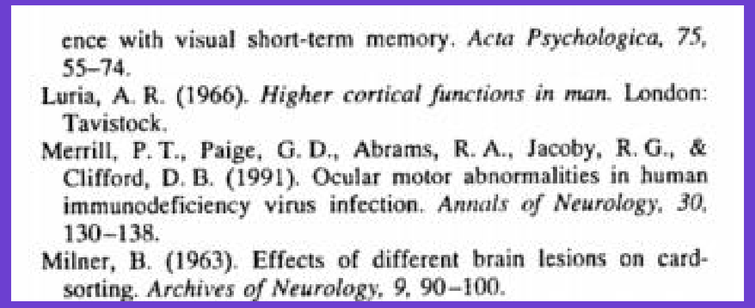
解决方法：在插入图片/线条时锚定邻近的段落，计算相对位置



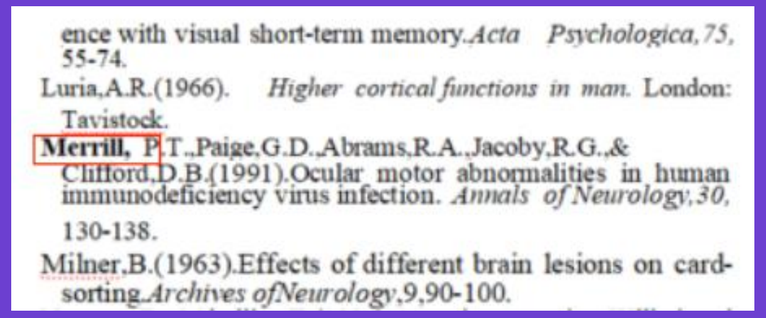
Part5 | 样式还原难点与踩坑记录

困难case1: 加粗文本信息丢失

区别于下划线文本，如果PDF内置信息中丢失了加粗信息，难以对加粗文本进行恢复。逐个文字进行分类判断计算成本大，并且在扫描件场景下会出现大量错判。



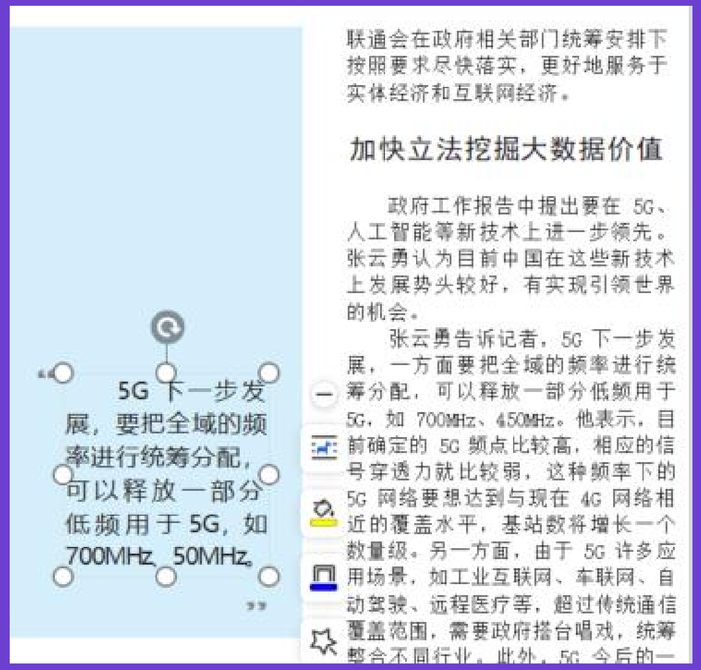
ence with visual short-term memory. *Acta Psychologica, 75,* 55–74.
Luria, A. R. (1966). *Higher cortical functions in man.* London: Tavistock.
Merrill, P. T., Paige, G. D., Abrams, R. A., Jacoby, R. G., & Clifford, D. B. (1991). Ocular motor abnormalities in human immunodeficiency virus infection. *Annals of Neurology, 30,* 130–138.
Milner, B. (1963). Effects of different brain lesions on card-sorting. *Archives of Neurology, 9,* 90–100.



ence with visual short-term memory.*Acta Psychologica,75,* 55-74.
Luria,A.R.(1966). *Higher cortical functions in man.* London: Tavistock.
Merrill, P.T.,Paige,G.D.,Abrams,R.A.,Jacoby,R.G.,& Clifford,D.B.(1991).Ocular motor abnormalities in human immunodeficiency virus infection. *Annals of Neurology,30,* 130-138.
Milner,B.(1963).Effects of different brain lesions on card-sorting.*Archives ofNeurology,9,*90-100.

困难case2: 文本框的使用在所难免

受限于Docx本身的能力，对于一些复杂文档，例如杂志、报纸，只能采用文本框来控制字体的位置。



5G下一步发展，要把全域的频率进行统筹分配，可以释放一部分低频用于5G，如700MHz、450MHz。

联通会在政府相关部门统筹安排下按照要求尽快落实，更好地服务于实体经济和互联网经济。

加快立法挖掘大数据价值

政府工作报告中提出要在5G、人工智能等新技术上进一步领先。张云勇认为目前中国在这些新技术上发展势头较好，有实现引领世界的机会。

张云勇告诉记者，5G下一步发展，一方面要把全域的频率进行统筹分配，可以释放一部分低频用于5G，如700MHz、450MHz。他表示，目前确定的5G频点比较高，相应的信号穿透力就比较弱，这种频率下的5G网络要想达到与现在4G网络相近的覆盖水平，基站数将增长一个数量级。另一方面，由于5G许多应用场景，如工业互联网、车联网、自动驾驶、远程医疗等，超过传统通信覆盖范围，需要政府搭台唱戏，统筹整合不同行业。此外，5G今后的一

Part5 | 总结与展望

通用文档解析和页面样式还原两大应用场景，皆可以采用多种偏工程的Pipeline方法和侧重模型能力的多模态方法进行解决，孰优孰劣需考虑具体应用场景进行综合判断。

通用文档解析

Pipeline方案：
可针对性优化各子模块，但模块间误差累积问题突出；
多模态方案：
端到端能力强，但在细粒度结构还原（如表格单元格坐标属性等）上仍有不足。

页面样式还原

工程化方法：
生成的Word文档在视觉上与原始的PDF相似，Word文旦的底层结构规范合规性较差；
多模态方案：
流程简单，易于维护，避免误差累积，但还原度细节对模型能力要求较高。

THANKS

演讲嘉宾：常鸿宇