

智能文档解析

在企查查业务中的真实落地应用

演讲嘉宾：陈汝龙

目录

CONTENT

01 场景需求

02 对比与选型

03 数据准备和模型训练

04 场景应用

05 加速方案落地

06 总结与展望

01 场景需求

场景需求

1. 原始输入（无边框表格）

项目	附注	2026年 1-6月	2025年 1-6月
一、营业收入	十七、3	197,926	201,731
减：营业成本	十七、3	-	-
税金及附加		2,174	3,807
管理费用		204,310	220,780
研发费用		1,205	791
财务费用		570,196	512,989
其中：利息费用		306,406	315,431
利息收入		3,611	8,197
加：其他收益		1,001	1,046
投资收益	十七、4	494,991	2,457,851
公允价值变动损失		-	-
资产处置损失		(124)	(1,132)
二、营业（亏损）/利润		(94,101)	1,621,129
加：营业外收入		1,040	-
减：营业外支出		40,362	-

2. 解析缺失表格信息

解析异常：缺乏表格结构

项目附注2026年1-6月2025年1-6月
一、营业收入十七、3 197,926 201,731
减：营业成本十七、3 - -
税金及附加 2,174 3,807
管理费用 204,310 220,780
研发费用 1,205 791
…

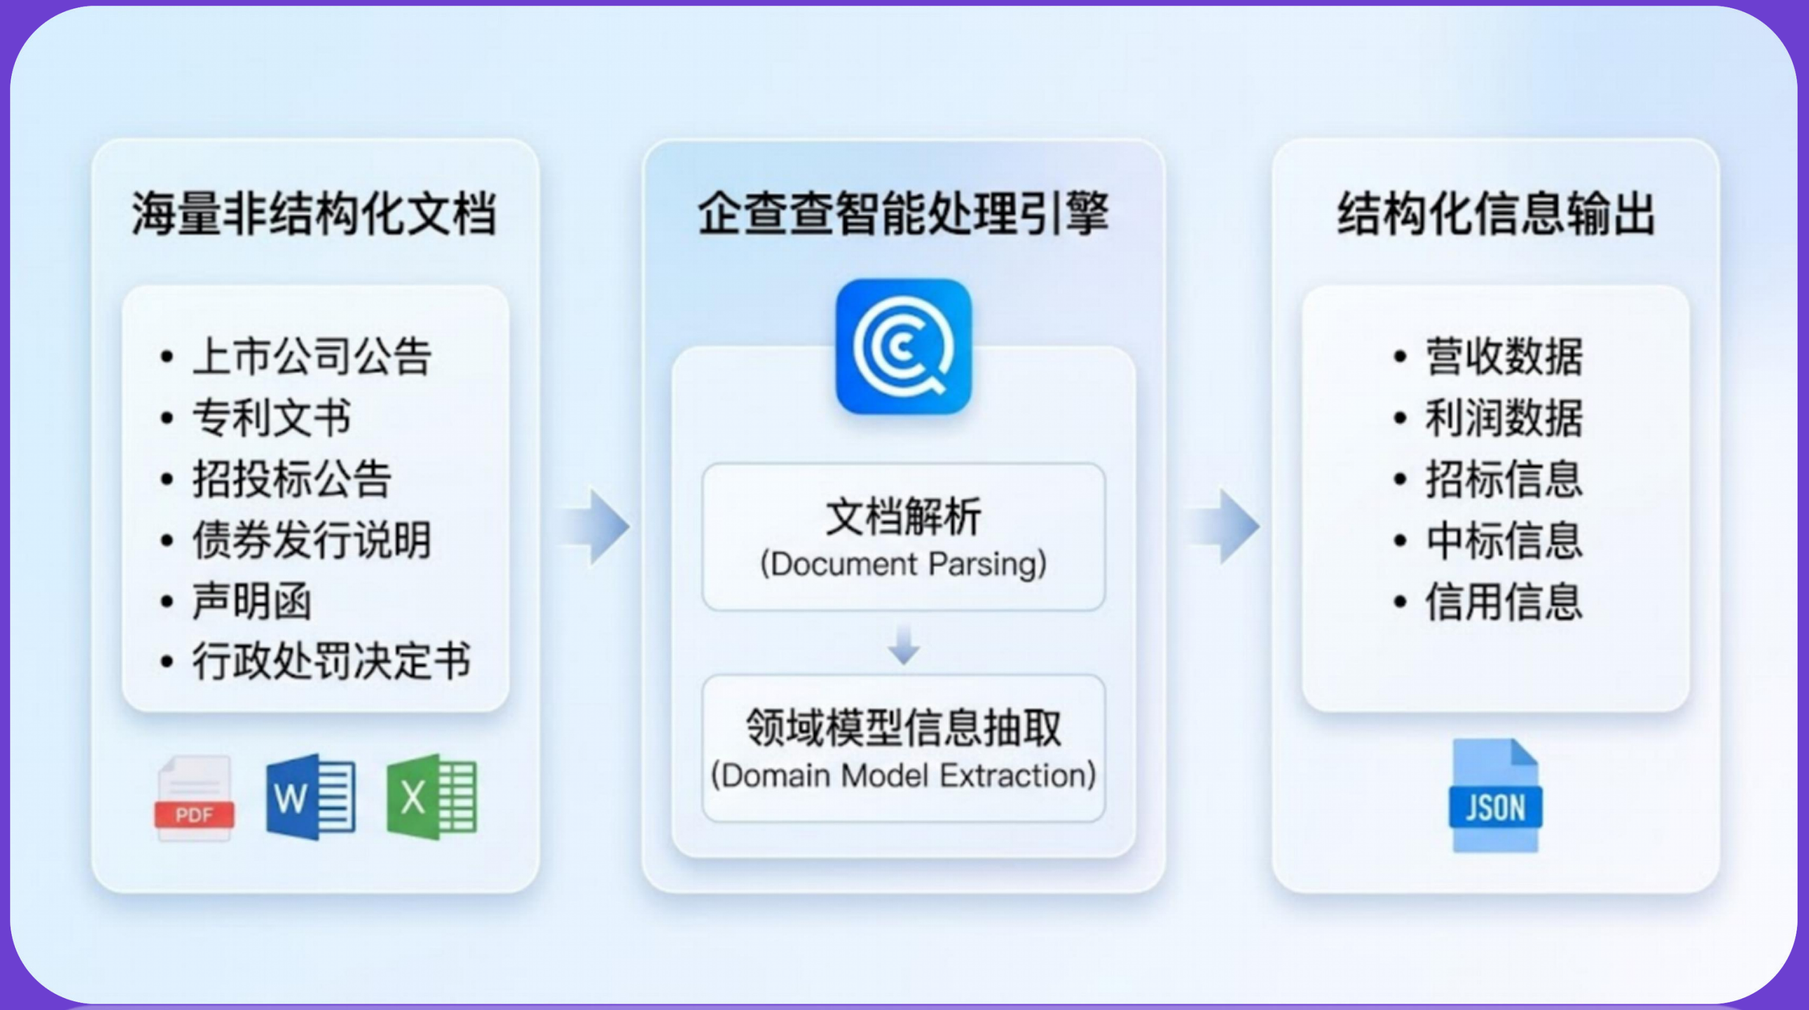
3. 业务无法抽取正确结果

提取失败：字段映射丢失 & 指标缺失

JSON

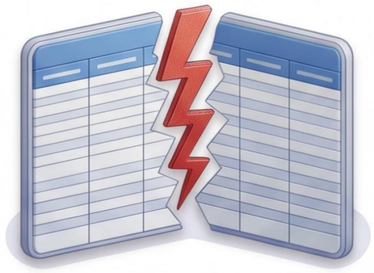
```
{
  "营业收入": null（未检测到）  Error
  "营业成本": null（解析失败）  Error
  ...
  "2026年1-6月": "无匹配数据"  Error
}
```

场景需求


海量非结构化文档
• 上市公司公告
• 专利文书
• 招投标公告
• 债券发行说明
• 声明函
• 行政处罚决定书
PDF
W
X
企查查智能处理引擎
文档解析
(Document Parsing)
领域模型信息抽取
(Domain Model Extraction)
结构化信息输出
• 营收数据
• 利润数据
• 招标信息
• 中标信息
• 信用信息
JSON

场景需求

跨页表格断裂



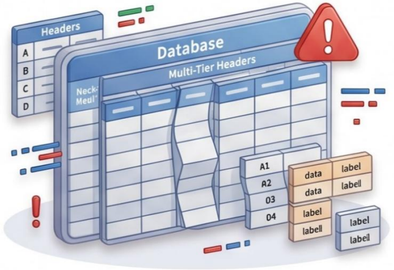
跨页表格断裂

OCR语义缺失



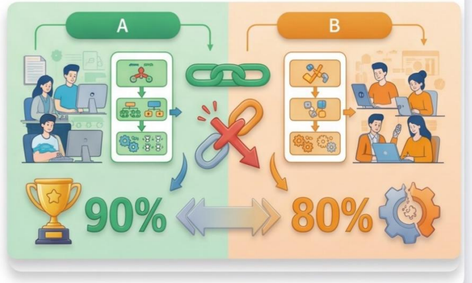
扫描件OCR缺少语义

复杂表格解析错误



复杂表格解析错误

协作与共享挑战



串联任务定位问题复杂，
文档处理经验缺少共享和共用

文档解析这个基础能力都错误的话，下游任务如何能处理的好？

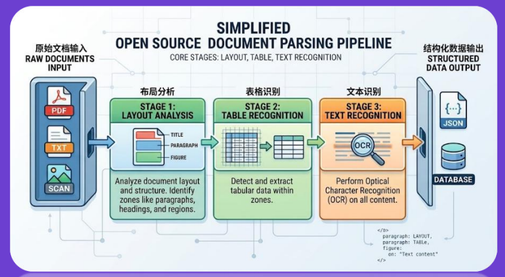
02 对比与选型

对比与选型



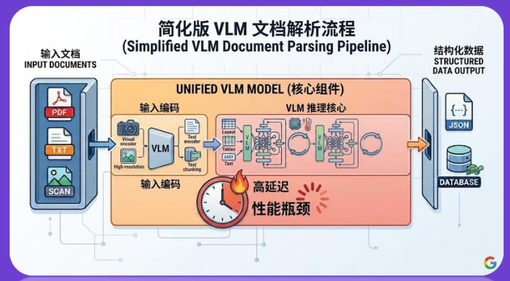
基础工具

速度快、精度低



传统pipeline

复杂度高、精度中等



开源VLM方案

速度慢、精度高，场景适配不足

对比与选型

01 精度要求

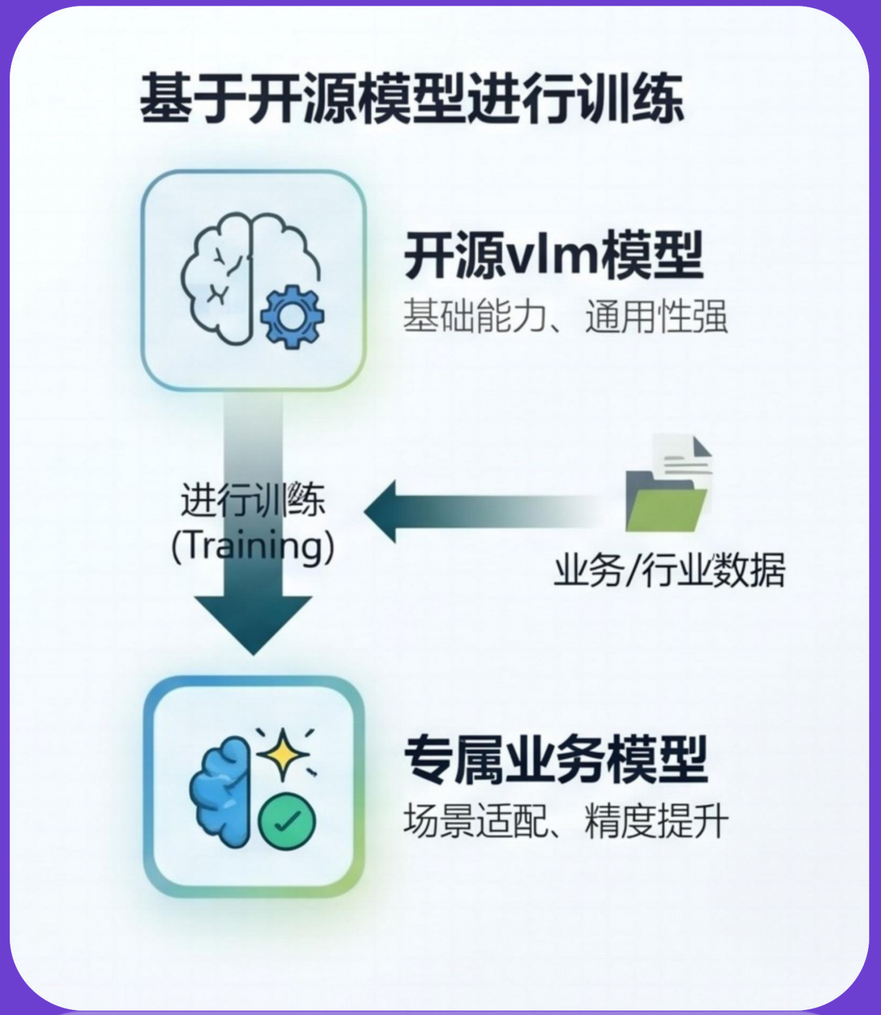
金融表格、招标中标信息，解析精度对后续的信息抽取至关重要。

02 解析速度

金融公告文档、招投标文书，海量的文档需要结构化。

03 场景适配

一些特殊场景要求，需要进行场景适配。



03 数据准备和模型训练

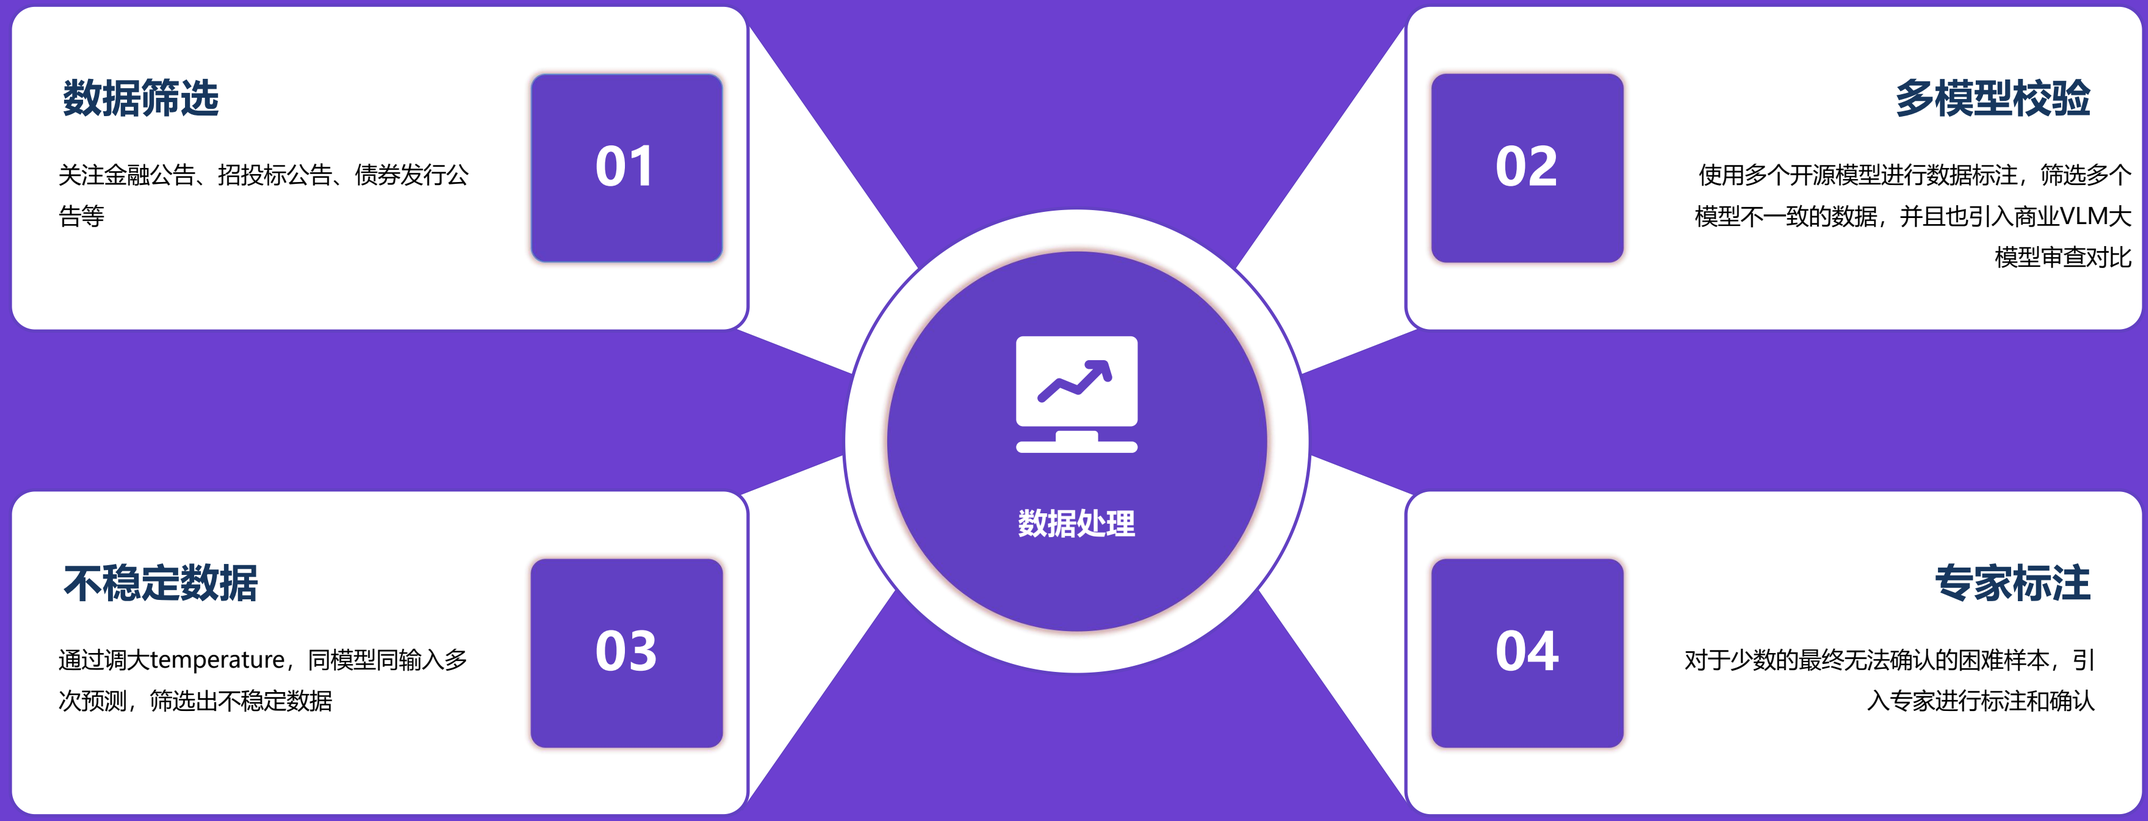
数据准备和模型训练

架构流程设计



数据准备和模型训练

数据标注



数据准备和模型训练

数据标注





数据准备和模型训练

样例

数量单位：股

	本次变动前		本次变动增减（+、-）		本次变动后	
	数量	比例	其它	小计	数量	比例
一、有限售条件股份	292189431	46.44%	-70598	-70598	292118833	46.43%
1、国家持股						
2、国有法人持股	291907045	46.40%			291907045	46.40%
3、其他内资持股						
其中：						
境内法人持股						
境内自然人持股						
4、外资持股						
其中：						
境外法人持股						
境外自然人持股						
5、高管股份	282386	0.04%	-70598	-70598	211788	0.03%
二、无限售条件股份	336920575	53.56%	+70598	+70598	336991173	53.57%
1、人民币普通股	336920575	53.56%	+70598	+70598	336991173	53.57%
2、境内上市的外资股						
3、境外上市的外资股						
4、其他						
三、股份总数	629110006	100%	0	0	629110006	100%

说明、报告期内，本公司总股份未发生变动，本公司有限售条件股份中境内自然人持股

项目	本次变动前		本次变动增减（+，-）		本次变动后	
	数量	比例	其它	小计	数量	比例
一、有限售条件股份1、国家持股	292189431	46.44%	-70598	-70598	292118833	46.43%
2、国有法人持股 3、其他内资持股 其中： 境内法人持股 境内自然人持股 4、外资持股 其中： 境外法人持股 境外自然人持股 5、高管股份	291907045 282386	46.40% 0.04%	-70598	-70598	291907045 211788	46.40% 0.03%
二、无限售条件股份	336920575	53.56%	+70598	+70598	336991173	53.57%
1、人民币普通股 2、境内上市的外资股3、境外上市的外资股4、其他	336920575	53.56%	+70598	+70598	336991173	53.57%
三、股份总数	629110006	100%	0	0	629110006	100%

	本次变动前		本次变动增减（+，-）		本次变动后	
	数量	比例	其它	小计	数量	比例
一、有限售条件股份	292189431	46.44%	-70598	-70598	292118833	46.43%
1、国家持股						
2、国有法人持股	291907045	46.40%			291907045	46.40%
3、其他内资持股						
其中：						
境内法人持股						
境内自然人持股						
4、外资持股						
其中：						
境外法人持股						
境外自然人持股						
5、高管股份	282386	0.04%	-70598	-70598	211788	0.03%
二、无限售条件股份	336920575	53.56%	+70598	+70598	336991173	53.57%
1、人民币普通股	336920575	53.56%	+70598	+70598	336991173	53.57%
2、境内上市的外资股						
3、境外上市的外资股						
4、其他						
三、股份总数	629110006	100%	0	0	629110006	100%

数据准备和模型训练

样例

（二）未纳入合并报表范围的控股公司

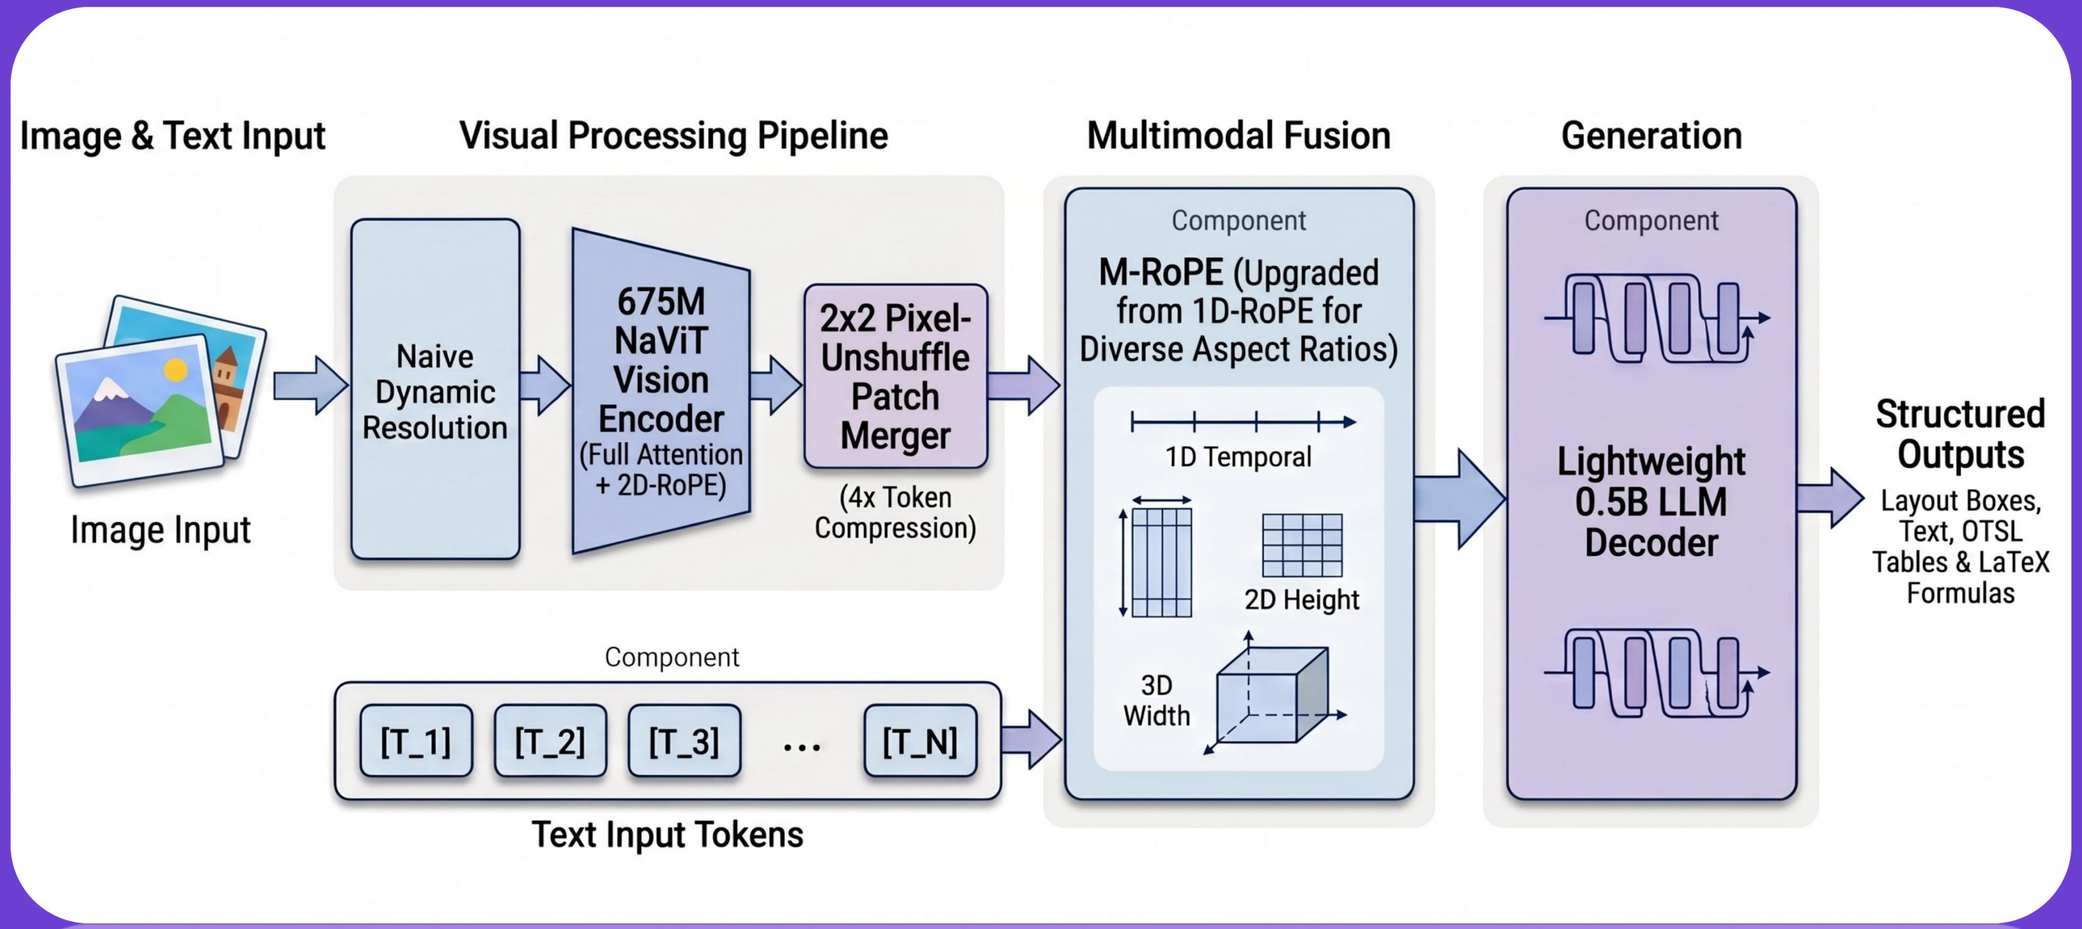
单位名称	注册地	法定代表人	注册资本	经营范围	投资额	权益比例
精美快速印务有限公司	天津市河西区解放南路325号	李克嘉	185万元	快速印刷	111万元	60%
珠海天粤实业公司	珠海市	赵学智	175万元	印刷机械、材料	160万元	91.43%
天津市爱赛智能卡系统工程有限公司	天津市高科技园区	姜肃敌	50万元	技术开发咨询、计算机批发零售	45万元	90%
天津市磁卡广告有限公司	天津市河西区解放南路327号	徐鸿钧	100万元	广告设计、制作	100万元	100%
新疆津卡实业发展公司	乌鲁木齐市	姜肃敌	1000万元	制卡开发销售	1000万元	100%
天津环球凯丰制版有限公司	天津市河西区解放南路325号	刘金生	50万元	制版印刷	50万元	100%
天津环球蔡伦纸业有限公司	天津市河西区温州道10号	徐鸿钧	50万元	包装纸业	50万元	100%
天津市河西区人民印刷复合包装厂	天津市河西区解放南路35号	宋平禄	44万元	印刷	44万元	100%
天津市人民印刷厂维修服务部	天津市河西区	乔文蓬	16万元	印刷设备及配件维修	16万元	100%

单位名称	注册地	法定代表人	注册资本 经营范围	投资额	权益比例
精美快速印务有限公司	天津市河西区解放南路325 号	李克嘉	185 万元快速印刷	111 万元	60%
珠海天粤实业公司	珠海市	赵学智	175 万元印刷机械、材料	160 万元	91.43%
天津市爱赛智能卡系统工程有限公司	天津市高科技园区	姜肃敌	技术开发咨询、计算机批 50 万元发零售	45 万元	90%
天津市磁卡广告有限公司	天津市河西区解放南路327 号	徐鸿钧	100 万元广告设计、制作	100 万元	100%
新疆津卡实业发展公司	乌鲁木齐市	姜肃敌	1000 万元制卡开发销售	1000 万元	100%

单位名称	注册地	法定代表人	注册资本	经营范围	投资额	权益比例
精美快速印务有限公司	天津市河西区解放南路325 号	李克嘉	185 万元	快速印刷	111 万元	60%
珠海天粤实业公司	珠海市	赵学智	175 万元	印刷机械、材料	160 万元	91.43%
天津市爱赛智能卡系统工程有限公司	天津市高科技园区	姜肃敌	50万元	技术开发咨询、计算机批发零售	45 万元	90%
天津市磁卡广告有限公司	天津市河西区解放南路327 号	徐鸿钧	100 万元	广告设计、制作	100 万元	100%
新疆津卡实业发展公司	乌鲁木齐市	姜肃敌	1000 万元	制卡开发销售	1000 万元	100%

数据准备和模型训练

模型结构



数据准备和模型训练

模型训练

分阶段训练策略

数据准备就绪后 | Stage-by-Stage Training Strategy

STAGE 01

SFT 微调训练

SFT Fine-Tuning

强化模型针对领域数据的适配

SFT 之后...

STAGE 02

GRPO 强化学习

GRPO Reinforcement Learning

- 设计 Layout & Table 相关奖励函数
- 针对 SFT 之后仍然不稳定的数据，继续强化训练

迭代渐进...

最终模型 / FINAL MODEL

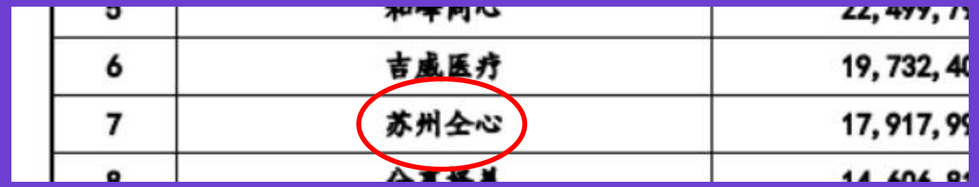
最终得到的模型

- 保证通用能力不退化
- 解决领域数据问题

04 场景应用

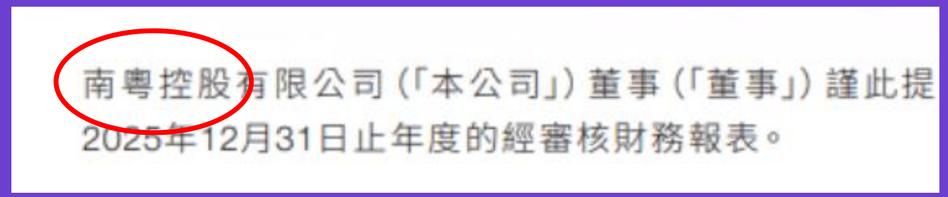
场景应用

幻觉和繁简问题



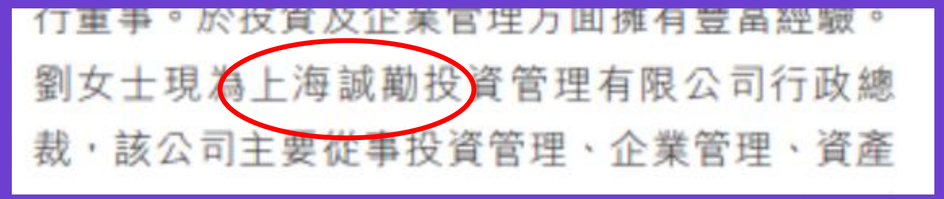
6	吉盛医疗	19,732,40
7	苏州全心	17,917,99

…苏州全心…



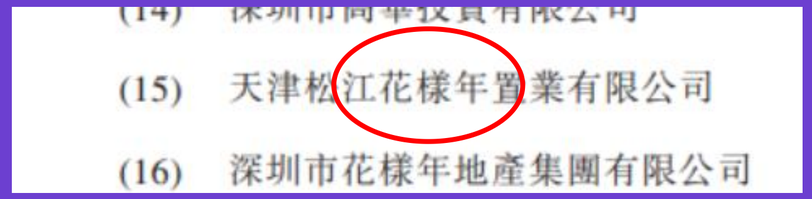
南粵控股有限公司(「本公司」)董事(「董事」)謹此提
2025年12月31日止年度的經審核財務報表。

…南粵控股…



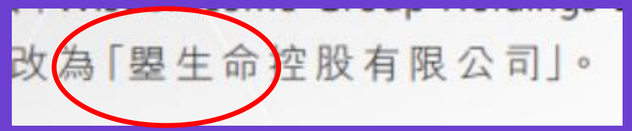
行董事。於投資及企業管理方面擁有豐富經驗。
劉女士現為上海誠勤投資管理有限公司行政總
裁,該公司主要從事投資管理、企業管理、資產

…上海誠勤…



(15) 天津松江花樣年置業有限公司
(16) 深圳市花樣年地產集團有限公司

…花樣年…



改為「嬰生命控股有限公司」。

…墨生命…

场景应用

幻觉和繁简问题-解决方案

（14） 深圳市高华投资有限公司

（15） 天津松江花樣年置业有限公司

（16） 深圳市花樣年地产集团有限公司

PDF

pdfium2

松江花樣年

↓

松江花樣年

南粵控股有限公司（「本公司」）董事（「董事」）謹此提2025年12月31日止年度的經審核財務報表。

PDF

pdfium2

南粵控股

↓

南粵控股



场景应用

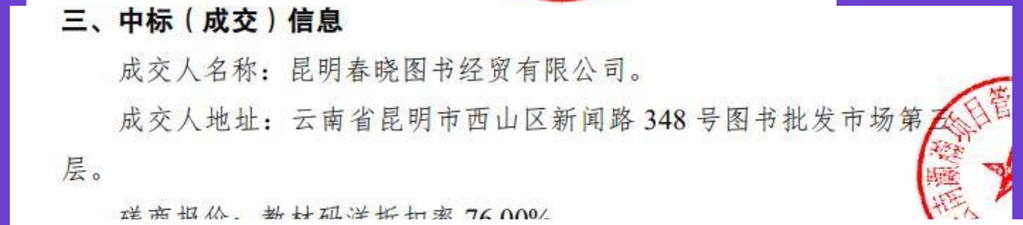
印章干扰



xxx-xx073xxxxxx



泽普县清和管家城市服务有限公司



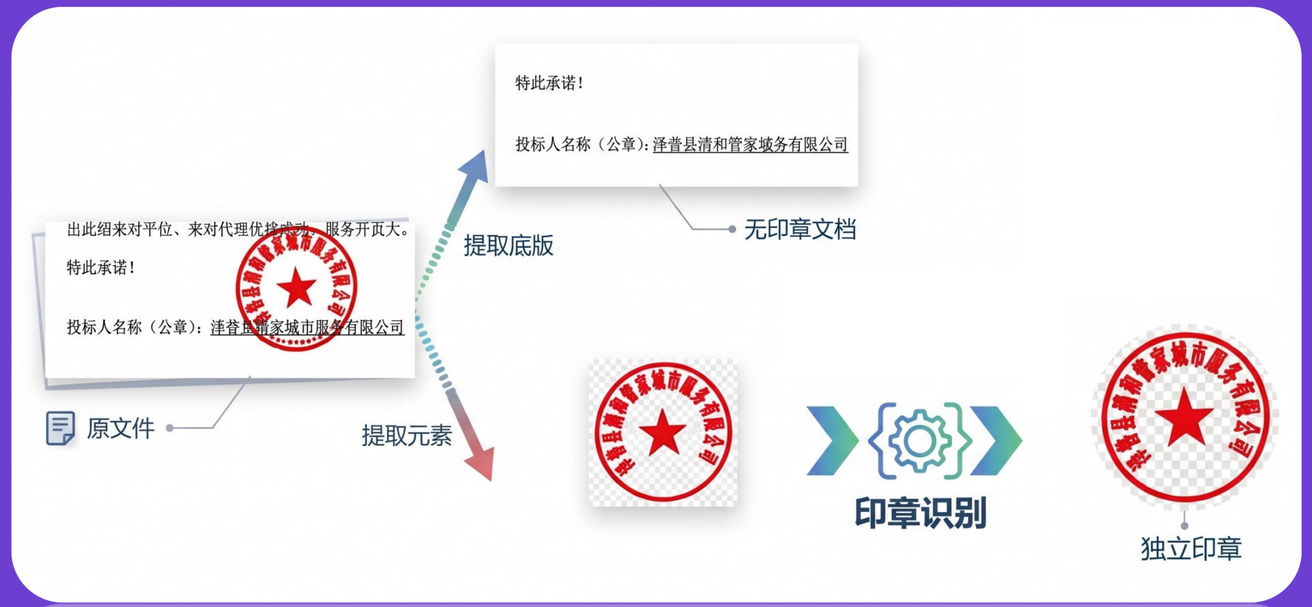
….批发市场第三层…

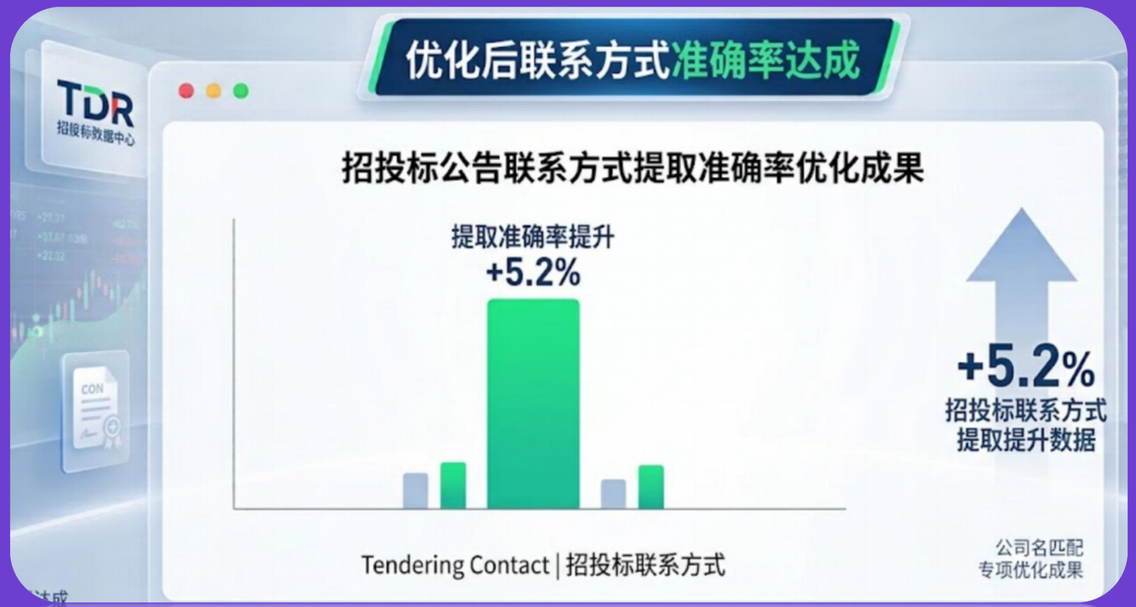


133xxxx688

场景应用

印章干扰-解决方案





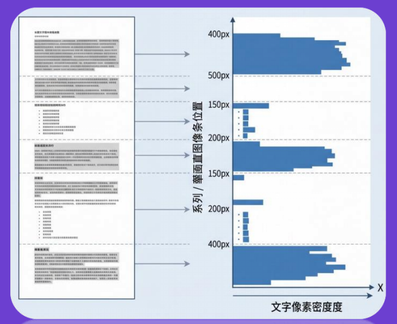
场景应用

超长图片切割

宽高比1:17



Y轴投影



超长图片（面条图）切割方案对比

痛点：1:17 超长面条图



直接输入VLM归一化会会导致字迹模糊无法看清

宽 ~900px / 高 ~17000px（宽高比 1:17）

方案一：固定高度硬切

然机	002448	中南建设	10:03	1	5.22
	605060	联德股份	10:48	1	2.25
	002333	贝斯股份	10:58	1	33.91
	603476	登康股份	13:38	1	1.50
算缺	300664	中石开控	02:25	2	2.94
	600172	黄河股份	09:34	1	10.40
	603389	舜网家居	09:51	1	1.27
	603889	劳然家居	10:58	1	12.35
玻璃基校	603773	天猿光光	09:34	1	6.69
	688378	奥美港	14:42	1	7.37
源波	000811	冰轮环境	13:30	1	18.61
电器器	605180	华帝科技	13:35	1	0.75
电源	301516	中远园	13:01	1	3.48

26.08.17	机器人(10)(29.47亿)				
	股票代码	股票名称	打板时间	第八股	成交块
	002448	南中股充	10:03	1	5.22
	605060	太黑股份	10:58	1	2.25

❌ 容易切碎文字，破坏语义

方案二：Y轴投影浮动切割

然机	002448	10:03	1	5.22	
	605060	10:48	1	2.25	
	002333	10:58	1	33.91	
	603476	13:38	1	1.50	
脚数	300684	02:25	2	2.94	
	600172	09:34	1	10.40	
	603389	09:51	1	1.27	
	301668	10:58	1	12.35	
玻璃基校	603773	09:54	1	6.69	
	688378	14:42	1	7.37	
源波	000811	13:30	1	18.61	
电器器	605180	13:35	1	0.75	
电源	301516	13:01	1	3.48	
境境	605188	13:35	1	0.75	
电源	301516	13:01	1	3.48	

26.08.17					
	股票代码	股票名称	第八股	成交块	
	002448	10:03	1	5.22	
	605060	10:48	1	2.25	
	002333	10:58	1	1.57	
	600366	09:39	1	14.22	
酸装	306772	09:34	1	2.94	
源波	600871	14:42	1	7.37	
电器器	605188	13:35	1	0.75	
电源	301156	13:01	1	3.48	

⚠️ 贪心算法，局部切点非最优

方案三：全局最优解切割（我们的解法）

26.08.17	大消费(8)(32.01亿)				
	股票代码	股票名称	打板时间	第八股	成交块
	605179	一鸣食品	10:28	1	10.97
	002820	桂发祥	09:25	2	2.55
	603102	百合股份	09:32	1	1.56
	001133	冠润股份	09:39	1	1.05
	600884	杉杉股份	10:06	1	1.13
	002668	TCL能源	10:33	1	1.11
	000564	供销大集	11:11	1	9.60

26.08.17	有色金属(6)(76.69亿)				
	股票代码	股票名称	打板时间	第八股	成交块
锡	000737	北方铜业	11:11	1	20.20
锡	603380	立天科工	10:02	1	5.31
铝	600281	华阳新材	14:21	1	0.77
镍	002578	闽发铝业	14:35	1	2.02
铁	600658	有形新材	09:45	1	37.36
	600459	贵研铂业	13:10	1	11.03

26.08.17	农业(5)(14.87亿)				
	股票代码	股票名称	打板时间	第八股	成交块
	600127	金健专业	09:30	1	3.26
	000505	京粮控股	09:40	1	1.40
	600013	农垦控股	09:40	1	3.56
	600213	农垦再方	09:40	1	1.17
	603399	亿通方	09:53	1	1.17
	600258	利尔化学	13:01	1	6.30

✅ 全局视野寻优，完整保留表格与语义块

场景应用

超长图片切割-解决方案

方案三：全局最优解切割（我们的解法）

26.08.17	大消费(8)(32.01亿)				
	腥寐代码	腥慑宕称	打敫时间	膊八股	成交昱
	605179	一切消费	10:28	1	10.97
	002600	撼宕孵	09:25	2	2.95
	603102	百合股份	09:32	1	1.56
	001133	国洚股份	09:39	1	1.05
	600884	能聩溥蒲	10:06	1	1.13
	002888	TCL茄鲴	10:33	1	1.11
	000564	例阢大寨	11:11	1	9.60

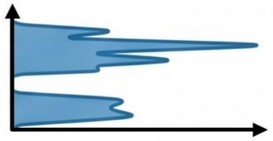
26.08.17	有色金属(6)(76.69亿)				
	股寨代码	脞签名称	打籍时间	第八股	成交块
锇	000737	北方墙璟	11:11	1	20.20
锇	003360	交尤施工	10:02	1	5.31
锇	000281	华艇龈材	14:21	1	0.77
锇	002578	厕洗匿涘	14:35	1	2.02
锇	000858	有新圃材	09:45	1	37:36
	600439	旄耜腑业	13:10	1	11:03

26.00.17	农业(5)(14.87亿)				
	股篆代码	股誓名称	打数时间	第八股	成交块
	000127	金琥专业	09:30	1	3.26
	000505	旒浇股抢	09:40	1	1.40
	600013	凉浇股抢	09:40	1	2.56
	600313	农淘筠方	09:40	1	1.17
	603299	红涸方	09:53	1	1.17
	000258	利水完尹	13:01	1	6.30

✅ 全局视野寻优，
完整保留表格与语义块

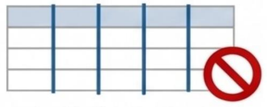
多维加权寻优算法

Y轴投影密度



权重 w_1

穿过连续竖线



避免截断表格内容

权重 w_2

目标图像高度



符合长度/比例限制

权重 w_3

加权全局最优解

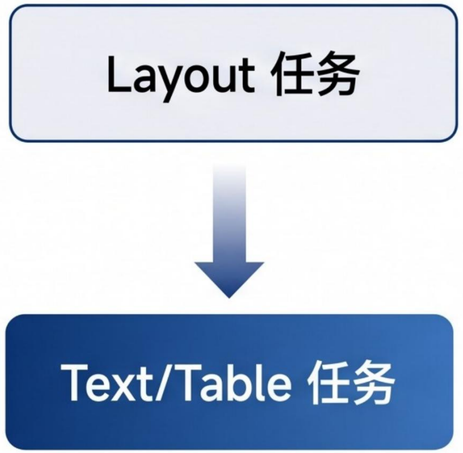
输出最优切割

05 加速方案落地

加速方案落地

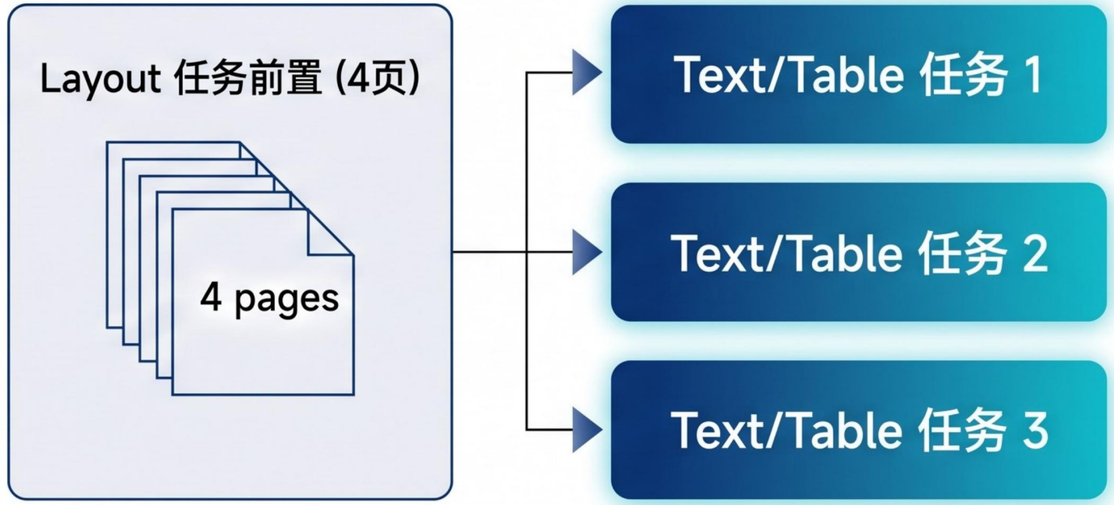
模型加速-调度

原调度（Serial）



串行等待，前置任务完成后
方可进行下一阶段

新调度（Parallel & Pipelined） (+3%)

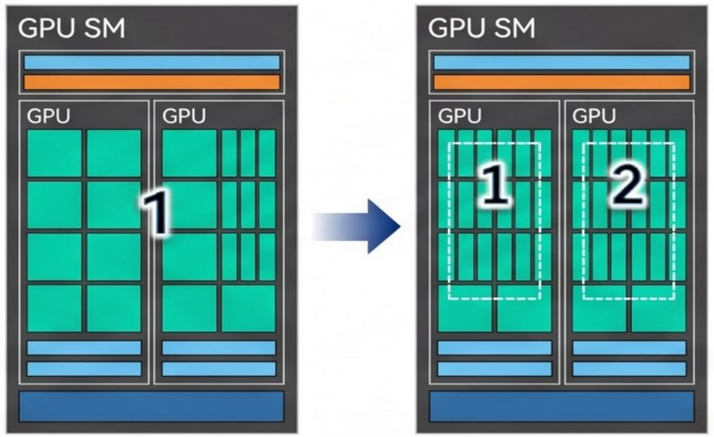


前置4页，打破串行等待，后续任务无须等待，
直接并行处理，实现持续批输入

加速方案落地

模型加速-算子

1. 图像 Attention 优化 (+6%)

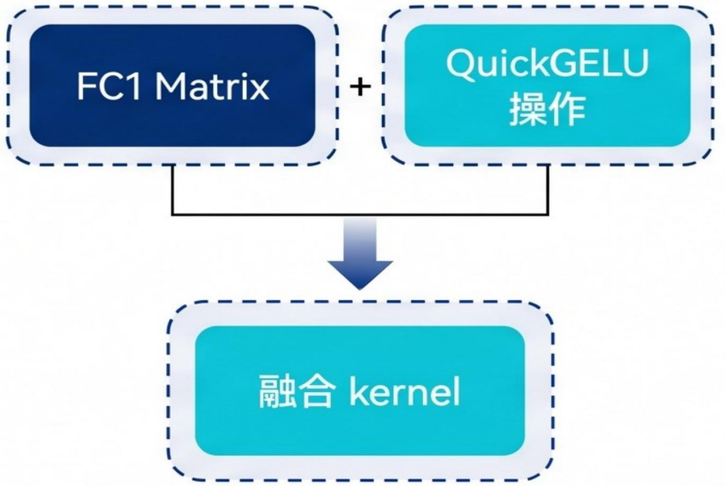


1 工作组每SM

2 工作组每SM
调整线程寄存器

特征数 256~6448 | 图片数 1~12张
(其余回退默认)

2. CUTLASS 算子融合 (+6%)



输入特征总数 2048~33000

加速方案落地

模型加速-Dflash投机解码

背景

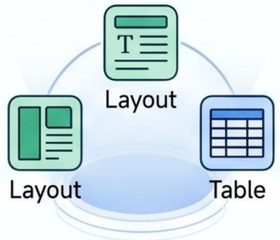


Dflash 是今年发布的新算法

我们其他业务上已用上，提速约30%

在此也引入此算法

核心工作 1



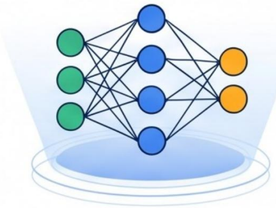
多任务 Draft 模型训练

加速比约 Layout 1.7x，Table 1.6x，Text 1.5x

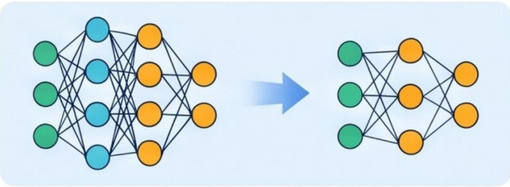


加速比约 Layout 1.7x，Table 1.6x，Text 1.5x

核心工作 2



模型结构简化



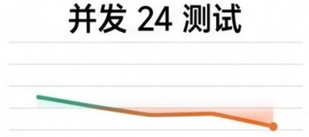
降低Hidden Layer层数：4 -> 3

接受率：50% - 60%（几乎未变）

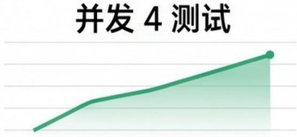
Draft 输出：3 tokens

成果与测试





-2%（Target Verify 成本抵消了收益）

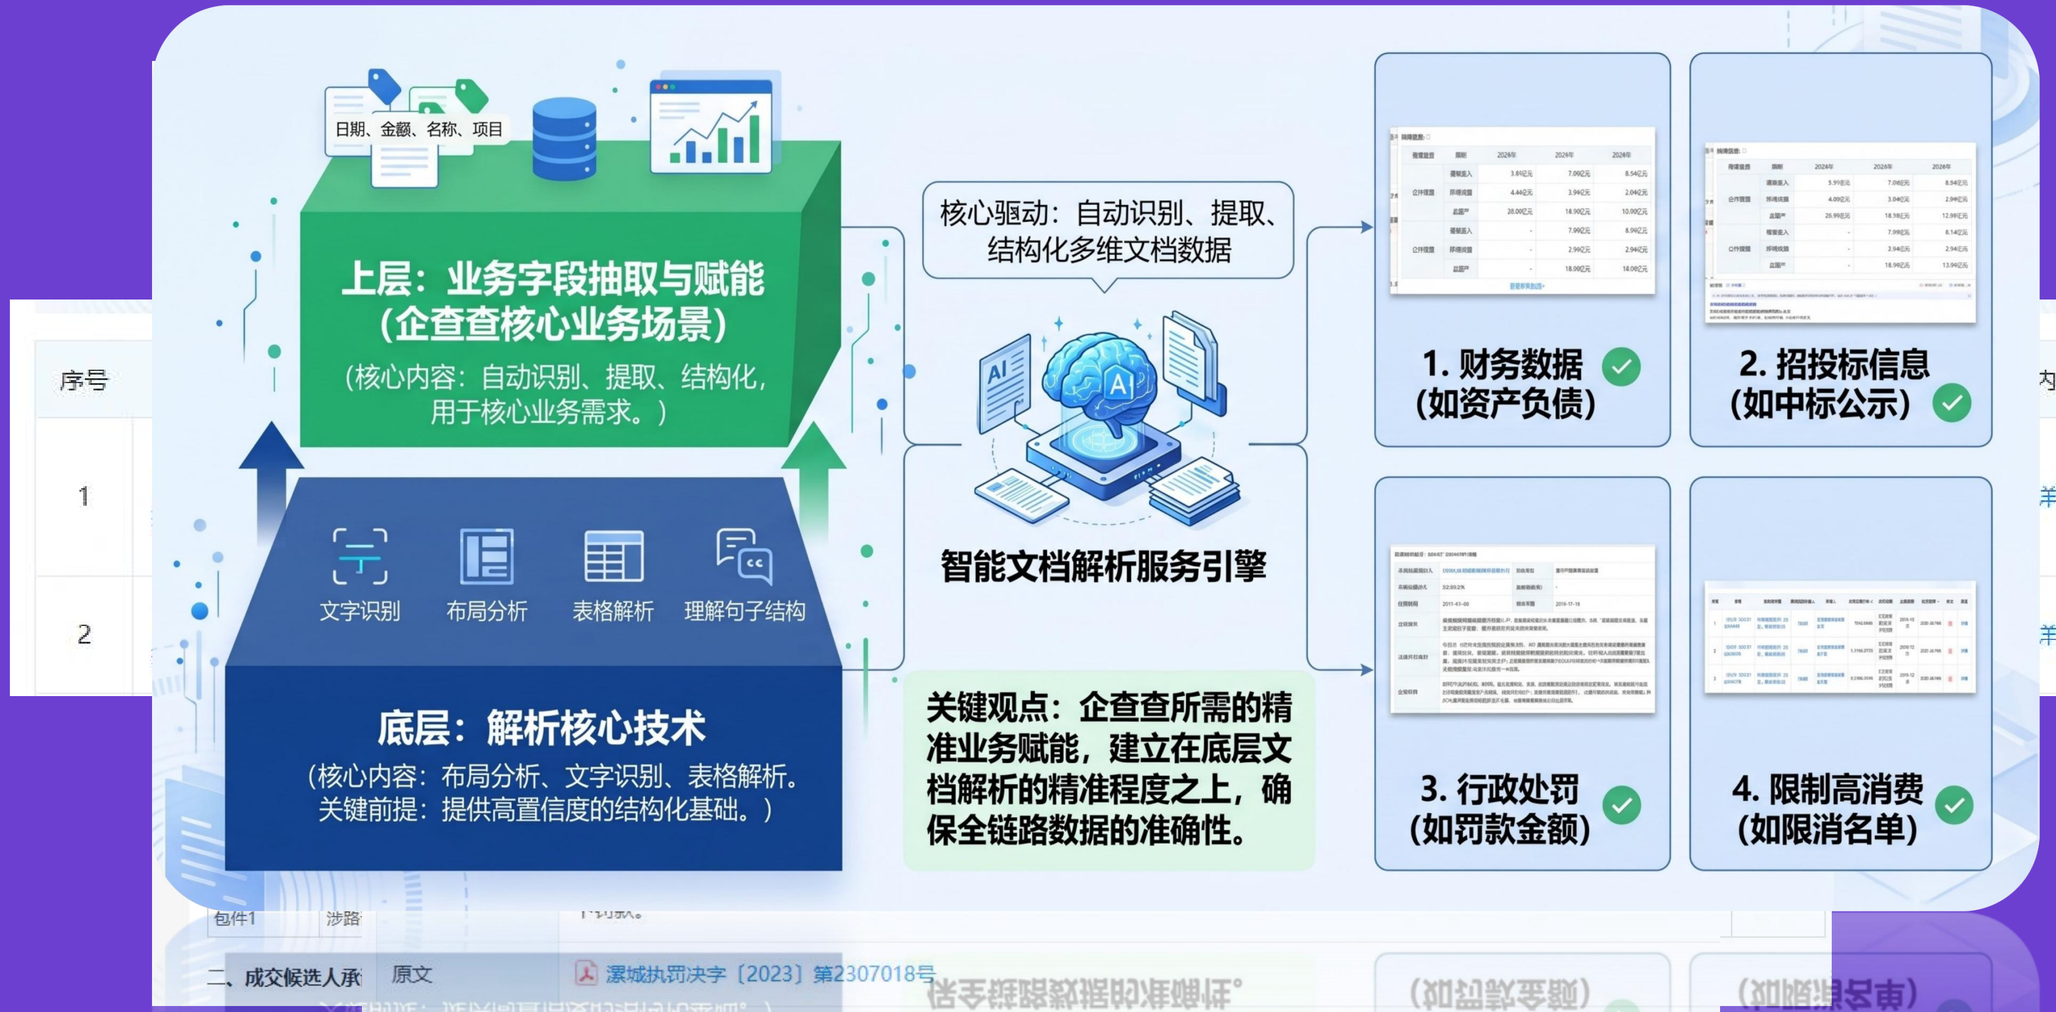


+8%

最终实际收益大约 2-3%

06 总结与展望

总结与展望


日期、金额、名称、项目
上层：业务字段抽取与赋能
（企查查核心业务场景）
（核心内容：自动识别、提取、结构化，
用于核心业务需求。）
文字识别
布局分析
表格解析
理解句子结构
底层：解析核心技术
（核心内容：布局分析、文字识别、表格解析。
关键前提：提供高置信度的结构化基础。）
核心驱动：自动识别、提取、
结构化多维文档数据
AI
智能文档解析服务引擎
关键观点：企查查所需的精准业务赋能，建立在底层文档解析的精准程度之上，确保全链路数据的准确性。
1. 财务数据
（如资产负债）
2. 招投标信息
（如中标公示）
3. 行政处罚
（如罚款金额）
4. 限制高消费
（如限消名单）

总结与展望

我们的经验

01

尽可能利用AI帮我们处理数据

采用不同厂商、不同尺寸模型多方校验。

02

模型无法解决所有问题

特定场景，可能我们深入进行定制化开发，比训练模型更高效，并且效果更好。

03

数据仍然决定模型上限

想要模型能力提升，一定是需要专家标注的高质量数据。

我们的展望

01

拓展文档解析覆盖的场景

我们还有一些文档的处理不是特别好，比如：司法拍卖等文档。

02

加速场景持续研究

目前DFLASH没有完全发挥出其加速作用，继续研究Dspark高并发方案。

03

端到端模式探索

现在已经有很多优秀的项目用了端到端的方式来解析，我们也需要尝试，并且对于Dflash理论上加速效果会更好。

THANKS

演讲嘉宾：陈汝龙